

PROBABILITÉ

FONDEMENTS, CARACTÉRISATION ET ANALYSE DES VARIABLES
ALÉATOIRES RÉELLES.

Lorenzo Segoni



TABLE DES MATIÈRES

VARIABLES ALÉATOIRES RÉELLES

I.1 DÉFINITION ET AXIOMES

On veut modéliser une expérience aléatoire via une variable aléatoire (v.a.) X à valeurs réelles, et donner un sens à $\mathbb{P}(X \in A)$ pour $A \subset \mathbb{R}$.

Jusqu'à présent, on ne considérait que des v.a. *discrètes*, prenant un nombre fini ou dénombrable de valeurs $S_X = \{x : \mathbb{P}(X = x) \neq 0\}$. Dans ce cas, la fonction de masse suffisait à définir la loi de X , puisque

$$\mathbb{P}(X \in A) = \sum_{x \in A} \mathbb{P}(X = x).$$

On souhaite maintenant s'affranchir de cette restriction, sans chercher à définir formellement une v.a. générale, mais seulement à en manipuler les probabilités.

Un problème apparaît alors : cette approche par sommation ne fonctionne plus en général. Prenons l'exemple d'un nombre X choisi uniformément dans $[0, 1]$. Par symétrie, on voudrait que $\mathbb{P}(X = x)$ soit la même pour tout $x \in [0, 1]$. Mais comme $[0, 1]$ est infini (non dénombrable), cela force $\mathbb{P}(X = x) = 0$ pour tout x — sinon $\mathbb{P}(X \in [0, 1])$ serait infinie.

Ainsi, connaître $\mathbb{P}(X = x)$ pour chaque x (ici, tous nuls) ne permet pas de reconstruire $\mathbb{P}(X \in A)$ pour un ensemble A quelconque.

AXIOMES DES PROBABILITÉS

Il nous faut donc trouver une autre approche pour définir les probabilités $\mathbb{P}(X \in A)$ pour des ensembles $A \subset \mathbb{R}$, c'est-à-dire pour spécifier la loi de X . Le point de départ est l'observation suivante : ces probabilités ne peuvent pas être arbitraires, elles doivent satisfaire certaines propriétés de cohérence.

Définition I.1. Si $A, B \subset \mathbb{R}$ sont deux ensembles disjoints (d'intersection vide), on souhaite que la probabilité soit *additive* sur ces ensembles, c'est-à-dire que

$$\mathbb{P}(X \in A \cup B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B).$$

Cette exigence de cohérence, ainsi que d'autres analogues, va nous permettre de construire une théorie générale. Pour définir la loi d'une variable aléatoire X à valeurs réelles, on part donc d'un petit nombre de règles fondamentales, appelées axiomes. Avant de les énoncer, introduisons une convention qui simplifiera grandement la présentation :

Définition 1.2. Dans toute la suite, on suppose que tout ensemble $A \subset \mathbb{R}$ considéré est soit un intervalle, soit une réunion finie d'intervalles disjoints.

Remarque 1.1. On entend ici par « intervalle » aussi bien les intervalles ouverts, fermés ou semi-ouverts, bornés ou non bornés. Cette notion englobe en particulier les cas limites que sont l'ensemble vide $\emptyset$ et la droite réelle $\mathbb{R}$ tout entière.

Cette classe d'ensembles présente l'avantage d'être stable pour un certain nombre d'opérations élémentaires, comme le montre la proposition suivante.

Proposition 1.1. Notons $A^c = \mathbb{R} \setminus A$ le complémentaire d'un ensemble A .

1. Si $A \subset \mathbb{R}$ est de la forme décrite ci-dessus, alors son complémentaire A^c l'est également.
2. Si A et B sont tous deux de cette forme, alors leur union $A \cup B$ et leur intersection $A \cap B$ le sont aussi.
3. En revanche, cette stabilité ne s'étend pas aux opérations infinies : si $A_0, A_1, A_2, \dots$ est une suite (infinie) d'ensembles de cette forme, alors $\bigcup_{n \in \mathbb{N}} A_n$ et $\bigcap_{n \in \mathbb{N}} A_n$ ne sont pas nécessairement des réunions finies d'intervalles.

Exercice 1.1. Démontrer cette proposition.

Précisons à présent les règles de calcul régissant les quantités $\mathbb{P}(X \in A)$, c'est-à-dire les axiomes que nous allons supposer valables pour toute la suite.

Définition 1.3. On suppose que :

1. *Positivité* : $\mathbb{P}(X \in A) \geq 0$ pour tout $A \subset \mathbb{R}$
2. $\mathbb{P}(X \in \emptyset) = 0$ et $\mathbb{P}(X \in \mathbb{R}) = 1$,
3. *Additivité* : Si $A, B \subset \mathbb{R}$ sont disjoints, alors

$$\mathbb{P}(X \in A \cup B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B).$$

Ces trois règles peuvent paraître minimales, mais elles suffisent déjà à en déduire un certain nombre de propriétés utiles, que nous établissons dans la proposition suivante. Nous introduirons un quatrième axiome un peu plus loin, une fois que nous aurons besoin de traiter des réunions infinies d'ensembles.

Proposition 1.2. On a les propriétés :

1. Si $A \subset B$, alors

$$\mathbb{P}(X \in A) \leq \mathbb{P}(X \in B) \quad (\text{monotonie de } A \mapsto \mathbb{P}(X \in A)).$$

2. $\mathbb{P}(X \in A) \in [0, 1]$ pour tout $A \subset \mathbb{R}$.
3. Si $A \subset B$, alors

$$\mathbb{P}(X \in B \setminus A) = \mathbb{P}(X \in B) - \mathbb{P}(X \in A).$$

En particulier, en prenant $B = \mathbb{R}$,

$$\mathbb{P}(X \in A^c) = 1 - \mathbb{P}(X \in A).$$

4. *Additivité finie* : Si $A_0, A_1, \dots, A_n \subset \mathbb{R}$ sont deux à deux disjoints, alors

$$\mathbb{P}\left(X \in \bigcup_{k=0}^n A_k\right) = \sum_{k=0}^n \mathbb{P}(X \in A_k).$$

Remarque 1.2. Ces propriétés ne sont pas des axiomes supplémentaires : elles découlent toutes des trois règles précédentes. Voyons rapidement pourquoi.

- Le point 1 (monotonie) découle immédiatement du point 3 : puisque $\mathbb{P}(X \in B \setminus A) \geq 0$ par positivité (règle 1), on a nécessairement $\mathbb{P}(X \in A) \leq \mathbb{P}(X \in B)$.
- Le point 2 est alors une conséquence de la monotonie appliquée à $\emptyset \subset A \subset \mathbb{R}$, combinée avec la règle 2 : on obtient $0 = \mathbb{P}(X \in \emptyset) \leq \mathbb{P}(X \in A) \leq \mathbb{P}(X \in \mathbb{R}) = 1$.
- Pour le point 3, remarquons que si $A \subset B$, alors B se décompose comme la réunion disjointe $B = A \cup (B \setminus A)$. L'axiome d'additivité (règle 3) donne alors directement

$$\mathbb{P}(X \in B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B \setminus A),$$

d'où l'on tire $\mathbb{P}(X \in B \setminus A) = \mathbb{P}(X \in B) - \mathbb{P}(X \in A)$.

- Enfin, le point 4 s'obtient par une récurrence immédiate sur n , en appliquant l'axiome d'additivité (règle 3) de proche en proche aux ensembles $A_0, \dots, A_n$, qui sont deux à deux disjoints.

On peut à présent introduire le quatrième axiome, qui vient compléter les trois premiers pour traiter le cas des réunions infinies.

Définition 1.4. On suppose que :

4. *Continuité croissante* : Si $A_0, A_1, A_2, \dots$ est une suite croissante d'ensembles (c'est-à-dire $A_n \subset A_{n+1}$ pour tout $n \in \mathbb{N}$) telle que $\bigcup_{n \in \mathbb{N}} A_n$ est encore un ensemble de la forme considérée, alors

$$\mathbb{P}\left(X \in \bigcup_{n \in \mathbb{N}} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n).$$

Notons que cette limite existe bien, puisque la suite $(\mathbb{P}(X \in A_n))_n$ est croissante par la propriété de monotonie établie plus haut, et majorée par 1.

Cet axiome mérite un commentaire. En effet, il n'est pas totalement nouveau : une partie de l'énoncé peut déjà se déduire des axiomes 1 à 3. C'est l'objet de l'exercice suivant.

Exercice 1.2. En utilisant uniquement les axiomes 1 à 3, montrer que l'on a déjà l'inégalité

$$\mathbb{P}\left(X \in \bigcup_{n \in \mathbb{N}} A_n\right) \geq \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n).$$

Remarquons également que l'axiome 4 admet une formulation équivalente en termes de suites décroissantes, que l'on obtient par un simple passage au complémentaire :

Définition 1.5. 4' Si $A_0, A_1, A_2, \dots$ est une suite ****décroissante**** d'ensembles (c'est-à-dire $A_{n+1} \subset A_n$ pour tout $n \in \mathbb{N}$) telle que $\bigcap_{n \in \mathbb{N}} A_n$ est encore un ensemble de la forme considérée, alors

$$\mathbb{P} \left(X \in \bigcap_{n \in \mathbb{N}} A_n \right) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n) \quad (\text{continuité décroissante}).$$

Remarque 1.3. L'équivalence entre 4 et 4' se voit en posant $B_n = A_n^c$: si (A_n) est décroissante, alors (B_n) est croissante, et $\bigcap_n A_n = (\bigcup_n B_n)^c$. Il suffit alors d'appliquer l'axiome 4 à la suite (B_n) et de repasser au complémentaire à l'aide de la propriété 3 de la proposition précédente.

Maintenant que les quatre axiomes sont posés, nous sommes en mesure de définir formellement ce qu'est une variable aléatoire.

Définition 1.6. On dit que X est une variable aléatoire s'il existe une famille de nombres $(\mathbb{P}(X \in A))_{A \subset \mathbb{R}}$ (autrement dit, une fonction $A \mapsto \mathbb{P}(X \in A)$ à valeurs dans $\mathbb{R}$) qui satisfait aux axiomes 1, 2, 3 et 4 ci-dessus. Cette famille, ou cette fonction, est appelée la loi de X .

Il est important de bien comprendre l'esprit de cette définition : on ne cherche pas ici à dire ce qu'est intrinsèquement une variable aléatoire, mais seulement à caractériser son comportement à travers les probabilités qu'elle induit sur les sous-ensembles de $\mathbb{R}$. C'est cette loi, c'est-à-dire la donnée de la fonction $A \mapsto \mathbb{P}(X \in A)$, qui contient toute l'information probabiliste dont nous aurons besoin par la suite.

Une conséquence importante des axiomes 3 et 4 est la propriété de *sigma-additivité*, qui étend l'additivité finie au cas d'une infinité dénombrable d'ensembles.

Définition 1.7. 4'' Si $A_0, A_1, A_2, \dots$ est une suite d'ensembles deux à deux disjoints (c'est-à-dire que $m \neq n$ implique $A_m \cap A_n = \emptyset$), alors

$$\mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} A_n \right) = \sum_{n \in \mathbb{N}} \mathbb{P}(X \in A_n).$$

Démonstration. Posons $B_n = \bigcup_{k=0}^n A_k$: comme les A_k sont deux à deux disjoints, cette union est disjointe, et la suite $(B_n)_{n \geq 0}$ est croissante, avec $\bigcup_{n \in \mathbb{N}} B_n = \bigcup_{n \in \mathbb{N}} A_n$. En appliquant successivement l'axiome 4 (continuité croissante), puis l'additivité finie (propriété 4 de la proposition précédente), on obtient :

$$\begin{aligned} \mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} A_n \right) &= \mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} B_n \right) \\ &= \lim_{n \rightarrow \infty} \mathbb{P}(X \in B_n) \\ &= \lim_{n \rightarrow \infty} \sum_{k=0}^n \mathbb{P}(X \in A_k), \end{aligned}$$

et cette dernière limite est précisément, par définition, la somme de la série $\sum_{n \in \mathbb{N}} \mathbb{P}(X \in A_n)$. $\square$

Ce résultat montre que, sous les axiomes 1 à 4, la sigma-additivité est automatiquement satisfaite. Il est naturel de se demander si l'on peut en réalité s'en tenir à un jeu d'axiomes plus économique. C'est effectivement le cas, comme le résume la proposition suivante.

Définition 1.8. Les jeux d'axiomes suivants sont équivalents :

- 1, 2, 3, 4
- 1, 2, 3, 4'
- 1, 2, 4''

Parmi ces jeux d'axiomes équivalents, il est courant de retenir le jeu 1, 2, 4''. Ce sont précisément ces trois axiomes qui figurent usuellement dans la définition d'une mesure de probabilité sur $\mathbb{R}$.

Il nous reste un dernier point à traiter. Jusqu'ici, $\mathbb{P}(X \in A)$ n'a été défini que pour les ensembles A qui sont des intervalles ou des réunions finies d'intervalles. Or nous aurons parfois besoin de donner un sens à $\mathbb{P}(X \in A)$ pour des ensembles A qui ne sont pas de cette forme — par exemple $A = \mathbb{N}$, ou plus généralement n'importe quel ensemble dénombrable.

Pour cela, on se limite aux ensembles A qui peuvent s'écrire comme limite monotone d'une suite d'ensembles $(A_n)_{n \geq 0}$ de la forme considérée (réunion finie d'intervalles). Par limite monotone, on entend un ensemble de la forme $\bigcup_n A_n$ (pour une suite

croissante (A_n)) ou $\bigcap_n A_n$ (pour une suite décroissante (A_n)), exactement comme dans les axiomes 4 et 4'. On pose alors, par définition,

$$\mathbb{P}(X \in A) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n),$$

où l'on note que cette limite existe toujours, par monotonie de la suite $(\mathbb{P}(X \in A_n))_n$.

Un exemple typique d'un tel ensemble est l'ensemble des rationnels $\mathbb{Q}$, ou plus généralement n'importe quel ensemble dénombrable $S \subset \mathbb{R}$. Pour un tel ensemble S , on vérifie que la définition ci-dessus redonne bien la formule attendue :

$$\mathbb{P}(X \in S) = \sum_{x \in S} \mathbb{P}(X = x).$$

1.2 ÉVÉNEMENTS

Rappelons pour finir la notion d'événement, qui nous accompagnera tout au long de ce cours.

Définition 1.9. Un événement est simplement un sous-ensemble de l'ensemble des résultats possibles d'une expérience aléatoire, et on dit que l'événement est réalisé si le résultat effectif de l'expérience appartient à ce sous-ensemble.

Exemple 1.1. Lors d'un lancer de dé, on pourrait s'intéresser à l'événement E : « le dé donne un nombre pair ».

Si X désigne la v.a. représentant le nombre obtenu, cet événement s'écrit symboliquement

$$E = \{X \in \{2, 4, 6\}\}, \quad \text{ou encore} \quad E = \{X \text{ pair}\}.$$

Cet événement se réalise alors avec la probabilité $\mathbb{P}(E) = \mathbb{P}(X \in \{2, 4, 6\})$ (on omet ici, par convention, les accolades autour de l'ensemble $\{2, 4, 6\}$ dans la notation).

Dans ce cours, nous nous limiterons aux événements définis à partir de variables aléatoires, c'est-à-dire aux événements de la forme

$$E = \{X \in A\}, \quad \text{pour } X \text{ une variable aléatoire et } A \subset \mathbb{R}.$$

La probabilité d'un tel événement est alors naturellement définie par $\mathbb{P}(E) = \mathbb{P}(X \in A)$.

L'intérêt de cette formulation est que l'on peut manipuler ces événements exactement comme des ensembles, en leur appliquant les opérations ensemblistes usuelles (complémentaire, union, intersection). On obtient ainsi les identités suivantes, qui traduisent simplement les opérations sur les ensembles A et B en opérations sur les événements correspondants :

$$\begin{aligned}\{X \in A\}^c &= \{X \in A^c\}, \\ \{X \in A\} \cup \{X \in B\} &= \{X \in A \cup B\}, \\ \{X \in A\} \cap \{X \in B\} &= \{X \in A \cap B\}.\end{aligned}$$

Ces identités permettent, en pratique, de traduire n'importe quelle combinaison logique d'événements (négation, « ou », « et ») en une opération sur les sous-ensembles de $\mathbb{R}$ correspondants, et donc de calculer sa probabilité à l'aide des axiomes énoncés précédemment.

Définition 1.10. Un événement de probabilité 1 est dit presque sûr. Un événement de probabilité 0 est dit négligeable.

Ainsi, un événement négligeable est le complémentaire d'un événement presque sûr.

Remarque 1.4. On rencontre la notation :

$$X \in A, \text{ p.s.} \quad (\text{pour un événement } A \text{ presque sûr})$$

et qui se lit : "presque sûrement, X appartient à A ".

1.3 FONCTION DE RÉPARTITION

Nous avons vu, dans la section précédente, comment définir la loi d'une variable aléatoire à partir des axiomes 1 à 4. Cette loi est constituée d'une famille de nombres réels $\mathbb{P}(X \in A)$, indexée par tous les ensembles $A \subset \mathbb{R}$ (de la forme considérée). Une telle définition est en pratique très lourde à manipuler : pour caractériser une loi particulière, il faudrait a priori spécifier la valeur de $\mathbb{P}(X \in A)$ pour chacun de ces ensembles A , qui peuvent avoir des formes arbitrairement compliquées.

Rappelons que, dans le cas d'une v.a. discrète (c'est-à-dire ne prenant qu'un nombre fini ou dénombrable de valeurs, que nous étudierons plus loin), cette difficulté disparaît : il suffit de connaître les valeurs $\mathbb{P}(X = x)$ pour tout x , c'est-à-dire la fonction de masse, pour reconstituer toute la loi. Nous avons cependant vu dans la section précédente

que cette simplification n'est plus disponible dans le cadre général, puisque ces valeurs peuvent être nulles pour tout $x \in \mathbb{R}$, sans pour autant que X soit une v.a. triviale.

L'astuce consiste alors à ne plus considérer $\mathbb{P}(X = x)$, mais plutôt les valeurs de $\mathbb{P}(X \leq x)$ pour tout $x \in \mathbb{R}$. (On aurait tout aussi bien pu choisir $\mathbb{P}(X < x)$, $\mathbb{P}(X \geq x)$ ou $\mathbb{P}(X > x)$; c'est simplement la convention qui a retenu $\mathbb{P}(X \leq x)$.) On obtient ainsi une fonction $F_X : \mathbb{R} \rightarrow [0, 1]$, définie par

$$F_X(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R},$$

que l'on appelle la fonction de répartition de X .

Il nous reste maintenant deux questions à élucider : d'une part, montrer que cette fonction F_X détermine bien entièrement la loi de X ; d'autre part, caractériser précisément quelles fonctions $F : \mathbb{R} \rightarrow [0, 1]$ peuvent apparaître comme fonction de répartition d'une variable aléatoire. C'est l'objet du théorème suivant.

Théorème 1.1. 1. *La fonction de répartition F_X d'une v.a.r. possède les propriétés suivantes :*

- *elle est croissante,*
- $F_X(-\infty) := \lim_{x \rightarrow -\infty} F_X(x) = 0,$
- $F_X(+\infty) := \lim_{x \rightarrow +\infty} F_X(x) = 1,$
- *elle est continue à droite.*

2. *La loi d'une v.a.r. X est déterminée de manière unique par sa fonction de répartition F_X .*

3. *Réciproquement, toute fonction sur $\mathbb{R}$ possédant les propriétés énoncées au point 1. est la fonction de répartition d'une variable aléatoire réelle.*

Ce théorème est fondamental : il montre que la fonction de répartition permet d'atteindre, dans le cas général, le même degré de simplicité que la fonction de masse dans le cas discret. Dans les deux situations, la notion — a priori complexe — de loi d'une variable aléatoire se ramène finalement à la donnée d'une simple fonction sur $\mathbb{R}$.

Il convient toutefois de nuancer cette simplicité : elle est avant tout conceptuelle. En pratique, la fonction de répartition F_X n'admet bien souvent pas d'expression explicite simple, et son calcul effectif peut s'avérer difficile — ce qui n'enlève rien à son importance théorique comme objet caractérisant entièrement la loi de X .

Démonstration. 1. Montrons les propriétés énoncées :

- Croissance : Ceci est une conséquence immédiate de la monotonie de $\mathbb{P}(X \in A)$ en A . Plus précisément, soient $x, y \in \mathbb{R}$ avec $x < y$. Alors $] - \infty, x] \subset] - \infty, y]$, si bien que

$$F_X(x) = \mathbb{P}(X \in] - \infty, x]) \leq \mathbb{P}(X \in] - \infty, y]) = F_X(y).$$

- On remarque d'abord que la fonction F_X est croissante et bornée inférieurement (par 0), la limite $F_X(-\infty) = \lim_{x \rightarrow -\infty} F_X(x)$ existe donc bien. En particulier,

$$F_X(-\infty) = \lim_{n \rightarrow \infty} F_X(-n) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in] - \infty, -n]).$$

La suite d'ensembles $A_n =] - \infty, -n]$ est décroissante et d'intersection vide. L'axiome 4' donne donc :

$$F_X(-\infty) = \mathbb{P} \left(X \in \bigcap_{n=1}^{\infty}] - \infty, -n] \right) = \mathbb{P}(X \in \emptyset) = 0.$$

- Pareil que $F_X(-\infty)$, on utilise le fait que F_X est bornée par 1 pour montrer l'existence de la limite, puis l'axiome 4 pour l'identifier.
- Continuité à droite. Soit $x \in \mathbb{R}$. Puisque F_X est croissante et bornée inférieurement, la limite $F_X(x^+) := \lim_{y \downarrow x} F_X(y)$ existe. En particulier,

$$F_X(x^+) = \lim_{n \rightarrow \infty} F_X \left(x + \frac{1}{n} \right) = \mathbb{P} \left(X \in \bigcap_{n=1}^{\infty}] - \infty, x + \frac{1}{n}] \right),$$

où on a encore utilisé l'axiome 4'. Le point clé est alors l'égalité suivante :

$$\bigcap_{n=1}^{\infty}] - \infty, x + \frac{1}{n}] =] - \infty, x].$$

Cela donne que $F_X(x^+) = \mathbb{P}(X \in] - \infty, x]) = F_X(x)$ et donc F_X est continue à droite en x . Puisque $x \in \mathbb{R}$ était arbitraire, F_X est continue à droite sur $\mathbb{R}$.

2. On veut montrer que pour tout ensemble A qui est une union finie d'intervalles disjoints, $\mathbb{P}(X \in A)$ s'écrit à partir de la fonction de répartition F_X . On procède cas par cas :
- $A =]-\infty, x]$, $x \in \mathbb{R}$: Par définition, $\mathbb{P}(X \in]-\infty, x]) = \mathbb{P}(X \leq x) = F_X(x)$.
 - $A =]-\infty, x[$, $x \in \mathbb{R}$: L'intervalle ouvert $] - \infty, x[$ s'écrit comme l'union dénombrable d'intervalles fermés :

$$]-\infty, x[= \bigcup_{n=1}^{\infty}]-\infty, x - \frac{1}{n}].$$

L'axiome 4 donne alors

$$\mathbb{P}(X < x) = \lim_{n \rightarrow \infty} \mathbb{P}\left(X \leq x - \frac{1}{n}\right) = \lim_{n \rightarrow \infty} F_X\left(x - \frac{1}{n}\right) = F_X(x^-),$$

où $F_X(x^-) := \lim_{y \uparrow x} F_X(y)$ qui existe car la fonction F_X est croissante.

- $A =]x, \infty[$ ou $A = [x, \infty[$, $x \in \mathbb{R}$: On utilise le fait que $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ et on se ramène aux deux premiers cas.
- $A =]x, y]$, $x < y$: On obtient

$$\mathbb{P}(x < X \leq y) = \mathbb{P}(X \leq y) - \mathbb{P}(X \leq x) = F_X(y) - F_X(x).$$

- $A = [x, y]$, $A = [x, y[$ ou $A =]x, y[$: Similaire à $A =]x, y]$, avec éventuellement $F_X(y^-)$ et $F_X(x^-)$ à la place de $F_X(y)$ ou $F_X(x)$. Par exemple

$$\mathbb{P}(X \in [x, y]) = \mathbb{P}(X \leq y) - \mathbb{P}(X < x) = F_X(y) - F_X(x^-).$$

- $A = I_1 \cup \dots \cup I_n$, avec $I_1, \dots, I_n$ des intervalles disjoints, alors par l'axiome 3, on a

$$\mathbb{P}(X \in A) = \mathbb{P}(X \in I_1) + \dots + \mathbb{P}(X \in I_n).$$

On se ramène alors au cas d'un intervalle traité précédemment.

3. Si F est une fonction avec les propriétés du théorème, on définit la loi d'une variable aléatoire X à partir de F en utilisant les formules pour $\mathbb{P}(X \in A)$ ci-dessus. Il suffit alors de montrer que cette loi satisfait aux axiomes 1 à 4. On omet la preuve de ce fait qui est laissée en exercice. La fonction F est alors par définition la fonction de répartition de cette variable aléatoire.

□

Introduisons, pour tout réel x , la notation $F_X(x^-) = \lim_{t \rightarrow x, t < x} F_X(t)$ pour désigner la limite à gauche de F_X en x (limite qui existe bien, la fonction F_X étant croissante).

Soulignons un fait important, rencontré au fil de la preuve du théorème précédent : la fonction de répartition F_X , étant croissante, admet une limite à gauche en tout point x , et cette limite s'identifie précisément à

$$F_X(x^-) = \mathbb{P}(X < x).$$

Exercice 1.3. Soit F une fonction de répartition. On suppose qu'il existe $x_0 < x_1$ deux réels tels que $\lim_{x \rightarrow x_0, x > x_0} F(x) = 0$, $\lim_{x \rightarrow x_1, x < x_1} F(x) = 1$.

1. Calculer $F(x_0)$ et $F(x_1)$.
2. En déduire que F est caractérisée par sa restriction à l'intervalle $]x_0, x_1[$.

1.4 CLASSES DE VARIABLES ALÉATOIRES

Ayant établi, à travers le théorème précédent, la forme générale que peut prendre la loi d'une v.a. réelle via sa fonction de répartition, il est naturel de vouloir maintenant distinguer différentes classes de v.a. selon les propriétés de leur fonction de répartition. Un premier outil utile dans cette optique est la notion d'atome.

Définition 1.11. On dit que $x \in \mathbb{R}$ est un atome de masse $m > 0$ de la loi de X si $\mathbb{P}(X = x) = m$, ou, de façon équivalente, si $F_X(x) - F_X(x^-) = m$.

Cette équivalence provient directement du calcul suivant :

$$\mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-).$$

Ainsi, un réel x est un atome de masse $m > 0$ pour la loi de X si et seulement si x est un point de discontinuité de la fonction F_X ; dans ce cas, m est précisément la hauteur du saut de F_X en x , à savoir $m = F_X(x) - F_X(x^-)$. En particulier, on retiendra le fait suivant : une v.a.r. X n'a aucun atome si et seulement si sa fonction de répartition F_X est continue sur $\mathbb{R}$.

Il découle alors d'un résultat classique sur les fonctions croissantes que le nombre d'atomes d'une loi ne peut jamais être trop grand.

Corollaire 1.1. *La loi d'une variable aléatoire X possède un nombre au plus dénombrable — c'est-à-dire fini ou dénombrable — d'atomes.*

Démonstration. Puisque la fonction F_X est croissante, il suffit de montrer qu'une fonction croissante ne peut avoir qu'un nombre au plus dénombrable de sauts. C'est un résultat classique d'analyse, que l'on pourra établir à titre d'exercice, en procédant en deux étapes : montrer d'abord que, pour une fonction croissante sur $[0, 1]$, le nombre de sauts de taille supérieure ou égale à $1/n$ est nécessairement fini, majoré par $n \cdot (f(1) - f(0))$; passer ensuite à la limite croissante en n , en remarquant qu'une réunion dénombrable d'ensembles finis est dénombrable, pour conclure que l'ensemble de tous les sauts (de taille strictement positive) est au plus dénombrable. $\square$

Variables aléatoires discrètes Nous disposons maintenant du vocabulaire nécessaire pour définir précisément une première classe importante de v.a. : celles dont toute la masse de probabilité se trouve concentrée dans leurs atomes.

Définition 1.12. Soit X une v.a.r. On dit que X est discrète s'il existe un sous-ensemble $S \subset \mathbb{R}$ au plus dénombrable tel que $\mathbb{P}(X \in S) = 1$.

Notons que cette définition ne serait pas pertinente si $\mathbb{R}$ lui-même était dénombrable — ce qui, bien entendu, n'est pas le cas : le fait que X concentre toute sa probabilité sur un ensemble dénombrable S est donc bien une restriction non triviale.

Parmi tous les ensembles dénombrables S satisfaisant $\mathbb{P}(X \in S) = 1$, il en existe un qui joue un rôle privilégié : celui des atomes de la loi de X .

Définition 1.13. On appelle ensemble des atomes de la loi de X , et on note S_X , l'ensemble

$$S_X := \{x : \mathbb{P}(X = x) > 0\}.$$

Nous avons vu au paragraphe précédent que S_X est toujours au plus dénombrable, quelle que soit la v.a. X considérée (discrète ou non). On peut donc toujours l'écrire sous la forme

$$S_X = \{s_k, k \in \mathbb{N}\} \quad \text{ou} \quad S_X = \{s_k, 0 \leq k \leq n\} \text{ pour un certain } n \in \mathbb{N},$$

où les réels s_k sont deux à deux distincts (le premier cas, infini dénombrable, pouvant être vu comme correspondant formellement à $n = +\infty$). Par abus de notation, on écrira simplement $S_X = \{s_k\}$, sans préciser à chaque fois si l'ensemble d'indices est fini ou infini.

Remarquons enfin que, pour une v.a. discrète, l'ensemble S_X des atomes constitue précisément un choix possible — et en un sens le plus économique — pour l'ensemble S de la définition : c'est le plus petit ensemble sur lequel se concentre toute la masse de probabilité de X .

Exercice 1.4. *Montrer que S_X est toujours au plus dénombrable : commencer par montrer qu'il y a au plus n atomes de masse $\geq 1/n$.*

Munis de la notion d'ensemble des atomes S_X , nous pouvons maintenant associer à toute v.a. discrète une fonction qui résume entièrement sa loi.

Définition 1.14 (Fonction de masse). Soit X une v.a.r. discrète, de support $S_X = \{s_k\}_k$. On appelle fonction de masse de X la fonction

$$\begin{cases} S_X \rightarrow \mathbb{R} \\ s_k \mapsto p_k := \mathbb{P}(X = s_k). \end{cases}$$

Les éléments s_k s'appellent alors les atomes de la loi, et p_k est la masse de l'atome s_k .

Il est naturel de se demander à quelle condition, exprimée directement en termes des masses p_k , une v.a.r. X est effectivement discrète. La proposition suivante répond à cette question et fournit ainsi un critère pratique, souvent bien plus simple à vérifier que la définition initiale.

Proposition 1.3. Soit X une v.a.r. Alors les trois assertions suivantes sont équivalentes :

- X est discrète;
- l'ensemble S_X des atomes de X vérifie $\mathbb{P}(X \in S_X) = 1$;
- $\sum_k p_k = 1$.

Intuitivement, cela signifie que toute la masse de la loi de X est concentrée dans ses seuls atomes : on lit aussi que la loi de X est "purement atomique".

Démonstration. — Puisque l'ensemble des atomes est au plus dénombrable, $\mathbb{P}(X \in S_X) = 1$ implique directement que X est discrète.

Si réciproquement X est discrète, soit S ensemble au plus dénombrable qui vérifie $\mathbb{P}(X \in S) = 1$.

- D'abord, on doit avoir $S \subset S_X$ car pour $x \in S_X \cap S^c$, on aurait $0 < \mathbb{P}(X = x) \leq \mathbb{P}(X \in S^c) = 1 - \mathbb{P}(X \in S) = 0$, absurde.

Dès lors on peut écrire S sous forme de la réunion disjointe : $S = S_X \cup (S \setminus S_X)$ donc $\mathbb{P}(X \in S \setminus S_X) = \sum_{s \in S \setminus S_X} \mathbb{P}(X = s) = \sum_{s \in S \setminus S_X} 0 = 0$ donc :

$$\begin{aligned}
 1 &= \mathbb{P}(X \in S) \\
 &= \mathbb{P}(X \in S \setminus S_X) + \mathbb{P}(X \in S_X) \\
 &= \mathbb{P}(X \in S_X)
 \end{aligned}$$

- L'équivalence concernant la somme des masses des atomes découle simplement du fait que S_X est une réunion au plus dénombrable de singletons (les atomes) :

$$\begin{aligned}
 \mathbb{P}(X \in S_X) &= \mathbb{P}\left(X \in \bigcup_k \{x_k\}\right) \\
 &= \sum_k \mathbb{P}(X = x_k) \\
 &= \sum_k p_k
 \end{aligned}$$

□

Un corollaire immédiat de la démonstration de la proposition précédente mérite d'être souligné : S_X est, dans le cas des v.a.r. discrètes, le plus petit ensemble $S \subset \mathbb{R}$ tel que $\mathbb{P}(X \in S) = 1$. C'est pour cette raison qu'on l'appelle également le support de la loi de X : il s'agit, en quelque sorte, du plus petit sous-ensemble de $\mathbb{R}$ nécessaire pour « porter » toute la probabilité de X .

Avant d'aller plus loin, il est utile d'introduire une notation qui va grandement simplifier l'écriture des formules à venir : la fonction indicatrice d'un ensemble A , définie par

$$\mathbb{I}_A(x) = \begin{cases} 1, & x \in A \\ 0, & x \notin A. \end{cases}$$

Cette fonction permet de « sélectionner » les éléments de A au sein d'une somme, en annulant automatiquement les termes correspondant aux éléments qui n'en font pas partie.

Proposition 1.4. *Soit X une v.a.r. discrète, d'ensemble d'atomes $S = \{s_k\}_k$ de masses respectives $p_k = \mathbb{P}(X = s_k)$. Alors la fonction de masse caractérise entièrement la loi de X : pour tout ensemble $A \subset \mathbb{R}$,*

$$\mathbb{P}(X \in A) = \sum_k p_k \mathbb{1}_A(s_k).$$

En particulier, en prenant $A = (-\infty, x]$, la fonction de répartition de X s'écrit

$$F_X(x) = \sum_k p_k \mathbb{1}_{\{s_k \leq x\}}.$$

Démonstration. Les deux cas S fini et dénombrable sont quasiment identiques, traitons le cas S dénombrable $S = \{s_k, k \in \mathbb{N}\}$. On décompose comme suit l'événement $\{X \in A\}$:

$$\begin{aligned} \mathbb{P}(X \in A) &= \mathbb{P}(X \in A \cap S) + \mathbb{P}(X \in A \cap S^c) \\ &= \mathbb{P}\left(X \in \bigcup_{k \in \mathbb{N}} (A \cap \{s_k\})\right) + 0 \\ &= \sum_{k \in \mathbb{N}} \mathbb{P}(X \in A \cap \{s_k\}) \end{aligned}$$

ayant utilisé à la seconde égalité que $0 \leq \mathbb{P}(X \in A \cap S^c) \leq \mathbb{P}(X \in S^c) = 1 - \mathbb{P}(X \in S) = 0$, et à la troisième égalité la propriété de sigma-additivité (additivité suffit dans le cas fini).

Maintenant,

$$\begin{aligned} \sum_{k \in \mathbb{N}} \mathbb{P}(X \in A \cap \{s_k\}) &= \sum_{k \in \mathbb{N}} \mathbb{1}_A(s_k) \mathbb{P}(X = s_k) \\ &= \sum_{k \in \mathbb{N}} \mathbb{1}_A(s_k) p_k. \end{aligned}$$

□

Intuitivement, une v.a. est discrète lorsque sa fonction de répartition F_X n'évolue que par sauts, restant constante entre ces sauts — c'est-à-dire lorsque F_X est une fonction en escalier. Il est délicat de formaliser cette idée de façon parfaitement générale, mais on peut néanmoins en donner une condition suffisante, énoncée dans la proposition suivante, qui couvre en pratique la quasi-totalité des situations rencontrées.

Proposition 1.5. Soit X une v.a.r. S'il existe une suite $(x_n)_{n \in \mathbb{Z}} \in [-\infty, +\infty]$ bi-infinie, croissante au sens large, de nombres réels $\dots \leq x_{-1} \leq x_0 \leq x_1 \leq \dots$, avec $\lim_{n \rightarrow -\infty} x_n = -\infty$ et $\lim_{n \rightarrow \infty} x_n = \infty$ (ces deux valeurs pouvant être atteintes dès un rang fini), telle que pour tout $k \in \mathbb{Z}$ pour lequel $x_k < x_{k+1}$, la restriction $(F_X)_{|]x_k, x_{k+1}[}$ soit constante, alors X est discrète, d'ensemble d'atomes $S_X \subset \{x_n\}_{n \in \mathbb{Z}}$. Plus précisément :

$$S_X = \{x_n : F_X(x_n) > F_X(x_{n-1})\}.$$

Démonstration. Soit $k \in \mathbb{Z}$ tel que $x_k < x_{k+1}$. On a $\mathbb{P}(X \in]x_k, x_{k+1}[) = F_X(x_{k+1}^-) - F_X(x_k) = F_X(x_{k+1}^-) - F_X(x_k^+) = 0$ puisque $(F_X)_{|]x_k, x_{k+1}[}$ est constante. Maintenant,

$$\begin{aligned} \mathbb{P}\left(X \in \mathbb{R} \setminus \bigcup_k \{x_k\}\right) &= \mathbb{P}\left(X \in \bigcup_{k: x_k < x_{k+1}}]x_k, x_{k+1}[\right) \\ &= \sum_{k: x_k < x_{k+1}} (F_X(x_{k+1}^-) - F_X(x_k^+)) = 0, \end{aligned}$$

ayant utilisé à la deuxième égalité que l'union est au plus dénombrable. Ceci implique $\mathbb{P}(X \in \bigcup_k \{x_k\}) = 1$ et donc X est donc bien discrète par définition. $\square$

Précisons toutefois que la condition donnée dans la proposition précédente est suffisante mais non nécessaire : il existe en effet des ensembles dénombrables (infinis) qui ne peuvent pas s'écrire sous la forme $\{x_k\}_k$ pour une suite $(x_k)_k$ croissante — l'exemple typique étant l'ensemble $\mathbb{Q}$ des nombres rationnels, dont les éléments ne peuvent être énumérés de façon croissante. Une v.a. discrète dont le support est un tel ensemble échappe donc au critère précédent, tout en restant discrète.

Variables aléatoires à densité Après avoir étudié les v.a. discrètes, dont toute la masse est concentrée sur un ensemble dénombrable de points, nous nous intéressons maintenant à une classe complémentaire de v.a., à l'opposé du cas discret : celles dont la loi peut être décrite par une densité.

Définition 1.15. Soit X une v.a.r. On dit que X est à densité si la fonction de répartition F_X s'écrit sous la forme

$$F_X(x) = \int_{-\infty}^x f_X(y) dy, \quad x \in \mathbb{R}, \quad (1.1)$$

pour une certaine fonction intégrable $f_X : \mathbb{R} \rightarrow \mathbb{R}_+$. Dans ce cas, on dit que f_X est une densité de X (ou de la loi de X), et que X **possède** la densité f_X .

Il convient d'apporter immédiatement une précision importante : la densité f_X associée à une v.a. X n'est en général pas unique. En effet, on peut modifier une fonction intégrable en un nombre fini, voire dénombrable, de points sans changer la valeur de son intégrale, et donc sans modifier F_X . En revanche, si X admet une densité qui est de surcroît continue, alors cette densité est unique (plus généralement, si X admet une densité continue par morceaux, celle-ci est unique en dehors de ses points de discontinuité). C'est en ce sens que parler de « la » densité d'une variable aléatoire constitue, à proprement parler, un léger abus de langage.

Remarquons également que la densité f_X s'intègre nécessairement à 1 sur $\mathbb{R}$ tout entier, puisque

$$\int_{-\infty}^{+\infty} f_X(y) dy = \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

La densité joue, pour les v.a. à densité, un rôle tout à fait analogue à celui que joue la fonction de masse pour les v.a. discrètes. L'intuition sous-jacente est la suivante : pour un « élément infinitésimal » dx autour d'un point x , on a heuristiquement

$$\ll \mathbb{P}(X \in dx) = f_X(x) dx \gg,$$

c'est-à-dire que $f_X(x)$ représente une sorte de « densité de probabilité » au voisinage de x , par analogie avec une densité de masse en physique. L'exercice suivant permet de donner un sens rigoureux à cette égalité, encore purement heuristique sous cette forme.

Exercice 1.5. Soit X une variable aléatoire à densité, dont la densité f_X est continue au point x . Montrer (à l'aide de l'égalité des accroissements finis par exemple) que

$$\lim_{\varepsilon \rightarrow 0} \frac{\mathbb{P}(X \in [x - \varepsilon/2, x + \varepsilon/2])}{\varepsilon} = f_X(x)$$

Nous venons d'introduire les variables aléatoires à densité comme une classe s'opposant, en un sens, en tout point aux v.a. discrètes. Il est alors naturel de commencer par confronter ces deux mondes sur le terrain des atomes : là où une v.a. discrète concentre toute sa masse en ses atomes, on s'attend, pour une v.a. à densité, à ce que la probabilité soit répartie de façon continue, sans qu'aucun point isolé ne porte de masse strictement positive. C'est précisément ce que confirme le lemme suivant.

Lemme 1.1. *Soit X une v.a.r. à densité. Alors l'ensemble des atomes S_X de la loi de X est vide, autrement dit la loi de X est sans atome.*

Ce lemme n'admet pas de réciproque, et il convient d'insister sur ce point, plus subtil qu'il n'y paraît : il existe des variables aléatoires sans aucun atome qui ne sont pourtant pas à densité. Nous y reviendrons plus loin, mais indiquons dès maintenant la traduction de ce phénomène en termes de fonctions de répartition — il existe des fonctions continues et croissantes qui ne peuvent s'écrire comme la primitive de leur propre dérivée (là où cette dérivée est définie). En d'autres termes, la continuité de F_X et l'existence d'une densité ne sont pas des propriétés synonymes.

Démonstration. La relation (??) exprime F_X comme une primitive; celle-ci est donc en particulier continue sur $\mathbb{R}$. Il s'ensuit que, pour tout $x \in \mathbb{R}$,

$$\mathbb{P}(X = x) = F_X(x) - F_X(x^-) = 0,$$

ce qui signifie exactement que x n'est pas un atome. Comme x était arbitraire, l'ensemble S_X est vide et la loi de X est sans atome. $\square$

Ce résultat met en lumière une opposition frappante entre les deux classes de v.a. rencontrées jusqu'ici. Pour une v.a. à densité, on a $\mathbb{P}(X \in S_X) = 0$, tandis que pour une v.a. discrète on avait au contraire $\mathbb{P}(X \in S_X) = 1$: les deux situations réalisent donc les deux valeurs extrêmes possibles de la quantité $\mathbb{P}(X \in S_X)$. Cette opposition va d'ailleurs bien au-delà des seuls atomes. Si X est à densité, alors pour n'importe quel ensemble au plus dénombrable $T \subset \mathbb{R}$ on a $\mathbb{P}(X \in T) = 0$: un tel ensemble, si volumineux soit-il du point de vue du cardinal, reste pour ainsi dire « invisible » aux yeux d'une v.a. à densité. C'est là toute la différence de nature entre v.a.r. discrète et v.a.r. à densité.

Comme dans le cas discret, où la fonction de masse résumait à elle seule toute la loi, la densité caractérise entièrement la fonction de répartition de X , et donc sa loi. On peut du reste exprimer directement cette loi au moyen de la densité, par une formule qui fait écho à celle établie pour les v.a. discrètes.

Proposition 1.6. *Si X est une v.a. à densité, de densité f_X , alors pour tout ensemble A ,*

$$\mathbb{P}(X \in A) = \int_{-\infty}^{\infty} f_X(x) \mathbb{1}_A(x) dx.$$

Remarque 1.5. Le résultat s'étend en réalité à tous les ensembles A mesurables au sens de Lebesgue. Notons toutefois une différence avec le cas discret : on ne peut plus ici considérer des ensembles A tout à fait quelconques. Cette restriction est cependant sans conséquence pratique, tant il est difficile — et le mot est faible — de construire explicitement un ensemble non mesurable.

Démonstration. Fixons $a, b \in [-\infty, +\infty]$ et vérifions d'abord la formule pour $A =]a, b]$. Par définition de la fonction de répartition,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= F_X(b) - F_X(a) \\ &= \int_a^b f_X(x) dx \\ &= \int_{-\infty}^{+\infty} f_X(x) \mathbb{1}_A(x) dx. \end{aligned}$$

Les autres types d'intervalles bornés se traitent de la même manière. En effet, F_X étant continue (lemme précédent), on a $F_X(x) = F_X(x^-)$ en tout point réel, de sorte que le fait d'ouvrir ou de fermer l'une ou l'autre des bornes ne modifie en rien la probabilité :

$$\begin{aligned} \mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X < b) \\ &= \mathbb{P}(a < X \leq b) \\ &= \int_a^b f_X(x) dx, \end{aligned}$$

ces égalités restant d'ailleurs valables pour $a = -\infty$ et $b = +\infty$. Enfin, si A est une réunion finie d'intervalles disjoints, la linéarité de l'intégrale permet de sommer les contributions de chacun d'eux, et l'on obtient encore

$$\mathbb{P}(X \in A) = \int_A f_X(x) dx = \int_{-\infty}^{+\infty} \mathbb{1}_A(x) f_X(x) dx.$$

□

Il nous reste à traiter une question de nature plus pratique : étant donnée la fonction de répartition d'une v.a., comment reconnaître qu'elle est à densité, et le cas échéant en exhiber une densité ? La proposition suivante fournit un critère commode, valable dans la grande majorité des situations rencontrées.

Proposition 1.7. *Soit X une v.a.r. dont la fonction de répartition F_X est continue sur $\mathbb{R}$ (de classe $C^0(\mathbb{R})$) et C^1 par morceaux — c'est-à-dire qu'il existe un nombre fini de points $x_1 < x_2 < \dots < x_n$ tels que F_X soit de classe C^1 sur chacun des intervalles $] -\infty, x_1[$, $]x_1, x_2[$, $\dots$, $]x_{n-1}, x_n[$, $]x_n, +\infty[$. Alors X est une v.a. à densité, et une densité de X est donnée par F'_X .*

Démonstration. Les hypothèses faites sur F_X autorisent à écrire, pour tous $x, y \in [-\infty, +\infty]$,

$$F_X(y) - F_X(x) = \int_x^y F'_X(z) dz.$$

En particulier, en prenant $x = -\infty$, on obtient pour tout $y \in \mathbb{R}$

$$F_X(y) = \int_{-\infty}^y F'_X(z) dz,$$

ce qui est exactement dire que F'_X est une densité de X . □

On recourt fréquemment à cette proposition pour établir qu'une v.a. est à densité. Il existe cependant une alternative, qui dispense de vérifier les hypothèses de continuité et de régularité par morceaux : mettre directement F_X sous la forme (??). Du point de vue de la rédaction, cette seconde voie est souvent la plus économique — même si, en pratique, pour deviner l'intégrande, on n'échappe pas au calcul de la dérivée de la fonction de répartition, exactement comme dans la proposition ci-dessus. L'exercice suivant met en regard les deux approches sur un même exemple.

Exercice 1.6. On pose $F(x) = x^2 \mathbb{1}_{[0,1/2]}(x) + (1 - 3(1-x)^2) \mathbb{1}_{[1/2,1]}(x) + \mathbb{1}_{[1,+\infty]}(x)$.

1. Appliquer la proposition précédente pour montrer que F est la fonction de répartition d'une variable aléatoire dont on précisera la densité.

2. *Vérifier que $F(x) = \int_{-\infty}^x [2t\mathbb{K}_{[0,1/2]}(t) + 6(1-t)\mathbb{K}_{[1/2,1]}(t)] dt$, et conclure comme précédemment.*

Toutes les v.a.r. à densité que nous croiserons dans ce cours auront une fonction de répartition du type précédent, à savoir continue sur $\mathbb{R}$ et C^1 par morceaux. Il faut toutefois se garder de croire que ce cas épuise la définition générale : la forme (??) autorise en réalité des fonctions de répartition de v.a.r. à densité qui ne sont pas de ce type. En effet, l'ensemble des fonctions qui s'écrivent comme primitive d'une fonction intégrable est strictement plus vaste que celui des fonctions $C^0(\mathbb{R})$ et C^1 par morceaux : il s'agit de la classe des fonctions dites *absolument continues*. Nous n'en aurons pas l'usage dans la suite, mais le lecteur curieux est invité à la découvrir par ses propres moyens — il en existe plusieurs caractérisations équivalentes, aisément accessibles par une recherche.

Les autres variables aléatoires. La quasi-totalité des variables aléatoires que nous rencontrerons dans ce cours relèvent de l'une des deux classes précédentes : discrètes d'un côté, à densité de l'autre. Il serait cependant trompeur de laisser penser que ces deux familles recouvrent tous les cas possibles.

Un premier type de v.a. échappant à cette dichotomie est constitué des « mélanges » des deux, c'est-à-dire des v.a. dont une partie de la masse est portée par des atomes et le reste réparti selon une densité. L'exercice ci-dessous en fournit un exemple explicite.

On peut par ailleurs se poser une question plus fine : existe-t-il des fonctions de répartition qui soient continues, mais qui ne s'écrivent malgré tout comme la primitive d'aucune fonction — de sorte que la v.a. correspondante ne serait ni discrète (puisqu'elle n'a pas d'atome), ni à densité ? La réponse est oui, mais la construction d'un tel objet dépasse le cadre de ce cours. Une ouverture possible est une recherche sur l'« escalier de Cantor », que son étrangeté a fait aussi surnommer l'« escalier du diable ».

Voici, comme annoncé, un exemple de v.a. combinant les deux types.

Exercice 1.7. Soit X une v.a.r. de fonction de répartition

$$F_X(t) = \frac{1+t}{2} \mathbb{K}_{[0,1[}(t) + \mathbb{K}_{[1,+\infty[}(t).$$

1. Vérifier qu'il s'agit bien d'une fonction de répartition.
2. Vérifier que $\mathbb{P}(X \in S_X) = 1/2$.
3. La v.a. X est-elle discrète ? Est-elle à densité ?
4. Soit $y \in [0, 1]$. Construire une variable aléatoire Y telle que $\mathbb{P}(Y \in S_Y) = y$ (on pourra considérer une généralisation simple de F_X).

1.5 LOI D'UNE FONCTION D'UNE VARIABLE ALÉATOIRE

Il est fréquent, une fois que l'on dispose d'une variable aléatoire X , de s'intéresser non pas à X elle-même mais à une quantité qui s'en déduit. Si $\phi : \mathbb{R} \rightarrow \mathbb{R}$ est une fonction, alors $\phi(X)$ est encore un nombre décrivant le résultat d'une expérience aléatoire : il est donc naturel de le considérer à son tour comme une variable aléatoire. Plus généralement, il n'est même pas nécessaire que ϕ soit définie partout : il suffit qu'elle le soit sur un ensemble $E \subset \mathbb{R}$ dans lequel X prend ses valeurs, au sens où $\mathbb{P}(X \in E^c) = 0$. Dans ce cas encore, la quantité $\phi(X)$ a un sens.

Reste à préciser ce que l'on entend par là, c'est-à-dire à définir $\mathbb{P}(\phi(X) \in A)$ pour tout ensemble A . Or il n'y a ici qu'une seule définition raisonnable, et elle est en quelque sorte imposée par la logique : dire que $\phi(X)$ tombe dans A , c'est exactement dire que X tombe dans l'ensemble des antécédents de A par ϕ . Autrement dit, les événements $\{\phi(X) \in A\}$ et $\{X \in \phi^{-1}(A)\}$ coïncident. On pose donc, pour tout ensemble $A \subset \mathbb{R}$ réunion finie d'intervalles disjoints,

$$\mathbb{P}(\phi(X) \in A) := \mathbb{P}(X \in \phi^{-1}(A)),$$

où $\phi^{-1}(A)$ désigne la préimage de A par ϕ . Pour que le membre de droite ait un sens dans notre cadre, on suppose que $\phi^{-1}(A)$ est lui aussi une réunion finie d'intervalles disjoints. Il s'agit là d'une hypothèse portant sur ϕ , mais anodine en pratique : elle est satisfaite par toute fonction « raisonnable ». On vérifie alors (exercice) que la fonction $A \mapsto \mathbb{P}(\phi(X) \in A)$ ainsi définie satisfait encore aux axiomes 1 à 4, si bien que $\phi(X)$ est bel et bien une variable aléatoire.

Retenons enfin l'aspect pratique de cette construction : pour déterminer la fonction de répartition de $\phi(X)$, tout se ramène au calcul des préimages $\phi^{-1}(]-\infty, x])$.

FONCTION DISCRÈTE D'UNE V.A.R.

Un cas particulièrement commode se présente lorsque ϕ envoie le support de X sur un ensemble au plus dénombrable. La variable $\phi(X)$ est alors discrète — et ce, remarquablement, même lorsque X ne l'était pas : une fonction bien choisie peut ainsi « discrétiser » une v.a. qui ne l'était pas au départ. Sa loi est dès lors entièrement décrite par sa fonction de masse. Plutôt que d'énoncer un théorème général, dont la formulation serait plus lourde qu'éclairante, il nous a paru préférable d'exposer la méthode sur une série d'exemples, du plus élémentaire au plus élaboré.

Exemple 1.2. $\phi : \mathbb{R} \rightarrow \{0, 1\}$, $\phi(x) = \mathbb{1}_{x \geq 0}$, avec X une v.a. quelconque. La fonction ϕ ne prend que les deux valeurs 0 et 1 ; la v.a. $\phi(X) = \mathbb{1}_{X \geq 0}$ est donc discrète, de fonction de masse

$$\mathbb{P}(\mathbb{1}_{X \geq 0} = 1) = \mathbb{P}(X \geq 0), \quad \mathbb{P}(\mathbb{1}_{X \geq 0} = 0) = \mathbb{P}(X < 0).$$

Autrement dit, $\mathbb{1}_{X \geq 0}$ suit la loi de Bernoulli de paramètre $p = \mathbb{P}(X \geq 0)$.

Passons à une fonction qui, cette fois, « tronque » la variable au-delà d'un certain seuil.

Exemple 1.3. $\phi : \mathbb{R}_+ \rightarrow \mathbb{R}_+$, $\phi(x) = \min(x, N)$ (avec $N \in \mathbb{N}$), et X une v.a. discrète à valeurs dans $\mathbb{N}$. Comme X est discrète, $\phi(X)$ l'est aussi. Sa fonction de masse s'obtient en distinguant selon que l'on est en deçà du seuil ou exactement au seuil :

$$\mathbb{P}(\min(X, N) = n) = \begin{cases} \mathbb{P}(X = n), & n \in \{0, \dots, N-1\}, \\ \mathbb{P}(X \geq N) = \sum_{k=N}^{\infty} \mathbb{P}(X = k), & n = N. \end{cases}$$

Toute la masse située à partir de N vient ainsi se concentrer sur la valeur N .

Les deux exemples suivants illustrent le phénomène de discrétisation annoncé plus haut : partant d'une v.a. à *densité*, on obtient une v.a. discrète.

Exemple 1.4. $\phi : [0, 1] \rightarrow \mathbb{N}$, $\phi(x) = \lfloor Nx \rfloor$ (avec $N \in \mathbb{N}$), et $X \sim \mathcal{U}(0, 1)$. La fonction ϕ est à valeurs dans $\{0, \dots, N-1\}$, de sorte que $\phi(X)$ est discrète. Pour tout $n \in \{0, \dots, N-1\}$,

$$\begin{aligned} \mathbb{P}(\lfloor NX \rfloor = n) &= \mathbb{P}\left(\frac{n}{N} \leq X < \frac{n+1}{N}\right) \\ &= \int_{n/N}^{(n+1)/N} 1 \, dx \\ &= \frac{1}{N}. \end{aligned}$$

La v.a. $\lfloor NX \rfloor$ suit donc la loi uniforme sur $\{0, \dots, N-1\}$: découper $[0, 1]$ en N tranches égales et repérer dans laquelle tombe X revient bien à tirer un entier au hasard, uniformément.

Exemple 1.5. $\phi : \mathbb{R}_+ \rightarrow \mathbb{N}$, $\phi(x) = \lfloor x \rfloor$, et $X \sim \mathcal{E}(\lambda)$. La fonction ϕ étant à valeurs dans $\mathbb{N}$, la v.a. $\phi(X)$ est discrète. Pour tout $n \in \mathbb{N}$,

$$\begin{aligned}
\mathbb{P}(\lfloor X \rfloor = n) &= \mathbb{P}(n \leq X < n+1) \\
&= \int_n^{n+1} \lambda e^{-\lambda x} dx \\
&= e^{-\lambda n} - e^{-\lambda(n+1)} \\
&= e^{-\lambda n}(1 - e^{-\lambda}).
\end{aligned}$$

On reconnaît là une loi géométrique : $\lfloor X \rfloor$ suit la loi $\mathcal{G}_{\mathbb{N}}(1 - e^{-\lambda})$.

Ce dernier résultat n'est pas un hasard, et l'exercice suivant invite à l'éclairer autrement, par le biais d'une propriété structurelle commune aux lois exponentielle et géométrique.

Exercice 1.8. *Retrouver le résultat ci-dessus sur la partie entière d'une v.a. de loi $\mathcal{E}(\lambda)$ en comparant les propriétés d'absence de mémoire, satisfaites respectivement par les lois $\mathcal{G}$ et $\mathcal{E}$.*

FONCTION RÉGULIÈRE D'UNE VARIABLE ALÉATOIRE À DENSITÉ

Nous abordons à présent la situation complémentaire de celle du paragraphe précédent : X est cette fois à densité, et la fonction ϕ est supposée suffisamment régulière pour ne pas venir concentrer la masse en des points isolés. Sous ces hypothèses, $\phi(X)$ demeure une v.a. à densité, et la marche à suivre est invariablement la même : on calcule d'abord la fonction de répartition de $\phi(X)$, puis on en déduit la densité, soit par dérivation, soit par mise sous forme intégrale. Ici encore, plutôt qu'un énoncé général, nous procédons par l'exemple. Commençons par un cas générique, où X est laissée quelconque.

Exemple 1.6. $\phi : \mathbb{R} \rightarrow \mathbb{R}, \phi(x) = x^2$, avec X une v.a.r. On calcule d'abord la fonction de répartition de $\phi(X)$. Pour $x \geq 0$,

$$\begin{aligned} F_{X^2}(x) &= \mathbb{P}(X^2 \leq x) \\ &= \mathbb{P}(-\sqrt{x} \leq X \leq \sqrt{x}) \\ &= F_X(\sqrt{x}) - F_X((-\sqrt{x})^-), \end{aligned}$$

soit, en tenant compte du cas $x < 0$ (où $X^2 \leq x$ est impossible),

$$F_{X^2}(x) = \begin{cases} F_X(\sqrt{x}) - F_X((-\sqrt{x})^-), & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Supposons maintenant X à densité, de densité f_X . On peut alors réécrire la différence des fonctions de répartition comme l'intégrale de f_X sur l'intervalle symétrique correspondant :

$$\begin{aligned} F_X(\sqrt{x}) - F_X((-\sqrt{x})^-) &= \int_{-\infty}^{\sqrt{x}} f_X(y) dy - \int_{-\infty}^{-\sqrt{x}} f_X(y) dy \\ &= \int_{-\sqrt{x}}^{\sqrt{x}} f_X(y) dy. \end{aligned}$$

À ce stade, deux voies mènent à la conclusion — elles aboutissent bien entendu au même résultat, et il est instructif de les avoir toutes deux à l'esprit.

- *Par dérivation.* On observe que $x \mapsto F_{X^2}(x)$ est de classe C^1 sur $]-\infty, 0[\cup]0, +\infty[$. Il suffit alors de la dériver — dérivation d'une fonction composée — pour conclure que X^2 est à densité, de densité

$$f_{X^2}(x) = \begin{cases} \frac{1}{2\sqrt{x}}(f_X(\sqrt{x}) + f_X(-\sqrt{x})), & x > 0, \\ 0, & \text{sinon.} \end{cases}$$

- *Par mise sous forme intégrale directe.* On coupe l'intégrale en son milieu, puis on ramène chaque morceau sur $[0, \sqrt{x}]$, avant un dernier changement de variable $y = \sqrt{z}$:

$$\begin{aligned} \int_{-\sqrt{x}}^{\sqrt{x}} f_X(y) dy &= \int_{-\sqrt{x}}^0 f_X(y) dy + \int_0^{\sqrt{x}} f_X(y) dy \\ &= \int_0^{\sqrt{x}} (f_X(-y) + f_X(y)) dy \\ &= \int_0^x [f_X(-\sqrt{z}) + f_X(\sqrt{z})] \frac{1}{2\sqrt{z}} dz. \end{aligned}$$

On retrouve, comme intégrande, la densité obtenue par la première méthode : les deux approches se rejoignent.

Le deuxième exemple est de nature un peu différente : X y suit une loi explicite, et surtout les ensembles de niveaux en jeu ne sont plus de simples intervalles mais des réunions *infinies* d'intervalles. C'est l'occasion de voir la sigma-additivité entrer en scène dans un calcul concret.

Exemple 1.7. $\phi : \mathbb{R} \rightarrow [0, 1[$, $\phi(x) = x - \lfloor x \rfloor$ (partie fractionnaire), avec $X \sim \mathcal{E}(\lambda)$. On calcule la fonction de répartition de $\phi(X)$. Pour tout $x \in [0, 1]$, en décomposant selon la valeur de $\lfloor X \rfloor$,

$$\begin{aligned}
 F_{\phi(X)}(x) &= \mathbb{P}(\phi(X) \leq x) \\
 &= \mathbb{P}(0 \leq X - \lfloor X \rfloor \leq x) \\
 &= \mathbb{P}(\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x) \\
 &= \mathbb{P}\left(\{\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x\} \cap \bigcup_{k \in \mathbb{N}} \{\lfloor X \rfloor = k\}\right) \\
 &= \sum_{k \in \mathbb{N}} \mathbb{P}(\{\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x\} \cap \{\lfloor X \rfloor = k\}) \\
 &= \sum_{k \in \mathbb{N}} \mathbb{P}(k \leq X \leq k + x) \\
 &= \sum_{k \in \mathbb{N}} \int_k^{k+x} \lambda e^{-\lambda y} dy \\
 &= \sum_{k \in \mathbb{N}} e^{-\lambda k} (1 - e^{-\lambda x}) \\
 &= \frac{1 - e^{-\lambda x}}{1 - e^{-\lambda}},
 \end{aligned}$$

la dernière égalité résultant de la sommation de la série géométrique de raison $e^{-\lambda} \in]0, 1[$. En rassemblant les différents cas, on obtient

$$F_{\phi(X)}(x) = \frac{1 - e^{-\lambda x}}{1 - e^{-\lambda}} \mathbb{K}_{[0,1[}(x) + \mathbb{K}_{[1,\infty[}(x).$$

Il ne reste plus qu'à identifier la densité, ce que l'on fait en mettant $F_{\phi(X)}$ sous forme intégrale :

$$F_{\phi(X)}(x) = \int_{-\infty}^x \frac{\lambda e^{-\lambda y}}{1 - e^{-\lambda}} \mathbb{K}_{[0,1]}(y) dy.$$

La partie fractionnaire d'une v.a. exponentielle possède donc une densité, proportionnelle sur $[0, 1]$ à celle de la loi exponentielle elle-même, renormalisée par le facteur $1 - e^{-\lambda}$.

Signalons enfin qu'une troisième voie existe, dite *méthode de la fonction muette*, elle aussi fondée sur le changement de variable. Nous l'étudierons au chapitre suivant.

1.6 SIMULATION DE LOIS

Pour clore ce chapitre, présentons une méthode de simulation reposant entièrement sur la fonction de répartition. L'idée de départ est simple : si l'on savait « inverser » F_X , on pourrait fabriquer une variable aléatoire de loi prescrite à partir d'un unique tirage uniforme. La difficulté est que F_X n'est en général pas inversible au sens usuel — elle peut présenter des paliers, sur lesquels elle n'est pas injective, aussi bien que des sauts, où elle n'est pas surjective. On contourne cet obstacle en lui associant un inverse « généralisé ».

Définition 1.16. On appelle fonction quantile l'inverse généralisé de la fonction de répartition, défini par

$$F_X^{-1}(y) = \inf\{x : F_X(x) \geq y\}, \quad y \in]0, 1[.$$

Avant d'en venir à la méthode de simulation proprement dite, établissons quelques propriétés de la fonction quantile. Précisons d'emblée qu'elles ne sont pas indispensables à la suite : le lecteur pressé pourra les sauter en première lecture et passer directement à la proposition de simulation.

Proposition 1.8. La fonction quantile F_X^{-1} est croissante, continue à gauche, et admet des limites à droite.

On observera que les rôles de la continuité à gauche et à droite sont ici échangés par rapport à ceux de la fonction de répartition F_X (croissante et continue à droite). Notons par ailleurs que la démonstration, purement analytique, ne fait appel qu'aux deux seules hypothèses de croissance et de continuité à droite de F_X .

Démonstration. Soient $y \leq z$ deux réels de $]0, 1[$. L'inclusion d'ensembles

$$\{x : F_X(x) \geq y\} \supset \{x : F_X(x) \geq z\}$$

entraîne aussitôt $F_X^{-1}(y) \leq F_X^{-1}(z)$: c'est la croissance.

Montrons à présent la continuité à gauche. Soit $(y_n)_n$ une suite croissante de $]0, 1[$, de limite $y = \lim_n y_n \in]0, 1[$, et posons $z = \lim_n F_X^{-1}(y_n)$ (limite qui existe, la suite étant croissante). Pour tout $\epsilon > 0$, on a

$$F_X(z + \epsilon) \geq y_n$$

pour tout n , donc

$$F_X(z + \epsilon) \geq y$$

par passage à la limite; il s'ensuit $z + \epsilon \geq F_X^{-1}(y)$, puis $z \geq F_X^{-1}(y)$ en faisant tendre ϵ vers 0.

La croissance de $(y_n)_n$ et de F_X^{-1} fournit l'inégalité inverse $z \leq F_X^{-1}(y)$, d'où l'égalité $z = F_X^{-1}(y)$, c'est-à-dire la continuité à gauche. Enfin, l'existence des limites à droite est une conséquence directe de la croissance. $\square$

Il est instructif de voir sur un cas concret que la continuité à droite, elle, fait bien défaut en général. Supposons que l'on puisse trouver $y \in]0, 1[$ ainsi que $x_1 < x_2$ tels que $F_X(x_1) = F_X(x_2) = y$ — autrement dit que $[x_1, x_2]$ soit un intervalle sur lequel F_X reste constante. Alors, pour toute suite $(y_n)_n$ strictement décroissante de limite y , on a $F_X^{-1}(y_n) \geq x_2$ tandis que $F_X^{-1}(y) \leq x_1$, si bien que

$$F_X^{-1}(y_n) - F_X^{-1}(y) \geq x_2 - x_1 > 0.$$

La limite à droite en y ne peut donc pas valoir $F_X^{-1}(y)$: un palier de F_X se traduit par un saut de F_X^{-1} .

Venons-en maintenant au résultat qui motive tout ce paragraphe. Tout l'intérêt de la fonction quantile est qu'elle permet de simuler la loi de X de façon remarquablement économique.

Proposition 1.9. *Soient U une variable aléatoire de loi uniforme $\text{Unif}(0, 1)$ et X une v.a.r. Alors $F_X^{-1}(U)$ suit la loi de X .*

La force de cette méthode tient à sa généralité : elle vaut pour n'importe quelle variable aléatoire réelle X , sans hypothèse aucune, puisqu'elle ne mobilise que la fonction de répartition. Dès lors qu'on sait produire des tirages uniformes sur $]0, 1[$ — ce que toute machine sait faire — et qu'on dispose de F_X^{-1} , on sait simuler X .

Démonstration. Tout repose sur l'équivalence suivante, que l'on établit par double inclusion : pour tous $u \in]0, 1[$ et $x \in \mathbb{R}$,

$$F_X^{-1}(u) \leq x \iff u \leq F_X(x).$$

Admise un instant, elle donne l'égalité d'événements $\{F_X^{-1}(U) \leq x\} = \{U \leq F_X(x)\}$, d'où, en prenant les probabilités,

$$\mathbb{P}(F_X^{-1}(U) \leq x) = \mathbb{P}(U \leq F_X(x)) = F_X(x),$$

la dernière égalité venant de ce que U est uniforme sur $]0, 1[$. Ainsi $F_X^{-1}(U)$ a pour fonction de répartition F_X , ce qui suffit à identifier sa loi à celle de X .

Il reste à prouver l'équivalence. Supposons d'abord $F_X^{-1}(u) \leq x$ et posons $y = F_X^{-1}(u)$. Pour tout $\epsilon > 0$ on a $F_X(y + \epsilon) \geq u$; par continuité à droite de F_X , on en déduit $F_X(y) = F_X(y^+) \geq u$. Comme $y \leq x$ entraîne $F_X(y) \leq F_X(x)$ par croissance, on obtient bien $u \leq F_X(x)$. Réciproquement, si $u \leq F_X(x)$, alors x appartient à $\{z : F_X(z) \geq u\}$, et $F_X^{-1}(u) \leq x$ résulte directement de la définition de F_X^{-1} comme borne inférieure de cet ensemble. $\square$

Remarque 1.6. Attention à ne pas croire que F_X^{-1} soit une réciproque au sens strict. On n'a pas toujours $F_X \circ F_X^{-1}(u) = u$ — penser au cas où $F_X(x^-) < u < F_X(x)$, c'est-à-dire à un saut de F_X — ni toujours $F_X^{-1} \circ F_X(x) = x$ — penser cette fois au cas où il existe $w < x$ avec $F_X(w) = F_X(x)$, c'est-à-dire à un palier. Nous invitons le lecteur à faire un dessin dans chacune de ces deux situations : tout y devient limpide.

Au-delà de la simulation, le calcul de F_X^{-1} a une autre vertu : il éclaire souvent la manière dont une loi dépend de ses paramètres. Les deux exemples suivants l'illustrent.

Exemple 1.8. $X \sim \mathcal{E}(\lambda)$. Pour $y \in]0, 1[$, on trouve $F_X^{-1}(y) = \frac{-\log(1-y)}{\lambda}$. Ainsi $\frac{-\log(1-U)}{\lambda}$ — ou encore $\frac{-\log(U)}{\lambda}$, qui suit la même loi puisque U et $1-U$ ont même loi — suit la loi $\mathcal{E}(\lambda)$. On lit au passage la dépendance en λ : le paramètre agit par simple facteur d'échelle, et $\lambda X \sim \mathcal{E}(1)$.

Exemple 1.9. $X \sim \mathcal{C}(a)$. Pour $y \in]0, 1[$, on trouve $F_X^{-1}(y) = a \tan(\pi(y - \frac{1}{2}))$. Ainsi $a \tan(\pi(U - \frac{1}{2}))$ — ou encore $a \tan(\pi U)$, qui suit la même loi — suit la loi $\mathcal{C}(a)$. Là encore, a n'est qu'un facteur d'échelle, et $X/a \sim \mathcal{C}(1)$.

Terminons par une mise en garde d'ordre pratique. Le calcul numérique de F_X^{-1} peut se révéler coûteux — et la question se pose d'ailleurs jusque dans les fonctions élémentaires qui y apparaissent : comment une machine calcule-t-elle un logarithme, au juste ? Lorsque cette inversion devient trop lourde, on lui préfère d'autres approches, telle la méthode dite du rejet.

TD0 : PRÉLIMINAIRES

Exercice 1.1. On rappelle l'expression de la fonction gamma d'Euler :

$$\forall x > 0, \quad \Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt.$$

1. Montrer que pour tout réel x strictement positif,

$$\Gamma(x+1) = x\Gamma(x).$$

2. En déduire la valeur de $\Gamma(n)$ pour n entier naturel non nul.
3. Montrer que

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}.$$

On pourra se ramener à l'intégrale de Gauss :

$$\int_{\mathbb{R}} e^{-x^2} dx = \sqrt{\pi}.$$

4. En déduire que pour tout entier naturel n ,

$$\Gamma\left(n + \frac{1}{2}\right) = \frac{(2n)!}{2^{2n}n!} \sqrt{\pi}$$

On pose pour tout entier naturel n :

$$\beta(n) = \int_{-\infty}^{\infty} x^n \exp\left(-\frac{x^2}{2}\right) dx.$$

5. Calculer $\beta(0)$ et $\beta(1)$.
6. Exprimer $\beta(n+2)$ en fonction de $\beta(n)$.
7. En déduire la valeur de $\beta(n)$ pour tout entier naturel n .
8. Faire un lien entre les résultats des questions 4 et 7, et retrouver ce résultat par un changement de variable.

- Exercice 1.2.** 1. Déterminer la valeur de $\sum_{k=1}^n k$ en calculant la somme $A = \sum_{k=1}^n (k+1)^2 - \sum_{k=1}^n k^2$ de deux façons différentes.
2. Par un raisonnement similaire, calculer $\sum_{k=1}^n k^2$.
3. Donner des équivalents de ces deux sommes pour $n \rightarrow \infty$.
4. Soit $\alpha > 0$ un réel. À l'aide de la comparaison série-intégrale :

$$\int_{k-1}^k t^\alpha dt \leq k^\alpha \leq \int_k^{k+1} t^\alpha dt,$$

- proposer un encadrement puis donner un équivalent de $\sum_{k=1}^n k^\alpha$.
5. On rappelle le résultat suivant au sujet de l'intégrale de Riemann : pour $f : [0, 1] \rightarrow \mathbb{R}$ continue bornée,

$$\frac{1}{n} \sum_{k=1}^n f\left(\frac{k}{n}\right) \xrightarrow{n \rightarrow \infty} \int_0^1 f(t) dt.$$

Retrouver à l'aide de ce résultat un équivalent de $\sum_{k=1}^n k^\alpha$ (sans encadrement toutefois).

- Exercice 1.3.** Soit $\lambda \in \mathbb{C}$; calculer les sommes des séries suivantes :

1. $A = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}.$

On peut au choix dire que c'est un DSE connu, ou se ramener à la définition de l'exponentielle comme unique solution de l'équation différentielle ordinaire $f' = f, f(0) = 1$.

2. $B = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!}.$

3. $C = \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k}{k!}.$

4. $D = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!}.$

- Exercice 1.4.** 1. Soit $\lambda \in \mathbb{C}$, et $n \in \mathbb{N}$. Simplifier $(1 - \lambda) \sum_{k=0}^n \lambda^k$.

2. En déduire, pour $|\lambda| < 1$, la valeur de la série entière $\sum_{k=0}^{+\infty} \lambda^k$.

3. À l'aide d'un produit de Cauchy, développer en série entière $(1 - \lambda)^{-2}$ pour $|\lambda| < 1$.

4. Retrouver cette identité au moyen du théorème de dérivation sous le signe somme des séries entières.

Les questions qui suivent sont plus difficiles.

5. Montrer que $\sum_{k_1, \dots, k_n \geq 0} \mathbb{1}_{k_1+k_2+\dots+k_n=j} = \binom{j+n-1}{j}$.

On pourra remarquer que le membre de gauche compte aussi les chemins du plan $\mathbb{Z}^2$ avec des pas vers le haut et vers la droite reliant $(0, 0)$ à $(n-1, j)$.

6. Soit $n \in \mathbb{N}^*$. Plus généralement, pour $|\lambda| < 1$, développer en série entière $(1 - \lambda)^{-n}$.

TD1 : VARIABLES ALÉATOIRES RÉELLES ET FONCTIONS DE RÉPARTITION

Exercice 1.1. Soit X une variable aléatoire dont la fonction de répartition F_X est définie par :

$$\forall t \in \mathbb{R} \quad F_X(t) = \begin{cases} 0 & \text{si } t < -2, \\ \frac{1}{30} & \text{si } -2 \leq t < 0, \\ \frac{1}{12} & \text{si } 0 \leq t < 1, \\ \frac{1}{4} & \text{si } 1 \leq t < 3, \\ \frac{1}{3} & \text{si } 3 \leq t < 5, \\ 1 & \text{si } t \geq 5. \end{cases}$$

1. Montrer que X est une v.a. discrète et déterminer sa fonction de masse.
2. Calculer $\mathbb{P}(-3 \leq X < \frac{1}{2})$.

Exercice 1.2. Soit X une variable aléatoire dont la fonction de répartition F_X est définie par :

$$\forall t \in \mathbb{R} \quad F_X(t) = \begin{cases} 0 & \text{si } t \leq 0, \\ \frac{t}{2} & \text{si } 0 \leq t \leq 2, \\ 1 & \text{si } t \geq 2. \end{cases}$$

1. Tracer la courbe représentative de F_X , montrer que X est une v.a. à densité et déterminer cette densité.
2. Calculer $\mathbb{P}(\frac{1}{4} < X < \frac{3}{4})$.

Exercice 1.3. Soit X une variable aléatoire de densité f définie par

$$f(x) = \begin{cases} \frac{10}{x^2} & \text{si } x > a, \\ 0 & \text{si } x \leq a, \end{cases}$$

pour un certain $a > 0$.

1. Calculer a .
2. Calculer $\mathbb{P}(X > 20)$.

3. Quelle est la fonction de répartition de X ?

Exercice 1.4. Soit X une variable aléatoire de densité f définie par

$$\forall x \in \mathbb{R} \quad f(x) = \frac{1}{4} \mathbb{1}_{\{0 < x < 1\}} + \frac{3}{8} \mathbb{1}_{\{3 < x < 5\}}.$$

1. Donner la fonction de répartition de X .
2. Calculer $\mathbb{P}(X \in [\frac{1}{2}, 2] \cup]3, 4])$.

TD2 : CONVERGENCE DE VARIABLES ALÉATOIRES ET THÉORÈMES LIMITES.

Exercice 1.1. On reprend l'exercice 1 de la feuille précédente. On rappelle la fonction de masse de X :

$$\begin{aligned}\mathbb{P}(X = -2) &= \frac{1}{30}, \\ \mathbb{P}(X = 0) &= \frac{1}{20}, \\ \mathbb{P}(X = 1) &= \frac{1}{6}, \\ \mathbb{P}(X = 3) &= \frac{1}{12}, \\ \mathbb{P}(X = 5) &= \frac{2}{3}.\end{aligned}$$

1. Montrer que $Y = -2X + 1$ est une v.a. discrète et déterminer sa fonction de masse.
2. Même question pour $Z = Y^2$.

Exercice 1.2. On reprend l'exercice 4 de la feuille précédente. On rappelle la fonction de répartition de X :

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ \frac{x}{4} & \text{si } 0 \leq x < 1, \\ \frac{1}{4} & \text{si } 1 \leq x < 3, \\ \frac{3x-7}{8} & \text{si } 3 \leq x < 5, \\ 1 & \text{si } x \geq 5. \end{cases}$$

1. Justifier que la variable aléatoire $Y = 1/X$ est bien définie.
2. Montrer que Y est à densité et calculer sa densité.

Exercice 1.3. Soit f_X la densité d'une variable aléatoire réelle X telle que $\mathbb{P}(X \geq 0) > 0$. On pose

$$f_Y(t) = af_X(|t|), \quad t \in \mathbb{R}$$

1. Calculer a (en fonction de f_X) pour que f_Y soit la densité d'une variable aléatoire Y .
2. Montrer que Y et $-Y$ ont même loi.

Exercice 1.4. Soit X une variable aléatoire de densité f continue et de fonction de répartition F .

1. Soit $Z = 2X\mathbb{1}_{\{X < 0\}} + 3X\mathbb{1}_{\{X \geq 0\}}$. Donner la fonction de répartition de Z en fonction de F , puis sa densité en fonction de f .
2. Soit $Y = X^2$. Donner la fonction de répartition de Y en fonction de F , puis sa densité en fonction de f .

Exercice 1.5. Soit X une variable aléatoire de fonction de répartition F , et soit $A =]a, b]$ un intervalle.

1. Soit $Y = \mathbb{1}_A(X)$. Donner la fonction de répartition de Y en fonction de F . (On pourra observer que $Y \sim \text{Ber}(p)$ pour une valeur de p à déterminer).
2. On suppose de plus $a > 0$. Soit $Z = X\mathbb{1}_A(X)$. Donner la fonction de répartition de Z en fonction de F .

Exercice 1.6. Soit X une variable aléatoire de fonction de répartition F . Soit $(a, b) \in \mathbb{R}^2$.

1. Exprimer à l'aide de F la fonction de répartition de la variable aléatoire $aX + b$.
2. Sous quelle condition sur le couple (a, b) la fonction $t \mapsto F(at + b)$ est-elle une fonction de répartition ? Sous cette condition, de quelle variable aléatoire cette fonction est-elle la fonction de répartition ?

TD₃ : FONCTION D'UNE VARIABLE ALÉATOIRE : EXEMPLES CONCRETS.

Exercice 1.1. Dans cet exercice, lorsqu'est demandé de préciser la loi d'une variable aléatoire, on donnera la fonction de répartition, et si cela a un sens, la densité.

1. On suppose que X suit la loi uniforme sur $[0, 1]$, notée $\mathcal{U}(0, 1)$. Quelle loi suit X^2 ?
2. On suppose que X^2 suit la loi uniforme sur $[0, 1]$, et $\mathbb{P}(X \geq 0) = 1$. Quelle loi suit X ?
3. On suppose que X suit la loi uniforme sur $[0, \pi]$. Quelle loi suit $\cos(X)$?
4. On suppose que $\cos(X)$ suit la loi uniforme sur $[-1, 1]$, et $\mathbb{P}(X \in [0, \pi]) = 1$. Quelle loi suit X ?

Exercice 1.2. Soit X une variable aléatoire de loi $\mathcal{E}(\alpha)$, pour $\alpha > 0$.

1. Quelle loi suit αX ?
2. Quelle loi suit $Y = e^X$?

On précisera dans les deux cas la valeur de la densité si la variable en admet une.

Exercice 1.3. Soit X une variable aléatoire de loi $\mathcal{N}(0, 1)$.

1. Quelle loi suit $\mu + \sigma X$, pour $\mu \in \mathbb{R}$, et $\sigma > 0$?
2. Quelle loi suit $Y = X^2$. Reconnaitre une loi $\Gamma(\alpha, \beta)$ pour des paramètres à préciser.

Exercice 1.4. Un bout de bois est cassé en un point uniforme, formant deux bouts; si l'on assimile le bout de bois à l'intervalle unité $[0, 1]$, quelle est la loi de la longueur du bout contenant la marque d'abscisse p , pour $p \in [0, 1]$? Quelle loi retrouve-t-on lorsque $p = 1/2$?

Exercice 1.5. Soit X une variable aléatoire de loi $\mathcal{C}(\alpha)$ pour $\alpha > 0$, qui est la loi de densité $x \mapsto \frac{\alpha}{\pi} \frac{1}{\alpha^2 + x^2}$ sur $\mathbb{R}$.


1. Calculer la fonction de répartition et en déduire que la fonction proposée est bien une densité.
2. Quelle loi suit X/α ?

3. Quelle loi suit $Y = 1/X$?

Pour la dernière question, on pourra librement utiliser la relation : pour $x \neq 0$, $\arctan(x) + \arctan(1/x) = \frac{\pi}{2}(\mathbb{1}_{\{x>0\}} - \mathbb{1}_{\{x<0\}})$.

Exercice 1.6. On considère un repère cartésien d'origine O et A le point de coordonnées $(0, -1)$. Pour $\Theta \in]-\pi/2, \pi/2[$, il existe un unique point B d'ordonnée -1 que l'angle $\widehat{AOB}$ est de Θ radians; on note alors X l'abscisse de B .

Ci-dessous, deux valeurs d'angles possibles : $\Theta > 0$ et $\Theta' < 0$, et les points B et B' correspondants :



Si Θ suit la loi uniforme sur $]-\pi/2, \pi/2[$, montrer que X suit la loi $\mathcal{C}(1)$.

Exercice 1.7 (Simulation à partir de la loi uniforme.). Soit F fonction de répartition qui réalise une bijection d'un intervalle I sur $]0, 1[$, et U une variable aléatoire de loi $\mathcal{U}(0, 1)$.

1. Quelle est la fonction de répartition de $F^{-1}(U)$? En déduire la loi de $F^{-1}(U)$.

Préciser I pour les deux lois suivantes, la bijection réciproque $F^{-1} :]0, 1[\rightarrow I$:

2. F fonction de répartition de $\mathcal{E}(\lambda)$ pour $\lambda > 0$.
3. F fonction de répartition de $\mathcal{C}(a)$ pour $a > 0$.

Application : Quelle est la loi de

4. $Z = -\frac{\ln U}{\lambda}$
5. $W = a \tan\left(\pi\left(U - \frac{1}{2}\right)\right)$.

ESPÉRANCE ET MOMENTS

Lançons une pièce équilibrée n fois, et intéressons-nous à la proportion de « pile » parmi ces n lancers. La pièce n'étant pas biaisée, chaque face apparaît avec probabilité $1/2$, et l'on s'attend naturellement à ce que cette proportion se rapproche de $1/2$ lorsque n tend vers l'infini. C'est là l'interprétation dite *fréquentiste* des probabilités, où une probabilité se lit comme une fréquence d'apparition limite. Plus généralement, donnons-nous une variable aléatoire X décrivant le résultat d'une expérience, et répétons cette expérience n fois de façon indépendante, en notant $X_1, \dots, X_n$ les valeurs successivement observées (le cas de la pièce correspond à $X \sim \mathcal{B}(1/2)$).

On s'attend alors à ce que la moyenne empirique $(X_1 + \dots + X_n)/n$ se stabilise, quand n grandit, autour d'une constante : la somme, sur toutes les valeurs que X peut prendre, de chaque valeur multipliée par sa probabilité. Cette somme pondérée — une « moyenne » de X , en un sens que nous préciserons — porte le nom d'*espérance* de X (parfois espérance mathématique), et se note $\mathbb{E}[X]$. La définition de $\mathbb{E}[X]$, et plus généralement celle de $\mathbb{E}[f(X)]$ pour une fonction f , est l'un des concepts les plus centraux de toute la théorie des probabilités.

L'espérance ouvre la voie à la notion de *moments* d'une variable aléatoire. La suite de ces moments constitue à son tour une description de la loi, souvent précieuse : dans certains cas, elle la caractérise entièrement ; surtout, elle fournit des bornes sur des probabilités d'événements que l'on ne sait pas calculer directement. C'est elle, enfin, qui permet de définir la fonction génératrice des moments — encore une autre manière de décrire la loi de X , au même titre que la fonction de répartition, mais dont l'expression se révèle bien souvent plus explicite (celle de F_X ne se simplifiant que rarement).

2.1 ESPÉRANCE D'UNE VARIABLE ALÉATOIRE

VARIABLE ALÉATOIRE POSITIVE OU NULLE

Commençons par le cas le plus favorable, celui des variables aléatoires positives ou nulles : pour elles, l'espérance peut toujours être définie, quitte à ce qu'elle vaille $+\infty$.

Définition 2.1. Soit X une variable aléatoire positive ou nulle, discrète ou à densité. L'espérance de X , notée $\mathbb{E}[X] \in [0, \infty]$, est définie par

$$\mathbb{E}[X] = \begin{cases} \sum x \mathbb{P}(X = x) & \text{si } X \text{ est discrète,} \\ \int_0^{+\infty} x f_X(x) dx & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

On dit que X est intégrable lorsque la somme (ou l'intégrale) figurant ci-dessus est convergente.

Intuitivement, $\mathbb{E}[X]$ est la moyenne des valeurs de X , pondérées par les probabilités de les atteindre. Une image mécanique éclaire bien cette idée : celle du *centre de gravité*. Supposons d'abord X discrète, prenant les valeurs x_i . Imaginons des masses disposées sur l'axe réel, l'une à chaque abscisse x_i , de poids $\mathbb{P}(X = x_i)$: alors $\mathbb{E}[X]$ n'est autre que l'abscisse du centre de gravité de ce système de masses. Si X est à densité, on imagine cette fois une masse totale égale à 1, étalée continûment le long de l'axe selon la densité f_X ; l'espérance $\mathbb{E}[X]$ en est, là encore, l'abscisse du centre de gravité.

Soulignons un fait immédiat mais qu'il vaut la peine de nommer : l'espérance d'une variable aléatoire positive est positive. Cela ne fait que refléter la positivité des termes sommés — ou de l'intégrande —, c'est-à-dire la positivité de la somme et de l'intégrale.

Exemple 2.1. Soit $X \sim \mathcal{B}(p)$, $p \in [0, 1]$. Alors

$$\mathbb{E}[X] = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Interprétation. En répétant n fois une expérience de Bernoulli de probabilité de succès p , on s'attend à ce que la proportion de succès s'approche de p lorsque $n \rightarrow \infty$.

Exemple 2.2. Soit $X \sim \mathcal{G}(p)$, $p \in]0, 1]$. Alors

$$\mathbb{E}[X] = \sum_{n=1}^{\infty} n p (1 - p)^{n-1} = \frac{1}{p}.$$

On obtient cette somme en dérivant terme à terme la série entière $\sum_{n=0}^{\infty} (1 - p)^n = \frac{1}{1 - (1 - p)} = \frac{1}{p}$, à l'intérieur de son disque de convergence (soit $|1 - p| < 1$) : la dérivation donne

$\sum_{n=1}^{\infty} n(1 - p)^{n-1} = \frac{1}{p^2}$, qu'il suffit alors de multiplier par p . *Interprétation.* Lorsqu'on répète une expérience de Bernoulli de probabilité de succès p jusqu'au premier succès, il faut en moyenne $1/p$ tentatives. Ainsi, une expérience réussissant avec 5% de chances devra être répétée en moyenne $1/0,05 = 20$ fois avant d'aboutir.

Exemple 2.3. Soit $X \sim \mathcal{E}(\lambda)$, $\lambda > 0$. Alors

$$\mathbb{E}[X] = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

Interprétation. Un composant dont le taux de panne est constant, égal à λ , a une durée de vie moyenne de $1/\lambda$.

Notons pour finir que toutes les variables aléatoires des exemples précédents sont intégrables.

VARIABLE ALÉATOIRE SIGNÉE

Pour une variable aléatoire positive, l'espérance avait toujours un sens, quitte à valoir $+\infty$. La situation devient plus délicate dès que X peut changer de signe : additionner ses contributions positives et négatives risque de conduire à une forme indéterminée du type « $\infty - \infty$ », dépourvue de sens. Pour écarter cet écueil, on commence par exiger que la somme (ou l'intégrale) des *valeurs absolues* converge. C'est cette condition, dite d'intégrabilité, qui garantit que l'espérance est bien définie.

Définition 2.2. Soit X une variable aléatoire discrète ou à densité. On dit que X est intégrable si

$$\begin{cases} \sum |x| \mathbb{P}(X = x) < \infty & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} |x| f_X(x) dx < \infty & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Dans ce cas, on définit l'espérance de X par

$$\mathbb{E}[X] = \begin{cases} \sum x \mathbb{P}(X = x) & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} x f_X(x) dx & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Remarque 2.1. Nous connaissons déjà une loi qui échoue à être intégrable : la loi de Cauchy. Si $X \sim \mathcal{C}(a)$, on a en effet

$$\int_{\mathbb{R}} \frac{a}{\pi} \cdot \frac{|x|}{a^2 + x^2} dx = \infty,$$

l'intégrande se comportant comme C/x au voisinage de $+\infty$ (et de $-\infty$), ce qui suffit à faire diverger l'intégrale. Pour une telle loi, l'espérance n'est tout simplement pas définie.

Exemple 2.4. Soit $X \sim \mathcal{U}(a, b)$, avec $a < b$. Alors

$$\mathbb{E}[X] = \int_a^b \frac{x}{b-a} dx = \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{a+b}{2},$$

en utilisant $b^2 - a^2 = (a+b)(b-a)$.

Interprétation. Le centre de gravité d'une masse répartie uniformément sur $[a, b]$ se situe, sans surprise, au milieu de l'intervalle, à l'abscisse $(a+b)/2$.

2.2 ESPÉRANCE D'UNE FONCTION D'UNE VARIABLE ALÉATOIRE

Nous aurons très souvent besoin, non pas de l'espérance de X elle-même, mais de celle d'une fonction $\phi(X)$. Une première approche consisterait à déterminer d'abord la loi de $\phi(X)$ — comme au chapitre précédent —, puis à lui appliquer la définition de l'espérance. La formule suivante, dite *de transfert*, permet de court-circuiter cette étape : elle calcule $\mathbb{E}[\phi(X)]$ directement à partir de la loi de X , sans qu'il soit nécessaire d'expliciter celle de $\phi(X)$. C'est de là que lui vient son nom : elle « transfère » le calcul sur la loi de départ.

Proposition 2.1 (Formule de transfert). *Soit X une variable aléatoire discrète ou à densité, et $\phi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. Alors $\phi(X)$ est intégrable si et seulement si*

$$\begin{cases} \sum |\phi(x)| \mathbb{P}(X = x) < \infty & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} |\phi(x)| f_X(x) dx < \infty & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Dans ce cas, son espérance est donnée par

$$\mathbb{E}[\phi(X)] = \begin{cases} \sum \phi(x) \mathbb{P}(X = x) & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} \phi(x) f_X(x) dx & \text{si } X \text{ admet la densité } f_X. \end{cases} \quad (2.1)$$

Quelques remarques avant la preuve. La condition d'intégrabilité assure l'absolue convergence de la série (ou de l'intégrale) qui définit l'espérance, de sorte que celle-ci a bien un sens. Cette formule englobe la définition de $\mathbb{E}[X]$, que l'on retrouve en choisissant pour ϕ l'identité $\phi(x) = x$. Elle contient aussi un cas particulièrement parlant, celui de la fonction indicatrice : en prenant $\phi = \mathbb{1}_A$,

$$\mathbb{E}[\mathbb{1}_A(X)] = 1 \cdot \mathbb{P}(X \in A) + 0 \cdot \mathbb{P}(X \notin A) = \mathbb{P}(X \in A).$$

On retrouve là le lien fondamental entre espérance et probabilité, cohérent du reste avec l'exemple de la loi de Bernoulli traité plus haut, puisque $\mathbb{1}_A(X)$ suit précisément une loi de Bernoulli de paramètre $\mathbb{P}(X \in A)$.

Démonstration. Cas discret. Si X est discrète, alors $\phi(X)$ l'est aussi, et sa fonction de masse s'obtient en regroupant les valeurs de x ayant même image :

$$\mathbb{P}(\phi(X) = y) = \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}}.$$

Traisons d'abord l'énoncé sur l'intégrabilité. Toutes les quantités étant positives, le théorème de Fubini positif autorise l'échange des sommations, et l'on écrit dans $[0, +\infty]$:

$$\begin{aligned} \sum_y |y| \mathbb{P}(\phi(X) = y) &= \sum_y |y| \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\ &= \sum_y \sum_x |\phi(x)| \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\ &= \sum_x |\phi(x)| \mathbb{P}(X = x) \sum_y \mathbb{1}_{\{\phi(x)=y\}} \\ &= \sum_x |\phi(x)| \mathbb{P}(X = x), \end{aligned}$$

la dernière égalité venant de ce que $\sum_y \mathbb{1}_{\{\phi(x)=y\}} = 1$. On en tire immédiatement l'équivalence des deux conditions d'intégrabilité :

$$\sum_y |y| \mathbb{P}(\phi(X) = y) < \infty \iff \sum_x |\phi(x)| \mathbb{P}(X = x) < \infty.$$

Le même enchaînement de manipulations, cette fois sans les valeurs absolues (licite dès que l'intégrabilité est acquise), fournit la formule de l'espérance :

$$\begin{aligned}
 \mathbb{E}[\phi(X)] &= \sum_y y \mathbb{P}(\phi(X) = y) \\
 &= \sum_y y \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_y \sum_x \phi(x) \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x \phi(x) \mathbb{P}(X = x) \sum_y \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x \phi(x) \mathbb{P}(X = x).
 \end{aligned}$$

Cas à densité. Nous nous limitons ici au cas où ϕ est de classe C^1 et strictement croissante, au sens où $\phi'(x) > 0$ pour tout x . Il existe alors $-\infty \leq a < b \leq +\infty$ tels que $\text{Im}(\phi) = (a, b)$. Pour $x \in \text{Im}(\phi)$, la stricte croissance de ϕ donne $\{\phi(X) \leq x\} = \{X \leq \phi^{-1}(x)\}$, d'où

$$\begin{aligned}
 \mathbb{P}(\phi(X) \leq x) &= \mathbb{P}(X \leq \phi^{-1}(x)) \\
 &= \int_{-\infty}^{\phi^{-1}(x)} f_X(y) dy \\
 &= \int_a^x f_X(\phi^{-1}(y)) (\phi^{-1})'(y) dy \\
 &= \int_{-\infty}^x f_X(\phi^{-1}(y)) (\phi^{-1})'(y) \mathbb{1}_{\text{Im} \phi}(y) dy,
 \end{aligned}$$

l'avant-dernière égalité résultant du changement de variable $y = \phi(\cdot)$. L'énoncé s'étend sans peine à $x \in \mathbb{R}$, ce qui permet d'identifier $f_X(\phi^{-1}(y)) (\phi^{-1})'(y) \mathbb{1}_{\text{Im} \phi}(y)$ comme une densité de $\phi(X)$. On conclut alors par un ultime changement de variable $x = \phi^{-1}(y)$, $dx = (\phi^{-1})'(y) dy$:

$$\begin{aligned}\mathbb{E}[\phi(X)] &= \int_{-\infty}^{+\infty} y f_{\phi(X)}(y) dy \\ &= \int_{-\infty}^{+\infty} y f_X(\phi^{-1}(y)) (\phi^{-1})'(y) dy \\ &= \int_{-\infty}^{+\infty} \phi(x) f_X(x) dx.\end{aligned}$$

□

La formule de transfert a un premier corollaire, aussi simple qu'omniprésent : la linéarité de l'espérance.

Corollaire 2.1 (Linéarité de l'espérance). *Si f_1 et f_2 sont deux fonctions telles que $f_1(X)$ et $f_2(X)$ soient intégrables, alors $(f_1 + f_2)(X)$ l'est aussi, et*

$$\mathbb{E}[(f_1 + f_2)(X)] = \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)].$$

En particulier, si X est intégrable, alors pour tous réels a, b ,

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b.$$

Démonstration. Tout repose sur le fait que l'intégrabilité de $f_1(X)$ et de $f_2(X)$ autorise à scinder la somme (ou l'intégrale) en deux. Dans le cas discret,

$$\begin{aligned}\mathbb{E}[(f_1 + f_2)(X)] &= \sum_x (f_1(x) + f_2(x)) \mathbb{P}(X = x) \\ &= \sum_x f_1(x) \mathbb{P}(X = x) + \sum_x f_2(x) \mathbb{P}(X = x) \\ &= \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)].\end{aligned}$$

De même, si X est à densité, la formule (??) donne

$$\begin{aligned}
 \mathbb{E}[(f_1 + f_2)(X)] &= \int_{-\infty}^{+\infty} (f_1(x) + f_2(x)) f_X(x) dx \\
 &= \int_{-\infty}^{+\infty} f_1(x) f_X(x) dx + \int_{-\infty}^{+\infty} f_2(x) f_X(x) dx \\
 &= \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)].
 \end{aligned}$$

La seconde formule s'en déduit en prenant $f_1(x) = ax$ et $f_2(x) = b$. □

En combinant transfert, linéarité et positivité, on obtient un résultat de comparaison bien commode, dont la démonstration est laissée au lecteur.

Lemme 2.1. *Soit X une variable aléatoire à valeurs dans I . Si $\phi_1, \phi_2 : I \rightarrow \mathbb{R}_+$ vérifient $\phi_1 \leq \phi_2$, alors $\mathbb{E}[\phi_1(X)] \leq \mathbb{E}[\phi_2(X)]$. En particulier, si $\phi_2(X)$ est intégrable, alors $\phi_1(X)$ l'est aussi.*

Lois symétriques. Certains calculs d'espérance se simplifient considérablement lorsque la loi possède une symétrie. Formalisons cette notion.

Définition 2.3. On dit que la loi de X est symétrique si X et $-X$ ont même loi, c'est-à-dire si, pour tout $A \subset \mathbb{R}$,

$$\mathbb{P}(X \in A) = \mathbb{P}(-X \in A).$$

En notant $-A = \{-x : x \in A\}$, cette égalité se réécrit aussi bien $\mathbb{P}(X \in A) = \mathbb{P}(X \in -A)$.

En pratique, la symétrie se lit directement sur la fonction de masse ou sur la densité, comme le montre la condition suffisante suivante.

Lemme 2.2. *La loi de X est symétrique dans chacun des deux cas suivants :*

1. *X est discrète et sa fonction de masse est paire;*
2. *X est à densité et admet une densité paire.*

Démonstration. Dans le cas discret, à fonction de masse paire, on réindexe la somme par $x_k \mapsto -x_k$:

$$\begin{aligned}
 \mathbb{P}(-X \in A) &= \mathbb{P}(X \in -A) \\
 &= \sum_{x_k \in -A} \mathbb{P}(X = x_k) \\
 &= \sum_{-x_k \in A} \mathbb{P}(X = -x_k) \\
 &= \sum_{x_k \in A} \mathbb{P}(X = x_k) = \mathbb{P}(X \in A).
 \end{aligned}$$

Dans le cas à densité paire, le même rôle est joué par le changement de variable $x \mapsto -x$:

$$\begin{aligned}
 \mathbb{P}(-X \in A) &= \mathbb{P}(X \in -A) \\
 &= \int_{\mathbb{R}} \mathbb{1}_{-A}(x) f_X(x) dx \\
 &= \int_{\mathbb{R}} \mathbb{1}_{-A}(-x) f_X(-x) dx \\
 &= \int_{\mathbb{R}} \mathbb{1}_A(x) f_X(x) dx = \mathbb{P}(X \in A).
 \end{aligned}$$

□

Tout l'intérêt de la symétrie apparaît dans le lemme suivant : elle annule l'espérance de toute fonction impaire de X .

Lemme 2.3. *Soit X une variable aléatoire symétrique et $\phi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction impaire — soit $\phi(-x) = -\phi(x)$ pour tout x — telle que $\phi(X)$ soit intégrable. Alors*

$$\mathbb{E}[\phi(X)] = 0.$$

Démonstration. Il suffit d'enchaîner symétrie, imparité et linéarité :

$$\begin{aligned}
 \mathbb{E}[\phi(X)] &= \mathbb{E}[\phi(-X)] & (X \stackrel{\text{loi}}{=} -X) \\
 &= \mathbb{E}[-\phi(X)] & (\phi \text{ impaire}) \\
 &= -\mathbb{E}[\phi(X)] & (\text{linéarité}).
 \end{aligned}$$

Une quantité égale à son opposé étant nulle, on conclut $\mathbb{E}[\phi(X)] = 0$. $\square$

L'hypothèse d'intégrabilité est ici cruciale, et non un simple confort de rédaction : sans elle, $\mathbb{E}[\phi(X)]$ pourrait ne pas être défini, et l'argument « une quantité égale à son opposé est nulle » n'aurait plus de sens (on retomberait sur l'indétermination $\infty - \infty$).

À titre d'illustration, toute variable aléatoire symétrique et intégrable est d'espérance nulle : il suffit d'appliquer le lemme avec $\phi(x) = x$. Introduisons enfin les parties positive et négative d'un réel,

$$x^+ = \max\{x, 0\} = x \mathbb{1}_{x>0}, \quad x^- = \max\{-x, 0\} = -x \mathbb{1}_{x<0},$$

qui vérifient les deux identités $x = x^+ - x^-$ et $|x| = x^+ + x^-$. Elles permettent de ramener l'intégrabilité de X à celle, plus élémentaire, de ses deux parties.

Lemme 2.4. *Soit X une variable aléatoire. Les trois conditions suivantes sont équivalentes : X est intégrable ; $|X|$ est intégrable ; X^+ et X^- sont intégrables. Dans ce cas,*

$$\mathbb{E}[|X|] = \mathbb{E}[X^+] + \mathbb{E}[X^-] \quad \text{et} \quad \mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

CARACTÉRISATION DES LOIS DE FONCTIONS DE VARIABLES ALÉATOIRES

La formule de transfert fournit, elle aussi, un moyen de caractériser la loi d'une fonction $g(X)$ d'une variable aléatoire. Elle vient ainsi s'ajouter à la méthode que nous connaissons déjà, fondée sur la seule fonction de répartition. Disons-le tout de suite : les deux approches sont parfaitement recevables, et le lecteur pourra retenir celle qui lui convient le mieux. La proposition suivante en énonce le principe.

Proposition 2.2. *Soit X une v.a.r. et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. S'il existe une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ telle que, pour toute fonction ϕ bornée,*

$$\mathbb{E}[\phi(g(X))] = \int_{\mathbb{R}} \phi(y) f(y) dy,$$

alors f est une densité de probabilité, et $g(X)$ est une v.a.r. à densité, de densité f .

La fonction auxiliaire ϕ porte le nom de *fonction test*, ou encore *fonction muette* — d'où le nom de méthode de la fonction muette parfois donné à ce procédé. Précisons

que, pour espérer aboutir à une expression de la forme voulue, il faut en règle générale partir d'une v.a.r. X elle-même à densité.

Démonstration. Il suffit d'appliquer l'hypothèse à la fonction (bornée) $\phi = \mathbb{K}_{]-\infty, x]}$:

$$\begin{aligned} \mathbb{P}(g(X) \leq x) &= \mathbb{E}[\mathbb{K}_{]-\infty, x]}(g(X)) \\ &= \int_{-\infty}^{+\infty} \mathbb{K}_{]-\infty, x]}(y) f(y) dy \\ &= \int_{-\infty}^x f(y) dy. \end{aligned}$$

La fonction de répartition de $g(X)$ est ainsi la primitive de f , et comme elle caractérise la loi, $g(X)$ admet bien f pour densité. $\square$

Cette preuve est instructive : elle montre qu'il suffit en réalité que l'égalité soit vérifiée pour la seule famille de fonctions $(\mathbb{K}_{]-\infty, x]})_{x \in \mathbb{R}}$, ce qui n'est autre que la caractérisation des lois par les fonctions de répartition. Autrement dit, sur le plan conceptuel, les deux méthodes ne diffèrent pas — et l'on pourrait même soutenir que le recours à une fonction test obscurcit quelque peu le propos par rapport à l'usage direct de F_X . Les exemples qui suivent aideront chacun à se forger sa préférence.

Exemple 2.5. Traitons plusieurs fonctions g par la méthode de la fonction muette, ϕ désignant à chaque fois une fonction bornée.

- $g(x) = x^2$, avec X à densité f_X . Le changement de variable $y = x^2$, effectué séparément sur chaque demi-droite, donne

$$\begin{aligned} \mathbb{E}[\phi(X^2)] &= \int_{\mathbb{R}} \phi(x^2) f_X(x) dx \\ &= \int_{-\infty}^0 \phi(x^2) f_X(x) dx + \int_0^{\infty} \phi(x^2) f_X(x) dx \\ &= \int_0^{\infty} \phi(y) f_X(-\sqrt{y}) \frac{1}{2\sqrt{y}} dy + \int_0^{\infty} \phi(y) f_X(\sqrt{y}) \frac{1}{2\sqrt{y}} dy \\ &= \int_{\mathbb{R}} \phi(y) (f_X(-\sqrt{y}) + f_X(\sqrt{y})) \frac{1}{2\sqrt{y}} \mathbb{K}_{\mathbb{R}_+}(y) dy. \end{aligned}$$

On retrouve bien la densité de X^2 déjà obtenue au chapitre précédent par la fonction de répartition.

- $g(x) = |x|$, avec X à densité f_X . Cette fois le changement de variable est $y = -x$ sur la demi-droite négative :

$$\begin{aligned}
 \mathbb{E}[\phi(|X|)] &= \int_{\mathbb{R}} \phi(|x|) f_X(x) dx \\
 &= \int_{-\infty}^0 \phi(-x) f_X(x) dx + \int_0^{\infty} \phi(x) f_X(x) dx \\
 &= \int_0^{\infty} \phi(y) f_X(-y) dy + \int_0^{\infty} \phi(x) f_X(x) dx \\
 &= \int_{\mathbb{R}} \phi(y) (f_X(-y) + f_X(y)) \mathbb{K}_{\mathbb{R}_+}(y) dy.
 \end{aligned}$$

- $g(x) = x - \lfloor x \rfloor$ (partie fractionnaire), avec $X \sim \mathcal{E}(\lambda)$. On découpe l'intégrale entier par entier, puis on translate chaque morceau sur $[0, 1[$:

$$\begin{aligned}
 \mathbb{E}[\phi(X - \lfloor X \rfloor)] &= \int_{\mathbb{R}} \phi(x - \lfloor x \rfloor) \lambda e^{-\lambda x} \mathbb{K}_{\mathbb{R}_+}(x) dx \\
 &= \sum_{n=0}^{\infty} \int_n^{n+1} \phi(x - \lfloor x \rfloor) \lambda e^{-\lambda x} dx \\
 &= \sum_{n=0}^{\infty} \int_0^1 \phi(x) \lambda e^{-\lambda(n+x)} dx \\
 &= \left(\sum_{n=0}^{\infty} e^{-\lambda n} \right) \left(\int_0^1 \phi(x) \lambda e^{-\lambda x} dx \right) \\
 &= \int_{\mathbb{R}} \phi(x) \left(\frac{\lambda e^{-\lambda x}}{1 - e^{-\lambda}} \mathbb{K}_{[0,1[}(x) \right) dx.
 \end{aligned}$$

On reconnaît, une nouvelle fois, la densité déjà calculée pour la partie fractionnaire d'une exponentielle.

- $g(x) = 1/x$, avec $X \sim \mathcal{C}(a)$. Le changement de variable $y = 1/x$ sur chaque demi-droite conduit à

$$\begin{aligned}
 \mathbb{E}[\phi(1/X)] &= \int_{\mathbb{R}} \phi\left(\frac{1}{x}\right) \frac{a}{\pi} \frac{1}{a^2 + x^2} dx \\
 &= \int_{-\infty}^0 \phi\left(\frac{1}{x}\right) \frac{a}{\pi} \frac{1}{a^2 + x^2} dx + \int_0^{+\infty} \phi\left(\frac{1}{x}\right) \frac{a}{\pi} \frac{1}{a^2 + x^2} dx \\
 &= \int_{-\infty}^0 \phi(y) \frac{a}{\pi} \frac{1}{a^2 + (1/y)^2} \frac{dy}{y^2} + \int_0^{+\infty} \phi(y) \frac{a}{\pi} \frac{1}{a^2 + (1/y)^2} \frac{dy}{y^2} \\
 &= \int_{\mathbb{R}} \phi(y) \frac{1/a}{\pi} \frac{1}{(1/a)^2 + y^2} dy,
 \end{aligned}$$

de sorte que $g(X) \sim \mathcal{C}(1/a)$: l'inverse d'une variable de Cauchy de paramètre a est encore une variable de Cauchy, de paramètre $1/a$.

La proposition précédente possède naturellement un pendant discret, dont la démonstration est en tous points analogue et que nous ne reproduisons pas.

Proposition 2.3. *Soit X une v.a.r. et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. S'il existe un ensemble S au plus dénombrable et une fonction $p : S \rightarrow]0, +\infty[$ telle que, pour toute fonction ϕ bornée,*

$$\mathbb{E}[\phi(g(X))] = \sum_{y \in S} \phi(y) p(y),$$

alors $g(X)$ est une variable aléatoire discrète, de fonction de masse p .

Exemple 2.6. Soit $g : \mathbb{R} \rightarrow \mathbb{R}$, $g(x) = \lfloor x \rfloor$, et $X \sim \mathcal{E}(\lambda)$ une v.a.r. à densité, de densité f_X .

$$\begin{aligned}
 \mathbb{E}[\phi(\lfloor X \rfloor)] &= \int_{\mathbb{R}} \phi(\lfloor x \rfloor) \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}^+}(x) dx \\
 &= \sum_{n=0}^{\infty} \int_n^{n+1} \phi(\lfloor x \rfloor) \lambda e^{-\lambda x} dx \\
 &= \sum_{n=0}^{\infty} \phi(n) \int_n^{n+1} \lambda e^{-\lambda x} dx \\
 &= \sum_{n=0}^{\infty} \phi(n) (e^{-\lambda n} - e^{-\lambda(n+1)}) \\
 &= \sum_{n=0}^{\infty} \phi(n) e^{-\lambda n} (1 - e^{-\lambda})
 \end{aligned}$$

Donc $\lfloor X \rfloor$ est une v.a.r. discrète de fonction de masse $n \in \mathbb{N} \mapsto \mathbb{P}(\lfloor X \rfloor = n) = e^{-\lambda n} (1 - e^{-\lambda})$.

2.3 MOMENTS ET QUANTITÉS ASSOCIÉES

L'espérance étant en place, on peut l'appliquer non plus à X mais à ses puissances successives. On accède ainsi à toute une famille de quantités, les *moments*, qui résument chacune un aspect différent de la loi.

Définition 2.4. Soit X une variable aléatoire telle que X^k soit intégrable, avec $k \in \mathbb{N}^*$. On dit alors que X admet un moment d'ordre k , et l'on appelle $\mathbb{E}[X^k]$ le k -ième moment de X (ou de sa loi).

On dit aussi, de façon équivalente, que X est *de puissance k intégrable* lorsque X^k l'est. Les moments décrivent différents traits de la loi de X ; mais leur intérêt majeur, sur lequel nous reviendrons plus loin dans ce chapitre, est de fournir des bornes sur des probabilités d'événements que l'on ne sait pas calculer directement. Nous concentrerons ici notre attention sur les deux premiers moments, $k = 1$ et $k = 2$, de loin les plus importants en pratique.

Auparavant, quelques généralités. Notons d'abord une dissymétrie entre moments pairs et impairs : pour k pair, la fonction $x \mapsto x^k$ est positive, si bien que le moment $\mathbb{E}[X^k]$ est *toujours* défini, quitte à valoir $+\infty$. Notons ensuite que l'existence d'un moment élevé est une condition d'autant plus exigeante qu'elle contraint davantage les queues de la loi ; il est donc naturel qu'elle entraîne l'existence de tous les moments d'ordre inférieur, comme le précise le lemme suivant.

Lemme 2.5. Soient $k < m$ deux entiers. Si X admet un moment d'ordre m , alors X admet un moment d'ordre k , et

$$\mathbb{E}[|X|^k] \leq \mathbb{E}[|X|^m] + 1.$$

Démonstration. Il suffit de partir de l'inégalité $|x|^k \leq 1 + |x|^m$, valable pour tout $x \in \mathbb{R}$, puis d'appliquer le lemme de comparaison. $\square$

Enfin, lorsque la loi présente une symétrie, ses moments impairs sont d'un calcul immédiat : ils sont nuls.

Lemme 2.6. Si la loi de X est symétrique et si X admet un moment d'ordre $k \in \mathbb{N}$ impair, alors $\mathbb{E}[X^k] = 0$.

Démonstration. On applique le lemme d'annulation des fonctions impaires à $\phi(x) = x^k$, impaire puisque k l'est. $\square$

ESPÉRANCE

Le premier moment $\mathbb{E}[X]$ est défini pour toute v.a.r. intégrable, ainsi que pour toute v.a.r. positive ou nulle. C'est lui que l'on nomme l'espérance, ou la moyenne, de X . On le notera souvent $\mu = \mathbb{E}[X]$. Lorsque $\mu = 0$, on dit que X est centrée.

Il est du reste toujours possible de se ramener à ce cas : il suffit de retrancher à X son espérance. La variable $X - \mu$, appelée variable centrée associée à X , est bien d'espérance nulle, comme le confirme la linéarité de l'espérance :

$$\mathbb{E}[X - \mu] = \mathbb{E}[X] - \mu = \mu - \mu = 0.$$

VARIANCE

Le deuxième moment est $\mathbb{E}[X^2]$. Comme $X^2 \geq 0$, il est défini pour toute variable aléatoire — quitte, encore une fois, à valoir $+\infty$. C'est à partir de lui que l'on construit la variance.

Définition 2.5. Soit X une variable aléatoire. On dit que X est de carré intégrable si $\mathbb{E}[X^2] < +\infty$. Dans ce cas, la variance de X est

$$\mathbb{V}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Cette définition est légitime : si X est de carré intégrable, elle admet d'après le lemme de domination un moment d'ordre 1, de sorte que $\mathbb{E}[X]$ existe bel et bien. La variance admet une seconde expression, moins compacte mais plus parlante, qui la fait apparaître comme l'écart quadratique moyen à la moyenne.

Lemme 2.7. *Soit X une variable aléatoire de carré intégrable. Alors*

$$\mathbb{V}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Sous l'une ou l'autre forme, on lit aussitôt que $\mathbb{V}(X) \geq 0$: par l'inégalité de Jensen à partir de la définition ($\mathbb{E}[X^2] \geq \mathbb{E}[X]^2$), ou plus simplement par la positivité de la fonction carré à partir du lemme. La variance est un *coefficient de dispersion* : elle mesure à quel point les valeurs de X s'étalent autour de son espérance. Une variance grande signale des valeurs très dispersées ; une variance petite, des valeurs concentrées au voisinage de la moyenne.

Démonstration. On développe le carré,

$$(X - \mathbb{E}[X])^2 = X^2 - 2X \mathbb{E}[X] + \mathbb{E}[X]^2,$$

puis on applique la linéarité de l'espérance (en traitant $\mathbb{E}[X]$ comme la constante qu'il est) :

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X])^2] &= \mathbb{E}[X^2 - 2X \mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2 \mathbb{E}[X] \mathbb{E}[X] + \mathbb{E}[X]^2 \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2. \end{aligned}$$

□

Un mot sur les *dimensions*, qui éclaire le passage à l'écart-type. Si X mesure une grandeur physique — mettons une longueur, en mètres —, alors la variance, définie à partir de X^2 , s'exprime dans le carré de cette dimension (des mètres carrés). Pour retrouver une quantité homogène à X , on en prend la racine carrée : c'est l'*écart-type*, généralement noté $\sigma \geq 0$ et défini par

$$\sigma = \sqrt{\mathbb{V}(X)}.$$

C'est ce qui justifie la notation courante σ^2 pour la variance. L'écart-type donne l'ordre de grandeur de la distance séparant les valeurs typiques de X de son espérance μ .

Définition 2.6. Soit X une v.a. de carré intégrable, d'espérance μ et d'écart-type $\sigma > 0$. On appelle

$$\frac{X - \mu}{\sigma}$$

la variable centrée réduite (ou simplement variable réduite) associée à X .

Cette variable est, comme son nom l'indique, d'espérance nulle et de variance 1 (donc d'écart-type 1). Pour l'espérance,

$$\begin{aligned}\mathbb{E}\left[\frac{X - \mu}{\sigma}\right] &= \frac{1}{\sigma} \mathbb{E}[X - \mu] \\ &= \frac{1}{\sigma} \times 0 = 0,\end{aligned}$$

et pour la variance,

$$\begin{aligned}\mathbb{V}\left(\frac{X - \mu}{\sigma}\right) &= \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^2\right] \\ &= \frac{1}{\sigma^2} \mathbb{E}[(X - \mu)^2] \\ &= \frac{1}{\sigma^2} \mathbb{V}(X) = 1.\end{aligned}$$

Pour boucler l'argument dimensionnel entamé plus haut : la variable centrée réduite est une grandeur *sans dimension*, puisque quotient de deux quantités de même dimension. Passer à la variable centrée réduite est ainsi la façon « naturelle » de normaliser une variable aléatoire pour lui donner espérance nulle et variance 1 — une opération dont on mesurera toute l'importance au moment d'énoncer le théorème central limite.

Propriétés de la variance. Rassemblons quelques propriétés fondamentales de la variance.

Proposition 2.4. *Soit X une variable aléatoire de carré intégrable.*

1. *Pour tous $a, b \in \mathbb{R}$,*

$$\mathbb{V}(aX + b) = a^2 \mathbb{V}(X)$$

(avec la convention $0 \times \infty = 0$). En particulier, $\mathbb{V}(X + b) = \mathbb{V}(X)$.

2. *$\mathbb{V}(X) = 0$ si et seulement si X est presque sûrement constante, c'est-à-dire $X \sim \delta_\mu$.*

Le premier point mérite un mot d'interprétation : une translation (b) ne change rien à la dispersion — déplacer toutes les valeurs en bloc ne les rapproche ni ne les éloigne les unes des autres —, tandis qu'une dilatation (a) agit sur la variance par le carré du facteur d'échelle, conformément à ce que l'analyse dimensionnelle laissait présager. Le second point, lui, confirme l'intuition selon laquelle une dispersion nulle ne peut correspondre qu'à une variable sans aléa.

Démonstration. 1. La linéarité de l'espérance donne $\mathbb{E}[aX + b] = a\mu + b$, d'où, en repartant de la forme de la variance comme écart quadratique moyen,

$$\begin{aligned} \mathbb{V}(aX + b) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(aX + b - a\mu - b)^2] \\ &= \mathbb{E}[a^2(X - \mu)^2] \\ &= a^2 \mathbb{V}(X). \end{aligned}$$

2. Posons $Y = (X - \mu)^2$. C'est une variable positive, nulle exactement lorsque $X = \mu$. Le lemme ?? ci-dessous, appliqué à Y , fournit alors la chaîne d'équivalences

$$X \sim \delta_\mu \iff \mathbb{E}[Y] = 0 \iff \mathbb{V}(X) = 0. \quad \square$$

Lemme 2.8. *Soit Y une variable aléatoire positive. Alors $Y \sim \delta_0$ si et seulement si $\mathbb{E}[Y] = 0$.*

L'implication directe est immédiate; celle de la réciproque, moins évidente, reposera sur l'inégalité de Markov et sera établie plus loin.

L'espérance, meilleure approximation constante de X . Il existe une manière particulièrement éclairante d'introduire conjointement l'espérance et la variance : comme la solution et la valeur d'un même problème d'optimisation. Parmi toutes les constantes, laquelle « ressemble » le plus à X ? Tout dépend de la façon dont on mesure la ressemblance ; si l'on choisit l'écart quadratique moyen, la réponse est l'espérance.

Lemme 2.9. *Soit X une variable aléatoire de carré intégrable. Alors*

$$\mathbb{V}(X) = \min_{a \in \mathbb{R}} \mathbb{E}[(X - a)^2],$$

et le minimum est atteint en l'unique point $a = \mathbb{E}[X]$.

Autrement dit, la constante qui approche le mieux X au sens de la distance $(X, Y) \mapsto \mathbb{E}[(X - Y)^2]$ — celle des « moindres carrés », ou encore du « risque quadratique », terme plus volontiers employé en économie — est précisément $\mathbb{E}[X]$, et l'erreur minimale ainsi commise n'est autre que la variance de X .

Démonstration. Il suffit de développer, puis de reconnaître un carré parfait :

$$\begin{aligned} \mathbb{E}[(X - a)^2] &= \mathbb{E}[a^2 - 2aX + X^2] \\ &= a^2 - 2a \mathbb{E}[X] + \mathbb{E}[X^2] \\ &= (a - \mathbb{E}[X])^2 + (\mathbb{E}[X^2] - \mathbb{E}[X]^2) \\ &= (a - \mathbb{E}[X])^2 + \mathbb{V}(X) \\ &\geq \mathbb{V}(X), \end{aligned}$$

avec égalité si et seulement si $a = \mathbb{E}[X]$. □

Ce point de vue variationnel a une retombée immédiate et souvent utile : il borne la variance de toute variable confinée dans un intervalle.

Corollaire 2.2. *Soit X une variable aléatoire à valeurs dans $[0, 1]$. Alors X est de carré intégrable et*

$$\mathbb{V}(X) \leq \frac{1}{4}.$$

Démonstration. D'après le lemme précédent, la variance minore $\mathbb{E}[(X - y)^2]$ pour tout $y \in \mathbb{R}$: on est donc libre de choisir le y le plus avantageux. Prenons $y = 1/2$, le milieu de l'intervalle. Comme $X \in [0, 1]$, on a $|X - 1/2| \leq 1/2$, et par suite

$$\mathbb{V}(X) \leq \mathbb{E}[(X - 1/2)^2] \leq \mathbb{E}[1/4] = \frac{1}{4}.$$

□

On peut légitimement se poser la même question en remplaçant le risque quadratique par la norme L^1 : quelle constante a minimise cette fois $a \mapsto \mathbb{E}[|X - a|]$ (l'infimum étant d'ailleurs atteint)? La réponse est plus délicate, et met en jeu une notion différente : celle de *médiane*. Nous y reviendrons.

2.4 FONCTION GÉNÉRATRICE DES MOMENTS

Nous avons annoncé, en ouverture de ce chapitre, un outil décrivant la loi de X au même titre que la fonction de répartition, mais souvent d'un maniement plus explicite. Le voici. Pour tout réel t , on définit la *fonction génératrice des moments* de X par

$$\phi_X(t) = \mathbb{E}[e^{tX}] \in]0, +\infty].$$

Son nom n'est pas usurpé : elle « engendre » les moments de X , que l'on récupère par simple développement en série entière, comme le précise la proposition suivante.

Proposition 2.5. *Supposons qu'il existe $t_0 > 0$ tel que $\phi_X(t) < \infty$ pour tout $|t| < t_0$. Alors, pour tout $|t| < t_0$,*

$$\phi_X(t) = \sum_{k=0}^{\infty} \mathbb{E}[X^k] \frac{t^k}{k!},$$

et le rayon de convergence de la série entière du membre de droite est au moins égal à t_0 . Dans ce cas, ϕ_X est indéfiniment dérivable sur $] - t_0, t_0[$, et pour tout $k \in \mathbb{N}^$,*

$$\mathbb{E}[X^k] = \phi_X^{(k)}(0).$$

Ainsi, connaître ϕ_X au voisinage de 0, c'est connaître d'un coup tous les moments de X : il suffit de les lire sur les coefficients de son développement, ou, ce qui revient au même, de dériver ϕ_X en 0 autant de fois qu'il le faut.

Démonstration. Nous traitons le cas discret, celui à densité étant en tout point semblable. Montrons d'abord que $\mathbb{E}[e^{|tX|}] < \infty$ dès que $|t| < t_0$. L'encadrement $e^{|tx|} \leq e^{tx} + e^{-tx}$, valable pour tout x , donne en effet

$$\mathbb{E}[e^{|tX|}] \leq \mathbb{E}[e^{tX}] + \mathbb{E}[e^{-tX}] < \infty$$

d'après l'hypothèse (appliquée à t et à $-t$, tous deux de module $< t_0$). Cela assure au passage l'intégrabilité de e^{tX} , et l'on peut alors écrire, pour de tels t ,

$$\begin{aligned} \phi_X(t) &= \mathbb{E}[e^{tX}] \\ &= \sum_x e^{tx} \mathbb{P}(X = x) \\ &= \sum_x \left(\sum_{k=0}^{\infty} \frac{(tx)^k}{k!} \mathbb{P}(X = x) \right). \end{aligned}$$

C'est ici qu'intervient la majoration précédente : puisque

$$\sum_x \left(\sum_{k=0}^{\infty} \frac{|tx|^k}{k!} \mathbb{P}(X = x) \right) = \mathbb{E}[e^{|tX|}] < \infty,$$

le théorème de Fubini autorise l'intervention des deux sommations :

$$\phi_X(t) = \sum_{k=0}^{\infty} \left(\sum_x \frac{(tx)^k}{k!} \mathbb{P}(X = x) \right).$$

En particulier, cette série en k converge, de somme $\phi_X(t)$. Il ne reste qu'à réorganiser chaque terme :

$$\begin{aligned} \phi_X(t) &= \sum_{k=0}^{\infty} \left(\sum_x x^k \mathbb{P}(X = x) \right) \frac{t^k}{k!} \\ &= \sum_{k=0}^{\infty} \mathbb{E}[X^k] \frac{t^k}{k!}. \end{aligned}$$

Cette série entière convergeant pour tout $|t| < t_0$, son rayon de convergence est au moins t_0 ; les formules sur les dérivées successives en 0 en découlent aussitôt, par identification des coefficients d'un développement en série entière. $\square$

La fonction génératrice ne se contente pas de restituer les moments : elle détermine la loi tout entière. C'est l'objet du théorème suivant, que nous admettons.

Théorème 2.1. *Supposons ϕ_X finie sur un voisinage de 0. Alors la loi de X est l'unique loi ayant ϕ_X pour fonction génératrice des moments.*

Passons à quelques exemples, en commençant par une propriété de transformation dont nous nous servirons à plusieurs reprises.

Exemple 2.7. Soient $a, b \in \mathbb{R}$. La fonction génératrice d'une transformation affine s'exprime très simplement à partir de celle de X :

$$\begin{aligned}\phi_{aX+b}(t) &= \mathbb{E}[e^{t(aX+b)}] \\ &= \mathbb{E}[e^{(at)X}] e^{tb} \\ &= \phi_X(at) e^{tb}.\end{aligned}$$

Exemple 2.8. $X \sim \mathcal{P}(\lambda)$, $\lambda \geq 0$. Pour tout $t \in \mathbb{R}$,

$$\begin{aligned}\phi_X(t) &= \sum_{n=0}^{\infty} e^{tn} e^{-\lambda} \frac{\lambda^n}{n!} \\ &= e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda e^t)^n}{n!} \\ &= e^{\lambda(e^t-1)},\end{aligned}$$

où l'on a reconnu, à l'avant-dernière ligne, le développement de l'exponentielle.

Exemple 2.9. $X \sim \mathcal{N}(0, 1)$. Pour tout $t \in \mathbb{R}$, la mise sous forme canonique de l'exposant fait apparaître une gaussienne recentrée :

$$\begin{aligned}
 \phi_X(t) &= \int_{-\infty}^{+\infty} \frac{e^{-x^2/2+tx}}{\sqrt{2\pi}} dx \\
 &= \int_{-\infty}^{+\infty} \frac{e^{-(x-t)^2/2+t^2/2}}{\sqrt{2\pi}} dx \\
 &= e^{t^2/2} \int_{-\infty}^{+\infty} \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy \quad (y = x - t) \\
 &= e^{t^2/2},
 \end{aligned}$$

la dernière intégrale valant 1 puisqu'il s'agit de l'intégrale d'une densité gaussienne. Si maintenant $Y \sim \mathcal{N}(\mu, \sigma^2)$, alors $Y \stackrel{\text{loi}}{=} \mu + \sigma X$, et l'exemple de la transformation affine donne

$$\phi_Y(t) = e^{t\mu} \phi_X(\sigma t) = e^{t\mu + \sigma^2 t^2/2}.$$

Revenons enfin à $X \sim \mathcal{N}(0, 1)$: l'unicité du développement en série entière (DSE) permet d'en lire tous les moments. En effet,

$$\phi_X(t) = \sum_{k=0}^{\infty} \frac{(t^2/2)^k}{k!} = \sum_{k=0}^{\infty} \frac{(2k)!}{2^k k!} \frac{t^{2k}}{(2k)!}.$$

Ce développement ne comportant que des puissances paires de t , on en déduit $\mathbb{E}[X^{2k+1}] = 0$ pour tout k (ce que la symétrie de la loi laissait d'ailleurs prévoir), tandis que

$$\mathbb{E}[X^{2k}] = \frac{(2k)!}{2^k k!} = \prod_{i=1}^k (2i - 1),$$

quantité que l'on note aussi $(2k - 1)!!$. En particulier, $\mathbb{E}[X^4] = 3$.

Exemple 2.10. $X \sim \mathcal{E}(1)$. On calcule

$$\begin{aligned}\phi_X(t) &= \int_0^\infty e^{tx} e^{-x} dx \\ &= \int_0^\infty e^{-(1-t)x} dx \\ &= \begin{cases} \frac{1}{1-t}, & t < 1, \\ +\infty, & t \geq 1. \end{cases}\end{aligned}$$

Sur $] -1, 1[$, on reconnaît la somme d’une série géométrique, qu’il suffit de réécrire pour faire apparaître les moments :

$$\phi_X(t) = \sum_{k=0}^{\infty} t^k = \sum_{k=0}^{\infty} k! \frac{t^k}{k!},$$

d’où, par unicité du DSE, $\mathbb{E}[X^k] = k!$ pour tout $k \in \mathbb{N}$.

2.5 INÉGALITÉS

Nous présentons dans cette section trois inégalités mettant en jeu l’espérance d’une variable aléatoire. Leur intérêt commun est de *borner* des quantités que l’on ne sait pas calculer exactement — le plus souvent, des probabilités d’événements — au moyen de quantités plus accessibles, comme l’espérance ou la variance.

INÉGALITÉ DE MARKOV

L’inégalité de Markov est l’inégalité fondamentale qui permet de contrôler une probabilité par une espérance. Aussi puissante soit-elle, elle repose sur une observation d’une déconcertante simplicité, portant sur des fonctions élémentaires.

Lemme 2.10. *Soient $y \geq 0$ et $x > 0$. Alors*

$$\mathbb{P}_{\{y \geq x\}} \leq \frac{y}{x}.$$

Démonstration. On distingue deux cas. Si $y \geq x$, alors $\mathbb{P}_{\{y \geq x\}} = 1 \leq y/x$. Si $y < x$, alors $\mathbb{P}_{\{y \geq x\}} = 0 \leq y/x$, cette dernière quantité étant positive puisque x et y le sont. $\square$

Le second ingrédient est le lien, déjà rencontré, entre probabilité et espérance d’une indicatrice.

Lemme 2.11. *Soient X une v.a. et $B \subset \mathbb{R}$. Alors*

$$\mathbb{P}(X \in B) = \mathbb{E}[\mathbb{1}_{\{X \in B\}}].$$

Démonstration. La variable $\mathbb{1}_{\{X \in B\}}$ est à valeurs dans $\{0, 1\}$ et vaut 1 avec probabilité $\mathbb{P}(X \in B)$: elle suit donc la loi de Bernoulli de paramètre $\mathbb{P}(X \in B)$, dont l’espérance vaut précisément $\mathbb{P}(X \in B)$. $\square$

Il suffit à présent de combiner ces deux lemmes pour obtenir l’inégalité annoncée.

Théorème 2.2 (Inégalité de Markov). *Soit X une v.a. positive. Alors, pour tout $x > 0$,*

$$\mathbb{P}(X \geq x) \leq \frac{\mathbb{E}[X]}{x}.$$

Intuitivement, une variable positive ne peut pas prendre des valeurs beaucoup plus grandes que sa moyenne « trop souvent » : la fréquence de tels dépassements décroît au moins comme $1/x$.

Démonstration. Soit $x > 0$. La variable X étant positive, le premier lemme (appliqué à $y = X$) donne $\mathbb{1}_{\{X \geq x\}} \leq X/x$. En passant à l’espérance, à l’aide du second lemme puis de la linéarité et de la croissance de l’espérance,

$$\mathbb{P}(X \geq x) = \mathbb{E}[\mathbb{1}_{\{X \geq x\}}] \leq \mathbb{E}\left[\frac{X}{x}\right] = \frac{\mathbb{E}[X]}{x}.$$

$\square$

Nous pouvons maintenant nous acquitter d’une dette contractée au paragraphe sur la variance : la réciproque du lemme ??, laissée alors en suspens, découle immédiatement de l’inégalité de Markov.

Démonstration du lemme ??. Si $Y \sim \delta_0$, alors $\mathbb{E}[Y] = 0 \times 1 = 0$. Réciproquement, supposons $Y \not\sim \delta_0$. Il existe alors $x > 0$ tel que $\mathbb{P}(Y \geq x) > 0$, et l’inégalité de Markov, lue à l’envers, donne

$$\mathbb{E}[Y] \geq x \mathbb{P}(Y \geq x) > 0.$$

Ainsi $\mathbb{E}[Y] = 0$ force $Y \sim \delta_0$, ce qui achève la preuve. $\square$

INÉGALITÉ DE BIENAYMÉ-TCHEBYCHEV

Appliquée non pas à X elle-même mais à son écart à la moyenne, l'inégalité de Markov fournit un contrôle de la *concentration* de X autour de son espérance. C'est l'inégalité de Bienaymé-Tchebychev.

Théorème 2.3 (Inégalité de Bienaymé-Tchebychev). *Soit X une v.a. d'espérance finie. Alors, pour tout $x > 0$,*

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) \leq \frac{\mathcal{V}(X)}{x^2}.$$

Démonstration. L'idée est de se ramener à une variable positive en passant au carré :

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) = \mathbb{P}((X - \mathbb{E}[X])^2 > x^2).$$

La variable $(X - \mathbb{E}[X])^2$ étant positive, l'inégalité de Markov (appliquée avec le seuil x^2) donne

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) \leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{x^2} = \frac{\mathcal{V}(X)}{x^2}.$$

$\square$

INÉGALITÉ DE JENSEN

La troisième inégalité relie l'espérance à la convexité. Rappelons qu'une fonction $\phi : I \rightarrow \mathbb{R}$, définie sur un intervalle $I \subset \mathbb{R}$, est dite *convexe* si, pour tous $x, y \in I$ et tout $t \in [0, 1]$,

$$\phi(tx + (1 - t)y) \leq t\phi(x) + (1 - t)\phi(y).$$

Remarque 2.2. Cette définition est déjà une inégalité de Jensen déguisée. Si X est la variable à deux valeurs telle que $\mathbb{P}(X = x) = t$ et $\mathbb{P}(X = y) = 1 - t$, alors $\mathbb{E}[X] = tx + (1 - t)y$ et $\mathbb{E}[\phi(X)] = t\phi(x) + (1 - t)\phi(y)$, de sorte que l'inégalité de convexité s'écrit exactement

$$\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)].$$

L'inégalité de Jensen n'est autre que la généralisation de cette observation à une variable aléatoire réelle intégrable quelconque. Avant de l'énoncer, rassemblons quelques rappels utiles sur la convexité.

Lorsque $\phi \in C^2(I)$, la convexité équivaut à $\phi'' \geq 0$. Sont ainsi convexes les fonctions

$$x \mapsto e^x, \quad x \mapsto e^{-x}, \quad x \mapsto |x|^k \quad (k \geq 1).$$

Une fonction ϕ telle que $-\phi$ soit convexe est dite *concave*; le sont par exemple

$$x > 0 \mapsto \log x, \quad x \geq 0 \mapsto x^k \quad (0 \leq k \leq 1).$$

Le fait géométrique clé, que nous admettons, est qu'une fonction convexe se situe au-dessus de chacune de ses tangentes — plus précisément, elle admet en tout point un minorant affine : pour tout $x_0 \in I$, il existe $a \in \mathbb{R}$ tel que

$$\phi(x_0) + a(x - x_0) \leq \phi(x) \quad \text{pour tout } x \in I.$$

Lorsque ϕ est dérivable en x_0 , on peut prendre $a = \phi'(x_0)$. Sinon, la convexité garantit l'existence de dérivées à gauche et à droite, avec $\phi'(x_0^-) \leq \phi'(x_0^+)$, et n'importe quel $a \in [\phi'(x_0^-), \phi'(x_0^+)]$ convient.

Théorème 2.4 (Inégalité de Jensen). *Soit X une v.a. d'espérance finie, à valeurs dans un intervalle $I \subset \mathbb{R}$, et $\phi : I \rightarrow \mathbb{R}$ convexe. Alors*

$$\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)],$$

le membre de droite pouvant être infini.

Démonstration. Posons $x_0 = \mathbb{E}[X]$, qui appartient bien à I . Le minorant affine de ϕ en x_0 fournit un réel a tel que $\phi(x_0) + a(x - x_0) \leq \phi(x)$ pour tout $x \in I$. En appliquant cette inégalité à X puis en prenant l'espérance,

$$\begin{aligned}
 \mathbb{E}[\phi(X)] &\geq \mathbb{E}[\phi(x_0) + a(X - x_0)] \\
 &= \phi(x_0) + a \mathbb{E}[X - x_0] \\
 &= \phi(x_0) + a (\mathbb{E}[X] - x_0) \\
 &= \phi(x_0),
 \end{aligned}$$

la dernière ligne venant de $x_0 = \mathbb{E}[X]$. Tout tient donc dans l'idée de minorer ϕ par sa tangente en la moyenne. $\square$

Exemple 2.11. Soit $t \in \mathbb{R}$. La fonction $x \mapsto e^{tx}$ étant convexe sur $\mathbb{R}$, on obtient pour toute v.a.r. intégrable X

$$e^{t\mathbb{E}[X]} \leq \mathbb{E}[e^{tX}],$$

le membre de droite pouvant valoir $+\infty$. On reconnaît une minoration de la fonction génératrice des moments.

Exemple 2.12. Jensen permet de préciser la hiérarchie des moments entrevue plus haut. Soient $k < m$ deux entiers. Si X admet un moment d'ordre k , la convexité de $x \mapsto x^{m/k}$ sur $]0, +\infty[$ (car $m/k > 1$) donne, appliquée à la variable positive $|X|^k$,

$$\mathbb{E}[|X|^k]^{m/k} \leq \mathbb{E}[(|X|^k)^{m/k}] = \mathbb{E}[|X|^m],$$

ce dernier moment pouvant être infini. On retrouve, sous forme quantitative, que l'existence d'un moment d'ordre m contrôle celle des moments d'ordre inférieur.

2.6 AUTRES DÉFINITIONS DE L'ESPÉRANCE

Notre définition de l'espérance souffre pour l'instant d'un défaut d'unité : elle se scinde selon que X est discrète ou à densité. On peut légitimement chercher une formulation unique, qui engloberait les deux cas. Une telle définition devrait remplir deux exigences :

- ne faire appel qu'à la fonction de répartition — c'est le seul objet dont nous disposons pour décrire une loi *générique* ;
- redonner les définitions déjà connues dans les cas discret et à densité.

Nous présentons deux voies répondant à ce cahier des charges, l'une « à la Lebesgue », l'autre « à la Riemann-Stieltjes », qui partagent une même idée sous-jacente : l'intégration par parties. Cette fin de chapitre s'adresse aux étudiants désireux d'aller plus loin, et peut être omise en première lecture.

À LA LEBESGUE

Lemme 2.12. Soit X une variable aléatoire positive ou nulle, de fonction de répartition F_X . On a l'égalité suivante, dans $[0, +\infty]$:

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt = \int_0^\infty (1 - F_X(t)) dt.$$

L'égalité s'entend au sens fort : les deux membres sont soit simultanément finis et égaux, soit simultanément infinis. En particulier, X est intégrable si et seulement si la fonction $t \mapsto \mathbb{P}(X > t) = 1 - F_X(t)$ est intégrable au voisinage de $+\infty$.

Une précision sur le statut de ce résultat. Nous ne pouvons le *démontrer* que pour les variables discrètes ou à densité, seules pour lesquelles l'espérance a été définie jusqu'ici. Mais la formule, elle, a un sens dès que la fonction de répartition est disponible — c'est-à-dire pour n'importe quelle variable aléatoire positive : on pourrait donc parfaitement l'adopter comme *définition* de $\mathbb{E}[X]$ dans le cas général. Si nous ne l'avons pas fait, c'est pour une raison pédagogique : cette définition n'a rien de naturel au premier abord, et l'on n'y reconnaît guère la moyenne pondérée qui donne tout son sens à l'espérance.

Démonstration. Traitons le cas à densité, de densité f_X ; le cas discret est analogue et laissé au lecteur. Le point de départ est l'écriture $X = \int_0^\infty \mathbb{1}_{\{X > t\}} dt$ (l'intégrande vaut 1 tant que $t < X$), qui ramène l'espérance à une double intégrale que le théorème de Fubini positif autorise à intervertir :

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E}\left[\int_0^\infty \mathbb{1}_{\{X > t\}} dt\right] \\ &= \int_0^\infty \left(\int_0^\infty \mathbb{1}_{\{x > t\}} dt\right) f_X(x) dx \\ &= \int_0^\infty \left(\int_0^\infty \mathbb{1}_{\{x > t\}} f_X(x) dx\right) dt \quad (\text{Fubini positif}) \\ &= \int_0^\infty \mathbb{E}[\mathbb{1}_{\{X > t\}}] dt \\ &= \int_0^\infty \mathbb{P}(X > t) dt. \end{aligned}$$

□

Pour les variables à valeurs entières, cette formule se discrétise en une somme, d'un usage très courant.

Corollaire 2.3. Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. On a, dans $[0, +\infty]$,

$$\mathbb{E}[X] = \sum_{n \in \mathbb{N}} \mathbb{P}(X > n) = \sum_{n \in \mathbb{N}^*} \mathbb{P}(X \geq n).$$

Démonstration. Deux chemins mènent au résultat. Le premier reprend l'argument du lemme, en partant de l'identité $m = \sum_{n \in \mathbb{N}} \mathbb{1}_{\{m > n\}} = \sum_{n \in \mathbb{N}^*} \mathbb{1}_{\{m \geq n\}}$, valable pour tout entier m . Le second exploite le fait que $t \mapsto \mathbb{P}(X > t)$ est constante sur chaque intervalle $[n, n + 1[$, où elle vaut $\mathbb{P}(X \geq n + 1)$:

$$\int_n^{n+1} \mathbb{P}(X > t) dt = \int_n^{n+1} \mathbb{P}(X \geq n + 1) dt = \mathbb{P}(X \geq n + 1).$$

Il ne reste qu'à sommer ces contributions :

$$\begin{aligned} \int_0^\infty \mathbb{P}(X > t) dt &= \sum_{n \in \mathbb{N}} \int_n^{n+1} \mathbb{P}(X > t) dt \\ &= \sum_{n \in \mathbb{N}} \mathbb{P}(X \geq n + 1) \\ &= \sum_{n \in \mathbb{N}^*} \mathbb{P}(X \geq n) = \sum_{n \in \mathbb{N}} \mathbb{P}(X > n). \end{aligned}$$

□

On peut voir dans ces formules une manifestation de l'idée fondatrice de l'intégrale de Lebesgue : plutôt que de sommer les contributions à l'aire sous la courbe en découpant l'axe des *abscisses* (comme le fait Riemann), on la découpe selon l'axe des *ordonnées* — ici, en intégrant la « hauteur » $\mathbb{P}(X > t)$ le long de t .

Exemple 2.13. Si $X \sim \mathcal{G}(p)$, avec $0 < p \leq 1$, alors pour $n \in \mathbb{N}$ on a $\mathbb{P}(X > n) = (1 - p)^n$ — les n premières épreuves de Bernoulli doivent toutes échouer. Le corollaire donne alors, sans le moindre calcul de moment,

$$\mathbb{E}[X] = \sum_{n \in \mathbb{N}} (1 - p)^n = \frac{1}{p}.$$

À LA RIEMANN-STIELTJES

L'intégrale de Stieltjes — ou de Riemann-Stieltjes — est particulièrement bien accordée au calcul des probabilités : elle permet précisément d'unifier les deux cadres que nous avons jusqu'ici traités séparément, celui des variables discrètes et celui des variables à densité.

Fixons $a < b$ deux réels et deux fonctions $f, g : [a, b] \rightarrow \mathbb{R}$. On appelle *partition* de $[a, b]$ une suite finie $\pi = (x_0, \dots, x_n)$ avec $a = x_0 < x_1 < \dots < x_n = b$; l'entier n en est la *longueur*, et le *pas* est la plus grande des largeurs $\max_{0 \leq i \leq n-1} (x_{i+1} - x_i)$. À une telle partition et à un choix de points intermédiaires $c_i \in [x_i, x_{i+1}]$, on associe la somme

$$I(f, g, \pi) = \sum_{i=0}^{n-1} f(c_i) [g(x_{i+1}) - g(x_i)].$$

Lorsque ces sommes admettent une limite quand le pas tend vers 0, cette limite est appelée l'intégrale de Stieltjes de f par rapport à g , notée $\int_a^b f(x) dg(x)$. Précisément : $A \in \mathbb{R}$ en est l'intégrale de Stieltjes si, pour tout $\varepsilon > 0$, il existe $\delta > 0$ tel que toute partition π de pas $\leq \delta$ vérifie $|I(f, g, \pi) - A| \leq \varepsilon$, et ce quel que soit le choix des points intermédiaires $c_0, \dots, c_{n-1}$.

On retrouve l'intégrale de Riemann usuelle en prenant $g(x) = x$. Et lorsque g est dérivable, l'intégrale de Stieltjes se ramène elle aussi à une intégrale de Riemann, l'accroissement dg devenant $g' dx$:

$$\int_a^b f(x) dg(x) = \int_a^b f(x) g'(x) dx.$$

La question centrale est alors de savoir quels intégrandes f et quels intégrateurs g donnent lieu à une intégrale bien définie. Un résultat important assure l'existence de l'intégrale dès que f est continue et g à *variation bornée* — c'est-à-dire que la quantité $\sum_{i=0}^{n-1} |g(x_{i+1}) - g(x_i)|$ reste uniformément majorée sur l'ensemble des partitions de $[a, b]$. Or c'est exactement le cas qui nous intéresse : si X est une variable aléatoire à valeurs dans $[a, b]$ presque sûrement, on prend pour intégrateur sa fonction de répartition $g = F_X$, qui, étant croissante, est automatiquement à variation bornée. On obtient ainsi, pour toute fonction ϕ continue,

$$\mathbb{E}[\phi(X)] = \int_a^b \phi(x) dF_X(x),$$

formule remarquable en ce qu'elle vaut pour *toute* v.a.r. X — discrète, à densité, ou d'aucun de ces deux types. Précisons toutefois, comme pour l'intégrale de Lebesgue, que donner un sens à une intégrale ne dit rien de la façon de la calculer.

Reste le cas des variables non bornées. On montre alors que, pour ϕ continue et bornée,

$$\int_a^b \phi(x) dF_X(x) \xrightarrow{a \rightarrow -\infty, b \rightarrow +\infty} \int_{-\infty}^{+\infty} \phi(x) dF_X(x) \in \mathbb{R},$$

et c'est cette limite que l'on adopte comme définition de $\mathbb{E}[\phi(X)]$ dans le cadre général.

TD4 : VARs, LOI, MOMENTS.

Exercice 2.1. Posons, $n \in \mathbb{N}^*$ et $t > 0$ réel :

$$I(n) = \int_t^\infty \frac{1}{(n-1)!} x^{n-1} e^{-x} dx.$$

1. Montrer que l'on a :

$$I(n) = \frac{1}{(n-1)!} t^{n-1} e^{-t} + I(n-1).$$

2. En déduire :

$$I(n) = \sum_{k=0}^{n-1} e^{-t} \frac{t^k}{k!}.$$

3. Soit $X_t \sim \mathcal{P}(t)$ et $Y_n \sim \Gamma(n, 1)$. Montrer que :

$$\mathbb{P}(X_t < n) = \mathbb{P}(Y_n > t).$$

Exercice 2.2. 1. On cherche à caractériser l'ensemble des lois des variables aléatoires réelles X qui satisfont à l'égalité en loi :

$$X \stackrel{\text{loi}}{=} X^2.$$

(a) Quel est le signe de X ? En déduire la fonction de répartition F de X sur $] -\infty, 0[$.

(b) Montrer que F satisfait $F(t) = F(t^2)$ pour tout $t \geq 0$.

(c) En déduire que F est constante sur les deux intervalles $[0, 1[$ et sur $[1, \infty[$.

(d) Conclure : trouver l'ensemble des lois solutions.

2. Adapter le raisonnement précédent pour les deux équations en loi suivantes :

(a) $X \stackrel{\text{loi}}{=} X^3$

(b) (plus difficile, en bonus) $X \stackrel{\text{loi}}{=} -X^3$

Exercice 2.3. On se donne $X_1, \dots, X_n$, n variables aléatoires indépendantes de loi $\mathcal{U}(0, 1)$ et on note $X_{(1)} \leq \dots \leq X_{(n)}$ leur réordonnement croissant (encore

appelé statistique d'ordre); ainsi, $X_{(1)}$ est le plus petit des X_i , $i = 1 \dots n$, $X_{(2)}$ le deuxième plus petit...

1. Montrer que $\mathbb{P}(X_{(n)} \leq t) = t^n$ pour tout $t \in [0, 1]$ et en déduire que $X_{(n)}$ suit une loi Bêta dont on précisera les paramètres.
2. Montrer que $\mathbb{P}(X_{(n-1)} \leq t) = t^n + n(1-t)t^{n-1}$ pour tout $t \in [0, 1]$ et en déduire que $X_{(n-1)}$ suit une loi Bêta dont on précisera les paramètres.
3. De même, donner les lois de $X_{(1)}$ et $X_{(2)}$.
4. Quel résultat peut-on conjecturer de façon plus générale au sujet de la loi de $X_{(i)}$ si $i \in \{1, \dots, n\}$?

Exercice 2.4. Soit $\alpha, \beta > 0$ et $n \in \mathbb{N}^*$. On rappelle la définition de la fonction Gamma d'Euler :

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx, \quad t > 0.$$

1. Montrer que $\Gamma(n+1) = n!$.
2. Calculer le n -ième moment de la loi exponentielle $\mathcal{E}(\beta)$, c'est-à-dire $\mathbb{E}[X^n]$ si $X \sim \mathcal{E}(\beta)$.
3. Calculer le n -ième moment de la loi Gamma $\Gamma(\alpha, \beta)$.
4. Comparez les résultats obtenus aux deux dernières questions.

Exercice 2.5. 1. Calculer les moments impairs de la loi normale centrée réduite $\mathcal{N}(0, 1)$.

2. On cherche maintenant à calculer les moments pairs de $\mathcal{N}(0, 1)$.

(a) Montrer à l'aide d'une intégration par parties que :

$$\int_{\mathbb{R}} x^{2n} e^{-\frac{x^2}{2}} dx = (2n-1) \int_{\mathbb{R}} x^{2n-2} e^{-\frac{x^2}{2}} dx$$

(b) En déduire que le $2n$ -ième moment de $\mathcal{N}(0, 1)$ vaut :

$$\prod_{k=1}^n (2k-1) = \frac{(2n)!}{2^n \cdot n!}$$

TD5 : MOMENTS DE VARIABLES ALÉATOIRES.

Exercice 2.1. Soit $\alpha, \beta > 0$ et $n \in \mathbb{N}^*$. On rappelle la définition de la fonction Gamma d'Euler :

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx, \quad t > 0.$$

1. Montrer que $\Gamma(n+1) = n!$
2. Calculer le n -ième moment de $\mathcal{E}(\beta)$, c'est-à-dire $\mathbb{E}[X^n]$ si $X \sim \mathcal{E}(\beta)$.
3. Calculer le n -ième moment de $\Gamma(\alpha, \beta)$.
4. Comparez les résultats obtenus aux deux dernières questions.

- Exercice 2.2.**
1. Calculer les moments impairs de $\mathcal{N}(0, 1)$.
 2. On cherche maintenant à calculer les moments pairs de $\mathcal{N}(0, 1)$.
(a) Montrer à l'aide d'une intégration par parties que :

$$\int_{\mathbb{R}} x^{2n} e^{-\frac{x^2}{2}} dx = (2n-1) \int_{\mathbb{R}} x^{2n-2} e^{-\frac{x^2}{2}} dx$$

- (b) En déduire que le $2n$ -ième moment de $\mathcal{N}(0, 1)$ vaut :

$$\prod_{k=1}^n (2k-1) = \frac{(2n)!}{2^n \cdot n!}$$

Exercice 2.3. Soit $n \in \mathbb{N}^*$, $p \in [0, 1]$, $\lambda > 0$.

1. Calculer la variance de la loi $\text{Ber}(p)$. Pour quelle valeur de p la variance de $\mathcal{B}(p)$ est maximale?
2. Montrer que, pour $1 \leq k \leq n$,

$$k \binom{n}{k} = n \binom{n-1}{k-1},$$

et pour $2 \leq k \leq n$,

$$k(k-1) \binom{n}{k} = n(n-1) \binom{n-2}{k-2}.$$

3. En déduire la variance de la loi $\mathcal{B}(n, p)$. (On pourra commencer par calculer $\mathbb{E}[X]$ et $\mathbb{E}[X(X-1)]$ si $X \sim \mathcal{B}(n, p)$). Commenter le résultat obtenu.
4. En utilisant la même méthode, calculer la variance de la loi $\mathcal{P}(\lambda)$. Commenter le résultat obtenu.

Exercice 2.4. Calculer la variance de la loi $\mathcal{U}(a, b)$ de deux façons :

1. par un calcul direct
2. en déduisant cette variance de celle de $\mathcal{U}(0, 1)$.

Exercice 2.5. Soit $X \sim \mathcal{B}(p)$ et $Y \sim \mathcal{B}(n, p)$, $p \in [0, 1]$, $n \in \mathbb{N}^*$.

1. Calculer les fonctions génératrices des moments de $\mathcal{B}(p)$ et $\mathcal{B}(n, p)$. Commenter.
2. Retrouver les valeurs de $\mathbb{E}[Y]$ et $\mathcal{V}(Y)$ calculées à l'exercice 3.

Exercice 2.6. Soit $\alpha, \beta > 0$.

1. Calculer la fonction génératrice des moments ϕ de la loi $\mathcal{E}(\beta)$.
2. Développer le résultat obtenu en série entière, et retrouver la valeur des moments de la loi $\mathcal{E}(\beta)$.
3. Calculer la fonction génératrice des moments ϕ de la loi $\Gamma(\alpha, \beta)$.
4. Retrouver les deux premiers moments de la loi $\Gamma(\alpha, \beta)$ calculés à l'exercice 1.

Exercice 2.7. 1. Calculer la fonction génératrice des moments ϕ de la loi $\mathcal{N}(0, 1)$.
2. Développer le résultat obtenu en série entière, et retrouver la valeur des moments de la loi $\mathcal{N}(0, 1)$.

Exercice 2.8. Soit $a < b$ deux réels, et X variable aléatoire telle que $\mathbb{P}(X \in [a, b]) = 1$. On veut montrer :

$$\mathcal{V}(X) \leq \frac{(b-a)^2}{4}.$$

1. On suppose d'abord $a = -1$ et $b = 1$. Montrer que $\mathcal{V}(X) \leq 1$, puis trouver une variable aléatoire qui satisfait le cas d'égalité.
2. Trouver une fonction affine $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ telle que $\varphi(a) = -1$ et $\varphi(b) = 1$.
3. Étudier $\varphi(X)$ et conclure.

Exercice 2.9. Soit N une variable aléatoire à valeurs dans $\mathbb{N}$.

1. Observer que pour $n \in \mathbb{N}$, $n = \sum_{i=1}^{+\infty} \mathbb{1}_{\{n \geq i\}}$ et en déduire :

$$\mathbb{E}[N] = \sum_{i=1}^{+\infty} \mathbb{P}(N \geq i)$$

2. Dans le cas où N est de plus de carré intégrable ($\mathbb{E}[N^2] < \infty$) montrer également que

$$\sum_{i=1}^{+\infty} i \mathbb{P}(N \geq i) = \frac{1}{2} (\mathbb{E}[N^2] + \mathbb{E}[N])$$

LOIS DISCRÈTES USUELLES : FORMULAIRE RAISONNÉ

A.1 LOI DE DIRAC

C'est la loi la plus simple qui soit : elle décrit une variable *constante*.

Définition A.1 (Loi de Dirac). Soit $x \in \mathbb{R}$. On dit que X *suit la loi de Dirac en* x , et l'on note $X \sim \delta_x$, si

$$\mathbb{P}(X = x) = 1.$$

On dit alors aussi que X est *presque sûrement* (*p.s.*) égale à x .

Proposition A.1 (Loi et fonction de répartition). Si $X \sim \delta_x$, alors pour toute partie $A \subset \mathbb{R}$,

$$\mathbb{P}(X \in A) = \mathbb{1}_A(x) = \begin{cases} 1 & \text{si } x \in A, \\ 0 & \text{si } x \notin A, \end{cases} \quad \text{et}$$

Et

$$F_X(y) = \mathbb{1}_{[x, +\infty[}(y) = \begin{cases} 0 & \text{si } y < x, \\ 1 & \text{si } y \geq x. \end{cases}$$

En particulier δ_x est la loi discrète d'ensemble d'atomes $S_X = \{x\}$, l'unique atome portant nécessairement la masse 1.

Proposition A.2 (Espérance, variance, moments). Si $X \sim \delta_x$, alors

- $\mathbb{E}[X] = x$,
- $\mathbb{V}[X] = 0$,
- $\mathbb{E}[X^n] = x^n$ avec $n \in \mathbb{N}$,
- $M_X(t) = e^{tx}$ avec $t \in \mathbb{R}$.

Démonstration. X est constante, donc $\mathbb{E}[g(X)] = g(x)$ pour toute fonction g ; il suffit de prendre $g(u) = u$, $g(u) = u^2$, puis $g(u) = e^{tu}$. La variance vaut $\mathbb{E}[(X - x)^2] = 0$. □

Proposition A.3 (Caractérisation par la variance). *Une v.a.r. X de carré intégrable vérifie $\mathbb{V}(X) = 0$ si et seulement s'il existe $x \in \mathbb{R}$ tel que $X \sim \delta_x$ (c'est-à-dire $X = \mathbb{E}[X]$ p.s.).*

Autrement dit, les lois de Dirac sont exactement les lois de variance nulle.

Remarque A.1. La loi de Dirac sert de « brique » élémentaire : toute loi discrète s'écrit comme une combinaison convexe de Dirac,

$$\mathbb{P}_X = \sum_{x \in S_X} p_X(x) \delta_x.$$

A.2 LOI UNIFORME (SUR UN ENSEMBLE FINI)

C'est la loi la plus simple d'une v.a. prenant un nombre *fini* de valeurs.

Définition A.2 (Loi uniforme). Soit $S \subset \mathbb{R}$ une partie finie non vide. On dit que X suit la loi uniforme sur S , et l'on note $X \sim \mathcal{U}(S)$, si pour tout $x \in S$:

$$\mathbb{P}(X = x) = \frac{1}{\text{Card}(S)}.$$

Proposition A.4 (Loi et fonction de répartition). Si $X \sim \mathcal{U}(S)$, alors pour toute partie $A \subset \mathbb{R}$,

$$\mathbb{P}(X \in A) = \frac{\text{Card}(A \cap S)}{\text{Card}(S)},$$

Et

$$F_X(x) = \frac{\text{Card}([-\infty, x] \cap S)}{\text{Card}(S)}.$$

La loi $\mathcal{U}(S)$ est la loi discrète d'ensemble d'atomes S dont la fonction de masse est constante sur S .

Proposition A.5 (Espérance et variance sur $\{1, \dots, n\}$). Dans le cas particulier $S = \{1, \dots, n\}$,

$$- \mathbb{E}[X] = \frac{n+1}{2},$$

$$\begin{aligned} - \mathbb{E}[X^2] &= \frac{(n+1)(2n+1)}{6}, \\ - \mathbb{V}[X] &= \frac{n^2-1}{12}. \end{aligned}$$

Démonstration. On utilise $\sum_{k=1}^n k = \frac{n(n+1)}{2}$ et $\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$. On a :

$$\mathbb{E}[X] = \frac{1}{n} \sum_{k=1}^n k = \frac{n+1}{2},$$

Et

$$\mathbb{E}[X^2] = \frac{1}{n} \sum_{k=1}^n k^2 = \frac{(n+1)(2n+1)}{6}.$$

Puis, par la formule de Koenig–Huygens,

$$\begin{aligned} \mathbb{V}[X] &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \\ &= \frac{(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} \\ &= (n+1) \frac{2(2n+1) - 3(n+1)}{12} \\ &= \frac{(n+1)(n-1)}{12}. \end{aligned}$$

□

Remarque A.2 (Cas général). Pour $S = \{x_1, \dots, x_N\}$ quelconque,

- $\mathbb{E}[X] = \frac{1}{N} \sum_i x_i$ est la moyenne arithmétique des valeurs,
- $\mathbb{V}(X) = \frac{1}{N} \sum_i x_i^2 - \left(\frac{1}{N} \sum_i x_i\right)^2$ leur variance empirique.

Proposition A.6 (Lien avec Bernoulli). *La loi $\mathcal{U}(\{0, 1\})$ coïncide avec $\mathcal{B}(1/2)$.*

Remarque A.3. La loi uniforme modélise les situations d'équiprobabilité : lancer d'un dé équilibré, tirage d'une carte, etc.

A.3 LOI DE BERNOULLI

Définition A.3 (Loi de Bernoulli). Soit $p \in [0, 1]$. On dit que X suit la loi de Bernoulli de paramètre p , et l'on note $X \sim \mathcal{B}(p)$, si

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Proposition A.7 (Fonction de répartition). Si $X \sim \mathcal{B}(p)$, alors

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - p, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

Proposition A.8 (Espérance, variance, moments). Si $X \sim \mathcal{B}(p)$, alors

- $\mathbb{E}[X] = p$,
- $\mathbb{V}(X) = p(1 - p)$,
- $\mathbb{E}[X^n] = p$ avec $n \geq 1$,
- $M_X(t) = 1 - p + p e^t$.

Démonstration. On a

$$\mathbb{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p.$$

Comme $X \in \{0, 1\}$ on a $X^n = X$ pour tout $n \geq 1$, d'où

$$\mathbb{E}[X^n] = p;$$

en particulier $\mathbb{E}[X^2] = p$ et

$$\mathbb{V}(X) = p - p^2 = p(1 - p).$$

Enfin

$$M_X(t) = e^t p + e^0 (1 - p) = 1 - p + p e^t.$$

□

Remarque A.4 (Interprétation). La loi de Bernoulli code une *expérience à deux issues* (succès/échec) : on pose $X = 1$ en cas de succès (de probabilité p) et $X = 0$ sinon.

C'est la brique de base de toute la section : la variance $p(1 - p)$ est maximale en $p = 1/2$ et nulle aux bornes $p \in \{0, 1\}$ (cas dégénérés de Dirac).

Proposition A.9 (Fonction indicatrice). *Pour tout événement B , la variable $\mathbb{1}_B$ suit la loi $\mathcal{B}(\mathbb{P}(B))$.*

Réciproquement, toute variable de Bernoulli est p.s égale à une indicatrice.

A.4 LOI BINOMIALE

Généralisation fondamentale de la loi de Bernoulli.

Définition A.4 (Loi binomiale). Soient $n \in \mathbb{N}$ et $p \in [0, 1]$. On dit que X suit la loi binomiale de paramètres n et p , et l'on note $X \sim \mathcal{B}(n, p)$, si

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k \in \{0, \dots, n\},$$

$$\text{où } \binom{n}{k} = \frac{n!}{k! (n-k)!}.$$

Proposition A.10 (Fonction de répartition). *La fonction de répartition n'admet pas d'expression plus simple que*

$$F_X(x) = \sum_{k \leq x} \binom{n}{k} p^k (1 - p)^{n-k}.$$

$$\text{On a } \mathbb{B}(1, p) = \mathbb{B}(p).$$

Proposition A.11 (La fonction de masse est une probabilité). *On a bien*

$$\sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} = 1,$$

conséquence du binôme de Newton

$$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

appliqué à $a = p, b = 1 - p$.

Démonstration. Développer $(a + b)^n$ revient à choisir, dans chacun des n facteurs, le terme a ou le terme b ; les configurations donnant $a^k b^{n-k}$ correspondent aux parties $I \subset \{1, \dots, n\}$ de cardinal k , au nombre de $\binom{n}{k}$. D'où

$$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k},$$

et l'on conclut avec $a = p, b = 1 - p$ (donc $a + b = 1$). □

Proposition A.12 (Espérance, variance, moments). *Si $X \sim \mathcal{B}(n, p)$, alors*

- $\mathbb{E}[X] = np$,
- $\mathbb{V}(X) = np(1 - p)$,
- $M_X(t) = (1 - p + p e^t)^n$.

Plus généralement les moments factoriels valent

$$\mathbb{E}[X(X - 1) \cdots (X - j + 1)] = n(n - 1) \cdots (n - j + 1) p^j$$

pour $0 \leq j \leq n$.

Démonstration. On utilise l'identité $k \binom{n}{k} = n \binom{n-1}{k-1}$:

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=1}^n k \binom{n}{k} p^k q^{n-k} \\ &= np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} q^{n-k} \\ &= np (p + q)^{n-1} = np. \end{aligned}$$

De même, $k(k - 1) \binom{n}{k} = n(n - 1) \binom{n-2}{k-2}$ donne

$$\mathbb{E}[X(X - 1)] = n(n - 1) p^2 (p + q)^{n-2} = n(n - 1) p^2,$$

d'où

$$\mathbb{E}[X^2] = n(n-1)p^2 + np$$

Et

$$\begin{aligned}\mathbb{V}(X) &= n(n-1)p^2 + np - (np)^2 \\ &= np - np^2 \\ &= np(1-p).\end{aligned}$$

Le calcul général des moments factoriels est identique. Enfin

$$M_X(t) = \sum_k \binom{n}{k} (pe^t)^k q^{n-k} = (q + pe^t)^n.$$

□

Proposition A.13 (Somme de Bernoulli et stabilité). *Si $X_1, \dots, X_n$ sont des v.a. indépendantes de loi $\mathcal{B}(p)$, alors $X_1 + \dots + X_n \sim \mathcal{B}(n, p)$. Plus généralement, si $X \sim \mathcal{B}(n, p)$ et $Y \sim \mathcal{B}(m, p)$ sont indépendantes et de même p , alors*

$$X + Y \sim \mathcal{B}(n + m, p).$$

Démonstration. Pour la stabilité, par la formule de Vandermonde $\sum_j \binom{n}{j} \binom{m}{k-j} = \binom{n+m}{k}$:

$$\begin{aligned}\mathbb{P}(X + Y = k) &= \sum_{j=0}^k \binom{n}{j} p^j q^{n-j} \binom{m}{k-j} p^{k-j} q^{m-k+j} \\ &= p^k q^{n+m-k} \binom{n+m}{k}.\end{aligned}$$

□

Remarque A.5 (Interprétation). $\mathcal{B}(n, p)$ est le nombre de succès lors de n répétitions indépendantes d'une expérience de Bernoulli de probabilité de succès p .

Exercice A.1. Soit $X = (X_1, \dots, X_n)$ une variable uniforme sur l'ensemble fini $\{0, 1\}^n$ des mots binaires de longueur n . Pour $x \in \{0, 1\}^n$, on pose $\phi(x) = \sum_{i=1}^n x_i$. Montrer que $\phi(X) \sim \mathcal{B}(n, 1/2)$.

A.5 LOI DE POISSON

Définition A.5 (Loi de Poisson). Soit $\lambda \geq 0$. On dit que X *suit la loi de Poisson de paramètre λ* , et l'on note $X \sim \mathcal{P}(\lambda)$, si pour tout $k \in \mathbb{N}$:

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Proposition A.14 (La fonction de masse est une probabilité). On a $\sum_{k \geq 0} e^{-\lambda} \frac{\lambda^k}{k!} = 1$, conséquence du développement en série entière de l'exponentielle, $e^z = \sum_{k \geq 0} \frac{z^k}{k!}$ appliqué à $z = \lambda$. La fonction de répartition n'admet pas de forme close plus simple.

Proposition A.15 (Espérance, variance, moments). Si $X \sim \mathcal{P}(\lambda)$, alors

- $\mathbb{E}[X] = \lambda$,
- $\mathbb{V}(X) = \lambda$,
- $M_X(t) = \exp(\lambda(e^t - 1))$, avec $t \in \mathbb{R}$.

Les moments factoriels sont particulièrement simples :

$$\mathbb{E}[X(X-1) \cdots (X-j+1)] = \lambda^j, \quad j \in \mathbb{N}^*.$$

Démonstration. On calcule

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k \geq 1} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} \sum_{k \geq 1} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} e^{\lambda} = \lambda. \end{aligned}$$

Plus généralement

$$\begin{aligned} \mathbb{E}[X(X-1) \cdots (X-j+1)] &= \sum_{k \geq j} \frac{k!}{(k-j)!} e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda^j e^{-\lambda} \sum_{k \geq j} \frac{\lambda^{k-j}}{(k-j)!} = \lambda^j. \end{aligned}$$

En particulier $\mathbb{E}[X(X-1)] = \lambda^2$, donc $\mathbb{E}[X^2] = \lambda^2 + \lambda$ et $\mathbb{V}(X) = \lambda$. Enfin

$$\begin{aligned} M_X(t) &= \sum_k e^{tk} e^{-\lambda} \frac{\lambda^k}{k!} \\ &= e^{-\lambda} \sum_k \frac{(\lambda e^t)^k}{k!} = e^{-\lambda} e^{\lambda e^t} \\ &= e^{\lambda(e^t - 1)}. \end{aligned}$$

□

Proposition A.16 (Stabilité par addition — à retenir). *Si $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$ sont indépendantes, alors $X + Y \sim \mathcal{P}(\lambda + \mu)$.*

Démonstration.

$$\begin{aligned} \mathbb{P}(X + Y = k) &= \sum_{j=0}^k e^{-\lambda} \frac{\lambda^j}{j!} e^{-\mu} \frac{\mu^{k-j}}{(k-j)!} \\ &= \frac{e^{-(\lambda+\mu)}}{k!} \sum_{j=0}^k \binom{k}{j} \lambda^j \mu^{k-j} \\ &= e^{-(\lambda+\mu)} \frac{(\lambda + \mu)^k}{k!}. \end{aligned}$$

□

Théorème A.1 (Approximation de Poisson de la loi binomiale; Prokhorov, Stein).
Pour tout $n \in \mathbb{N}$ et $p \in [0, 1]$,

$$\sum_{k \in \mathbb{N}} \left| \binom{n}{k} p^k (1-p)^{n-k} - e^{-np} \frac{(np)^k}{k!} \right| \leq \min\{2np^2, 3p\}.$$

En conséquence, si $X_n \sim \mathcal{B}(n, p)$ et $X \sim \mathcal{P}(np)$, alors pour tout $J \subset \mathbb{N}$,

$$|\mathbb{P}(X_n \in J) - \mathbb{P}(X \in J)| \leq \min\{2np^2, 3p\}.$$

Démonstration de la conséquence. Par inégalité triangulaire,

$$\begin{aligned}
 |\mathbb{P}(X_n \in J) - \mathbb{P}(X \in J)| &= \left| \sum_{k \in J} (\mathbb{P}(X_n = k) - \mathbb{P}(X = k)) \right| \\
 &\leq \sum_{k \in J} |\mathbb{P}(X_n = k) - \mathbb{P}(X = k)| \\
 &\leq \sum_{k \in \mathbb{N}} |\mathbb{P}(X_n = k) - \mathbb{P}(X = k)|,
 \end{aligned}$$

et cette dernière somme est majorée par $\min\{2np^2, 3p\}$ d'après le premier énoncé. $\square$

Remarque A.6. Ce résultat montre que $\mathcal{P}(\lambda)$ avec $\lambda = np$ approche bien $\mathcal{B}(n, p)$ dès que p est petit, *et ce indépendamment de n* (résultat souvent méconnu). C'est la « loi des petits nombres » : on retrouve en particulier, à $\lambda \geq 0$ et k fixés,

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \xrightarrow{n \rightarrow \infty} e^{-\lambda} \frac{\lambda^k}{k!}.$$

A.6 LOI GÉOMÉTRIQUE

Définition A.6 (Loi géométrique sur $\mathbb{N}^*$). Soit $p \in]0, 1]$. On dit que X suit la loi géométrique de paramètre p , et l'on note $X \sim \mathcal{G}(p)$, si

$$\mathbb{P}(X = k) = p(1 - p)^{k-1}, \quad k \in \mathbb{N}^* = \{1, 2, \dots\}.$$

Proposition A.17 (Fonction de répartition et queue). Pour $X \sim \mathcal{G}(p)$, avec $\lfloor \cdot \rfloor$ la partie entière,

$$F_X(x) = \begin{cases} 1 - (1 - p)^{\lfloor x \rfloor}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

Et en particulier

$$\mathbb{P}(X > k) = (1 - p)^k \quad (k \in \mathbb{N}).$$

Démonstration. Pour $k \in \mathbb{N}^*$,

$$\begin{aligned}
 \mathbb{P}(X > k) &= \sum_{j>k} pq^{j-1} \\
 &= pq^k \sum_{i\geq 0} q^i \\
 &= pq^k \cdot \frac{1}{1-q} \\
 &= q^k,
 \end{aligned}$$

avec $q = 1 - p$. On en déduit $F_X(k) = 1 - q^k$, puis la forme avec la partie entière. $\square$

Proposition A.18 (La fonction de masse est une probabilité). *On a*

$$\sum_{k\geq 1} p(1-p)^{k-1} = 1,$$

conséquence de la série géométrique : pour $|z| < 1$, $\sum_{k\geq 0} z^k = \frac{1}{1-z}$, d'où

$$\sum_{k\geq 1} q^{k-1} = \frac{1}{1-q} = \frac{1}{p}.$$

Démonstration. Pour tout $z \neq 1$, $\sum_{k=0}^n z^k(1-z) = 1 - z^{n+1}$ donne

$$\sum_{k=0}^n z^k = \frac{1 - z^{n+1}}{1 - z};$$

on passe à la limite pour $|z| < 1$. Avec $z = q : \sum_{k\geq 1} q^{k-1} = \frac{1}{1-q} = \frac{1}{p}$, donc

$$\sum_{k\geq 1} pq^{k-1} = 1.$$

$\square$

Proposition A.19 (Espérance, variance, moments). *Si $X \sim \mathcal{G}(p)$, alors*

- $\mathbb{E}[X] = \frac{1}{p}$,
- $\mathbb{V}(X) = \frac{1-p}{p^2}$,

$$- M_X(t) = \frac{pe^t}{1-(1-p)e^t}, \text{ pour } e^t(1-p) < 1.$$

Démonstration. En dérivant $\sum_{k \geq 0} q^k = \frac{1}{1-q}$ on obtient

$$\sum_{k \geq 1} kq^{k-1} = \frac{1}{(1-q)^2} = \frac{1}{p^2},$$

d'où

$$\mathbb{E}[X] = p \sum_{k \geq 1} kq^{k-1} = \frac{1}{p}.$$

En dérivant une seconde fois,

$$\sum_{k \geq 2} k(k-1)q^{k-2} = \frac{2}{(1-q)^3},$$

donc

$$\mathbb{E}[X(X-1)] = pq \sum_{k \geq 2} k(k-1)q^{k-2} = \frac{2q}{p^2};$$

ainsi

$$\mathbb{E}[X^2] = \frac{2q}{p^2} + \frac{1}{p}$$

et

$$\mathbb{V}(X) = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{q}{p^2} = \frac{1-p}{p^2}.$$

Enfin

$$M_X(t) = \sum_{k \geq 1} e^{tk} pq^{k-1} = pe^t \sum_{k \geq 1} (qe^t)^{k-1} = \frac{pe^t}{1-qe^t}$$

dès que $qe^t < 1$.

□

Remarque A.7 (Interprétation). $X \sim \mathcal{G}(p)$ modélise le *rang du premier succès* dans une suite d'expériences de Bernoulli indépendantes de probabilité de succès p : la probabilité d'échouer aux $k - 1$ premiers essais puis de réussir au k -ième vaut exactement $(1 - p)^{k-1}p$.

Proposition A.20 (Absence de mémoire). *Soit X une v.a.r. Alors $X \sim \mathcal{G}(p)$ pour un certain $p \in]0, 1]$ si et seulement si X vérifie la propriété d'absence de mémoire :*

$$\mathbb{P}(X \in \mathbb{N}^*) = 1 \quad \text{et} \quad \mathbb{P}(X - k > \ell \mid X > k) = \mathbb{P}(X > \ell), \quad \forall k, \ell \in \mathbb{N}.$$

Autrement dit, conditionnellement à $\{X > k\}$, la loi de $X - k$ est celle de X : si X est un temps de vie, il n'y a pas de vieillissement.

Démonstration. Sens direct. Supposons l'absence de mémoire. En prenant $k = 1$ et par récurrence sur $\ell \in \mathbb{N}^*$, on obtient $\mathbb{P}(X > \ell) = \mathbb{P}(X > 1)^\ell$. Comme $\mathbb{P}(X \in \mathbb{N}^*) = 1$,

$$\begin{aligned} \mathbb{P}(X = \ell) &= \mathbb{P}(X > \ell - 1) - \mathbb{P}(X > \ell) \\ &= \mathbb{P}(X > 1)^{\ell-1} (1 - \mathbb{P}(X > 1)) \\ &= (1 - p)^{\ell-1} p, \end{aligned}$$

avec $p := \mathbb{P}(X = 1) = 1 - \mathbb{P}(X > 1)$; donc $X \sim \mathcal{G}(p)$.

Réciproque. Si $X \sim \mathcal{G}(p)$, alors $\mathbb{P}(X > \ell) = q^\ell$ et

$$\begin{aligned} \mathbb{P}(X - k > \ell \mid X > k) &= \frac{\mathbb{P}(X > k + \ell)}{\mathbb{P}(X > k)} \\ &= \frac{q^{k+\ell}}{q^k} \\ &= q^\ell \\ &= \mathbb{P}(X > \ell). \end{aligned}$$

□

Remarque A.8 (Convention sur $\mathbb{N}$). On rencontre aussi la *loi géométrique sur $\mathbb{N}$* , simple décalage de 1n : $Y \sim \mathcal{G}_{\mathbb{N}}(p)$ si $Y + 1 \sim \mathcal{G}(p)$, c'est-à-dire

$$\mathbb{P}(Y = k) = p(1 - p)^k, \quad k \in \mathbb{N} = \{0, 1, 2, \dots\}.$$

On a alors $\mathbb{E}[Y] = \frac{1-p}{p}$ et $\mathbb{V}(Y) = \frac{1-p}{p^2}$. Bien préciser l'indice $\mathbb{N}$ selon la convention utilisée; les deux sont fréquentes.

A.7 AUTRES LOIS DISCRÈTES

LOI BINOMIALE NÉGATIVE

Définition A.7 (Loi binomiale négative). Soient $r \in \mathbb{N}^*$ et $p \in]0, 1]$. On dit que $X \sim \mathcal{N}_{\mathcal{B}}(r, p)$ si

$$\mathbb{P}(X = n) = \binom{n-1}{r-1} p^r (1-p)^{n-r}, \quad n \in \{r, r+1, \dots\}.$$

Proposition A.21 (Premiers moments). Si $X \sim \mathcal{N}_{\mathcal{B}}(r, p)$, alors

- $\mathbb{E}[X] = \frac{r}{p}$,
- $\mathbb{V}(X) = \frac{r(1-p)}{p^2}$,
- $M_X(t) = \left(\frac{p e^t}{1 - (1-p)e^t} \right)^r$.

En particulier $\mathcal{N}_{\mathcal{B}}(1, p) = \mathcal{G}(p)$.

Remarque A.9 (Interprétation). X est le *nombre d'essais* d'une suite d'expériences de Bernoulli indépendantes jusqu'à cumuler r succès. Le dernier essai est nécessairement un succès; les $r-1$ autres succès se répartissent parmi les $n-1$ premiers essais, d'où le facteur $\binom{n-1}{r-1}$, chaque configuration ayant probabilité $p^r (1-p)^{n-r}$. Ainsi X est somme de r variables $\mathcal{G}(p)$ indépendantes, ce qui redonne $\mathbb{E}[X] = r/p$ et $\mathbb{V}(X) = r(1-p)/p^2$.

Proposition A.22 (La fonction de masse est une probabilité). Avec $q = 1 - p$, la série entière de $(1 - q)^{-r}$ donne $(1 - q)^{-r} = \sum_{k \geq 0} \binom{r-1+k}{r-1} q^k$, d'où

$$\sum_{n \geq r} \binom{n-1}{r-1} (1-p)^{n-r} p^r = 1.$$

Démonstration. On écrit

$$(1 - q)^{-r} = \left(\sum_{j \geq 0} q^j \right)^r = \sum_{j_1, \dots, j_r \geq 0} q^{j_1 + \dots + j_r}.$$

Le coefficient de q^k compte les r -uplets $(j_1, \dots, j_r)$ d'entiers ≥ 0 de somme k ; ces uplets sont en bijection avec les chemins Nord-Est de $(0, 0)$ à $(k, r - 1)$, au nombre de $\binom{r-1+k}{r-1}$. En réindiquant $n = k + r$ et en posant $q = 1 - p$, on obtient l'identité annoncée. $\square$

Remarque A.10 (Autre convention). On compte parfois le *nombre d'échecs* $X - r$ avant d'atteindre r succès :

$$\mathbb{P}(X - r = j) = \binom{r + j - 1}{r - 1} p^r (1 - p)^j, \quad j \in \mathbb{N}.$$

LOI HYPERGÉOMÉTRIQUE

Définition A.8 (Loi hypergéométrique). Soient $n, N, m \in \mathbb{N}$ avec $n \leq N$ et $m \leq N$. On dit que $X \sim \mathcal{H}_G(n, N, m)$ si

$$\mathbb{P}(X = k) = \frac{\binom{m}{k} \binom{N-m}{n-k}}{\binom{N}{n}}, \quad k = 0, \dots, \min\{m, n\}.$$

Proposition A.23 (Premiers moments). Si $X \sim \mathcal{H}_G(n, N, m)$, en posant $p = m/N$,

- $\mathbb{E}[X] = n \frac{m}{N} = np$,
- $\mathbb{V}(X) = n \frac{m}{N} \left(1 - \frac{m}{N}\right) \frac{N-n}{N-1} = np(1-p) \frac{N-n}{N-1}$.

Remarque A.11 (Interprétation et « facteur de population finie »). On tire *sans remise* n boules d'une urne en contenant N , dont m blanches; X est le nombre de boules blanches tirées. On retrouve la même espérance que la binomiale $\mathcal{B}(n, p)$, mais la variance est corrigée par le facteur $\frac{N-n}{N-1} < 1$ (tirage sans remise), qui vaut 1 quand $n = 1$ et tend vers 1 quand $N \rightarrow \infty$.

Exercice A.2. Soit $X_N \sim \mathcal{H}_G(n, N, m)$. On suppose $m = m_N$ avec $m_N/N \rightarrow p$ quand $N \rightarrow \infty$. Montrer que

$$\mathbb{P}(X_N = k) \xrightarrow{N \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, \dots, n\}.$$

(Le tirage sans remise se comporte comme un tirage avec remise quand la population devient grande.)

LOI ZÊTA (OU DE ZIPF)

Définition A.9 (Loi zêta / de Zipf). Soit $\alpha > 0$. On dit que X suit une *loi zêta* (ou de Zipf) de paramètre α si

$$\mathbb{P}(X = k) = \frac{C}{k^{\alpha+1}}, \quad k \in \mathbb{N}^*,$$

Avec

$$C = \frac{1}{\sum_{k \geq 1} k^{-(\alpha+1)}} = \frac{1}{\zeta(\alpha+1)},$$

où ζ désigne la fonction zêta de Riemann.

Proposition A.24 (Moments : existence conditionnelle). Si X suit la loi zêta de paramètre α , alors

$$\mathbb{E}[X] = \frac{\zeta(\alpha)}{\zeta(\alpha+1)} < \infty \iff \alpha > 1,$$

Et

$$\mathbb{E}[X^2] = \frac{\zeta(\alpha-1)}{\zeta(\alpha+1)} < \infty \iff \alpha > 2.$$

Plus généralement, le moment d'ordre j est fini si et seulement si $\alpha > j$.

Démonstration.

$$\mathbb{E}[X^j] = C \sum_{k \geq 1} k^j k^{-(\alpha+1)} = C \sum_{k \geq 1} k^{-(\alpha+1-j)},$$

série de Riemann convergente ssi $\alpha + 1 - j > 1$, c'est-à-dire $\alpha > j$; sa valeur est alors $\zeta(\alpha + 1 - j)/\zeta(\alpha + 1)$. $\square$

Remarque A.12 (Queues lourdes). La loi de Zipf est l'archétype d'une loi à *queue lourde* : contrairement aux lois précédentes, ses moments ne sont pas tous finis. Elle intervient en linguistique, en analyse des réseaux et pour les phénomènes suivant une loi de puissance.

VARIABLES ALÉATOIRES CONTINUE

B.1 LOI UNIFORME (CONTINUE)

Analogue continu de la loi uniforme discrète : c'est cette fois la *densité* qui est constante sur un intervalle.

Définition B.1 (Loi uniforme continue). Soit $I \subset \mathbb{R}$ un intervalle borné, de bornes $a = \inf I$ et $b = \sup I$ ($a < b$), de longueur $|I| = b - a$. On dit que X suit la loi uniforme sur I , et l'on note $X \sim \mathcal{U}(a, b)$, si X admet la densité

$$f_X(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x).$$

Proposition B.1 (Fonction de répartition). Pour $X \sim \mathcal{U}(a, b)$,

$$F_X(t) = \begin{cases} 0, & t < a, \\ \frac{t-a}{b-a}, & a \leq t \leq b, \\ 1, & t > b. \end{cases}$$

La notation $\mathcal{U}(a, b)$ ne précise pas si les bornes sont incluses : cela n'a aucune incidence, un point étant de probabilité nulle.

Proposition B.2 (Espérance, variance, moments). Si $X \sim \mathcal{U}(a, b)$, alors

- $\mathbb{E}[X] = \frac{a+b}{2}$,
- $\mathbb{V}(X) = \frac{(b-a)^2}{12}$,
- $M_X(t) = \frac{e^{tb} - e^{ta}}{t(b-a)}$ avec $t \neq 0$.
- Plus généralement $\mathbb{E}[X^n] = \frac{b^{n+1} - a^{n+1}}{(n+1)(b-a)}$.

Démonstration.

$$\mathbb{E}[X] = \frac{1}{b-a} \int_a^b x \, dx = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}$$

et

$$\mathbb{E}[X^2] = \frac{1}{b-a} \int_a^b x^2 \, dx = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3}.$$

D'où

$$\begin{aligned}
\mathbb{V}(X) &= \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} \\
&= \frac{4(a^2 + ab + b^2) - 3(a+b)^2}{12} \\
&= \frac{(b-a)^2}{12}.
\end{aligned}$$

$$\text{Enfin } M_X(t) = \frac{1}{b-a} \int_a^b e^{tx} dx = \frac{e^{tb} - e^{ta}}{t(b-a)}. \quad \square$$

Remarque B.1 (L'intervalle est nécessairement borné). On ne peut pas prendre $a = -\infty$ ou $b = +\infty$: il n'existe pas de loi uniforme sur $\mathbb{R}$ tout entier (de même qu'il n'existe pas de loi uniforme sur $\mathbb{N}$).

Exercice B.1. Soit $X \sim \mathcal{U}(0, 1)$ et $a, b \in \mathbb{R}$ avec $a \neq 0$. Déterminer la loi de $aX + b$. (Réponse : $\mathcal{U}$ des bornes b et $a + b$.)

B.2 LOI NORMALE (OU GAUSSIENNE)

Définition B.2 (Loi normale). Soient $\mu \in \mathbb{R}$ et $\sigma^2 > 0$. On dit que X suit la loi normale (ou gaussienne) de moyenne μ et variance σ^2 , et l'on note $X \sim \mathcal{N}(\mu, \sigma^2)$, si X admet la densité

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Si $\mu = 0$, X est dite *centrée*; si de plus $\sigma^2 = 1$, *réduite*.

Proposition B.3 (f_X est bien une densité). On a $\int_{\mathbb{R}} f_X = 1$. Par le changement de variable $t = (x - \mu)/(\sigma\sqrt{2})$ on se ramène à l'intégrale de Gauss $\int_{\mathbb{R}} e^{-t^2} dt = \sqrt{\pi}$.

Notation B.1 (Fonction Φ). La fonction de répartition de la loi *centrée réduite* $\mathcal{N}(0, 1)$ est notée

$$\Phi(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy.$$

Elle n'a pas d'expression élémentaire (elle est reliée à la fonction d'erreur $\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-y^2} dy$), mais elle est tabulée et disponible dans tout logiciel de calcul.

Lemme B.1 (Transformation affine — à retenir). Si $N \sim \mathcal{N}(0, 1)$ et $\mu, \sigma \in \mathbb{R}$ avec $\sigma \neq 0$, alors $\mu + \sigma N \sim \mathcal{N}(\mu, \sigma^2)$.

Démonstration. Cas $\sigma > 0$. Pour $t \in \mathbb{R}$,

$$\begin{aligned} \mathbb{P}(\mu + \sigma N \leq t) &= \mathbb{P}\left(N \leq \frac{t-\mu}{\sigma}\right) \\ &= \int_{-\infty}^{(t-\mu)/\sigma} \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy \\ &= \int_{-\infty}^t \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(z-\mu)^2/(2\sigma^2)} dz, \end{aligned}$$

après le changement de variable affine $y = (z - \mu)/\sigma$. On reconnaît $F_{\mathcal{N}(\mu, \sigma^2)}$. Pour $\sigma < 0$, on note que N et $-N$ ont même loi, donc $\mu + \sigma N$ et $\mu - \sigma N$ aussi. $\square$

Proposition B.4 (Espérance, variance, moments). *Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors*

- $\mathbb{E}[X] = \mu$,
- $\mathbb{V}(X) = \sigma^2$,
- $M_X(t) = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)$, avec $t \in \mathbb{R}$.

Les moments centrés sont, pour $N \sim \mathcal{N}(0, 1)$:

- $\mathbb{E}[N^{2k+1}] = 0$
- $\mathbb{E}[N^{2k}] = (2k - 1)!! = \frac{(2k)!}{2^k k!}$.

Démonstration. Écrivons $X = \mu + \sigma N$. Par imparité, $\mathbb{E}[N] = 0$;

une intégration par parties donne $\mathbb{E}[N^2] = \int y^2 \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy = 1$.

Donc $\mathbb{E}[X] = \mu$ et $\mathbb{V}(X) = \sigma^2 \mathbb{V}(N) = \sigma^2$. Pour la FGM,

$$M_N(t) = \int_{\mathbb{R}} e^{ty} \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy = e^{t^2/2} \int_{\mathbb{R}} \frac{e^{-(y-t)^2/2}}{\sqrt{2\pi}} dy = e^{t^2/2},$$

d'où $M_X(t) = e^{\mu t} M_N(\sigma t) = e^{\mu t + \sigma^2 t^2/2}$. Les moments de N s'obtiennent en identifiant le développement en série de $e^{t^2/2}$. $\square$

Proposition B.5 (Convention $\sigma = 0$). *On pose $\mathcal{N}(\mu, 0) := \delta_\mu$ (loi de Dirac en μ) : ce n'est plus une loi à densité.*

Remarque B.2 (Forme de la densité). La densité est la « courbe en cloche » de Gauss, symétrique autour de μ , croissante puis décroissante; plus σ^2 est petit, plus elle est resserrée autour de μ .

Exercice B.2 (Encadrement de la queue gaussienne). *Soit $N \sim \mathcal{N}(0, 1)$. Montrer, par intégrations par parties successives de $1 - \Phi(t)$, l'encadrement (excellent pour t grand) :*

$$\left(\frac{1}{t} - \frac{1}{t^3}\right) e^{-t^2/2} \leq \sqrt{2\pi} \mathbb{P}(N \geq t) \leq \frac{1}{t} e^{-t^2/2}, \quad t > 0.$$

APPROXIMATION GAUSSIENNE DE LA LOI BINOMIALE

Théorème B.1 (de Moivre-Laplace). Soit $p \in]0, 1[$ et, pour tout n , $X_n \sim \mathcal{B}(n, p)$. Alors pour tous $-\infty \leq a < b \leq +\infty$,

$$\mathbb{P}\left(np + a\sqrt{np(1-p)} \leq X_n \leq np + b\sqrt{np(1-p)}\right) \xrightarrow[n \rightarrow \infty]{} \Phi(b) - \Phi(a).$$

Remarque B.3 (Heuristique). Le théorème dit qu'à p fixé et n grand,

$$X_n \approx np + \sqrt{np(1-p)} N, \quad N \sim \mathcal{N}(0, 1),$$

c'est-à-dire qu'on approche $\mathcal{B}(n, p)$ par $\mathcal{N}(np, np(1-p))$. Historiquement, de Moivre traita le cas $p = 1/2$ (1733), Laplace le cas général (1812); c'est un cas particulier du théorème central limite. En pratique, l'approximation est jugée bonne dès que $np(1-p) \geq 10$.

Remarque B.4 (Correction de continuité). Pour approcher $\mathbb{P}(a \leq X_n \leq b)$ avec a, b entiers, on approche chaque atome par un intervalle de largeur 1 centré en lui : $\mathbb{P}(X_n = k) \approx \mathbb{P}(k - \frac{1}{2} < X \leq k + \frac{1}{2})$ avec $X \sim \mathcal{N}(np, np(1-p))$. En sommant sur $k \in \{a, \dots, b\}$ et en posant $N \sim \mathcal{N}(0, 1)$,

$$\mathbb{P}(a \leq X_n \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - \frac{1}{2} - np}{\sqrt{np(1-p)}}\right).$$

Les demi-entiers $a - \frac{1}{2}$ et $b + \frac{1}{2}$ (au lieu de a, b) constituent la *correction de continuité*; elle améliore sensiblement l'approximation.

B.3 LOI EXPONENTIELLE

Analogie continu de la loi géométrique.

Définition B.3 (Loi exponentielle). Soit $\lambda > 0$. On dit que $X \sim \mathcal{E}(\lambda)$ si X admet la densité

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x).$$

Proposition B.6 (Fonction de répartition et queue). Pour $X \sim \mathcal{E}(\lambda)$,

$$F_X(t) = (1 - e^{-\lambda t}) \mathbb{1}_{\mathbb{R}_+}(t),$$

Et en particulier

$$\mathbb{P}(X > t) = e^{-\lambda t} \quad (t \geq 0).$$

Proposition B.7 (Espérance, variance, moments). *Si $X \sim \mathcal{E}(\lambda)$, alors*

- $\mathbb{E}[X] = \frac{1}{\lambda}$,
- $\mathbb{V}(X) = \frac{1}{\lambda^2}$,
- $\mathbb{E}[X^n] = \frac{n!}{\lambda^n}$,
- $M_X(t) = \frac{\lambda}{\lambda - t}$ avec $t < \lambda$.

Démonstration.

$$\mathbb{E}[X^n] = \int_0^\infty x^n \lambda e^{-\lambda x} dx = \frac{n!}{\lambda^n}$$

(intégrale gamma). En particulier

$$\mathbb{E}[X] = 1/\lambda, \quad \mathbb{E}[X^2] = 2/\lambda^2,$$

d'où

$$\mathbb{V}(X) = 2/\lambda^2 - 1/\lambda^2 = 1/\lambda^2.$$

Enfin

$$M_X(t) = \int_0^\infty e^{tx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - t}$$

si $t < \lambda$. □

Proposition B.8 (Absence de mémoire — caractérisation à retenir). *Soit X une v.a.r. Alors $X \sim \mathcal{E}(\lambda)$ pour un certain $\lambda > 0$ si et seulement si*

$$\mathbb{P}(X \in \mathbb{R}_+) = 1 \quad \text{et} \quad \mathbb{P}(X > t+s \mid X > t) = \mathbb{P}(X > s), \quad \forall t, s \in \mathbb{R}_+.$$

C'est l'exact analogue continu de la loi géométrique.

Démonstration. La condition s'écrit $g(t+s) = g(t)g(s)$ avec $g(t) = \mathbb{P}(X > t)$. Pour $p, q \in \mathbb{N}^*$,

$$g(p/q) = g(1/q)^p = g(1)^{p/q};$$

comme g est décroissante, on prolonge à tout $t \in \mathbb{R}_+$:

$$g(t) = g(1)^t = e^{-\lambda t} \quad \text{avec} \quad \lambda = -\log g(1) \geq 0.$$

On reconnaît la queue de $\mathcal{E}(\lambda)$. La réciproque est un calcul direct :

$$\frac{\mathbb{P}(X > t + s)}{\mathbb{P}(X > t)} = \frac{e^{-\lambda(t+s)}}{e^{-\lambda t}} = e^{-\lambda s}.$$

□

Lemme B.2 (Changement d'échelle). *Si $X \sim \mathcal{E}(\lambda)$ et $\mu > 0$, alors $\mu X \sim \mathcal{E}(\lambda/\mu)$.*

Démonstration. Pour $x \geq 0$,

$$F_{\mu X}(x) = \mathbb{P}(X \leq x/\mu) = 1 - e^{-(\lambda/\mu)x},$$

qui est la fonction de répartition de $\mathcal{E}(\lambda/\mu)$.

□

B.4 LOI GAMMA

Définition B.4 (Loi gamma). Soient $\alpha, \beta > 0$. On dit que $X \sim \Gamma(\alpha, \beta)$ si X admet la densité

$$f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \mathbb{1}_{]0, +\infty[}(x),$$

où $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$ est la fonction gamma d'Euler, qui vérifie $\Gamma(n) = (n-1)!$ pour $n \in \mathbb{N}^*$ et interpole donc la factorielle.

Proposition B.9 (Espérance, variance, moments). *Si $X \sim \Gamma(\alpha, \beta)$, alors*

- $\mathbb{E}[X] = \frac{\alpha}{\beta}$,
- $\mathbb{V}(X) = \frac{\alpha}{\beta^2}$,
- $\mathbb{E}[X^n] = \frac{\Gamma(\alpha+n)}{\Gamma(\alpha)\beta^n} = \frac{\alpha(\alpha+1)\cdots(\alpha+n-1)}{\beta^n}$,
- $M_X(t) = (1 - t/\beta)^{-\alpha}$ pour $t < \beta$.

La fonction de répartition n'a pas de forme close simple.

Démonstration. Par définition de Γ ,

$$\mathbb{E}[X^n] = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha+n-1} e^{-\beta x} dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+n)}{\beta^{\alpha+n}} = \frac{\Gamma(\alpha+n)}{\Gamma(\alpha)\beta^n}.$$

Pour $n = 1, 2$ on obtient $\mathbb{E}[X] = \alpha/\beta$ et $\mathbb{E}[X^2] = \alpha(\alpha+1)/\beta^2$, d'où $\mathbb{V}(X) = \alpha/\beta^2$. Le calcul de M_X est identique en remplaçant β par $\beta - t$. $\square$

Proposition B.10 (Lien avec l'exponentielle). *On a $\Gamma(1, \beta) = \mathcal{E}(\beta)$. Plus généralement, si $\alpha = r \in \mathbb{N}^*$ et $X_1, \dots, X_r$ sont indépendantes de loi $\mathcal{E}(\beta)$, alors $X_1 + \dots + X_r \sim \Gamma(r, \beta)$.*

Remarque B.5. Les valeurs *non entières* de α donnent un sens à des « sommes non entières » de lois $\mathcal{E}(\beta)$, tout comme Γ interpole la factorielle. La loi gamma est aussi reliée à la loi de Poisson, d'où de nombreuses applications (files d'attente, fiabilité).

B.5 LOI DE CAUCHY

Définition B.5 (Loi de Cauchy). Soit $a > 0$. On dit que $X \sim \mathcal{C}(a)$ si X admet la densité

$$f_X(x) = \frac{a}{\pi} \frac{1}{a^2 + x^2}, \quad x \in \mathbb{R}.$$

Proposition B.11 (Fonction de répartition). *Pour $X \sim \mathcal{C}(a)$,*

$$F_X(t) = \int_{-\infty}^t \frac{a}{\pi} \frac{dx}{a^2 + x^2} = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{t}{a}\right).$$

Proposition B.12 (Aucun moment n'existe). *Si $X \sim \mathcal{C}(a)$, alors $\mathbb{E}[|X|] = +\infty$: l'espérance n'existe pas (et a fortiori ni la variance, ni la FGM). La fonction caractéristique vaut néanmoins $\mathbb{E}[e^{itX}] = e^{-a|t|}$.*

Démonstration.

$$\int_{\mathbb{R}} |x| \frac{a}{\pi} \frac{dx}{a^2 + x^2} = \frac{2a}{\pi} \int_0^\infty \frac{x}{a^2 + x^2} dx$$

diverge (l'intégrande se comporte en $1/x$ à l'infini). Donc X n'est pas intégrable. $\square$

Remarque B.6. La densité de Cauchy a elle aussi une allure « en cloche », mais à *queues lourdes* : elle décroît en $1/x^2$, bien plus lentement que la gaussienne, ce qui explique la non-existence des moments.

- Exercice B.3** (Loi de l'inverse). 1. *Montrer que $\arctan(t) + \arctan(1/t) = \frac{\pi}{2}$ ($\mathbb{1}_{t>0} - \mathbb{1}_{t<0}$) pour tout $t \neq 0$.*
2. *Soit $X \sim \mathcal{C}(a)$ (on a $\mathbb{P}(X \neq 0) = 1$). En déduire la loi de $1/X$. (Réponse : $1/X \sim \mathcal{C}(1/a)$.)*

B.6 AUTRES LOIS À DENSITÉ

Comme dans le cas discret, ces lois ne sont pas à connaître par cœur.

LOI DE WEIBULL

Définition B.6 (Loi de Weibull). Soient $\alpha, \beta > 0$. On dit que $X \sim \text{Weibull}(\alpha, \beta)$ si sa fonction de répartition est

$$F_X(x) = \begin{cases} 1 - \exp(-(x/\alpha)^\beta), & x \geq 0, \\ 0, & x < 0, \end{cases}$$

soit, en dérivant, la densité $f_X(x) = \frac{\beta}{\alpha} \left(\frac{x}{\alpha}\right)^{\beta-1} \exp(-(x/\alpha)^\beta) \mathbb{1}_{x \geq 0}$.

Proposition B.13 (Premiers moments). Si $X \sim \text{Weibull}(\alpha, \beta)$, alors

$$\mathbb{E}[X] = \alpha \Gamma\left(1 + \frac{1}{\beta}\right), \quad \mathbb{V}(X) = \alpha^2 \left[\Gamma\left(1 + \frac{2}{\beta}\right) - \Gamma\left(1 + \frac{1}{\beta}\right)^2 \right].$$

Remarque B.7. La loi de Weibull généralise l'exponentielle : pour $\beta = 1$ on retrouve $\mathcal{E}(1/\alpha)$. Selon que $\beta < 1$, $\beta = 1$ ou $\beta > 1$, le « taux de panne » décroît, reste constant ou croît avec le temps : d'où son usage en modélisation de l'usure de pièces et en fiabilité.

Probabilité

Ce cours présente les fondements de la théorie des probabilités centrés sur l'étude d'une variable aléatoire réelle unique. On y étudie d'abord le cadre axiomatique, la fonction de répartition et les propriétés des grandes classes de lois (discrètes et à densité), ainsi que les méthodes pour déterminer la loi d'une fonction d'une variable et simuler ces comportements. Le cours approfondit ensuite les notions d'espérance et de moments (variance), introduisant la fonction génératrice comme outil de caractérisation analytique. Enfin, on aborde les inégalités probabilistes incontournables (Markov, Bienaymé-Tchebychev, Jensen) et les définitions avancées de l'espérance selon Lebesgue et Riemann-Stieltjes. Le fil conducteur est la construction d'un cadre théorique et calculatoire rigoureux avant d'étendre l'analyse à plusieurs variables.

