

PROBABILITÉ

FONDEMENTS, CARACTÉRISATION ET ANALYSE DES VARIABLES
ALÉATOIRES RÉELLES.

Lorenzo Segoni



TABLE DES MATIÈRES

I	Variables aléatoires réelles	3
1.1	Définition et axiomes	3
	Axiomes des probabilités	3
1.2	Événements	9
1.3	Fonction de répartition	10
1.4	Classes de variables aléatoires	15
1.5	Loi d'une fonction d'une variable aléatoire	25
	Fonction discrète d'une v.a.r.	25
	Fonction régulière d'une variable aléatoire à densité	27
1.6	Simulation de lois	29
2	Espérance et Moments	41
2.1	Espérance d'une variable aléatoire	41
	Variable aléatoire positive ou nulle	41
	Variable aléatoire signée	43
2.2	Espérance d'une fonction d'une variable aléatoire	43
	Caractérisation des lois de fonctions de variables aléatoires	49
2.3	Moments et quantités associées	52
	Espérance	53
	Variance	53
2.4	Fonction génératrice des moments	57
2.5	Inégalités	61
	Inégalité de Markov	61
	Inégalité de Bienaymé-Tchebychev	62
	Inégalité de Jensen	63
2.6	Autres définitions de l'espérance	65
	À la Lebesgue.	65
	À la Riemann-Stieltjes	67
3	Complet page 21	74

VARIABLES ALÉATOIRES RÉELLES

I.1 DÉFINITION ET AXIOMES

On veut modéliser une expérience aléatoire via une variable aléatoire (v.a.) X à valeurs réelles, et donner un sens à $\mathbb{P}(X \in A)$ pour $A \subset \mathbb{R}$.

Jusqu'à présent, on ne considérait que des v.a. *discrètes*, prenant un nombre fini ou dénombrable de valeurs $S_X = \{x : \mathbb{P}(X = x) \neq 0\}$. Dans ce cas, la fonction de masse suffisait à définir la loi de X , puisque

$$\mathbb{P}(X \in A) = \sum_{x \in A} \mathbb{P}(X = x).$$

On souhaite maintenant s'affranchir de cette restriction, sans chercher à définir formellement une v.a. générale, mais seulement à en manipuler les probabilités.

Un problème apparaît alors : cette approche par sommation ne fonctionne plus en général. Prenons l'exemple d'un nombre X choisi uniformément dans $[0, 1]$. Par symétrie, on voudrait que $\mathbb{P}(X = x)$ soit la même pour tout $x \in [0, 1]$. Mais comme $[0, 1]$ est infini (non dénombrable), cela force $\mathbb{P}(X = x) = 0$ pour tout x — sinon $\mathbb{P}(X \in [0, 1])$ serait infinie.

Ainsi, connaître $\mathbb{P}(X = x)$ pour chaque x (ici, tous nuls) ne permet pas de reconstruire $\mathbb{P}(X \in A)$ pour un ensemble A quelconque.

AXIOMES DES PROBABILITÉS

Il nous faut donc trouver une autre approche pour définir les probabilités $\mathbb{P}(X \in A)$ pour des ensembles $A \subset \mathbb{R}$, c'est-à-dire pour spécifier la loi de X . Le point de départ est l'observation suivante : ces probabilités ne peuvent pas être arbitraires, elles doivent satisfaire certaines propriétés de cohérence.

Définition I.1. Si $A, B \subset \mathbb{R}$ sont deux ensembles disjoints (d'intersection vide), on souhaite que la probabilité soit *additive* sur ces ensembles, c'est-à-dire que

$$\mathbb{P}(X \in A \cup B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B).$$

Cette exigence de cohérence, ainsi que d'autres analogues, va nous permettre de construire une théorie générale. Pour définir la loi d'une variable aléatoire X à valeurs réelles, on part donc d'un petit nombre de règles fondamentales, appelées axiomes. Avant de les énoncer, introduisons une convention qui simplifiera grandement la présentation :

Définition 1.2. Dans toute la suite, on suppose que tout ensemble $A \subset \mathbb{R}$ considéré est soit un intervalle, soit une réunion finie d'intervalles disjoints.

Remarque 1.1. On entend ici par « intervalle » aussi bien les intervalles ouverts, fermés ou semi-ouverts, bornés ou non bornés. Cette notion englobe en particulier les cas limites que sont l'ensemble vide $\emptyset$ et la droite réelle $\mathbb{R}$ tout entière.

Cette classe d'ensembles présente l'avantage d'être stable pour un certain nombre d'opérations élémentaires, comme le montre la proposition suivante.

Proposition 1.1. Notons $A^c = \mathbb{R} \setminus A$ le complémentaire d'un ensemble A .

1. Si $A \subset \mathbb{R}$ est de la forme décrite ci-dessus, alors son complémentaire A^c l'est également.
2. Si A et B sont tous deux de cette forme, alors leur union $A \cup B$ et leur intersection $A \cap B$ le sont aussi.
3. En revanche, cette stabilité ne s'étend pas aux opérations infinies : si $A_0, A_1, A_2, \dots$ est une suite (infinie) d'ensembles de cette forme, alors $\bigcup_{n \in \mathbb{N}} A_n$ et $\bigcap_{n \in \mathbb{N}} A_n$ ne sont pas nécessairement des réunions finies d'intervalles.

Exercice 1.1. Démontrer cette proposition.

Précisons à présent les règles de calcul régissant les quantités $\mathbb{P}(X \in A)$, c'est-à-dire les axiomes que nous allons supposer valables pour toute la suite.

Définition 1.3. On suppose que :

1. *Positivité* : $\mathbb{P}(X \in A) \geq 0$ pour tout $A \subset \mathbb{R}$
2. $\mathbb{P}(X \in \emptyset) = 0$ et $\mathbb{P}(X \in \mathbb{R}) = 1$,
3. *Additivité* : Si $A, B \subset \mathbb{R}$ sont disjoints, alors

$$\mathbb{P}(X \in A \cup B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B).$$

Ces trois règles peuvent paraître minimales, mais elles suffisent déjà à en déduire un certain nombre de propriétés utiles, que nous établissons dans la proposition suivante. Nous introduirons un quatrième axiome un peu plus loin, une fois que nous aurons besoin de traiter des réunions infinies d'ensembles.

Proposition 1.2. On a les propriétés :

1. Si $A \subset B$, alors

$$\mathbb{P}(X \in A) \leq \mathbb{P}(X \in B) \quad (\text{monotonie de } A \mapsto \mathbb{P}(X \in A)).$$

2. $\mathbb{P}(X \in A) \in [0, 1]$ pour tout $A \subset \mathbb{R}$.
3. Si $A \subset B$, alors

$$\mathbb{P}(X \in B \setminus A) = \mathbb{P}(X \in B) - \mathbb{P}(X \in A).$$

En particulier, en prenant $B = \mathbb{R}$,

$$\mathbb{P}(X \in A^c) = 1 - \mathbb{P}(X \in A).$$

4. *Additivité finie* : Si $A_0, A_1, \dots, A_n \subset \mathbb{R}$ sont deux à deux disjoints, alors

$$\mathbb{P}\left(X \in \bigcup_{k=0}^n A_k\right) = \sum_{k=0}^n \mathbb{P}(X \in A_k).$$

Remarque 1.2. Ces propriétés ne sont pas des axiomes supplémentaires : elles découlent toutes des trois règles précédentes. Voyons rapidement pourquoi.

- Le point 1 (monotonie) découle immédiatement du point 3 : puisque $\mathbb{P}(X \in B \setminus A) \geq 0$ par positivité (règle 1), on a nécessairement $\mathbb{P}(X \in A) \leq \mathbb{P}(X \in B)$.
- Le point 2 est alors une conséquence de la monotonie appliquée à $\emptyset \subset A \subset \mathbb{R}$, combinée avec la règle 2 : on obtient $0 = \mathbb{P}(X \in \emptyset) \leq \mathbb{P}(X \in A) \leq \mathbb{P}(X \in \mathbb{R}) = 1$.
- Pour le point 3, remarquons que si $A \subset B$, alors B se décompose comme la réunion disjointe $B = A \cup (B \setminus A)$. L'axiome d'additivité (règle 3) donne alors directement

$$\mathbb{P}(X \in B) = \mathbb{P}(X \in A) + \mathbb{P}(X \in B \setminus A),$$

d'où l'on tire $\mathbb{P}(X \in B \setminus A) = \mathbb{P}(X \in B) - \mathbb{P}(X \in A)$.

- Enfin, le point 4 s'obtient par une récurrence immédiate sur n , en appliquant l'axiome d'additivité (règle 3) de proche en proche aux ensembles $A_0, \dots, A_n$, qui sont deux à deux disjoints.

On peut à présent introduire le quatrième axiome, qui vient compléter les trois premiers pour traiter le cas des réunions infinies.

Définition 1.4. On suppose que :

4. *Continuité croissante* : Si $A_0, A_1, A_2, \dots$ est une suite croissante d'ensembles (c'est-à-dire $A_n \subset A_{n+1}$ pour tout $n \in \mathbb{N}$) telle que $\bigcup_{n \in \mathbb{N}} A_n$ est encore un ensemble de la forme considérée, alors

$$\mathbb{P}\left(X \in \bigcup_{n \in \mathbb{N}} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n).$$

Notons que cette limite existe bien, puisque la suite $(\mathbb{P}(X \in A_n))_n$ est croissante par la propriété de monotonie établie plus haut, et majorée par 1.

Cet axiome mérite un commentaire. En effet, il n'est pas totalement nouveau : une partie de l'énoncé peut déjà se déduire des axiomes 1 à 3. C'est l'objet de l'exercice suivant.

Exercice 1.2. En utilisant uniquement les axiomes 1 à 3, montrer que l'on a déjà l'inégalité

$$\mathbb{P}\left(X \in \bigcup_{n \in \mathbb{N}} A_n\right) \geq \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n).$$

Remarquons également que l'axiome 4 admet une formulation équivalente en termes de suites décroissantes, que l'on obtient par un simple passage au complémentaire :

Définition 1.5. 4' Si $A_0, A_1, A_2, \dots$ est une suite ****décroissante**** d'ensembles (c'est-à-dire $A_{n+1} \subset A_n$ pour tout $n \in \mathbb{N}$) telle que $\bigcap_{n \in \mathbb{N}} A_n$ est encore un ensemble de la forme considérée, alors

$$\mathbb{P} \left(X \in \bigcap_{n \in \mathbb{N}} A_n \right) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n) \quad (\text{continuité décroissante}).$$

Remarque 1.3. L'équivalence entre 4 et 4' se voit en posant $B_n = A_n^c$: si (A_n) est décroissante, alors (B_n) est croissante, et $\bigcap_n A_n = (\bigcup_n B_n)^c$. Il suffit alors d'appliquer l'axiome 4 à la suite (B_n) et de repasser au complémentaire à l'aide de la propriété 3 de la proposition précédente.

Maintenant que les quatre axiomes sont posés, nous sommes en mesure de définir formellement ce qu'est une variable aléatoire.

Définition 1.6. On dit que X est une variable aléatoire s'il existe une famille de nombres $(\mathbb{P}(X \in A))_{A \subset \mathbb{R}}$ (autrement dit, une fonction $A \mapsto \mathbb{P}(X \in A)$ à valeurs dans $\mathbb{R}$) qui satisfait aux axiomes 1, 2, 3 et 4 ci-dessus. Cette famille, ou cette fonction, est appelée la loi de X .

Il est important de bien comprendre l'esprit de cette définition : on ne cherche pas ici à dire ce qu'est intrinsèquement une variable aléatoire, mais seulement à caractériser son comportement à travers les probabilités qu'elle induit sur les sous-ensembles de $\mathbb{R}$. C'est cette loi, c'est-à-dire la donnée de la fonction $A \mapsto \mathbb{P}(X \in A)$, qui contient toute l'information probabiliste dont nous aurons besoin par la suite.

Une conséquence importante des axiomes 3 et 4 est la propriété de *sigma-additivité*, qui étend l'additivité finie au cas d'une infinité dénombrable d'ensembles.

Définition 1.7. 4'' Si $A_0, A_1, A_2, \dots$ est une suite d'ensembles deux à deux disjoints (c'est-à-dire que $m \neq n$ implique $A_m \cap A_n = \emptyset$), alors

$$\mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} A_n \right) = \sum_{n \in \mathbb{N}} \mathbb{P}(X \in A_n).$$

Démonstration. Posons $B_n = \bigcup_{k=0}^n A_k$: comme les A_k sont deux à deux disjoints, cette union est disjointe, et la suite $(B_n)_{n \geq 0}$ est croissante, avec $\bigcup_{n \in \mathbb{N}} B_n = \bigcup_{n \in \mathbb{N}} A_n$. En appliquant successivement l'axiome 4 (continuité croissante), puis l'additivité finie (propriété 4 de la proposition précédente), on obtient :

$$\begin{aligned} \mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} A_n \right) &= \mathbb{P} \left(X \in \bigcup_{n \in \mathbb{N}} B_n \right) \\ &= \lim_{n \rightarrow \infty} \mathbb{P}(X \in B_n) \\ &= \lim_{n \rightarrow \infty} \sum_{k=0}^n \mathbb{P}(X \in A_k), \end{aligned}$$

et cette dernière limite est précisément, par définition, la somme de la série $\sum_{n \in \mathbb{N}} \mathbb{P}(X \in A_n)$. $\square$

Ce résultat montre que, sous les axiomes 1 à 4, la sigma-additivité est automatiquement satisfaite. Il est naturel de se demander si l'on peut en réalité s'en tenir à un jeu d'axiomes plus économique. C'est effectivement le cas, comme le résume la proposition suivante.

Définition 1.8. Les jeux d'axiomes suivants sont équivalents :

- 1, 2, 3, 4
- 1, 2, 3, 4'
- 1, 2, 4''

Parmi ces jeux d'axiomes équivalents, il est courant de retenir le jeu 1, 2, 4''. Ce sont précisément ces trois axiomes qui figurent usuellement dans la définition d'une mesure de probabilité sur $\mathbb{R}$.

Il nous reste un dernier point à traiter. Jusqu'ici, $\mathbb{P}(X \in A)$ n'a été défini que pour les ensembles A qui sont des intervalles ou des réunions finies d'intervalles. Or nous aurons parfois besoin de donner un sens à $\mathbb{P}(X \in A)$ pour des ensembles A qui ne sont pas de cette forme — par exemple $A = \mathbb{N}$, ou plus généralement n'importe quel ensemble dénombrable.

Pour cela, on se limite aux ensembles A qui peuvent s'écrire comme limite monotone d'une suite d'ensembles $(A_n)_{n \geq 0}$ de la forme considérée (réunion finie d'intervalles). Par limite monotone, on entend un ensemble de la forme $\bigcup_n A_n$ (pour une suite

croissante (A_n)) ou $\bigcap_n A_n$ (pour une suite décroissante (A_n)), exactement comme dans les axiomes 4 et 4'. On pose alors, par définition,

$$\mathbb{P}(X \in A) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in A_n),$$

où l'on note que cette limite existe toujours, par monotonie de la suite $(\mathbb{P}(X \in A_n))_n$.

Un exemple typique d'un tel ensemble est l'ensemble des rationnels $\mathbb{Q}$, ou plus généralement n'importe quel ensemble dénombrable $S \subset \mathbb{R}$. Pour un tel ensemble S , on vérifie que la définition ci-dessus redonne bien la formule attendue :

$$\mathbb{P}(X \in S) = \sum_{x \in S} \mathbb{P}(X = x).$$

1.2 ÉVÉNEMENTS

Rappelons pour finir la notion d'événement, qui nous accompagnera tout au long de ce cours.

Définition 1.9. Un événement est simplement un sous-ensemble de l'ensemble des résultats possibles d'une expérience aléatoire, et on dit que l'événement est réalisé si le résultat effectif de l'expérience appartient à ce sous-ensemble.

Exemple 1.1. Lors d'un lancer de dé, on pourrait s'intéresser à l'événement E : « le dé donne un nombre pair ».

Si X désigne la v.a. représentant le nombre obtenu, cet événement s'écrit symboliquement

$$E = \{X \in \{2, 4, 6\}\}, \quad \text{ou encore} \quad E = \{X \text{ pair}\}.$$

Cet événement se réalise alors avec la probabilité $\mathbb{P}(E) = \mathbb{P}(X \in \{2, 4, 6\})$ (on omet ici, par convention, les accolades autour de l'ensemble $\{2, 4, 6\}$ dans la notation).

Dans ce cours, nous nous limiterons aux événements définis à partir de variables aléatoires, c'est-à-dire aux événements de la forme

$$E = \{X \in A\}, \quad \text{pour } X \text{ une variable aléatoire et } A \subset \mathbb{R}.$$

La probabilité d'un tel événement est alors naturellement définie par $\mathbb{P}(E) = \mathbb{P}(X \in A)$.

L'intérêt de cette formulation est que l'on peut manipuler ces événements exactement comme des ensembles, en leur appliquant les opérations ensemblistes usuelles (complémentaire, union, intersection). On obtient ainsi les identités suivantes, qui traduisent simplement les opérations sur les ensembles A et B en opérations sur les événements correspondants :

$$\begin{aligned}\{X \in A\}^c &= \{X \in A^c\}, \\ \{X \in A\} \cup \{X \in B\} &= \{X \in A \cup B\}, \\ \{X \in A\} \cap \{X \in B\} &= \{X \in A \cap B\}.\end{aligned}$$

Ces identités permettent, en pratique, de traduire n'importe quelle combinaison logique d'événements (négation, « ou », « et ») en une opération sur les sous-ensembles de $\mathbb{R}$ correspondants, et donc de calculer sa probabilité à l'aide des axiomes énoncés précédemment.

Définition 1.10. Un événement de probabilité 1 est dit presque sûr. Un événement de probabilité 0 est dit négligeable.

Ainsi, un événement négligeable est le complémentaire d'un événement presque sûr.

Remarque 1.4. On rencontre la notation :

$$X \in A, \text{ p.s.} \quad (\text{pour un événement } A \text{ presque sûr})$$

et qui se lit : "presque sûrement, X appartient à A ".

1.3 FONCTION DE RÉPARTITION

Nous avons vu, dans la section précédente, comment définir la loi d'une variable aléatoire à partir des axiomes 1 à 4. Cette loi est constituée d'une famille de nombres réels $\mathbb{P}(X \in A)$, indexée par tous les ensembles $A \subset \mathbb{R}$ (de la forme considérée). Une telle définition est en pratique très lourde à manipuler : pour caractériser une loi particulière, il faudrait a priori spécifier la valeur de $\mathbb{P}(X \in A)$ pour chacun de ces ensembles A , qui peuvent avoir des formes arbitrairement compliquées.

Rappelons que, dans le cas d'une v.a. discrète (c'est-à-dire ne prenant qu'un nombre fini ou dénombrable de valeurs, que nous étudierons plus loin), cette difficulté disparaît : il suffit de connaître les valeurs $\mathbb{P}(X = x)$ pour tout x , c'est-à-dire la fonction de masse, pour reconstituer toute la loi. Nous avons cependant vu dans la section précédente

que cette simplification n'est plus disponible dans le cadre général, puisque ces valeurs peuvent être nulles pour tout $x \in \mathbb{R}$, sans pour autant que X soit une v.a. triviale.

L'astuce consiste alors à ne plus considérer $\mathbb{P}(X = x)$, mais plutôt les valeurs de $\mathbb{P}(X \leq x)$ pour tout $x \in \mathbb{R}$. (On aurait tout aussi bien pu choisir $\mathbb{P}(X < x)$, $\mathbb{P}(X \geq x)$ ou $\mathbb{P}(X > x)$; c'est simplement la convention qui a retenu $\mathbb{P}(X \leq x)$.) On obtient ainsi une fonction $F_X : \mathbb{R} \rightarrow [0, 1]$, définie par

$$F_X(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R},$$

que l'on appelle la fonction de répartition de X .

Il nous reste maintenant deux questions à élucider : d'une part, montrer que cette fonction F_X détermine bien entièrement la loi de X ; d'autre part, caractériser précisément quelles fonctions $F : \mathbb{R} \rightarrow [0, 1]$ peuvent apparaître comme fonction de répartition d'une variable aléatoire. C'est l'objet du théorème suivant.

Théorème 1.1. 1. *La fonction de répartition F_X d'une v.a.r. possède les propriétés suivantes :*

- *elle est croissante,*
- $F_X(-\infty) := \lim_{x \rightarrow -\infty} F_X(x) = 0,$
- $F_X(+\infty) := \lim_{x \rightarrow +\infty} F_X(x) = 1,$
- *elle est continue à droite.*

2. *La loi d'une v.a.r. X est déterminée de manière unique par sa fonction de répartition F_X .*

3. *Réciproquement, toute fonction sur $\mathbb{R}$ possédant les propriétés énoncées au point 1. est la fonction de répartition d'une variable aléatoire réelle.*

Ce théorème est fondamental : il montre que la fonction de répartition permet d'atteindre, dans le cas général, le même degré de simplicité que la fonction de masse dans le cas discret. Dans les deux situations, la notion — a priori complexe — de loi d'une variable aléatoire se ramène finalement à la donnée d'une simple fonction sur $\mathbb{R}$.

Il convient toutefois de nuancer cette simplicité : elle est avant tout conceptuelle. En pratique, la fonction de répartition F_X n'admet bien souvent pas d'expression explicite simple, et son calcul effectif peut s'avérer difficile — ce qui n'enlève rien à son importance théorique comme objet caractérisant entièrement la loi de X .

Démonstration. 1. Montrons les propriétés énoncées :

- Croissance : Ceci est une conséquence immédiate de la monotonie de $\mathbb{P}(X \in A)$ en A . Plus précisément, soient $x, y \in \mathbb{R}$ avec $x < y$. Alors $] - \infty, x] \subset] - \infty, y]$, si bien que

$$F_X(x) = \mathbb{P}(X \in] - \infty, x]) \leq \mathbb{P}(X \in] - \infty, y]) = F_X(y).$$

- On remarque d'abord que la fonction F_X est croissante et bornée inférieurement (par 0), la limite $F_X(-\infty) = \lim_{x \rightarrow -\infty} F_X(x)$ existe donc bien. En particulier,

$$F_X(-\infty) = \lim_{n \rightarrow \infty} F_X(-n) = \lim_{n \rightarrow \infty} \mathbb{P}(X \in] - \infty, -n]).$$

La suite d'ensembles $A_n =] - \infty, -n]$ est décroissante et d'intersection vide. L'axiome 4' donne donc :

$$F_X(-\infty) = \mathbb{P} \left(X \in \bigcap_{n=1}^{\infty}] - \infty, -n] \right) = \mathbb{P}(X \in \emptyset) = 0.$$

- Pareil que $F_X(-\infty)$, on utilise le fait que F_X est bornée par 1 pour montrer l'existence de la limite, puis l'axiome 4 pour l'identifier.
- Continuité à droite. Soit $x \in \mathbb{R}$. Puisque F_X est croissante et bornée inférieurement, la limite $F_X(x^+) := \lim_{y \downarrow x} F_X(y)$ existe. En particulier,

$$F_X(x^+) = \lim_{n \rightarrow \infty} F_X \left(x + \frac{1}{n} \right) = \mathbb{P} \left(X \in \bigcap_{n=1}^{\infty}] - \infty, x + \frac{1}{n}] \right),$$

où on a encore utilisé l'axiome 4'. Le point clé est alors l'égalité suivante :

$$\bigcap_{n=1}^{\infty}] - \infty, x + \frac{1}{n}] =] - \infty, x].$$

Cela donne que $F_X(x^+) = \mathbb{P}(X \in] - \infty, x]) = F_X(x)$ et donc F_X est continue à droite en x . Puisque $x \in \mathbb{R}$ était arbitraire, F_X est continue à droite sur $\mathbb{R}$.

2. On veut montrer que pour tout ensemble A qui est une union finie d'intervalles disjoints, $\mathbb{P}(X \in A)$ s'écrit à partir de la fonction de répartition F_X . On procède cas par cas :
- $A =]-\infty, x]$, $x \in \mathbb{R}$: Par définition, $\mathbb{P}(X \in]-\infty, x]) = \mathbb{P}(X \leq x) = F_X(x)$.
 - $A =]-\infty, x[$, $x \in \mathbb{R}$: L'intervalle ouvert $] - \infty, x[$ s'écrit comme l'union dénombrable d'intervalles fermés :

$$]-\infty, x[= \bigcup_{n=1}^{\infty}]-\infty, x - \frac{1}{n}].$$

L'axiome 4 donne alors

$$\mathbb{P}(X < x) = \lim_{n \rightarrow \infty} \mathbb{P}\left(X \leq x - \frac{1}{n}\right) = \lim_{n \rightarrow \infty} F_X\left(x - \frac{1}{n}\right) = F_X(x^-),$$

où $F_X(x^-) := \lim_{y \uparrow x} F_X(y)$ qui existe car la fonction F_X est croissante.

- $A =]x, \infty[$ ou $A = [x, \infty[$, $x \in \mathbb{R}$: On utilise le fait que $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ et on se ramène aux deux premiers cas.
- $A =]x, y]$, $x < y$: On obtient

$$\mathbb{P}(x < X \leq y) = \mathbb{P}(X \leq y) - \mathbb{P}(X \leq x) = F_X(y) - F_X(x).$$

- $A = [x, y]$, $A = [x, y[$ ou $A =]x, y[$: Similaire à $A =]x, y]$, avec éventuellement $F_X(y^-)$ et $F_X(x^-)$ à la place de $F_X(y)$ ou $F_X(x)$. Par exemple

$$\mathbb{P}(X \in [x, y]) = \mathbb{P}(X \leq y) - \mathbb{P}(X < x) = F_X(y) - F_X(x^-).$$

- $A = I_1 \cup \dots \cup I_n$, avec $I_1, \dots, I_n$ des intervalles disjoints, alors par l'axiome 3, on a

$$\mathbb{P}(X \in A) = \mathbb{P}(X \in I_1) + \dots + \mathbb{P}(X \in I_n).$$

On se ramène alors au cas d'un intervalle traité précédemment.

3. Si F est une fonction avec les propriétés du théorème, on définit la loi d'une variable aléatoire X à partir de F en utilisant les formules pour $\mathbb{P}(X \in A)$ ci-dessus. Il suffit alors de montrer que cette loi satisfait aux axiomes 1 à 4. On omet la preuve de ce fait qui est laissée en exercice. La fonction F est alors par définition la fonction de répartition de cette variable aléatoire.

□

Introduisons, pour tout réel x , la notation $F_X(x^-) = \lim_{t \rightarrow x, t < x} F_X(t)$ pour désigner la limite à gauche de F_X en x (limite qui existe bien, la fonction F_X étant croissante).

Soulignons un fait important, rencontré au fil de la preuve du théorème précédent : la fonction de répartition F_X , étant croissante, admet une limite à gauche en tout point x , et cette limite s'identifie précisément à

$$F_X(x^-) = \mathbb{P}(X < x).$$

Exercice 1.3. Soit F une fonction de répartition. On suppose qu'il existe $x_0 < x_1$ deux réels tels que $\lim_{x \rightarrow x_0, x > x_0} F(x) = 0$, $\lim_{x \rightarrow x_1, x < x_1} F(x) = 1$.

1. Calculer $F(x_0)$ et $F(x_1)$.
2. En déduire que F est caractérisée par sa restriction à l'intervalle $]x_0, x_1[$.

1.4 CLASSES DE VARIABLES ALÉATOIRES

Ayant établi, à travers le théorème précédent, la forme générale que peut prendre la loi d'une v.a. réelle via sa fonction de répartition, il est naturel de vouloir maintenant distinguer différentes classes de v.a. selon les propriétés de leur fonction de répartition. Un premier outil utile dans cette optique est la notion d'atome.

Définition 1.11. On dit que $x \in \mathbb{R}$ est un atome de masse $m > 0$ de la loi de X si $\mathbb{P}(X = x) = m$, ou, de façon équivalente, si $F_X(x) - F_X(x^-) = m$.

Cette équivalence provient directement du calcul suivant :

$$\mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-).$$

Ainsi, un réel x est un atome de masse $m > 0$ pour la loi de X si et seulement si x est un point de discontinuité de la fonction F_X ; dans ce cas, m est précisément la hauteur du saut de F_X en x , à savoir $m = F_X(x) - F_X(x^-)$. En particulier, on retiendra le fait suivant : une v.a.r. X n'a aucun atome si et seulement si sa fonction de répartition F_X est continue sur $\mathbb{R}$.

Il découle alors d'un résultat classique sur les fonctions croissantes que le nombre d'atomes d'une loi ne peut jamais être trop grand.

Corollaire 1.1. *La loi d'une variable aléatoire X possède un nombre au plus dénombrable — c'est-à-dire fini ou dénombrable — d'atomes.*

Démonstration. Puisque la fonction F_X est croissante, il suffit de montrer qu'une fonction croissante ne peut avoir qu'un nombre au plus dénombrable de sauts. C'est un résultat classique d'analyse, que l'on pourra établir à titre d'exercice, en procédant en deux étapes : montrer d'abord que, pour une fonction croissante sur $[0, 1]$, le nombre de sauts de taille supérieure ou égale à $1/n$ est nécessairement fini, majoré par $n \cdot (f(1) - f(0))$; passer ensuite à la limite croissante en n , en remarquant qu'une réunion dénombrable d'ensembles finis est dénombrable, pour conclure que l'ensemble de tous les sauts (de taille strictement positive) est au plus dénombrable. $\square$

Variables aléatoires discrètes Nous disposons maintenant du vocabulaire nécessaire pour définir précisément une première classe importante de v.a. : celles dont toute la masse de probabilité se trouve concentrée dans leurs atomes.

Définition 1.12. Soit X une v.a.r. On dit que X est discrète s'il existe un sous-ensemble $S \subset \mathbb{R}$ au plus dénombrable tel que $\mathbb{P}(X \in S) = 1$.

Notons que cette définition ne serait pas pertinente si $\mathbb{R}$ lui-même était dénombrable — ce qui, bien entendu, n'est pas le cas : le fait que X concentre toute sa probabilité sur un ensemble dénombrable S est donc bien une restriction non triviale.

Parmi tous les ensembles dénombrables S satisfaisant $\mathbb{P}(X \in S) = 1$, il en existe un qui joue un rôle privilégié : celui des atomes de la loi de X .

Définition 1.13. On appelle ensemble des atomes de la loi de X , et on note S_X , l'ensemble

$$S_X := \{x : \mathbb{P}(X = x) > 0\}.$$

Nous avons vu au paragraphe précédent que S_X est toujours au plus dénombrable, quelle que soit la v.a. X considérée (discrète ou non). On peut donc toujours l'écrire sous la forme

$$S_X = \{s_k, k \in \mathbb{N}\} \quad \text{ou} \quad S_X = \{s_k, 0 \leq k \leq n\} \text{ pour un certain } n \in \mathbb{N},$$

où les réels s_k sont deux à deux distincts (le premier cas, infini dénombrable, pouvant être vu comme correspondant formellement à $n = +\infty$). Par abus de notation, on écrira simplement $S_X = \{s_k\}$, sans préciser à chaque fois si l'ensemble d'indices est fini ou infini.

Remarquons enfin que, pour une v.a. discrète, l'ensemble S_X des atomes constitue précisément un choix possible — et en un sens le plus économique — pour l'ensemble S de la définition : c'est le plus petit ensemble sur lequel se concentre toute la masse de probabilité de X .

Exercice 1.4. *Montrer que S_X est toujours au plus dénombrable : commencer par montrer qu'il y a au plus n atomes de masse $\geq 1/n$.*

Munis de la notion d'ensemble des atomes S_X , nous pouvons maintenant associer à toute v.a. discrète une fonction qui résume entièrement sa loi.

Définition 1.14 (Fonction de masse). Soit X une v.a.r. discrète, de support $S_X = \{s_k\}_k$. On appelle fonction de masse de X la fonction

$$\begin{cases} S_X \rightarrow \mathbb{R} \\ s_k \mapsto p_k := \mathbb{P}(X = s_k). \end{cases}$$

Les éléments s_k s'appellent alors les atomes de la loi, et p_k est la masse de l'atome s_k .

Il est naturel de se demander à quelle condition, exprimée directement en termes des masses p_k , une v.a.r. X est effectivement discrète. La proposition suivante répond à cette question et fournit ainsi un critère pratique, souvent bien plus simple à vérifier que la définition initiale.

Proposition 1.3. Soit X une v.a.r. Alors les trois assertions suivantes sont équivalentes :

- X est discrète;
- l'ensemble S_X des atomes de X vérifie $\mathbb{P}(X \in S_X) = 1$;
- $\sum_k p_k = 1$.

Intuitivement, cela signifie que toute la masse de la loi de X est concentrée dans ses seuls atomes : on lit aussi que la loi de X est "purement atomique".

Démonstration. — Puisque l'ensemble des atomes est au plus dénombrable, $\mathbb{P}(X \in S_X) = 1$ implique directement que X est discrète.

Si réciproquement X est discrète, soit S ensemble au plus dénombrable qui vérifie $\mathbb{P}(X \in S) = 1$.

- D'abord, on doit avoir $S \subset S_X$ car pour $x \in S_X \cap S^c$, on aurait $0 < \mathbb{P}(X = x) \leq \mathbb{P}(X \in S^c) = 1 - \mathbb{P}(X \in S) = 0$, absurde.

Dès lors on peut écrire S sous forme de la réunion disjointe : $S = S_X \cup (S \setminus S_X)$ donc $\mathbb{P}(X \in S \setminus S_X) = \sum_{s \in S \setminus S_X} \mathbb{P}(X = s) = \sum_{s \in S \setminus S_X} 0 = 0$ donc :

$$\begin{aligned}
 1 &= \mathbb{P}(X \in S) \\
 &= \mathbb{P}(X \in S \setminus S_X) + \mathbb{P}(X \in S_X) \\
 &= \mathbb{P}(X \in S_X)
 \end{aligned}$$

- L'équivalence concernant la somme des masses des atomes découle simplement du fait que S_X est une réunion au plus dénombrable de singletons (les atomes) :

$$\begin{aligned}
 \mathbb{P}(X \in S_X) &= \mathbb{P}\left(X \in \bigcup_k \{x_k\}\right) \\
 &= \sum_k \mathbb{P}(X = x_k) \\
 &= \sum_k p_k
 \end{aligned}$$

□

Un corollaire immédiat de la démonstration de la proposition précédente mérite d'être souligné : S_X est, dans le cas des v.a.r. discrètes, le plus petit ensemble $S \subset \mathbb{R}$ tel que $\mathbb{P}(X \in S) = 1$. C'est pour cette raison qu'on l'appelle également le support de la loi de X : il s'agit, en quelque sorte, du plus petit sous-ensemble de $\mathbb{R}$ nécessaire pour « porter » toute la probabilité de X .

Avant d'aller plus loin, il est utile d'introduire une notation qui va grandement simplifier l'écriture des formules à venir : la fonction indicatrice d'un ensemble A , définie par

$$\mathbb{I}_A(x) = \begin{cases} 1, & x \in A \\ 0, & x \notin A. \end{cases}$$

Cette fonction permet de « sélectionner » les éléments de A au sein d'une somme, en annulant automatiquement les termes correspondant aux éléments qui n'en font pas partie.

Proposition 1.4. *Soit X une v.a.r. discrète, d'ensemble d'atomes $S = \{s_k\}_k$ de masses respectives $p_k = \mathbb{P}(X = s_k)$. Alors la fonction de masse caractérise entièrement la loi de X : pour tout ensemble $A \subset \mathbb{R}$,*

$$\mathbb{P}(X \in A) = \sum_k p_k \mathbb{1}_A(s_k).$$

En particulier, en prenant $A = (-\infty, x]$, la fonction de répartition de X s'écrit

$$F_X(x) = \sum_k p_k \mathbb{1}_{\{s_k \leq x\}}.$$

Démonstration. Les deux cas S fini et dénombrable sont quasiment identiques, traitons le cas S dénombrable $S = \{s_k, k \in \mathbb{N}\}$. On décompose comme suit l'événement $\{X \in A\}$:

$$\begin{aligned} \mathbb{P}(X \in A) &= \mathbb{P}(X \in A \cap S) + \mathbb{P}(X \in A \cap S^c) \\ &= \mathbb{P}\left(X \in \bigcup_{k \in \mathbb{N}} (A \cap \{s_k\})\right) + 0 \\ &= \sum_{k \in \mathbb{N}} \mathbb{P}(X \in A \cap \{s_k\}) \end{aligned}$$

ayant utilisé à la seconde égalité que $0 \leq \mathbb{P}(X \in A \cap S^c) \leq \mathbb{P}(X \in S^c) = 1 - \mathbb{P}(X \in S) = 0$, et à la troisième égalité la propriété de sigma-additivité (additivité suffit dans le cas fini).

Maintenant,

$$\begin{aligned} \sum_{k \in \mathbb{N}} \mathbb{P}(X \in A \cap \{s_k\}) &= \sum_{k \in \mathbb{N}} \mathbb{1}_A(s_k) \mathbb{P}(X = s_k) \\ &= \sum_{k \in \mathbb{N}} \mathbb{1}_A(s_k) p_k. \end{aligned}$$

□

Intuitivement, une v.a. est discrète lorsque sa fonction de répartition F_X n'évolue que par sauts, restant constante entre ces sauts — c'est-à-dire lorsque F_X est une fonction en escalier. Il est délicat de formaliser cette idée de façon parfaitement générale, mais on peut néanmoins en donner une condition suffisante, énoncée dans la proposition suivante, qui couvre en pratique la quasi-totalité des situations rencontrées.

Proposition 1.5. Soit X une v.a.r. S'il existe une suite $(x_n)_{n \in \mathbb{Z}} \in [-\infty, +\infty]$ bi-infinie, croissante au sens large, de nombres réels $\dots \leq x_{-1} \leq x_0 \leq x_1 \leq \dots$, avec $\lim_{n \rightarrow -\infty} x_n = -\infty$ et $\lim_{n \rightarrow \infty} x_n = \infty$ (ces deux valeurs pouvant être atteintes dès un rang fini), telle que pour tout $k \in \mathbb{Z}$ pour lequel $x_k < x_{k+1}$, la restriction $(F_X)_{|]x_k, x_{k+1}[}$ soit constante, alors X est discrète, d'ensemble d'atomes $S_X \subset \{x_n\}_{n \in \mathbb{Z}}$. Plus précisément :

$$S_X = \{x_n : F_X(x_n) > F_X(x_{n-1})\}.$$

Démonstration. Soit $k \in \mathbb{Z}$ tel que $x_k < x_{k+1}$. On a $\mathbb{P}(X \in]x_k, x_{k+1}[) = F_X(x_{k+1}^-) - F_X(x_k) = F_X(x_{k+1}^-) - F_X(x_k^+) = 0$ puisque $(F_X)_{|]x_k, x_{k+1}[}$ est constante. Maintenant,

$$\begin{aligned} \mathbb{P}\left(X \in \mathbb{R} \setminus \bigcup_k \{x_k\}\right) &= \mathbb{P}\left(X \in \bigcup_{k: x_k < x_{k+1}}]x_k, x_{k+1}[\right) \\ &= \sum_{k: x_k < x_{k+1}} (F_X(x_{k+1}^-) - F_X(x_k^+)) = 0, \end{aligned}$$

ayant utilisé à la deuxième égalité que l'union est au plus dénombrable. Ceci implique $\mathbb{P}(X \in \bigcup_k \{x_k\}) = 1$ et donc X est donc bien discrète par définition. $\square$

Précisons toutefois que la condition donnée dans la proposition précédente est suffisante mais non nécessaire : il existe en effet des ensembles dénombrables (infinis) qui ne peuvent pas s'écrire sous la forme $\{x_k\}_k$ pour une suite $(x_k)_k$ croissante — l'exemple typique étant l'ensemble $\mathbb{Q}$ des nombres rationnels, dont les éléments ne peuvent être énumérés de façon croissante. Une v.a. discrète dont le support est un tel ensemble échappe donc au critère précédent, tout en restant discrète.

Variables aléatoires à densité Après avoir étudié les v.a. discrètes, dont toute la masse est concentrée sur un ensemble dénombrable de points, nous nous intéressons maintenant à une classe complémentaire de v.a., à l'opposé du cas discret : celles dont la loi peut être décrite par une densité.

Définition 1.15. Soit X une v.a.r. On dit que X est à densité si la fonction de répartition F_X s'écrit sous la forme

$$F_X(x) = \int_{-\infty}^x f_X(y) dy, \quad x \in \mathbb{R}, \quad (1.1)$$

pour une certaine fonction intégrable $f_X : \mathbb{R} \rightarrow \mathbb{R}_+$. Dans ce cas, on dit que f_X est une densité de X (ou de la loi de X), et que X **possède** la densité f_X .

Il convient d'apporter immédiatement une précision importante : la densité f_X associée à une v.a. X n'est en général pas unique. En effet, on peut modifier une fonction intégrable en un nombre fini, voire dénombrable, de points sans changer la valeur de son intégrale, et donc sans modifier F_X . En revanche, si X admet une densité qui est de surcroît continue, alors cette densité est unique (plus généralement, si X admet une densité continue par morceaux, celle-ci est unique en dehors de ses points de discontinuité). C'est en ce sens que parler de « la » densité d'une variable aléatoire constitue, à proprement parler, un léger abus de langage.

Remarquons également que la densité f_X s'intègre nécessairement à 1 sur $\mathbb{R}$ tout entier, puisque

$$\int_{-\infty}^{+\infty} f_X(y) dy = \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

La densité joue, pour les v.a. à densité, un rôle tout à fait analogue à celui que joue la fonction de masse pour les v.a. discrètes. L'intuition sous-jacente est la suivante : pour un « élément infinitésimal » dx autour d'un point x , on a heuristiquement

$$\ll \mathbb{P}(X \in dx) = f_X(x) dx \gg,$$

c'est-à-dire que $f_X(x)$ représente une sorte de « densité de probabilité » au voisinage de x , par analogie avec une densité de masse en physique. L'exercice suivant permet de donner un sens rigoureux à cette égalité, encore purement heuristique sous cette forme.

Exercice 1.5. Soit X une variable aléatoire à densité, dont la densité f_X est continue au point x . Montrer (à l'aide de l'égalité des accroissements finis par exemple) que

$$\lim_{\varepsilon \rightarrow 0} \frac{\mathbb{P}(X \in [x - \varepsilon/2, x + \varepsilon/2])}{\varepsilon} = f_X(x)$$

En particulier, on note le

Lemme 1.1. *Soit X v.a.r. à densité. Alors l'ensemble des atomes S_X de la loi de X vérifie : $S_X = \emptyset$, c'est-à-dire que la loi de X est sans atome.*

Ce lemme n'admet pas de réciproque. Nous reviendrons plus tard sur ce point subtil : il existe des variables aléatoires sans atomes qui ne sont pas à densité ; du point de vue des fonctions de répartition, cela revient à dire qu'il existe des fonctions continues croissantes qui ne s'écrivent pas comme primitive de leur dérivée (partout où celle-ci est définie).

Démonstration. La fonction F_X est continue en tant que primitive, voir (1.1), en particulier, pour tout $x \in \mathbb{R}$:

$$\mathbb{P}(X = x) = F_X(x) - F_X(x^-) = 0$$

c'est-à-dire que x n'est pas un atome. □

Ainsi pour une variable aléatoire à densité $\mathbb{P}(X \in S_X) = 0$, à comparer avec le fait que $\mathbb{P}(X \in S_X) = 1$ pour une variable aléatoire discrète : on voit donc que ces deux types de variables aléatoires correspondent aux deux valeurs extrêmes pour $\mathbb{P}(X \in S_X)$. En particulier, si X est une v.a. à densité, pour tout ensemble au plus dénombrable $T \subset \mathbb{R}$, on a $\mathbb{P}(X \in T) = 0$, ce qui montre la différence de nature entre v.a.r. discrète et v.a.r. à densité. La densité caractérise la fonction de répartition de X et donc la loi de X .

On peut en outre facilement exprimer cette loi à l'aide de la densité :

Proposition 1.6. *Si X est une v.a. à densité de densité f_X , alors on a pour tout ensemble A :*

$$\mathbb{P}(X \in A) = \int_{-\infty}^{\infty} f_X(x) \mathbb{1}_A(x) dx.$$

Remarque 1.5. Le résultat s'étend aux ensembles mesurables au sens de Lebesgue ; en revanche à la différence du résultat pour les variables aléatoires discrètes on ne peut cette fois-ci considérer des ensembles A quelconques ; en pratique cependant, il est très difficile de construire des ensembles non mesurables.

Démonstration. On se donne $a, b \in [-\infty, +\infty]$. On commence par vérifier le résultat pour $A =]a, b]$: $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(x) dx =$

$\int_{-\infty}^{+\infty} f_X(x) \mathbb{1}_A(x) dx$. Les cas $A = [a, b]$, $A = [a, b[$, $A =]a, b]$, $A =]a, b[$ ne posent pas de difficulté, la fonction F_X étant continue, $F_X(x) = F_X(x^-)$ pour tout réel x et donc, on a : $\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b) = \mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx = \int_{-\infty}^{+\infty} f_X(x) \mathbb{1}_A(x) dx$. Noter que ces relations valent encore pour $a = -\infty$ et $b = +\infty$. Par linéarité de l'intégrale, pour A réunion d'un nombre fini d'intervalles disjoints de $\mathbb{R}$, on a encore : $\mathbb{P}(X \in A) = \int_A f_X(x) dx = \int_{-\infty}^{+\infty} \mathbb{1}_A(x) f_X(x) dx$. $\square$

Le résultat suivant est utile pour identifier la densité à partir de la fonction de répartition.

Proposition 1.7. *Soit X v.a.r. dont la fonction de répartition F_X est $C^0(\mathbb{R})$ (continue), et C^1 par morceaux (c'est-à-dire qu'il existe un nombre fini de points $x_1 < x_2 < \dots < x_n$ t.q. F_X est C^1 sur $] -\infty, x_1[$, $]x_1, x_2[$, $\dots$, $]x_{n-1}, x_n[$, $]x_n, +\infty[$) alors X est une v.a. à densité et une densité de X est F'_X .*

Démonstration. Les propriétés de la fonction F_X garantissent qu'on peut écrire pour tout $x, y \in [-\infty, \infty]$, $F_X(y) - F_X(x) = \int_x^y F'_X(z) dz$ et donc, avec $x = -\infty$, en particulier, on a pour tout $y \in \mathbb{R}$, $F_X(y) = \int_{-\infty}^y F'_X(z) dz$, donc F'_X est une densité de X . $\square$

On utilise souvent cette proposition pour vérifier qu'une variable aléatoire est à densité. Cependant, une alternative à cette proposition (et à la vérification de ses hypothèses...) est de mettre F directement sous la forme (1.1) : du point de vue de la rédaction, c'est souvent plus simple, même si en pratique, pour trouver l'intégrande, on dérive bien la fonction de répartition, comme dans la proposition précédente...). Voyez plutôt :

Exercice 1.6. On pose $F(x) = x^2 \mathbb{1}_{[0, 1/2]}(x) + (1 - 3(1-x)^2) \mathbb{1}_{[1/2, 1]}(x) + \mathbb{1}_{[1, +\infty]}(x)$.

1. Appliquer la proposition précédente pour montrer que F est la fonction de répartition d'une variable aléatoire dont on précisera la densité.
2. Vérifier que $F(x) = \int_{-\infty}^x [2t \mathbb{1}_{[0, 1/2]}(t) + 6(1-t) \mathbb{1}_{[1/2, 1]}(t)] dt$, et conclure comme précédemment.

Toutes les v.a.r. à densité que nous rencontrerons dans ce cours auront une fonction de répartition du type précédent ($C^0(\mathbb{R})$ et C^1 par morceaux). Cependant, la forme générale autorise des fonctions de répartition de v.a.r. à densité qui ne sont pas de ce type. L'ensemble des fonctions qui s'écrivent comme primitive d'une fonction intégrable ne se réduit pas à l'ensemble des fonctions $C^0(\mathbb{R})$ et C^1 par morceaux : il s'agit de l'ensemble des fonctions absolument continues, que le lecteur curieux est invité à découvrir par ses propres moyens (diverses caractérisations de cet ensemble existent, googlez pour les trouver).

Les autres variables aléatoires.

- Quasiment toutes les variables aléatoires que nous allons rencontrer dans ce cours font partie d'une des deux classes ci-dessus. Parmi les autres, on peut mentionner celles qui sont une combinaison des deux types de variables aléatoires, voir l'exercice ci-dessous.
- Il est aussi légitime de se demander s'il existe des fonctions de répartition qui sont continues mais ne s'écrivent pas comme la primitive d'une autre fonction. La réponse est oui, mais la construction d'une telle fonction dépasse le contenu de ce cours. Les curieux sont invités à googler "l'escalier de Cantor", également appelé "l'escalier du diable...".

Voici un exemple de combinaison des deux types de variables aléatoires tel que mentionné ci-dessus :

Exercice 1.7. Soit X v.a.r. de fonction de répartition $F_X(t) = \frac{1+t}{2} \mathbb{1}_{[0,1[}(t) + \mathbb{1}_{[1,+\infty[}(t)$.

1. Vérifier qu'il s'agit d'une fonction de répartition.
2. Vérifier que $\mathbb{P}(X \in S_X) = 1/2$.
3. X est-elle discrète, est-elle à densité?
4. Soit $y \in [0, 1]$. Construire une variable aléatoire Y telle que $\mathbb{P}(Y \in S_Y) = y$ (on pourra considérer une généralisation simple de F_X).

1.5 LOI D'UNE FONCTION D'UNE VARIABLE ALÉATOIRE

Si $\phi : \mathbb{R} \rightarrow \mathbb{R}$ est une fonction et X une variable aléatoire, alors $\phi(X)$ est encore un nombre qui décrit le résultat d'une expérience aléatoire, il est donc naturel de considérer $\phi(X)$ comme une nouvelle variable aléatoire. Plus généralement, si ϕ est seulement définie sur un ensemble $E \subset \mathbb{R}$ et si la variable X est à valeurs dans E , donc si $\mathbb{P}(X \in E^c) = 0$, il y a un sens à parler de $\phi(X)$. Pour définir $\phi(X)$ comme une variable aléatoire, il faut alors définir $\mathbb{P}(\phi(X) \in A)$ pour tout ensemble A . La seule définition naturelle est la suivante : pour tout ensemble $A \subset \mathbb{R}$, réunion finie d'intervalles disjoints,

$$\mathbb{P}(\phi(X) \in A) := \mathbb{P}(X \in \phi^{-1}(A)),$$

où $\phi^{-1}(A)$ est la préimage de A par l'application ϕ . On suppose ici que l'ensemble $\phi^{-1}(A)$ est encore une réunion finie d'intervalles disjoints. Ceci est une hypothèse sur la fonction ϕ qui est satisfaite par toute fonction "raisonnable". On peut vérifier (exercice), que la fonction $A \mapsto \mathbb{P}(\phi(X) \in A)$ ainsi définie satisfait encore aux axiomes 1 à 4. En pratique il suffira pour calculer la fonction de répartition de $\phi(X)$ de déterminer les ensembles $\phi^{-1}(]-\infty, x])$.

FONCTION DISCRÈTE D'UNE V.A.R.

Dans le cas où la fonction ϕ envoie le support de la v.a.r. X (quelconque) sur un ensemble au plus dénombrable, $\phi(X)$ est une variable aléatoire discrète (et ceci même si la v.a.r. X ne l'était pas). Dans ce cas, la loi de $\phi(X)$ est caractérisée par sa fonction de masse. Plutôt que d'énoncer un théorème général, nous détaillons la méthode à suivre sur quelques exemples.

Exemple 1.2. $\phi : \mathbb{R} \rightarrow \{0, 1\}$, $\phi(x) = \mathbb{1}_{x \geq 0}$, X une v.a. quelconque. La fonction ϕ ne prend alors que deux valeurs, 0 ou 1. Par conséquent, la v.a. $\phi(X) = \mathbb{1}_{X \geq 0}$ est discrète. Sa fonction de masse est donnée par :

$$\mathbb{P}(\mathbb{1}_{X \geq 0} = 1) = \mathbb{P}(X \geq 0), \quad \mathbb{P}(\mathbb{1}_{X \geq 0} = 0) = \mathbb{P}(X < 0).$$

La v.a. $\mathbb{1}_{X \geq 0}$ suit alors la loi de Bernoulli de paramètre $p = \mathbb{P}(X \geq 0)$.

Exemple 1.3. $\phi : \mathbb{R}_+ \rightarrow \mathbb{R}_+$, $\phi(x) = \min(x, N)$ (avec $N \in \mathbb{N}$), X une v.a. discrète à valeurs dans $\mathbb{N}$. Puisque X est une v.a. discrète, $\phi(X)$ l'est aussi. Sa fonction de masse est donnée par

$$\mathbb{P}(\min(X, N) = n) = \begin{cases} \mathbb{P}(X = n), & n \in \{0, \dots, N-1\} \\ \mathbb{P}(X \geq N) = \sum_{k=N}^{\infty} \mathbb{P}(X = k), & n = N. \end{cases}$$

Exemple 1.4. $\phi : [0, 1] \rightarrow \mathbb{N}$, $\phi(x) = \lfloor Nx \rfloor$ (avec $N \in \mathbb{N}$), $X \sim \mathcal{U}(0, 1)$. La fonction ϕ est à valeurs dans $\{0, \dots, N-1\}$, la v.a. $\phi(X)$ est donc discrète. Sa fonction de masse est donnée pour tout $n \in \{0, \dots, N-1\}$ par :

$$\mathbb{P}(\lfloor NX \rfloor = n) = \mathbb{P}(n/N \leq X < (n+1)/N) = \int_{n/N}^{(n+1)/N} 1 dx = \frac{1}{N}.$$

La v.a. $\lfloor NX \rfloor$ suit donc la loi uniforme sur $\{0, \dots, N-1\}$.

Exemple 1.5. $\phi : \mathbb{R}_+ \rightarrow \mathbb{N}$, $\phi(x) = \lfloor x \rfloor$, $X \sim \mathcal{E}(\lambda)$. La fonction ϕ est à valeurs dans $\mathbb{N}$, la v.a. $\phi(X)$ est donc discrète. Sa fonction de masse est donnée pour tout $n \in \mathbb{N}$ par :

$$\mathbb{P}(\lfloor X \rfloor = n) = \mathbb{P}(n \leq X < n+1) = \int_n^{n+1} \lambda e^{-\lambda x} dx = e^{-\lambda n} - e^{-\lambda(n+1)} = e^{-\lambda n}(1 - e^{-\lambda})$$

La v.a. $\lfloor X \rfloor$ suit donc la loi $\mathcal{G}_{\mathbb{N}}(1 - e^{-\lambda})$.

Exercice 1.8. Retrouver ce résultat sur la partie entière d'une variable aléatoire de loi $\mathcal{E}$ en comparant les propriétés d'absence de mémoire, satisfaites par les lois $\mathcal{G}$ et $\mathcal{E}$ respectivement.

FONCTION RÉGULIÈRE D'UNE VARIABLE ALÉATOIRE À DENSITÉ

Dans le cas où X est une v.a.r. à densité et la fonction ϕ est suffisamment régulière, alors $\phi(X)$ est encore une variable aléatoire à densité; la méthode consiste alors à calculer la fonction de répartition pour en déduire la densité. Nous détaillons plusieurs exemples, tout d'abord un exemple générique, c'est-à-dire avec une v.a. X quelconque.

Exemple 1.6. $\phi : \mathbb{R} \rightarrow \mathbb{R}, \phi(x) = x^2, X$ une v.a.r. On commence par calculer la fonction de répartition de $\phi(X)$: pour $x \geq 0$,

$$\begin{aligned} F_{X^2}(x) &= \mathbb{P}(X^2 \leq x) \\ &= \mathbb{P}(-\sqrt{x} \leq X \leq \sqrt{x}) \\ &= F_X(\sqrt{x}) - F_X((-\sqrt{x})^-). \end{aligned}$$

C'est-à-dire :

$$F_{X^2}(x) = \begin{cases} F_X(\sqrt{x}) - F_X((-\sqrt{x})^-), & x \geq 0 \\ 0, & x < 0. \end{cases}$$

Si maintenant X est à densité de densité f_X , alors on peut écrire que :

$$\begin{aligned} F_X(\sqrt{x}) - F_X((-\sqrt{x})^-) &= \int_{-\infty}^{\sqrt{x}} f_X(y) dy - \int_{-\infty}^{-\sqrt{x}} f_X(y) dy \\ &= \int_{-\sqrt{x}}^{\sqrt{x}} f_X(y) dy. \end{aligned}$$

Il existe alors deux méthodes pour conclure :

- ou bien on observe que $x \mapsto F_{X^2}(x)$ est de classe C^1 sur $] -\infty, 0[\cup]0, +\infty[$: il suffit de dériver cette fonction (dérivation d'une fonction composée) pour obtenir que X^2 est encore à densité, de densité :

$$f_{X^2}(x) = \begin{cases} \frac{1}{2\sqrt{x}}(f_X(\sqrt{x}) + f_X(-\sqrt{x})) & x > 0 \\ 0 & \text{sinon.} \end{cases}$$

- ou bien on se met directement sous la forme de la définition d'une variable aléatoire à densité en utilisant deux changements de variables comme suit :

$$\begin{aligned}
 \int_{-\sqrt{x}}^{\sqrt{x}} f_X(y) dy &= \int_{-\sqrt{x}}^0 f_X(y) dy + \int_0^{\sqrt{x}} f_X(y) dy \\
 &= \int_0^{\sqrt{x}} (f_X(-y) + f_X(y)) dy \\
 &= \int_0^x [f_X(-\sqrt{z}) + f_X(\sqrt{z})] \frac{1}{2\sqrt{z}} dz
 \end{aligned}$$

Et maintenant un exemple pratique où X suit une loi donnée (et où les ensembles de niveaux sont des réunions infinies d'intervalles).

Exemple 1.7. $\phi : \mathbb{R} \rightarrow [0, 1[, \phi(x) = x - \lfloor x \rfloor, X \sim \mathcal{E}(\lambda)$. On commence par calculer la fonction de répartition de $\phi(X)$: pour tout $x \in [0, 1]$,

$$\begin{aligned}
 F_{\phi(X)}(x) &= \mathbb{P}(\phi(X) \leq x) \\
 &= \mathbb{P}(0 \leq X - \lfloor X \rfloor \leq x) \\
 &= \mathbb{P}(\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x) \\
 &= \mathbb{P}\left(\{\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x\} \cap \bigcup_{k \in \mathbb{N}} \{\lfloor X \rfloor = k\}\right) \\
 &= \sum_{k \in \mathbb{N}} \mathbb{P}(\{\lfloor X \rfloor \leq X \leq \lfloor X \rfloor + x\} \cap \{\lfloor X \rfloor = k\}) \\
 &= \sum_{k \in \mathbb{N}} \mathbb{P}(k \leq X \leq k + x) \\
 &= \sum_{k \in \mathbb{N}} \int_k^{k+x} \lambda e^{-\lambda y} dy \\
 &= \sum_{k \in \mathbb{N}} e^{-\lambda k} (1 - e^{-\lambda x}) \\
 &= \frac{1 - e^{-\lambda x}}{1 - e^{-\lambda}}
 \end{aligned}$$

C'est-à-dire :

$$F_{\phi(X)}(x) = \frac{1 - e^{-\lambda x}}{1 - e^{-\lambda}} \mathbb{K}_{[0,1[}(x) + \mathbb{K}_{[1,\infty[}(x)$$

et on identifie la densité via l'écriture :

$$F_{\phi(X)}(x) = \int_{-\infty}^x \frac{\lambda e^{-\lambda y}}{1 - e^{-\lambda}} \mathbb{K}_{[0,1]}(y) dy$$

Une dernière méthode possible est la méthode dite de la fonction muette, elle aussi basée sur le changement de variable, qui sera étudiée au chapitre suivant.

1.6 SIMULATION DE LOIS

On conclut ce chapitre par une méthode de simulation basée sur la notion de fonction de répartition.

Définition 1.16. On appelle fonction quantile l'inverse généralisé de la fonction de répartition défini par :

$$F_X^{-1}(y) = \inf\{x : F_X(x) \geq y\}, \quad y \in]0, 1[$$

On énonce d'abord quelques propriétés de la fonction quantile (non nécessaires pour la méthode de simulation qui suit, et qu'on pourra sauter en première lecture).

Proposition 1.8. La fonction quantile F_X^{-1} est croissante, continue à gauche et admet des limites à droite.

On note que les propriétés de continuité sont échangées par rapport à celle de la fonction de répartition F_X . Notons aussi que la preuve (purement analytique) de ces propriétés se base sur les seules hypothèses de croissance et de continuité à droite de F_X .

Démonstration. Si $y \leq z$ sont deux réels dans $]0, 1[$, on a l'inclusion d'ensembles $\{x : F_X(x) \geq y\} \supset \{x : F_X(x) \geq z\}$ qui implique bien $F_X^{-1}(y) \leq F_X^{-1}(z)$: c'est la croissance. Si maintenant $(y_n)_n$ est une suite croissante de $]0, 1[$, avec $y = \lim y_n \in]0, 1[$, considérons $z = \lim_n F_X^{-1}(y_n)$. Alors $F_X(z + \epsilon) \geq y_n$ pour tout n donc $F_X(z + \epsilon) \geq y$ d'où $z + \epsilon \geq F_X^{-1}(y)$ puis $z \geq F_X^{-1}(y)$. Par croissance de la suite $(y_n)_n$ et de F_X^{-1} , on a par ailleurs toujours l'inégalité dans l'autre sens : $z \leq F_X^{-1}(y)$, d'où l'égalité annoncée, et la continuité à gauche. L'existence des limites à droite découle de la propriété de croissance. $\square$

Donnons un exemple pour lequel F_X^{-1} ne sera pas continue à droite : supposons qu'on puisse trouver $y \in]0, 1[$ et $x_1 < x_2$ tels que $F_X(x_1) = F_X(x_2) = y$ (c'est-à-dire

que $[x_1, x_2]$ est un intervalle de constance de la fonction F_X) alors, si $(y_n)_n$ est une suite strictement décroissante de limite y , on a $F_X^{-1}(y_n) \geq x_2$ tandis que $F_X^{-1}(y) \leq x_1$, en conséquence de quoi :

$$F_X^{-1}(y_n) - F_X^{-1}(y) \geq x_2 - x_1 > 0.$$

L'intérêt de la fonction quantile est de permettre la simulation très simple de la variable aléatoire associée :

Proposition 1.9. *Soit U variable aléatoire de loi uniforme $\text{Unif}(0, 1)$ et X une v.a.r. Alors $F_X^{-1}(U)$ suit la loi de X .*

L'intérêt de la méthode réside dans le fait qu'elle vaut quelle que soit la variable aléatoire réelle X (on utilise seulement la notion de fonction de répartition).

Démonstration. Il suffit de vérifier par double inclusion que quels que soient $u \in]0, 1[$, $x \in \mathbb{R}$,

$$F_X^{-1}(u) \leq x \iff u \leq F_X(x),$$

et on conclura alors en prenant les probabilités des deux événements $\{F_X^{-1}(U) \leq x\} = \{U \leq F_X(x)\} : \mathbb{P}(F_X^{-1}(U) \leq x) = \mathbb{P}(U \leq F_X(x)) = F_X(x)$ et donc $F_X^{-1}(U)$ a pour fonction de répartition F_X , ce qui suffit à conclure.

Supposons $F_X^{-1}(u) \leq x$. Posons $y = F_X^{-1}(u)$. Alors quel que soit $\epsilon > 0$, $F_X(y + \epsilon) \geq u$ et par continuité à droite de F_X , on tire $F_X(y) = F_X(y^+) \geq u$. Comme par ailleurs $F_X(y) \leq F_X(x)$ suit de la croissance de F_X , on a bien $u \leq F_X(x)$ comme attendu. Réciproquement, si l'on suppose $u \leq F_X(x)$, alors $x \in \{z : F_X(z) \geq u\}$ donc $F_X^{-1}(u) \leq x$ suit de la définition de F_X comme l'infimum de l'ensemble $\{z : F_X(z) \geq u\}$. $\square$

Attention, on n'a pas toujours $F_X \circ F_X^{-1}(u) = u$: considérer le cas où $F_X(x^-) < u < F_X(x)$ par exemple ; de même on n'a pas toujours $F_X^{-1} \circ F_X(x) = x$, considérer le cas où il existe $w < x$ tel que $F_X(w) = F_X(x)$: nous invitons le lecteur à faire des dessins dans chacun de ces cas.

De façon intéressante, le calcul de F_X^{-1} permet souvent de comprendre la dépendance d'une loi en ses paramètres. Considérons le cas des deux exemples suivants :

Exemple 1.8. $X \sim \mathcal{E}(\lambda)$. Pour $y \in]0, 1[$, $F_X^{-1}(y) = \frac{-\log(1-y)}{\lambda}$: ainsi $\frac{-\log(1-U)}{\lambda}$ (ou encore $\frac{-\log(U)}{\lambda}$ qui a même loi) suit la loi $\mathcal{E}(\lambda)$ et donc $\lambda X \sim \mathcal{E}(1)$.

Exemple 1.9. $X \sim \mathcal{C}(a)$. Pour $y \in]0, 1[$, $F_X^{-1}(y) = a \tan\left(\pi\left(y - \frac{1}{2}\right)\right)$, ainsi $a \tan\left(\pi\left(U - \frac{1}{2}\right)\right)$ (ou encore $a \tan(\pi U)$ qui a même loi) suit la loi $\mathcal{C}(a)$ et donc $X/a \sim \mathcal{C}(1)$.

En pratique le calcul numérique de F_X^{-1} peut être long, donc comment calcule-t-on un "log" sur une machine? Alors d'autres méthodes (comme la méthode du rejet) sont utilisées dans ce cas.

TD0 : PRÉLIMINAIRES

Exercice 1.9. On rappelle l'expression de la fonction gamma d'Euler :

$$\forall x > 0, \quad \Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt.$$

1. Montrer que pour tout réel x strictement positif,

$$\Gamma(x+1) = x\Gamma(x).$$

2. En déduire la valeur de $\Gamma(n)$ pour n entier naturel non nul.
3. Montrer que

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}.$$

On pourra se ramener à l'intégrale de Gauss :

$$\int_{\mathbb{R}} e^{-x^2} dx = \sqrt{\pi}.$$

4. En déduire que pour tout entier naturel n ,

$$\Gamma\left(n + \frac{1}{2}\right) = \frac{(2n)!}{2^{2n}n!} \sqrt{\pi}$$

On pose pour tout entier naturel n :

$$\beta(n) = \int_{-\infty}^{\infty} x^n \exp\left(-\frac{x^2}{2}\right) dx.$$

5. Calculer $\beta(0)$ et $\beta(1)$.
6. Exprimer $\beta(n+2)$ en fonction de $\beta(n)$.
7. En déduire la valeur de $\beta(n)$ pour tout entier naturel n .
8. Faire un lien entre les résultats des questions 4 et 7, et retrouver ce résultat par un changement de variable.

Exercice 1.10. 1. Déterminer la valeur de $\sum_{k=1}^n k$ en calculant la somme

$$A = \sum_{k=1}^n (k+1)^2 - \sum_{k=1}^n k^2 \text{ de deux façons différentes.}$$

2. Par un raisonnement similaire, calculer $\sum_{k=1}^n k^2$.
3. Donner des équivalents de ces deux sommes pour $n \rightarrow \infty$.
4. Soit $\alpha > 0$ un réel. À l'aide de la comparaison série-intégrale :

$$\int_{k-1}^k t^\alpha dt \leq k^\alpha \leq \int_k^{k+1} t^\alpha dt,$$

proposer un encadrement puis donner un équivalent de $\sum_{k=1}^n k^\alpha$.

5. On rappelle le résultat suivant au sujet de l'intégrale de Riemann : pour $f : [0, 1] \rightarrow \mathbb{R}$ continue bornée,

$$\frac{1}{n} \sum_{k=1}^n f\left(\frac{k}{n}\right) \xrightarrow{n \rightarrow \infty} \int_0^1 f(t) dt.$$

Retrouver à l'aide de ce résultat un équivalent de $\sum_{k=1}^n k^\alpha$ (sans encadrement toutefois).

Exercice 1.11. Soit $\lambda \in \mathbb{C}$; calculer les sommes des séries suivantes :

1. $A = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}.$

On peut au choix dire que c'est un DSE connu, ou se ramener à la définition de l'exponentielle comme unique solution de l'équation différentielle ordinaire $f' = f, f(0) = 1$.

2. $B = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!}.$
3. $C = \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k}{k!}.$
4. $D = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!}.$

Exercice 1.12. 1. Soit $\lambda \in \mathbb{C}$, et $n \in \mathbb{N}$. Simplifier $(1 - \lambda) \sum_{k=0}^n \lambda^k$.

2. En déduire, pour $|\lambda| < 1$, la valeur de la série entière $\sum_{k=0}^{+\infty} \lambda^k$.
3. À l'aide d'un produit de Cauchy, développer en série entière $(1 - \lambda)^{-2}$ pour $|\lambda| < 1$.
4. Retrouver cette identité au moyen du théorème de dérivation sous le signe somme des séries entières.

Les questions qui suivent sont plus difficiles.

5. Montrer que $\sum_{k_1, \dots, k_n \geq 0} \mathbb{1}_{k_1 + k_2 + \dots + k_n = j} = \binom{j+n-1}{j}$.

On pourra remarquer que le membre de gauche compte aussi les chemins du plan $\mathbb{Z}^2$ avec des pas vers le haut et vers la droite reliant $(0, 0)$ à $(n-1, j)$.

6. Soit $n \in \mathbb{N}^*$. Plus généralement, pour $|\lambda| < 1$, développer en série entière $(1 - \lambda)^{-n}$.

TD1 : VARIABLES ALÉATOIRES RÉELLES ET FONCTIONS DE RÉPARTITION

Exercice 1.13. Soit X une variable aléatoire dont la fonction de répartition F_X est définie par :

$$\forall t \in \mathbb{R} \quad F_X(t) = \begin{cases} 0 & \text{si } t < -2, \\ \frac{1}{30} & \text{si } -2 \leq t < 0, \\ \frac{1}{12} & \text{si } 0 \leq t < 1, \\ \frac{1}{4} & \text{si } 1 \leq t < 3, \\ \frac{1}{3} & \text{si } 3 \leq t < 5, \\ 1 & \text{si } t \geq 5. \end{cases}$$

1. Montrer que X est une v.a. discrète et déterminer sa fonction de masse.
2. Calculer $\mathbb{P}(-3 \leq X < \frac{1}{2})$.

Exercice 1.14. Soit X une variable aléatoire dont la fonction de répartition F_X est définie par :

$$\forall t \in \mathbb{R} \quad F_X(t) = \begin{cases} 0 & \text{si } t \leq 0, \\ \frac{t}{2} & \text{si } 0 \leq t \leq 2, \\ 1 & \text{si } t \geq 2. \end{cases}$$

1. Tracer la courbe représentative de F_X , montrer que X est une v.a. à densité et déterminer cette densité.
2. Calculer $\mathbb{P}(\frac{1}{4} < X < \frac{3}{4})$.

Exercice 1.15. Soit X une variable aléatoire de densité f définie par

$$f(x) = \begin{cases} \frac{10}{x^2} & \text{si } x > a, \\ 0 & \text{si } x \leq a, \end{cases}$$

pour un certain $a > 0$.

1. Calculer a .
2. Calculer $\mathbb{P}(X > 20)$.

3. Quelle est la fonction de répartition de X ?

Exercice 1.16. Soit X une variable aléatoire de densité f définie par

$$\forall x \in \mathbb{R} \quad f(x) = \frac{1}{4} \mathbb{1}_{\{0 < x < 1\}} + \frac{3}{8} \mathbb{1}_{\{3 < x < 5\}}.$$

1. Donner la fonction de répartition de X .
2. Calculer $\mathbb{P}(X \in [\frac{1}{2}, 2] \cup]3, 4])$.

TD2 : CONVERGENCE DE VARIABLES ALÉATOIRES ET THÉORÈMES LIMITES.

Exercice 1.17. On reprend l'exercice 1 de la feuille précédente. On rappelle la fonction de masse de X :

$$\begin{aligned}\mathbb{P}(X = -2) &= \frac{1}{30}, \\ \mathbb{P}(X = 0) &= \frac{1}{20}, \\ \mathbb{P}(X = 1) &= \frac{1}{6}, \\ \mathbb{P}(X = 3) &= \frac{1}{12}, \\ \mathbb{P}(X = 5) &= \frac{2}{3}.\end{aligned}$$

1. Montrer que $Y = -2X + 1$ est une v.a. discrète et déterminer sa fonction de masse.
2. Même question pour $Z = Y^2$.

Exercice 1.18. On reprend l'exercice 4 de la feuille précédente. On rappelle la fonction de répartition de X :

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ \frac{x}{4} & \text{si } 0 \leq x < 1, \\ \frac{1}{4} & \text{si } 1 \leq x < 3, \\ \frac{3x-7}{8} & \text{si } 3 \leq x < 5, \\ 1 & \text{si } x \geq 5. \end{cases}$$

1. Justifier que la variable aléatoire $Y = 1/X$ est bien définie.
2. Montrer que Y est à densité et calculer sa densité.

Exercice 1.19. Soit f_X la densité d'une variable aléatoire réelle X telle que $\mathbb{P}(X \geq 0) > 0$. On pose

$$f_Y(t) = af_X(|t|), \quad t \in \mathbb{R}$$

1. Calculer a (en fonction de f_X) pour que f_Y soit la densité d'une variable aléatoire Y .
2. Montrer que Y et $-Y$ ont même loi.

Exercice 1.20. Soit X une variable aléatoire de densité f continue et de fonction de répartition F .

1. Soit $Z = 2X\mathbb{1}_{\{X < 0\}} + 3X\mathbb{1}_{\{X \geq 0\}}$. Donner la fonction de répartition de Z en fonction de F , puis sa densité en fonction de f .
2. Soit $Y = X^2$. Donner la fonction de répartition de Y en fonction de F , puis sa densité en fonction de f .

Exercice 1.21. Soit X une variable aléatoire de fonction de répartition F , et soit $A =]a, b]$ un intervalle.

1. Soit $Y = \mathbb{1}_A(X)$. Donner la fonction de répartition de Y en fonction de F . (On pourra observer que $Y \sim \text{Ber}(p)$ pour une valeur de p à déterminer).
2. On suppose de plus $a > 0$. Soit $Z = X\mathbb{1}_A(X)$. Donner la fonction de répartition de Z en fonction de F .

Exercice 1.22. Soit X une variable aléatoire de fonction de répartition F . Soit $(a, b) \in \mathbb{R}^2$.

1. Exprimer à l'aide de F la fonction de répartition de la variable aléatoire $aX + b$.
2. Sous quelle condition sur le couple (a, b) la fonction $t \mapsto F(at + b)$ est-elle une fonction de répartition ? Sous cette condition, de quelle variable aléatoire cette fonction est-elle la fonction de répartition ?

TD₃ : FONCTION D'UNE VARIABLE ALÉATOIRE : EXEMPLES CONCRETS.

Exercice 1.23. Dans cet exercice, lorsqu'est demandé de préciser la loi d'une variable aléatoire, on donnera la fonction de répartition, et si cela a un sens, la densité.

1. On suppose que X suit la loi uniforme sur $[0, 1]$, notée $\mathcal{U}(0, 1)$. Quelle loi suit X^2 ?
2. On suppose que X^2 suit la loi uniforme sur $[0, 1]$, et $\mathbb{P}(X \geq 0) = 1$. Quelle loi suit X ?
3. On suppose que X suit la loi uniforme sur $[0, \pi]$. Quelle loi suit $\cos(X)$?
4. On suppose que $\cos(X)$ suit la loi uniforme sur $[-1, 1]$, et $\mathbb{P}(X \in [0, \pi]) = 1$. Quelle loi suit X ?

Exercice 1.24. Soit X une variable aléatoire de loi $\mathcal{E}(\alpha)$, pour $\alpha > 0$.

1. Quelle loi suit αX ?
2. Quelle loi suit $Y = e^X$?

On précisera dans les deux cas la valeur de la densité si la variable en admet une.

Exercice 1.25. Soit X une variable aléatoire de loi $\mathcal{N}(0, 1)$.

1. Quelle loi suit $\mu + \sigma X$, pour $\mu \in \mathbb{R}$, et $\sigma > 0$?
2. Quelle loi suit $Y = X^2$. Reconnaitre une loi $\Gamma(\alpha, \beta)$ pour des paramètres à préciser.

Exercice 1.26. Un bout de bois est cassé en un point uniforme, formant deux bouts ; si l'on assimile le bout de bois à l'intervalle unité $[0, 1]$, quelle est la loi de la longueur du bout contenant la marque d'abscisse p , pour $p \in [0, 1]$? Quelle loi retrouve-t-on lorsque $p = 1/2$?

Exercice 1.27. Soit X une variable aléatoire de loi $\mathcal{C}(\alpha)$ pour $\alpha > 0$, qui est la loi de densité $x \mapsto \frac{\alpha}{\pi} \frac{1}{\alpha^2 + x^2}$ sur $\mathbb{R}$.


1. Calculer la fonction de répartition et en déduire que la fonction proposée est bien une densité.
2. Quelle loi suit X/α ?

3. Quelle loi suit $Y = 1/X$?

Pour la dernière question, on pourra librement utiliser la relation : pour $x \neq 0$, $\arctan(x) + \arctan(1/x) = \frac{\pi}{2}(\mathbb{1}_{\{x>0\}} - \mathbb{1}_{\{x<0\}})$.

Exercice 1.28. On considère un repère cartésien d'origine O et A le point de coordonnées $(0, -1)$. Pour $\Theta \in]-\pi/2, \pi/2[$, il existe un unique point B d'ordonnée -1 que l'angle $\widehat{AOB}$ est de Θ radians; on note alors X l'abscisse de B .

Ci-dessous, deux valeurs d'angles possibles : $\Theta > 0$ et $\Theta' < 0$, et les points B et B' correspondants :



Si Θ suit la loi uniforme sur $]-\pi/2, \pi/2[$, montrer que X suit la loi $\mathcal{C}(1)$.

Exercice 1.29 (Simulation à partir de la loi uniforme.). Soit F fonction de répartition qui réalise une bijection d'un intervalle I sur $]0, 1[$, et U une variable aléatoire de loi $\mathcal{U}(0, 1)$.

1. Quelle est la fonction de répartition de $F^{-1}(U)$? En déduire la loi de $F^{-1}(U)$.

Préciser I pour les deux lois suivantes, la bijection réciproque $F^{-1} :]0, 1[\rightarrow I$:

2. F fonction de répartition de $\mathcal{E}(\lambda)$ pour $\lambda > 0$.
3. F fonction de répartition de $\mathcal{C}(a)$ pour $a > 0$.

Application : Quelle est la loi de

4. $Z = -\frac{\ln U}{\lambda}$
5. $W = a \tan\left(\pi\left(U - \frac{1}{2}\right)\right)$.

ESPÉRANCE ET MOMENTS

Supposons qu'on lance une pièce équilibrée n fois et qu'on s'intéresse à la proportion de lancers « pile » parmi ces n lancers. Puisque la pièce est non biaisée, chaque face a probabilité $1/2$ d'apparaître, et on s'attend alors à ce que la proportion de piles approche $1/2$ quand n tend vers l'infini : c'est l'interprétation dite fréquentiste, dans laquelle les probabilités s'interprètent comme une fréquence d'apparition limite. Plus généralement, supposons qu'on ait une variable aléatoire X décrivant le résultat d'une expérience aléatoire et qu'on répète n fois cette expérience en notant $x_1, \dots, x_n$ les valeurs de cette variable aléatoire observées lors des n répétitions (le cas précédent correspond à X qui suit la loi Bernoulli de paramètre $1/2$).

On s'attend alors à ce que la moyenne $(X_1 + \dots + X_n)/n$ approche une constante quand n tend vers l'infini, égale à la somme sur les valeurs possibles de la variable aléatoire X des valeurs possiblement prises par la variable fois leur probabilité ; cette somme pondérée, qui serait en un sens la moyenne de la variable aléatoire X , est appelée l'espérance de la variable aléatoire X , quelquefois l'espérance mathématique, et notée $\mathbb{E}[X]$. La définition de l'espérance de X (et plus généralement, celle de $f(X)$ où f est une fonction) est l'un des concepts les plus importants en théorie des probabilités.

L'espérance permet de définir les moments d'une variable aléatoire ; la suite des moments fournit en retour une description de la loi qui peut être utile : dans certains cas, elle caractérise la loi ; surtout, elle fournit des bornes intéressantes sur les probabilités d'événements qu'on ne peut calculer directement. Elle est aussi utilisée pour définir la fonction génératrice des moments, qui fournit encore une autre façon de décrire la loi de la variable aléatoire, tout comme la fonction de répartition, mais avec un résultat souvent plus explicite (l'expression de la fonction de répartition ne se simplifie que rarement).

2.1 ESPÉRANCE D'UNE VARIABLE ALÉATOIRE

VARIABLE ALÉATOIRE POSITIVE OU NULLE

Dans le cas où X est une variable aléatoire positive ou nulle on peut toujours définir son espérance :

Définition 2.1. Soit X une variable aléatoire positive ou nulle, discrète ou à densité. Alors l'espérance de X , notée $\mathbb{E}[X] \in [0, \infty]$, est définie par

$$\mathbb{E}[X] = \begin{cases} \sum_x x \mathbb{P}(X = x) & \text{si } X \text{ est discrète} \\ \int_0^{+\infty} x f_X(x) dx & \text{si } X \text{ admet la densité } f_X, \end{cases}$$

et on dit que X est intégrable si la somme ou l'intégrale dans l'expression précédente est convergente.

L'espérance $\mathbb{E}[X]$ est intuitivement la moyenne pondérée des valeurs que X peut prendre, les poids étant les probabilités que ces valeurs soient prises. On peut la rapprocher à la notion de centre de gravité au sens de la mécanique. Pour illustrer cette analogie, supposons d'abord que X est discrète et notons x_i les valeurs que peut prendre X . Imaginons-nous alors des masses situées sur l'axe réel aux abscisses x_i et de poids $\mathbb{P}(X = x_i)$. L'espérance $\mathbb{E}[X]$ correspond alors à l'abscisse du centre de gravité de ce groupe de masses. Si X est à densité, alors on s'imagine une masse d'une unité répartie continuellement sur l'axe réel selon la densité f_X . L'espérance $\mathbb{E}[X]$ correspond alors encore à l'abscisse du centre de gravité de cette masse.

Insistons en particulier sur le fait que l'espérance d'une variable aléatoire positive est positive (les termes de la somme, comme l'intégrande dans l'intégrale sont positifs) : c'est la positivité de l'intégrale.

Exemple 2.1. Soit $X \sim \mathcal{B}(p)$, $p \in [0, 1]$. Alors

$$\mathbb{E}[X] = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Interprétation : en répétant n fois une expérience de Bernoulli de probabilité de succès p , on s'attend à ce que la proportion de succès approche p quand n tend vers l'infini.

Exemple 2.2. Soit $X \sim \mathcal{G}(p)$, $p \in]0, 1]$. Alors

$$\mathbb{E}[X] = \sum_{n=1}^{\infty} np(1-p)^{n-1} = \frac{1}{p},$$

où la dernière série se calcule par dérivation de la série entière $\sum_{n=1}^{\infty} (1-p)^n = \frac{1}{p}$ à l'intérieur du disque de convergence, c'est-à-dire pour $|1-p| < 1$. Interprétation : Quand on répète une expérience de Bernoulli de probabilité de succès p jusqu'à ce qu'elle réussisse, on doit la répéter en moyenne $1/p$ fois. Par exemple, si une expérience a 5

Exemple 2.3. Soit $X \sim \mathcal{E}(\lambda)$, $\lambda > 0$. Alors

$$\mathbb{E}[X] = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

Interprétation : Une pièce ayant un taux de panne constant égal à λ a une durée de vie de $1/\lambda$ en moyenne.

Toutes les variables aléatoires précédentes sont intégrables.

VARIABLE ALÉATOIRE SIGNÉE

Définition 2.2. Soit X une variable aléatoire discrète ou à densité. On dit que X est intégrable si

$$\begin{cases} \sum_x |x| \mathbb{P}(X = x) < \infty & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} |x| f_X(x) dx < \infty & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Dans ce cas on définit l'espérance de X par la formule suivante :

$$\mathbb{E}[X] = \begin{cases} \sum_x x \mathbb{P}(X = x) & \text{si } X \text{ est discrète,} \\ \int_{-\infty}^{+\infty} x f_X(x) dx & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Remarque 2.1. On connaît déjà une loi non intégrable, c'est la loi de Cauchy. En effet, si $X \sim \mathcal{C}(a)$, alors

$$\int_{\mathbb{R}} \frac{a}{\pi} \cdot \frac{|x|}{a^2 + x^2} dx = \infty,$$

car l'intégrande est équivalent à C/x en $+\infty$ par exemple.

Exemple 2.4. Soit $X \sim \mathcal{U}(a, b)$, $a < b$. Alors

$$\mathbb{E}[X] = \int_a^b \frac{x}{b-a} dx = \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{a+b}{2},$$

$$\text{car } b^2 - a^2 = (a+b)(b-a).$$

Interprétation : Le centre de gravité d'une masse répartie uniformément dans l'intervalle $[a, b]$ se trouve au point d'abscisse $(a+b)/2$.

2.2 ESPÉRANCE D'UNE FONCTION D'UNE VARIABLE ALÉATOIRE

Il sera utile d'étendre la définition de l'espérance ci-dessus à l'espérance d'une fonction d'une variable aléatoire.

Proposition 2.1 (Formule de transfert). *Soit X une variable aléatoire discrète ou à densité et $\phi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. $\phi(X)$ est une variable aléatoire intégrable ssi*

$$\begin{cases} \sum_x |\phi(x)| \mathbb{P}(X = x) < \infty & \text{si } X \text{ est discrète} \\ \int_{-\infty}^{+\infty} |\phi(x)| f_X(x) dx < \infty & \text{si } X \text{ admet la densité } f_X. \end{cases}$$

Dans ce cas, son espérance est donnée par :

$$\mathbb{E}[\phi(X)] = \begin{cases} \sum_x \phi(x) \mathbb{P}(X = x) & \text{si } X \text{ est discrète} \\ \int_{-\infty}^{+\infty} \phi(x) f_X(x) dx & \text{si } X \text{ admet la densité } f_X. \end{cases} \quad (2.1)$$

Notons que l'intégrabilité garantit l'absolue convergence de la série/intégrale qui donne l'espérance. Cette définition généralise celle de $\mathbb{E}[X]$ qu'on retrouve en prenant pour ϕ l'application identité $\phi(x) = x$. Appliquant cette définition avec $\phi = \mathbb{1}_A$, on retrouve bien :

$$\mathbb{E}[\mathbb{1}_A(X)] = 1 \cdot \mathbb{P}(X \in A) + 0 \cdot \mathbb{P}(X \notin A) = \mathbb{P}(X \in A),$$

ce qui est cohérent avec l'exemple 2.2 puisque $\mathbb{1}_A(X)$ suit une loi de Bernoulli de paramètre $\mathbb{P}(X \in A)$.

Démonstration. Considérons d'abord le cas où X est discrète. Alors $\phi(X)$ l'est aussi et :

$$\mathbb{P}(\phi(X) = y) = \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}}$$

On commence par traiter l'énoncé au sujet de l'intégrabilité, en écrivant la suite d'égalités suivantes, dans $[0, +\infty]$ à l'aide de Fubini positif :

$$\begin{aligned}
 \sum_y |y| \mathbb{P}(\phi(X) = y) &= \sum_y |y| \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_y \sum_x |\phi(x)| \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x |\phi(x)| \mathbb{P}(X = x) \sum_y \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x |\phi(x)| \mathbb{P}(X = x),
 \end{aligned}$$

On en déduit bien que

$$\sum_y |y| \mathbb{P}(\phi(X) = y) < \infty \iff \sum_x |\phi(x)| \mathbb{P}(X = x) < \infty$$

Ainsi :

$$\begin{aligned}
 \mathbb{E}[\phi(X)] &= \sum_y y \mathbb{P}(\phi(X) = y) &= \sum_y y \sum_x \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_y \sum_x \phi(x) \mathbb{P}(X = x) \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x \phi(x) \mathbb{P}(X = x) \sum_y \mathbb{1}_{\{\phi(x)=y\}} \\
 &= \sum_x \phi(x) \mathbb{P}(X = x),
 \end{aligned}$$

On considère maintenant le cas où X est à densité. On traitera seulement ici le cas où ϕ est C^1 et de dérivée $\phi'(x) > 0$ pour tout $x \in \mathbb{R}$. Alors il existe $-\infty \leq a < b \leq +\infty$ tels que $\text{Im}(\phi) = (a, b)$. Soit $x \in \text{Im}(\phi)$. On a alors :

$$\begin{aligned}
 \mathbb{P}(\phi(X) \leq x) &= \mathbb{P}(X \leq \phi^{-1}(x)) \\
 &= \int_{-\infty}^{\phi^{-1}(x)} f_X(y) dy \\
 &= \int_a^x f_X(\phi^{-1}(y))(\phi^{-1})'(y) dy \\
 &= \int_{-\infty}^x f_X(\phi^{-1}(y))(\phi^{-1})'(y) \mathbb{K}_{\text{Im}\phi}(y) dy
 \end{aligned}$$

puis on étend facilement l'énoncé à $x \in \mathbb{R}$, ce qui permet d'identifier $f_X(\phi^{-1}(y))(\phi^{-1})'(y)\mathbb{K}_{\text{Im}\phi}(y)$ comme une densité de $\phi(X)$. Maintenant,

$$\begin{aligned}
 \mathbb{E}[\phi(X)] &= \int_{-\infty}^{+\infty} y f_{\phi(X)}(y) dy \\
 &= \int_{-\infty}^{+\infty} y f_X(\phi^{-1}(y))(\phi^{-1})'(y) dy \\
 &= \int_{-\infty}^{+\infty} \phi(x) f_X(x) dx,
 \end{aligned}$$

par un changement de variable $x = \phi^{-1}(y)$, $dx = (\phi^{-1})'(y)dy$. Ceci conclut la preuve du théorème. $\square$

Une conséquence importante qui découle très facilement de la formule de transfert est la suivante :

Corollaire 2.1 (Linéarité de l'intégrale). *Si f_1 et f_2 sont des fonctions telles que $f_1(X)$ et $f_2(X)$ sont intégrables, alors $(f_1 + f_2)(X)$ est intégrable et*

$$\mathbb{E}[(f_1 + f_2)(X)] = \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)],$$

En particulier, si X est intégrable,

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b,$$

Démonstration. Et dans le cas où X est une variable aléatoire discrète. Noter qu'on a le droit de découper la somme en 2 car $f_1(X)$ et $f_2(X)$ sont intégrables :

$$\begin{aligned}
 \mathbb{E}[(f_1 + f_2)(X)] &= \sum_x (f_1(x) + f_2(x))\mathbb{P}(X = x) \\
 &= \sum_x f_1(x)\mathbb{P}(X = x) + \sum_x f_2(x)\mathbb{P}(X = x) \\
 &= \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)]
 \end{aligned}$$

De même, si X est à densité, par (2.1),

$$\begin{aligned}
 \mathbb{E}[(f_1 + f_2)(X)] &= \int_{-\infty}^{+\infty} (f_1(x) + f_2(x))f_X(x)dx \\
 &= \int_{-\infty}^{+\infty} f_1(x)f_X(x)dx + \int_{-\infty}^{+\infty} f_2(x)f_X(x)dx \\
 &= \mathbb{E}[f_1(X)] + \mathbb{E}[f_2(X)].
 \end{aligned}$$

Pour le deuxième item, on prend seulement $f_1(x) = a \cdot x$ et $f_2(x) = b$. □

Une conséquence directe du théorème de transfert, de la linéarité et de la positivité est le résultat suivant de comparaison, dont la preuve est laissée au lecteur :

Lemme 2.1. *Soit X une variable aléatoire à valeurs dans I . Si $\phi_1, \phi_2 : I \rightarrow \mathbb{R}_+$ vérifient $\phi_1 \leq \phi_2$, alors $\mathbb{E}[\phi_1(X)] \leq \mathbb{E}[\phi_2(X)]$. En particulier, si $\phi_2(X)$ est intégrable, alors $\phi_1(X)$ est intégrable.*

Pour les variables aléatoires de loi symétrique, certains calculs d'espérance peuvent se simplifier.

Définition 2.3. On dit que la loi de la variable aléatoire X est symétrique si X et $-X$ sont égales en loi, c'est-à-dire que pour tout $A \subset \mathbb{R}$,

$$\mathbb{P}(X \in A) = \mathbb{P}(-X \in A).$$

On peut encore écrire cette dernière égalité : $\mathbb{P}(X \in A) = \mathbb{P}(X \in -A)$ si $-A = \{-x, x \in A\}$.

Notons la condition suffisante suivante :

Lemme 2.2. *La loi de X est symétrique dans les deux cas suivants :*

1. *X est une variable aléatoire discrète dont la fonction de masse est paire.*
2. *X est une variable aléatoire à densité dont une densité est paire.*

Démonstration. Si X est une variable aléatoire discrète dont la fonction de masse est paire :

$$\begin{aligned}
 \mathbb{P}(-X \in A) &= \mathbb{P}(X \in -A) \\
 &= \sum_{x_k \in -A} \mathbb{P}(X = x_k) \\
 &= \sum_{-x_k \in A} \mathbb{P}(X = -x_k) \\
 &= \sum_{x_k \in A} \mathbb{P}(X = x_k) = \mathbb{P}(X \in A)
 \end{aligned}$$

Si X est une variable aléatoire à densité dont une densité est paire :

$$\begin{aligned}
 \mathbb{P}(-X \in A) &= \mathbb{P}(X \in -A) \\
 &= \int_{\mathbb{R}} \mathbb{1}_{-A}(x) f_X(x) dx \\
 &= \int_{\mathbb{R}} \mathbb{1}_{-A}(-x) f_X(-x) dx \\
 &= \int_{\mathbb{R}} \mathbb{1}_A(x) f_X(x) dx
 \end{aligned}$$

□

Lemme 2.3. *Soit X une variable aléatoire symétrique et $\phi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction impaire, c'est-à-dire $\phi(-x) = -\phi(x)$ pour tout $x \in \mathbb{R}$, telle que $\phi(X)$ est intégrable. Alors*

$$\mathbb{E}[\phi(X)] = 0$$

Il est clef ici que la variable considérée soit intégrable.

Démonstration. On note simplement que :

$$\begin{aligned}\mathbb{E}[\phi(X)] &= \mathbb{E}[\phi(-X)] && (X \stackrel{\text{loi}}{=} -X) \\ &= \mathbb{E}[-\phi(X)] && (\phi \text{ impaire}) \\ &= -\mathbb{E}[\phi(X)] && (\text{linéarité de l'espérance}).\end{aligned}$$

Par conséquent, $\mathbb{E}[\phi(X)] = 0$. □

Par exemple, si X est symétrique et intégrable, alors $\mathbb{E}[X] = 0$ (utiliser $\phi(x) = x$). Si l'on note $x^+ = \max\{x, 0\} = x\mathbb{1}_{x>0}$ et $x^- = \max\{-x, 0\} = -x\mathbb{1}_{x<0}$ les parties positives et négatives du réel x , qui vérifient $x = x^+ - x^-$ et $|x| = x^+ + x^-$. On peut relier l'intégrabilité d'une variable aléatoire à celle de ses parties positives et négatives comme suit :

Lemme 2.4. *Soit X une variable aléatoire. X est intégrable ssi $|X|$ est intégrable ssi X^+ et X^- sont intégrables. Dans ce cas, on peut alors écrire :*

$$\mathbb{E}[|X|] = \mathbb{E}[X^+] + \mathbb{E}[X^-] \quad \text{et} \quad \mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

CARACTÉRISATION DES LOIS DE FONCTIONS DE VARIABLES ALÉATOIRES

La formule dite de transfert permet de caractériser la loi d'une fonction d'une variable aléatoire; on comparera cette méthode avec les autres qui utilise la seule notion de fonction de répartition. Les deux méthodes sont également recevables, et vous pouvez choisir celle que vous préférez. La proposition suivante permet de caractériser la loi d'une variable aléatoire $g(X)$.

Proposition 2.2. *Soit X une v.a.r, et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. S'il existe une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ telle que pour toute fonction ϕ bornée,*

$$\mathbb{E}[\phi(g(X))] = \int_{\mathbb{R}} \phi(y) f(y) dy$$

alors f est une densité de probabilité, et $g(X)$ est une v.a.r. à densité de densité f .

La fonction ϕ porte le nom de "fonction test" ou encore "fonction muette" : aussi la méthode est quelquefois appelée méthode de la fonction muette. Pour que le résultat se mette sous la forme demandée il faut en fait partir d'une v.a.r. X à densité.

Démonstration. Il suffit de choisir $\phi = \mathbb{1}_{]-\infty, x]}$: on a alors

$$\begin{aligned}
 \mathbb{P}(g(X) \leq x) &= \mathbb{E}[\mathcal{K}_{]-\infty, x]}(g(X))] \\
 &= \int_{-\infty}^{+\infty} \mathcal{K}_{]-\infty, x]}(y) f(y) dy \\
 &= \int_{-\infty}^x f(y) dy
 \end{aligned}$$

et puisque la fonction de répartition caractérise la loi, la v.a. $g(X)$ admet bien f pour densité. $\square$

On note qu'il suffit en fait que la classe de fonctions ϕ pour laquelle la propriété vaut contienne les fonctions $(\mathcal{K}_{]-\infty, x]}, x \in \mathbb{R})$, ce qui revient à appliquer la caractérisation des lois par les fonctions de répartition. Conceptuellement il n'y a pas de différence entre les deux méthodes, et on pourrait même argumenter que l'emploi d'une fonction test obscurcit le propos par rapport à l'usage de la seule fonction de répartition. Les exemples suivants pourront aider à faire son choix entre les deux méthodes.

Exemple 2.5. $g : \mathbb{R} \rightarrow \mathbb{R}, g(x) = x^2$, X une v.a.r. à densité, de densité f_X , ϕ bornée.

$$\begin{aligned}
 \mathbb{E}[\phi(X^2)] &= \int_{\mathbb{R}} \phi(x^2) f_X(x) dx \\
 &= \int_{-\infty}^0 \phi(x^2) f_X(x) dx + \int_0^{\infty} \phi(x^2) f_X(x) dx \\
 &= \int_0^{\infty} \phi(y) f_X(-\sqrt{y}) \frac{1}{2\sqrt{y}} dy + \int_0^{\infty} \phi(y) f_X(\sqrt{y}) \frac{1}{2\sqrt{y}} dy \\
 &= \int_{\mathbb{R}} \phi(y) (f_X(-\sqrt{y}) + f_X(\sqrt{y})) \frac{1}{2\sqrt{y}} \mathcal{K}_{\mathbb{R}_+}(y) dy
 \end{aligned}$$

— $g : \mathbb{R} \rightarrow \mathbb{R}, g(x) = |x|$, X une v.a.r. à densité, de densité f_X , ϕ bornée.

$$\begin{aligned}
 \mathbb{E}[\phi(|X|)] &= \int_{\mathbb{R}} \phi(|x|) f_X(x) dx \\
 &= \int_{-\infty}^0 \phi(-x) f_X(x) dx + \int_0^{\infty} \phi(x) f_X(x) dx \\
 &= \int_0^{\infty} \phi(y) f_X(-y) dy + \int_0^{\infty} \phi(x) f_X(x) dx \\
 &= \int_{\mathbb{R}} \phi(y) (f_X(-y) + f_X(y)) \mathbb{1}_{\mathbb{R}_+}(y) dy
 \end{aligned}$$

$$- \quad g : \mathbb{R} \rightarrow \mathbb{R}, g(x) = x - \lfloor x \rfloor, X \sim \mathcal{E}(\lambda),$$

$$\begin{aligned}
 \mathbb{E}[\phi(X - \lfloor X \rfloor)] &= \int_{\mathbb{R}} \phi(x - \lfloor x \rfloor) \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x) dx \\
 &= \int_0^{\infty} \phi(x - \lfloor x \rfloor) \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}_+}(x) dx \\
 &= \sum_{n=0}^{\infty} \int_n^{n+1} \phi(x - \lfloor x \rfloor) \lambda e^{-\lambda x} dx \\
 &= \sum_{n=0}^{\infty} \int_0^1 \phi(n + x - \lfloor n + x \rfloor) \lambda e^{-\lambda(n+x)} dx \\
 &= \left(\sum_{n=0}^{\infty} e^{-\lambda n} \right) \left(\int_0^1 \phi(x) \lambda e^{-\lambda x} dx \right) \\
 &= \int_{\mathbb{R}} \phi(x) \left(\frac{\lambda e^{-\lambda x}}{1 - e^{-\lambda}} \mathbb{1}_{[0,1[}(x) \right) dx
 \end{aligned}$$

$$- \quad g : \mathbb{R} \rightarrow \mathbb{R}, g(x) = 1/x, X \sim \mathcal{C}(a),$$

$$\begin{aligned}
 \mathbb{E}[\phi(1/X)] &= \int_{\mathbb{R}} \phi\left(\frac{1}{x}\right) \frac{a}{\pi} \frac{1}{a^2 + x^2} dx \\
 &= \int_{-\infty}^0 \phi\left(\frac{1}{x}\right) \frac{1}{\pi} \frac{1}{a^2 + x^2} dx + \int_0^{+\infty} \phi\left(\frac{1}{x}\right) \frac{a}{\pi} \frac{1}{a^2 + x^2} dx \\
 &= \int_{-\infty}^0 \phi(y) \frac{a}{\pi} \frac{1}{a^2 + (1/y)^2} \frac{dy}{y^2} + \int_0^{+\infty} \phi(y) \frac{a}{\pi} \frac{1}{a^2 + (1/y)^2} \frac{dy}{y^2} \\
 &= \int_{\mathbb{R}} \phi(y) \frac{1/a}{\pi} \frac{1}{(1/a)^2 + y^2} dy
 \end{aligned}$$

donc $g(X) \sim \mathcal{C}(1/a)$.

Cette proposition a évidemment son pendant discret, dont la preuve est similaire.

Proposition 2.3. *Soit X une v.a.r, et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. S'il existe un ensemble S au plus dénombrable et une fonction $p : S \rightarrow]0, +\infty[$ telle que pour toute fonction ϕ bornée,*

$$\mathbb{E}[\phi(g(X))] = \sum_{y \in S} \phi(y)p(y)$$

alors $g(X)$ est une variable aléatoire discrète, de fonction de masse p .

Un nouvel exemple dans ce dernier cadre.

Exemple 2.6. Soit $g : \mathbb{R} \rightarrow \mathbb{R}$, $g(x) = \lfloor x \rfloor$, et $X \sim \mathcal{E}(\lambda)$ une v.a.r. à densité, de densité f_X .

$$\begin{aligned} \mathbb{E}[\phi(\lfloor X \rfloor)] &= \int_{\mathbb{R}} \phi(\lfloor x \rfloor) \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}^+}(x) dx \\ &= \sum_{n=0}^{\infty} \int_n^{n+1} \phi(\lfloor x \rfloor) \lambda e^{-\lambda x} dx \\ &= \sum_{n=0}^{\infty} \phi(n) \int_n^{n+1} \lambda e^{-\lambda x} dx \\ &= \sum_{n=0}^{\infty} \phi(n) (e^{-\lambda n} - e^{-\lambda(n+1)}) \\ &= \sum_{n=0}^{\infty} \phi(n) e^{-\lambda n} (1 - e^{-\lambda}) \end{aligned}$$

Donc $\lfloor X \rfloor$ est une v.a.r. discrète de fonction de masse $n \in \mathbb{N} \mapsto \mathbb{P}(\lfloor X \rfloor = n) = e^{-\lambda n} (1 - e^{-\lambda})$.

2.3 MOMENTS ET QUANTITÉS ASSOCIÉES

Définition 2.4. Si X est une variable aléatoire telle que X^k est intégrable, alors on dit que X admet un moment d'ordre k et on appelle la quantité $\mathbb{E}[X^k]$, $k \in \mathbb{N}^*$ son k -ième moment (ou le k -ième moment de sa loi).

On dit encore que X est de puissance k intégrable lorsque X^k est intégrable. Les

moments d'une variable aléatoire décrivent différents aspects de sa loi. Aussi et surtout ils permettent de donner des bornes sur des probabilités d'événements, comme nous le verrons plus loin dans ce chapitre. Nous allons nous concentrer dans ce cours sur les deux premiers moments (c'est-à-dire $k = 1, 2$), qui sont les plus importants. Tout d'abord quelques généralités. Formellement, on peut toujours définir les moments pairs, puisque la fonction $x \mapsto x^k$ est positive pour $k \in \mathbb{N}$ pair, mais ces moments peuvent alors être infinis.

Lemme 2.5. *Soit $k < m$ deux entiers. Si X admet un moment d'ordre m , alors X admet un moment d'ordre k et*

$$\mathbb{E}[|X|^k] \leq \mathbb{E}[|X|^m] + 1$$

Démonstration. On note que $|x|^k \leq 1 + |x|^m$ pour tout $x \in \mathbb{R}$ et on applique le lemme de comparaison. $\square$

On note que les moments impairs sont simples à calculer quand la loi est paire :

Lemme 2.6. *Si la loi de X est symétrique, et X admet un moment d'ordre $k \in \mathbb{N}$ impair, alors $\mathbb{E}[X^k] = 0$.*

Démonstration. On utilise la fonction $\phi(x) = x^k$ impaire puisque k est impair. $\square$

ESPÉRANCE

Le premier moment $\mathbb{E}[X]$ est défini pour toute v.a.r. intégrable, ou positive ou nulle. Il est appelé l'espérance ou la moyenne de la variable aléatoire X , et dans le cas où $\mathbb{E}[X] = 0$, on dit que la v.a. X est centrée. Notons qu'il est toujours possible de centrer la v.a. X en lui retranchant son espérance : on appelle $X - \mathbb{E}[X]$ la variable centrée; par linéarité de l'espérance, on a bien $\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = \mu - \mu = 0$.

VARIANCE

Le second moment est $\mathbb{E}[X^2]$, il est défini pour toute variable aléatoire, puisque $X^2 \geq 0$, mais il peut être infini.

Définition 2.5. Soit X variable aléatoire. On dit que X est de carré intégrable si $\mathbb{E}[X^2] < +\infty$. Dans ce cas, la variance de X est définie par

$$\mathcal{V}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Si X est de carré intégrable, X admet un premier moment, donc la définition

utilisant $\mathbb{E}[X^2]$ et $\mathbb{E}[X]$ est légitime. Une définition équivalente plus intuitive est la suivante :

Lemme 2.7. *Soit X variable aléatoire de carré intégrable. On a aussi :*

$$\mathcal{V}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

De la définition comme du lemme, on a que $\mathcal{V}(X) \geq 0$ (utiliser Jensen pour la définition ou la positivité de la fonction carré pour le lemme). La variance est un coefficient de dispersion : il mesure comment les valeurs de X sont étalées autour de son espérance. Si la variance est grande, les valeurs sont très étalées, alors que si la variance est petite, les valeurs sont concentrées autour de l'espérance.

Démonstration. On écrit :

$$(X - \mathbb{E}[X])^2 = X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2$$

Grâce à la linéarité de l'espérance, on obtient :

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X])^2] &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + \mathbb{E}[X]^2 \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \end{aligned}$$

□

Si X a une « dimension », c'est-à-dire si X mesure une quantité qui possède une dimension physique (par exemple une longueur en mètres), alors la variance aura comme dimension le carré de la dimension de X (par exemple mètres carrés). Pour obtenir une quantité de la même dimension que X , on prend alors la racine carrée de la variance qu'on nomme écart-type, noté souvent $\sigma \geq 0$, et défini par

$$\sigma = \sqrt{\mathcal{V}(X)}.$$

Cela conduit à noter la variance par σ^2 . L'écart-type donne l'ordre de grandeur de la distance entre les valeurs typiques de X et son espérance μ .

Définition 2.6. Si X est une v.a. de carré intégrable, d'espérance μ et d'écart-type $\sigma > 0$, on appelle

$$\frac{X - \mu}{\sigma}$$

la variable centrée réduite (ou simplement variable réduite) associée à X .

Elle est d'espérance nulle et de variance égale à 1 (et écart-type égal à 1), car

$$\begin{aligned}\mathbb{E}\left[\frac{X - \mu}{\sigma}\right] &= \frac{1}{\sigma}\mathbb{E}[X - \mu] \\ &= \frac{1}{\sigma} \times 0 \\ &= 0\end{aligned}$$

Et

$$\begin{aligned}\mathcal{V}\left(\frac{X - \mu}{\sigma}\right) &= \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^2\right] \\ &= \frac{1}{\sigma^2}\mathbb{E}[(X - \mu)^2] \\ &= \frac{1}{\sigma^2}\mathcal{V}(X) \\ &= 1.\end{aligned}$$

En poursuivant le raisonnement « dimensionnel » ci-dessus, la variable centrée réduite est une quantité adimensionnelle, car c'est le quotient de deux quantités de même dimension. Passer à la variable centrée réduite est le moyen « naturel » de normaliser une variable aléatoire de telle façon à obtenir une variable d'espérance nulle et de variance 1.

Propriétés de la variance. Nous résumons ici quelques propriétés importantes de la variance :

Proposition 2.4. *Soit X une variable aléatoire de carré intégrable.*

1. Si $a, b \in \mathbb{R}$,

$$\mathcal{V}(aX + b) = a^2\mathcal{V}(X)$$

(avec $0 \times \infty = 0$). En particulier, $\mathcal{V}(X + b) = \mathcal{V}(X)$.
 2. $\mathcal{V}(X) = 0$ si et seulement si X est p.s. constante, c'est-à-dire que $X \sim \delta_\mu$.

Démonstration. 1. Par linéarité de l'espérance, $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b = a\mu + b$,
 si bien que

$$\begin{aligned}\mathcal{V}(aX + b) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(aX + b - a\mathbb{E}[X] - b)^2] \\ &= \mathbb{E}[a^2(X - \mathbb{E}[X])^2] \\ &= a^2\mathcal{V}(X).\end{aligned}$$

2. On définit la variable aléatoire $Y = (X - \mu)^2$. Alors $Y \geq 0$ et $Y = 0$ si et seulement si $X = \mu$. Le Lemme ci-dessous appliqué à Y donne alors

$$X \sim \delta_\mu \iff \mathbb{E}[Y] = 0 \iff \mathcal{V}(X) = 0.$$

□

Lemme 2.8. Soit Y une v.a. positive. Alors $Y \sim \delta_0$ si et seulement si $\mathbb{E}[Y] = 0$.

La preuve de la réciproque (l'implication non évidente) sera faite en suite.

L'espérance est la constante qui approche le mieux la variable aléatoire. Dans le cadre des variables aléatoires de carré intégrable, une façon naturelle d'introduire espérance et variance est de les voir comme solution du problème d'optimisation suivant :

Lemme 2.9. Soit X une variable aléatoire de carré intégrable. On a :

$$\mathcal{V}(X) = \min_{a \in \mathbb{R}} \mathbb{E}[(X - a)^2],$$

et le minimum est atteint en un unique élément a égal à $\mathbb{E}[X]$.

Cet énoncé dit que la constante qui approche le mieux la variable aléatoire X au sens de la distance $(X, Y) \mapsto \mathbb{E}[(X - Y)^2]$ (dite des "moindres carrés" ou encore du "risque quadratique", un terme plus particulièrement employé en économie) est la constante égale à $\mathbb{E}[X]$.

Démonstration. Par linéarité de l'intégrale,

$$\begin{aligned}
 \mathbb{E}[(X - a)^2] &= \mathbb{E}[a^2 - 2aX + X^2] \\
 &= a^2 - 2a\mathbb{E}[X] + \mathbb{E}[X^2] \\
 &= (a - \mathbb{E}[X])^2 + (\mathbb{E}[X^2] - \mathbb{E}[X]^2) \\
 &= (a - \mathbb{E}[X])^2 + \mathcal{V}(X) \\
 &\geq \mathcal{V}(X),
 \end{aligned}$$

avec égalité si et seulement si $a = \mathbb{E}[X]$.

□

Un corollaire simple de ce résultat est alors que

Corollaire 2.2. *Soit X variable aléatoire à valeurs dans $[0, 1]$. Alors X est de carré intégrable et*

$$\mathcal{V}(X) \leq 1/4$$

Démonstration. D'après le lemme précédent, pour tout $y \in \mathbb{R}$, $\mathcal{V}(X) \leq \mathbb{E}[(X - y)^2]$. On choisit alors $y = 1/2$ et on observe que $|X - 1/2| \leq 1/2$ implique alors :

$$\mathcal{V}(X) \leq \mathbb{E}[(X - 1/2)^2] \leq \mathbb{E}[1/4] = 1/4.$$

□

On peut se demander quelle constante approche le mieux une variable aléatoire au sens de la norme L^1 cette fois, c'est-à-dire en quel point $a \mapsto \mathbb{E}[|X - a|]$ atteint son infimum (en fait un minimum). C'est un exercice plus ardu, qui conduit à l'introduction de la notion de médiane.

2.4 FONCTION GÉNÉRATRICE DES MOMENTS

On définit pour tout réel t , la fonction génératrice des moments ϕ_X de la variable aléatoire X par

$$\phi_X(t) = \mathbb{E}[e^{tX}] \in]0, +\infty[.$$

Comme son nom l'indique, c'est un outil adapté au calcul des moments au moyen de développements en série entière :

Proposition 2.5. *Supposons qu'il existe $t_0 > 0$ tel que $\phi_X(t) < \infty$ pour tout $|t| < t_0$. Alors pour tout $|t| < t_0$,*

$$\phi_X(t) = \sum_{k=0}^{\infty} \mathbb{E}[X^k] \frac{t^k}{k!},$$

et le rayon de convergence de la série entière du membre de droite est supérieur ou égal à t_0 . Dans ce cas, ϕ_X admet des dérivées à tout ordre sur $] -t_0, t_0[$ et on a, pour tout $k \in \mathbb{N}^$,*

$$\mathbb{E}[X^k] = \phi_X^{(k)}(0),$$

où $\phi_X^{(k)}$ est la k -ième dérivée de la fonction ϕ_X .

Démonstration. On suppose X discrète, la preuve pour X à densité étant très similaire. On montre d'abord que $\mathbb{E}[e^{|tX|}] < \infty$ pour tout $|t| < t_0$. En effet, $e^{|tx|} \leq e^{tx} + e^{-tx}$ pour tout $x \in \mathbb{R}$ et donc

$$\mathbb{E}[e^{|tX|}] \leq \mathbb{E}[e^{tX}] + \mathbb{E}[e^{-tX}] < \infty,$$

par hypothèse. Ceci garantit l'intégrabilité de e^{tX} pour $|t| < t_0$, et on calcule alors pour ces valeurs de t ,

$$\begin{aligned} \phi_X(t) &= \mathbb{E}[e^{tX}] \\ &= \sum_x e^{tx} \mathbb{P}(X = x) \\ &= \sum_x \left(\sum_{k=0}^{\infty} \frac{(tx)^k}{k!} \mathbb{P}(X = x) \right). \end{aligned}$$

Puisque

$$\sum_x \left(\sum_{k=0}^{\infty} \frac{|tx|^k}{k!} \mathbb{P}(X = x) \right) = \mathbb{E}[e^{|tX|}] < \infty$$

le théorème de Fubini s'applique et donne :

$$\phi_X(t) = \sum_{k=0}^{\infty} \left(\sum_x \frac{(tx)^k}{k!} \mathbb{P}(X = x) \right),$$

c'est-à-dire que cette série (en k) converge et a comme limite $\phi_X(t)$. En réarrangeant, on obtient

$$\begin{aligned} \phi_X(t) &= \sum_{k=0}^{\infty} \left(\sum_x x^k \mathbb{P}(X = x) \right) \frac{t^k}{k!} \\ &= \sum_{k=0}^{\infty} \mathbb{E}[X^k] \frac{t^k}{k!}. \end{aligned}$$

En particulier, cette dernière série entière converge pour tout $|t| < t_0$, si bien que son rayon de convergence est supérieur ou égal à t_0 . Le résultat sur les dérivées successives en o en découle. $\square$

La fonction génératrice permet non seulement de retrouver les moments, mais également toute la loi. Ceci est le contenu du théorème suivant (admis) :

Théorème 2.1. *Supposons ϕ_X finie dans un voisinage de 0. Alors la loi de X est l'unique loi de fonction génératrice ϕ_X .*

Nous donnons maintenant plusieurs exemples :

Exemple 2.7. Soit $a, b \in \mathbb{R}$. La fonction génératrice des moments d'une combinaison linéaire s'exprime simplement :

$$\begin{aligned} \phi_{aX+b}(t) &= \mathbb{E}[e^{t(aX+b)}] \\ &= \mathbb{E}[e^{(at)X}] e^{tb} \\ &= \phi_X(at) e^{tb}. \end{aligned}$$

Exemple 2.8. $X \sim \mathcal{P}(\lambda)$, $\lambda \geq 0$. Alors pour tout $t \in \mathbb{R}$,

$$\begin{aligned}
 \phi_X(t) &= \mathbb{E}[e^{tX}] \\
 &= \sum_{n=0}^{\infty} e^{tn} e^{-\lambda} \frac{\lambda^n}{n!} \\
 &= e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda e^t)^n}{n!} \\
 &= e^{\lambda(e^t-1)}.
 \end{aligned}$$

Exemple 2.9. $X \sim \mathcal{N}(0, 1)$. Alors pour tout $t \in \mathbb{R}$,

$$\begin{aligned}
 \phi_X(t) &= \int_{-\infty}^{+\infty} \frac{e^{-x^2/2+tx}}{\sqrt{2\pi}} dx \\
 &= \int_{-\infty}^{+\infty} \frac{e^{-(x-t)^2/2+t^2/2}}{\sqrt{2\pi}} dx \\
 &= e^{t^2/2} \int_{-\infty}^{+\infty} \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy \quad (y = x - t) \\
 &= e^{t^2/2}.
 \end{aligned}$$

Si $Y \sim \mathcal{N}(\mu, \sigma^2)$, alors $Y \stackrel{\text{loi}}{=} \mu + \sigma X$, donc

$$\phi_Y(t) = e^{t\mu} \phi_X(\sigma t) = e^{t\mu + \sigma^2 t^2/2}.$$

En particulier, si $X \sim \mathcal{N}(0, 1)$, on retrouve les moments de X par unicité du développement en série entière (DSE) :

$$\phi_X(t) = \sum_{k=0}^{\infty} \frac{(t^2/2)^k}{k!} = \sum_{k=0}^{\infty} \frac{(2k)!}{2^k k!} \frac{t^{2k}}{(2k)!},$$

si bien que $\mathbb{E}[X^{2k+1}] = 0$ pour tout $k \in \mathbb{N}$, et

$$\mathbb{E}[X^{2k}] = \frac{(2k)!}{2^k k!} = \prod_{i=1}^k (2i - 1),$$

cette dernière quantité étant également notée $(2k-1)!!$. En particulier, $\mathbb{E}[X^4] = 3$.

Exemple 2.10. $X \sim \mathcal{E}(1)$. Alors

$$\begin{aligned}\phi_X(t) &= \int_0^\infty e^{tx} e^{-x} dx \\ &= \int_0^\infty e^{-(1-t)x} dx \\ &= \begin{cases} \frac{1}{1-t}, & t < 1 \\ +\infty, & t \geq 1. \end{cases}\end{aligned}$$

On reconnaît une série géométrique :

$$\phi_X(t) = \sum_{k=0}^{\infty} t^k = \sum_{k=0}^{\infty} k! \frac{t^k}{k!},$$

et on en déduit par unicité du DSE que $\mathbb{E}[X^k] = k!$ pour tout $k \in \mathbb{N}$.

2.5 INÉGALITÉS

Nous présentons trois inégalités faisant intervenir l'espérance d'une variable aléatoire.

INÉGALITÉ DE MARKOV

L'inégalité de Markov est l'inégalité fondamentale permettant de borner des probabilités par des espérances. Cette inégalité repose sur une inégalité simple de fonctions élémentaires.

Lemme 2.10. Soit $y \geq 0$ et $x > 0$. Alors

$$\mathbb{P}_{\{y \geq x\}} \leq \frac{y}{x}.$$

Démonstration. On distingue les deux cas : si $y \geq x$, alors $\mathbb{P}_{\{y \geq x\}} = 1 \leq y/x$, et si $y < x$, alors $0 \leq y/x$, car y et x sont positifs. $\square$

Lemme 2.11. Soit X une v.a. et $B \subset \mathbb{R}$. Alors

$$\mathbb{P}(X \in B) = \mathbb{E}[\mathbb{P}_{\{X \in B\}}].$$

Démonstration. La v.a. $\mathbb{1}_{\{X \in B\}}$ suit la loi de Bernoulli de paramètre $\mathbb{P}(X \in B)$ car elle est à valeurs dans $\{0, 1\}$ et elle vaut 1 avec probabilité $\mathbb{P}(X \in B)$. Son espérance vaut alors $\mathbb{P}(X \in B)$. $\square$

Théorème 2.2 (Inégalité de Markov). *Soit X une v.a. positive. Alors pour tout $x > 0$,*

$$\mathbb{P}(X \geq x) \leq \frac{\mathbb{E}[X]}{x}.$$

Démonstration. Soit $x > 0$. Puisque $X \geq 0$, les Lemmes précédents montrent que $\mathbb{1}_{\{X \geq x\}} \leq X/x$. Et on a aussi par les Lemmes,

$$\mathbb{P}(X \geq x) = \mathbb{E}[\mathbb{1}_{\{X \geq x\}}] \leq \mathbb{E}\left[\frac{X}{x}\right] = \frac{\mathbb{E}[X]}{x},$$

par linéarité de l'espérance. $\square$

Démonstration Lemme 2.8. Si $Y \sim \delta_0$, alors par définition de l'espérance, $\mathbb{E}[Y] = 0 \times 1 = 0$. Si $Y \not\sim \delta_0$, alors il existe $x > 0$ tel que $\mathbb{P}(Y \geq x) > 0$. Par l'inégalité de Markov,

$$\mathbb{E}[Y] \geq \mathbb{P}(Y \geq x) \times x > 0.$$

Ceci conclut la preuve. $\square$

INÉGALITÉ DE BIENAYMÉ-TCHEBYCHEV

Théorème 2.3 (Inégalité de Tchebychev). *Soit X une v.a. d'espérance finie. Alors pour tout $x > 0$,*

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) \leq \frac{\mathcal{V}(X)}{x^2}.$$

Démonstration. On remarque que

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) = \mathbb{P}((X - \mathbb{E}[X])^2 > x^2).$$

La variable $(X - \mathbb{E}[X])^2$ étant positive, on peut appliquer l'inégalité de Markov pour obtenir

$$\mathbb{P}(|X - \mathbb{E}[X]| > x) \leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{x^2} = \frac{\mathcal{V}(X)}{x^2}.$$

□

INÉGALITÉ DE JENSEN

Soit $I \subset \mathbb{R}$ un intervalle. On rappelle qu'une fonction $\phi : I \rightarrow \mathbb{R}$ est convexe si pour tout $x, y \in I, t \in [0, 1]$,

$$\phi(tx + (1 - t)y) \leq t\phi(x) + (1 - t)\phi(y).$$

Remarque 2.2. On note que si X est une variable aléatoire telle que $\mathbb{P}(X = x) = p$, $\mathbb{P}(X = y) = 1 - p$, alors l'inégalité précédente s'écrit encore très simplement :

$$\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)].$$

L'inégalité de Jensen consiste en la généralisation de cette inégalité aux variables aléatoires réelles X intégrables.

Si $\phi \in C^2(I)$, alors ϕ est convexe si et seulement si $\phi'' \geq 0$. Des exemples sont les fonctions

$$(x \mapsto e^x), \quad (x \mapsto e^{-x}) \quad \text{et} \quad (x \mapsto |x|^k) \quad \text{pour } k \geq 1.$$

Une fonction ϕ telle que $-\phi$ est convexe est dite concave. Exemples :

$$(x > 0 \mapsto \log x) \quad \text{et} \quad (x \geq 0 \mapsto x^k) \quad \text{pour } k \leq 1.$$

On admet qu'une fonction convexe admet des minorants affines en tout point : si $x_0 \in I$, alors il existe $a \in \mathbb{R}$ tel que pour tout $x \in I$,

$$\phi(x_0) + a(x - x_0) \leq \phi(x).$$

(Dans le cas où ϕ est dérivable en x_0 , on peut simplement choisir $a = \phi'(x_0)$; sinon, de la convexité, ϕ admet des dérivées à gauche et à droite distinctes, avec nécessairement $\phi'((x_0)^-) \leq \phi'((x_0)^+)$; tout nombre $a \in [\phi'((x_0)^-), \phi'((x_0)^+)]$ convient alors.)

Théorème 2.4 (Inégalité de Jensen). *Soit X une v.a. d'espérance finie, à valeurs dans un intervalle $I \subset \mathbb{R}$ et $\phi : I \rightarrow \mathbb{R}$ convexe. Alors*

$$\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)],$$

inégalité dans laquelle le membre de droite peut être infini.

Démonstration. Posons $x_0 = \mathbb{E}[X]$. On peut alors montrer qu'il existe $a \in \mathbb{R}$, tel que pour tout $x \in \mathbb{R}$,

$$\phi(x_0) + a(x - x_0) \leq \phi(x).$$

Par conséquent,

$$\begin{aligned} \mathbb{E}[\phi(X)] &\geq \mathbb{E}[\phi(x_0) + a(X - x_0)] \\ &= \phi(x_0) + a(\mathbb{E}[X - x_0]) \\ &= \phi(x_0) + a(\mathbb{E}[X] - x_0) \\ &= \phi(x_0), \end{aligned}$$

car $x_0 = \mathbb{E}[X]$. □

Exemple 2.11. Soit $t \in \mathbb{R}$. La fonction $x \mapsto e^{tx}$ est convexe sur $\mathbb{R}$ donc, pour X variable aléatoire réelle intégrable,

$$e^{t\mathbb{E}[X]} \leq \mathbb{E}[e^{tX}],$$

ce dernier terme pouvant être infini.

Exemple 2.12. On peut préciser l'inégalité comme suit. Soit $k < m$ deux entiers. Si X admet un moment d'ordre k , alors, par convexité de $x \mapsto x^{m/k}$ sur $]0, +\infty[$,

$$\mathbb{E}[|X|^k]^{m/k} \leq \mathbb{E}[(|X|^k)^{m/k}] = \mathbb{E}[|X|^m],$$

ce dernier moment pouvant être infini.

2.6 AUTRES DÉFINITIONS DE L'ESPÉRANCE

On se demande ici s'il est possible d'offrir une version unifiée de la définition de l'espérance, qui pour le moment diffère selon que la variable sous-jacente est à densité ou discrète. Une telle définition doit :

- faire intervenir la seule fonction de répartition (c'est la seule façon que l'on a de définir une loi générique),
- coïncider avec les définitions précédentes pour les variables discrètes ou à densité.

Une idée commune aux deux méthodes ci-dessous est l'intégration par parties. Cette fin de chapitre s'adresse aux étudiants désireux d'aller plus loin.

À LA LEBESGUE.

Lemme 2.12. *Soit X variable aléatoire positive ou nulle de fonction de répartition F_X . On a l'égalité suivante dans $[0, +\infty]$:*

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt = \int_0^\infty (1 - F_X(t)) dt.$$

Cette égalité signifie que les quantités de part et d'autre du symbole d'égalité sont soit simultanément finies et égales, soit simultanément infinies.

On notera en particulier que l'intégrabilité de X est équivalente à l'intégrabilité de la fonction $t \mapsto \mathbb{P}(X > t) = 1 - F_X(t)$ au voisinage de $+\infty$.

Bien sûr, on ne peut démontrer ce résultat que dans le cas des variables discrètes ou à densité pour lesquelles l'espérance a été préalablement définie; cependant, la formule a un sens dès lors que la fonction de répartition est définie, et on pourrait donc la prendre comme une définition de l'espérance pour toute variable aléatoire positive ou nulle. Nous avons choisi de ne pas procéder de la sorte pour des raisons pédagogiques, cette définition n'étant pas très naturelle de prime abord (on ne voit pas en quoi $\mathbb{E}[X]$ représente une moyenne pondérée).

Démonstration. Si X est à densité, de densité f_X , alors :

$$\begin{aligned}
 \mathbb{E}[X] &= \mathbb{E} \left[\int_0^\infty \mathbb{1}_{\{X>t\}} dt \right] \\
 &= \int_0^\infty \left(\int_0^\infty \mathbb{1}_{\{x>t\}} dt \right) f_X(x) dx \\
 &= \int_0^\infty \left(\int_0^\infty \mathbb{1}_{\{x>t\}} f_X(x) dx \right) dt \quad \text{de Fubini positif} \\
 &= \int_0^\infty \mathbb{E}[\mathbb{1}_{\{X>t\}}] dt \\
 &= \int_0^\infty \mathbb{P}(X > t) dt
 \end{aligned}$$

Le cas où X est discrète est analogue et laissé au lecteur. $\square$

Dans le cas de variables aléatoires à valeurs entières, le résultat précédent prend une forme plus simple, très utilisée dans la pratique :

Corollaire 2.3. *Soit X variable aléatoire à valeurs dans $\mathbb{N}$, on a l'égalité suivante dans $[0, +\infty]$:*

$$\mathbb{E}[X] = \sum_{n \in \mathbb{N}} \mathbb{P}(X > n) = \sum_{n \in \mathbb{N}^*} \mathbb{P}(X \geq n),$$

Démonstration. Deux possibilités : ou bien on reprend le raisonnement précédent en notant que pour tout entier m , $m = \sum_{n \in \mathbb{N}} \mathbb{1}_{\{m>n\}} = \sum_{n \in \mathbb{N}^*} \mathbb{1}_{\{m \geq n\}}$, ou bien on note que pour tout $t \in [n, n+1[$, $\mathbb{P}(X > t) = \mathbb{P}(X \geq n+1)$, d'où l'on déduit :

$$\begin{aligned}
 \int_n^{n+1} \mathbb{P}(X > t) dt &= \int_n^{n+1} \mathbb{P}(X \geq n+1) dt \\
 &= \mathbb{P}(X \geq n+1)
 \end{aligned}$$

qui implique bien le résultat cherché puisque :

$$\begin{aligned}
 \int_0^\infty \mathbb{P}(X > t) dt &= \sum_{n \in \mathbb{N}} \int_n^{n+1} \mathbb{P}(X > t) dt \\
 &= \sum_{n \in \mathbb{N}} \mathbb{P}(X \geq n+1) \\
 &= \sum_{n \in \mathbb{N}^*} \mathbb{P}(X \geq n) \\
 &= \sum_{n \in \mathbb{N}} \mathbb{P}(X > n)
 \end{aligned}$$

□

Aussi, notons le lien entre ces formules et l'intégrale de Riemann-Lebesgue, dont l'idée fondatrice est de considérer les contributions à l'aire sous la courbe en procédant à un découpage de l'axe des ordonnées plutôt que de l'axe des abscisses.

Exemple 2.13. On sait que si $X \sim \mathcal{G}(p)$, $0 < p \leq 1$, alors, pour $n \in \mathbb{N}$, $\mathbb{P}(X > n) = (1 - p)^n$ (les n premières expériences de Bernoulli sont des échecs), et ainsi $\mathbb{E}[X] = \sum_{n \in \mathbb{N}} (1 - p)^n = 1/p$.

À LA RIEMANN-STIELTJES

L'intégrale de Stieltjes (aussi appelée Riemann-Stieltjes) est une intégrale très adaptée au calcul des probabilités : elle permet notamment d'unifier les deux cadres théoriques ici présentés séparément ; celui du calcul d'espérance de variables discrètes ou continues.

Soit $a < b$ deux réels, $f, g : [a, b] \rightarrow \mathbb{R}$. On appelle *partition* de $[a, b]$ une suite finie $\pi = (x_0, \dots, x_n)$ de nombres réels avec $a = x_0 < x_1 < \dots < x_n = b$: l'entier n s'appelle alors la *longueur* de la partition, et le *pas* de la partition est la quantité $\max_{i=0 \dots n-1} (x_{i+1} - x_i)$; considérons la quantité

$$I(f, g, \pi) = \sum_{i=0}^{n-1} f(c_i) [g(x_{i+1}) - g(x_i)]$$

pour $c_i \in [x_i, x_{i+1}]$. Si ces quantités admettent une limite lorsque le pas de la subdivision tend vers 0, alors la limite est appelée l'intégrale de Stieltjes de f par rapport à g , et notée :

$$\int_a^b f(x) dg(x).$$

Précisément, on dit que $A \in \mathbb{R}$ est l'intégrale de Stieltjes de f par rapport à g si quel que soit $\varepsilon > 0$, il existe $\delta > 0$ tel que pour toute partition π de $[a, b]$ de pas $\leq \delta$, et pour tout choix de $c_0, \dots, c_{n-1}$ où n désigne la longueur de la partition π , $|I(f, g, \pi) - A| \leq \varepsilon$. Cette définition coïncide avec celle de l'intégrale de Riemann usuelle lorsque $g(x) = x$. Aussi, si g est dérivable alors on peut interpréter l'intégrale obtenue comme une intégrale de Riemann :

$$\int_a^b f(x)dg(x) = \int_a^b f(x)g'(x)dx.$$

Cette définition étant posée, l'enjeu principal est alors de comprendre quelles fonctions f (les intégrandes) et quelles fonctions g (les intégrateurs) donnent lieu à une intégrale de Stieltjes bien définie : un résultat important est l'existence de l'intégrale lorsqu'on prend f continue et g à variation bornée ($\sum_{i=0}^{n-1} |g(x_{i+1}) - g(x_i)|$ admet une borne uniforme sur l'ensemble des partitions π de $[a, b]$). Dans notre cadre probabiliste, soit X une variable aléatoire à valeurs dans $[a, b]$ p.s., alors prenant pour g la fonction de répartition F_X de X (g étant croissante, elle est évidemment à variation bornée) on obtient, pour toute fonction ϕ continue :

$$\mathbb{E}[\phi(X)] = \int_a^b \phi(x)dF_X(x)$$

et cette formule vaut pour toute v.a.r. X , qu'elle soit discrète, à densité, ou ni l'une ni l'autre. Bien entendu, tout comme pour l'introduction de l'intégrale de Lebesgue, donner un sens à une intégrale ne permet pas plus de la calculer...

Dans le cas où la v.a.r X ne prend pas ses valeurs dans un intervalle borné, alors on peut montrer que, pour ϕ continue bornée,

$$\int_a^b \phi(x)dF_X(x) \rightarrow \int_{-\infty}^{+\infty} \phi(x)dF_X(x) \in \mathbb{R}, \quad \text{quand } a \rightarrow -\infty, b \rightarrow \infty$$

et cette dernière quantité est prise comme définition de $\mathbb{E}[\phi(X)]$.

TD3 : VARs, LOI, MOMENTS.

Exercice 2.1. Posons, $n \in \mathbb{N}^*$ et $t > 0$ réel :

$$I(n) = \int_t^\infty \frac{1}{(n-1)!} x^{n-1} e^{-x} dx.$$

1. Montrer que l'on a :

$$I(n) = \frac{1}{(n-1)!} t^{n-1} e^{-t} + I(n-1).$$

2. En déduire :

$$I(n) = \sum_{k=0}^{n-1} e^{-t} \frac{t^k}{k!}.$$

3. Soit $X_t \sim \mathcal{P}(t)$ et $Y_n \sim \Gamma(n, 1)$. Montrer que :

$$\mathbb{P}(X_t < n) = \mathbb{P}(Y_n > t).$$

Exercice 2.2. 1. On cherche à caractériser l'ensemble des lois des variables aléatoires réelles X qui satisfont à l'égalité en loi :

$$X \stackrel{\text{loi}}{=} X^2.$$

(a) Quel est le signe de X ? En déduire la fonction de répartition F de X sur $] -\infty, 0[$.

(b) Montrer que F satisfait $F(t) = F(t^2)$ pour tout $t \geq 0$.

(c) En déduire que F est constante sur les deux intervalles $[0, 1[$ et sur $[1, \infty[$.

(d) Conclure : trouver l'ensemble des lois solutions.

2. Adapter le raisonnement précédent pour les deux équations en loi suivantes :

(a) $X \stackrel{\text{loi}}{=} X^3$

(b) (plus difficile, en bonus) $X \stackrel{\text{loi}}{=} -X^3$

Exercice 2.3. On se donne $X_1, \dots, X_n$, n variables aléatoires indépendantes de loi $\mathcal{U}(0, 1)$ et on note $X_{(1)} \leq \dots \leq X_{(n)}$ leur réordonnement croissant (encore

appelé statistique d'ordre); ainsi, $X_{(1)}$ est le plus petit des X_i , $i = 1 \dots n$, $X_{(2)}$ le deuxième plus petit...

1. Montrer que $\mathbb{P}(X_{(n)} \leq t) = t^n$ pour tout $t \in [0, 1]$ et en déduire que $X_{(n)}$ suit une loi Bêta dont on précisera les paramètres.
2. Montrer que $\mathbb{P}(X_{(n-1)} \leq t) = t^n + n(1-t)t^{n-1}$ pour tout $t \in [0, 1]$ et en déduire que $X_{(n-1)}$ suit une loi Bêta dont on précisera les paramètres.
3. De même, donner les lois de $X_{(1)}$ et $X_{(2)}$.
4. Quel résultat peut-on conjecturer de façon plus générale au sujet de la loi de $X_{(i)}$ si $i \in \{1, \dots, n\}$?

Exercice 2.4. Soit $\alpha, \beta > 0$ et $n \in \mathbb{N}^*$. On rappelle la définition de la fonction Gamma d'Euler :

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx, \quad t > 0.$$

1. Montrer que $\Gamma(n+1) = n!$.
2. Calculer le n -ième moment de la loi exponentielle $\mathcal{E}(\beta)$, c'est-à-dire $\mathbb{E}[X^n]$ si $X \sim \mathcal{E}(\beta)$.
3. Calculer le n -ième moment de la loi Gamma $\Gamma(\alpha, \beta)$.
4. Comparez les résultats obtenus aux deux dernières questions.

Exercice 2.5. 1. Calculer les moments impairs de la loi normale centrée réduite $\mathcal{N}(0, 1)$.

2. On cherche maintenant à calculer les moments pairs de $\mathcal{N}(0, 1)$.

(a) Montrer à l'aide d'une intégration par parties que :

$$\int_{\mathbb{R}} x^{2n} e^{-\frac{x^2}{2}} dx = (2n-1) \int_{\mathbb{R}} x^{2n-2} e^{-\frac{x^2}{2}} dx$$

(b) En déduire que le $2n$ -ième moment de $\mathcal{N}(0, 1)$ vaut :

$$\prod_{k=1}^n (2k-1) = \frac{(2n)!}{2^n \cdot n!}$$

TD5 : MOMENTS DE VARIABLES ALÉATOIRES.

Exercice 2.6. Soit $\alpha, \beta > 0$ et $n \in \mathbb{N}^*$. On rappelle la définition de la fonction Gamma d'Euler :

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx, \quad t > 0.$$

1. Montrer que $\Gamma(n+1) = n!$
2. Calculer le n -ième moment de $\mathcal{E}(\beta)$, c'est-à-dire $\mathbb{E}[X^n]$ si $X \sim \mathcal{E}(\beta)$.
3. Calculer le n -ième moment de $\Gamma(\alpha, \beta)$.
4. Comparez les résultats obtenus aux deux dernières questions.

- Exercice 2.7.**
1. Calculer les moments impairs de $\mathcal{N}(0, 1)$.
 2. On cherche maintenant à calculer les moments pairs de $\mathcal{N}(0, 1)$.
(a) Montrer à l'aide d'une intégration par parties que :

$$\int_{\mathbb{R}} x^{2n} e^{-\frac{x^2}{2}} dx = (2n-1) \int_{\mathbb{R}} x^{2n-2} e^{-\frac{x^2}{2}} dx$$

- (b) En déduire que le $2n$ -ième moment de $\mathcal{N}(0, 1)$ vaut :

$$\prod_{k=1}^n (2k-1) = \frac{(2n)!}{2^n \cdot n!}$$

Exercice 2.8. Soit $n \in \mathbb{N}^*$, $p \in [0, 1]$, $\lambda > 0$.

1. Calculer la variance de la loi $\text{Ber}(p)$. Pour quelle valeur de p la variance de $\mathcal{B}(p)$ est maximale?
2. Montrer que, pour $1 \leq k \leq n$,

$$k \binom{n}{k} = n \binom{n-1}{k-1},$$

et pour $2 \leq k \leq n$,

$$k(k-1) \binom{n}{k} = n(n-1) \binom{n-2}{k-2}.$$

3. En déduire la variance de la loi $\mathcal{B}(n, p)$. (On pourra commencer par calculer $\mathbb{E}[X]$ et $\mathbb{E}[X(X-1)]$ si $X \sim \mathcal{B}(n, p)$). Commenter le résultat obtenu.
4. En utilisant la même méthode, calculer la variance de la loi $\mathcal{P}(\lambda)$. Commenter le résultat obtenu.

Exercice 2.9. Calculer la variance de la loi $\mathcal{U}(a, b)$ de deux façons :

1. par un calcul direct
2. en déduisant cette variance de celle de $\mathcal{U}(0, 1)$.

Exercice 2.10. Soit $X \sim \mathcal{B}(p)$ et $Y \sim \mathcal{B}(n, p)$, $p \in [0, 1]$, $n \in \mathbb{N}^*$.

1. Calculer les fonctions génératrices des moments de $\mathcal{B}(p)$ et $\mathcal{B}(n, p)$. Commenter.
2. Retrouver les valeurs de $\mathbb{E}[Y]$ et $\mathcal{V}(Y)$ calculées à l'exercice 3.

Exercice 2.11. Soit $\alpha, \beta > 0$.

1. Calculer la fonction génératrice des moments ϕ de la loi $\mathcal{E}(\beta)$.
2. Développer le résultat obtenu en série entière, et retrouver la valeur des moments de la loi $\mathcal{E}(\beta)$.
3. Calculer la fonction génératrice des moments ϕ de la loi $\Gamma(\alpha, \beta)$.
4. Retrouver les deux premiers moments de la loi $\Gamma(\alpha, \beta)$ calculés à l'exercice 1.

Exercice 2.12. 1. Calculer la fonction génératrice des moments ϕ de la loi $\mathcal{N}(0, 1)$.
2. Développer le résultat obtenu en série entière, et retrouver la valeur des moments de la loi $\mathcal{N}(0, 1)$.

Exercice 2.13. Soit $a < b$ deux réels, et X variable aléatoire telle que $\mathbb{P}(X \in [a, b]) = 1$. On veut montrer :

$$\mathcal{V}(X) \leq \frac{(b-a)^2}{4}.$$

1. On suppose d'abord $a = -1$ et $b = 1$. Montrer que $\mathcal{V}(X) \leq 1$, puis trouver une variable aléatoire qui satisfait le cas d'égalité.
2. Trouver une fonction affine $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ telle que $\varphi(a) = -1$ et $\varphi(b) = 1$.

3. Étudier $\varphi(X)$ et conclure.

Exercice 2.14. Soit N une variable aléatoire à valeurs dans $\mathbb{N}$.

1. Observer que pour $n \in \mathbb{N}$, $n = \sum_{i=1}^{+\infty} \mathbb{1}_{\{n \geq i\}}$ et en déduire :

$$\mathbb{E}[N] = \sum_{i=1}^{+\infty} \mathbb{P}(N \geq i)$$

2. Dans le cas où N est de plus de carré intégrable ($\mathbb{E}[N^2] < \infty$) montrer également que

$$\sum_{i=1}^{+\infty} i \mathbb{P}(N \geq i) = \frac{1}{2}(\mathbb{E}[N^2] + \mathbb{E}[N])$$

COMPLET PAGE 2I

Probabilité

Ce cours présente les fondements de la théorie des probabilités centrés sur l'étude d'une variable aléatoire réelle unique. On y étudie d'abord le cadre axiomatique, la fonction de répartition et les propriétés des grandes classes de lois (discrètes et à densité), ainsi que les méthodes pour déterminer la loi d'une fonction d'une variable et simuler ces comportements. Le cours approfondit ensuite les notions d'espérance et de moments (variance), introduisant la fonction génératrice comme outil de caractérisation analytique. Enfin, on aborde les inégalités probabilistes incontournables (Markov, Bienaymé-Tchebychev, Jensen) et les définitions avancées de l'espérance selon Lebesgue et Riemann-Stieltjes. Le fil conducteur est la construction d'un cadre théorique et calculatoire rigoureux avant d'étendre l'analyse à plusieurs variables.

