

PROBABILITÉ

VECTEURS ALÉATOIRES, INDÉPENDANCE ET THÉORÈMES LIMITES

Lorenzo Segoni



TABLE DES MATIÈRES

I	Variables aléatoire indépendantes	3
1.1	Variables aléatoires simultanées	3
	Variables aléatoires discrètes	5
	Vecteur aléatoire à densité	6
	Fonction d'un vecteur aléatoire	9
1.2	Variables aléatoires indépendantes	10
1.3	Fonctions de variables aléatoires indépendantes	17
	Maximum et minimum	17
	Somme	20
	Cas général	27
2	TD6 : Variables aléatoires indépendantes	37
3	Suites de variables aléatoires et théorèmes limites	41
3.1	Convergence de suites de variables aléatoires	41
	Convergence en loi	41
	Convergence en probabilité	45
	Convergence dans L^p	48
	Convergence presque sûre	49
3.2	Convergence de couples aléatoires	51
3.3	Loi des grands nombres	54
3.4	Théorème central limite	56
4	Variables aléatoires dépendantes	62
4.1	Lois marginales	62
4.2	Lois conditionnelles	64
4.3	Covariance et corrélation	66

VARIABLES ALÉATOIRE INDÉPENDANTES

1.1 VARIABLES ALÉATOIRES SIMULTANÉES

Nous avons vu qu'une variable aléatoire X décrit un aspect d'une expérience aléatoire. Par exemple, lors de n lancers d'une pièce équilibrée, on peut s'intéresser au nombre de lancers pile qu'on modélise par une variable aléatoire X de loi $\text{Bin}(n, 1/2)$. On pourrait également s'intéresser au nombre de lancers face qu'on pourrait également modéliser par une variable aléatoire Y de même loi. Ces deux variables aléatoires décrivent donc deux aspects de la même expérience aléatoire. Ces deux variables aléatoires sont bien sûr de même loi, mais elles retournent des résultats distincts (sauf si n est pair et $X = Y = n/2$).

On peut aussi considérer n lancers de deux pièces équilibrées, et compter le nombre de piles X de la première pièce, et le nombre de piles Y de la seconde pièce. À nouveau, X et Y ont même loi, mais cette fois-ci, à moins que les deux pièces ne partagent un mystérieux lien, X ne donne aucune information sur Y : c'est l'indépendance (stochastique).

Bien entendu, on peut ne pas se limiter à deux variables aléatoires, et définir n variables aléatoires $X_1, \dots, X_n$ pour rendre compte des différents aspects d'une même expérience aléatoire. De manière générale, on peut considérer une infinité de variables aléatoires $(X_i)_{i \in I}$ indicées par un ensemble I au plus dénombrable.

D'un point de vue abstrait, il est utile de voir la donnée de n variables aléatoires $X_1, \dots, X_n$ comme la donnée d'un seul vecteur aléatoire $X = (X_1, \dots, X_n)$ à valeurs dans $\mathbb{R}^n$. On définit alors la loi du vecteur aléatoire $X = (X_1, \dots, X_n)$ par la fonction

$$A \mapsto \mathbb{P}(X \in A) = \mathbb{P}((X_1, \dots, X_n) \in A), \quad A \subset \mathbb{R}^n$$

On dit encore qu'il s'agit de la *loi jointe* des variables aléatoires $X_1, \dots, X_n$. On doit encore se restreindre à des ensembles A pas complètement arbitraires, mais nous allons passer cela sous silence. Cette fonction devra encore satisfaire à des axiomes tout à fait analogues aux axiomes 1.-4. vus au début du cours pour des variables aléatoires réelles : il suffit de remplacer dans ces axiomes X par $(X_1, \dots, X_n)$ et $A \subset \mathbb{R}$ par $A \subset \mathbb{R}^n$.

On voit dans cette définition qu'on peut également considérer $(X_1, \dots, X_n)$ comme un vecteur aléatoire, la loi jointe des $X_1, \dots, X_n$ est également appelée la loi du vecteur aléatoire $(X_1, \dots, X_n)$.

Définition 1.1. Pour tout $i \in \{1, \dots, n\}$, la loi de X_i donnée, pour tout $A \subset \mathbb{R}$, par :

$$\mathbb{P}(X_i \in A) = \mathbb{P}((X_1, \dots, X_n) \in \mathbb{R}^{i-1} \times A \times \mathbb{R}^{n-i})$$

est appelée la *loi marginale* de la loi du vecteur X .

La *fonction de répartition* d'un vecteur aléatoire $X = (X_1, \dots, X_n)$ est définie par

$$\begin{aligned} \mathbb{R}^n &\rightarrow [0, 1], \\ x = (x_1, \dots, x_n) &\mapsto F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n). \end{aligned}$$

Elle a des propriétés tout à fait analogues à celle d'une v.a.r. comme le montre le théorème suivant :

Théorème 1.1. 1. La fonction de répartition $F_{X_1, \dots, X_n}$ d'un vecteur aléatoire $X = (X_1, \dots, X_n)$ a les propriétés suivantes :

- elle est croissante en chaque coordonnée,
- $F_X(-\infty) := \lim_{x_1 \rightarrow -\infty, \dots, x_n \rightarrow -\infty} F_X(x_1, \dots, x_n) = 0$,
- $F_X(+\infty) := \lim_{x_1 \rightarrow +\infty, \dots, x_n \rightarrow +\infty} F_X(x_1, \dots, x_n) = 1$,
- elle est continue à droite en chaque coordonnée.

2. La loi jointe d'un vecteur aléatoire $X = (X_1, \dots, X_n)$ est déterminée de manière unique par sa fonction de répartition conjointe $F_{X_1, \dots, X_n}$.

Rappelons-nous qu'en dimension 1, ce théorème était complété par un troisième point, à savoir "3. Chaque fonction sur $\mathbb{R}$ ayant les propriétés données dans 1. est la fonction de répartition d'une variable aléatoire X ". Ce point ne vaut pas ici, comme le montre le (contre)-exemple ci-dessous.

Exemple 1.1. Soit la fonction F suivante, pour $n = 2$:

$$F(x, y) = \mathbb{1}_{x+y \geq 0}$$

F vérifie les 4 tirets du point 1 : elle est en chaque coordonnée croissante et continue à droite, et les valeurs des limites conviennent. Supposons maintenant qu'il existe un vecteur $X = (X_1, X_2)$ de fonction de répartition F , alors, écrivant $] -\infty, 1] \times] -\infty, 1]$ comme la réunion de quatre rectangles disjoints basés sur le point $(-1, -1)$, on peut écrire :

$$\begin{aligned}\mathbb{P}((X_1, X_2) \in]-1, 1] \times]-1, 1]) &= F(1, 1) - F(1, -1) - F(-1, 1) + F(-1, -1) \\ &= \mathbb{K}_{1+1 \geq 0} - \mathbb{K}_{1-1 \geq 0} - \mathbb{K}_{-1+1 \geq 0} + \mathbb{K}_{-1-1 \geq 0} \\ &= 1 - 2 + 0 = -1 < 0\end{aligned}$$

ce qui est absurde. Donc F n'est pas la fonction de répartition d'un vecteur aléatoire de $\mathbb{R}^2$.

esquisse. Nous n'allons pas démontrer ce théorème mais seulement en donner quelques idées clés pour nous en convaincre. Le point central est le fait que la fonction de répartition conjointe définit la loi jointe. En fait, en suivant la preuve du théorème dans le cas univarié, on voit facilement que la fonction de répartition définit de manière unique les probabilités de la forme

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n), \quad A_1, \dots, A_n \subset \mathbb{R},$$

donc les probabilités $\mathbb{P}((X_1, \dots, X_n) \in A)$ pour des ensembles A de la forme $A_1 \times \dots \times A_n$.

On appelle ces ensembles des pavés. Pour passer de là à des ensembles généraux, on approche ces ensembles par des réunions ou intersections d'un nombre dénombrable de pavés. Il est laissé au lecteur de se convaincre à travers quelques exemples que cela est bien possible pour des ensembles "raisonnables" (par exemple des boules, des hyperplans...) $\square$

VARIABLES ALÉATOIRES DISCRÈTES

Définition 1.2. On dit que $X = (X_1, \dots, X_n)$ est un vecteur aléatoire discret à valeurs dans $\mathbb{R}^n$ ssi il existe un sous-ensemble au plus dénombrable $S \subset \mathbb{R}^n$ tel que $\mathbb{P}(X \in S) = 1$.

Proposition 1.1. X est un vecteur aléatoire discret ssi les X_i sont des variables aléatoires réelles discrètes.

Démonstration. Si les v.a. $X_1, \dots, X_n$ sont discrètes, c'est-à-dire si elles prennent leurs valeurs dans des ensembles au plus dénombrables $E_1, \dots, E_n \subset \mathbb{R}$, alors le vecteur $(X_1, \dots, X_n)$ prend ses valeurs dans l'ensemble $E_1 \times \dots \times E_n$, qui est également au plus dénombrable. La réciproque est claire puisque la projection sur toute coordonnée d'un ensemble au plus dénombrable reste au plus dénombrable. $\square$

La fonction de masse du vecteur aléatoire discret $X = (X_1, \dots, X_n)$ est donnée par :

$$x = (x_1, \dots, x_n) \mapsto \mathbb{P}(X_1 = x_1, \dots, X_n = x_n), \quad x_1, \dots, x_n \in \mathbb{R},$$

elle détermine la loi de ce vecteur au travers de la formule :

$$\mathbb{P}((X_1, \dots, X_n) \in A) = \sum_{(x_1, \dots, x_n) \in A} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n), \quad (\text{I.I})$$

(on rappelle que la somme porte sur tous les $(x_1, \dots, x_n)$ tels que la probabilité correspondante est non-nulle, donc il s'agit d'une somme portant sur un ensemble au plus dénombrable). En particulier, on a le calcul suivant des lois marginales.

Proposition 1.2. *Soit $(X_1, \dots, X_n)$ vecteur aléatoire discret. Alors pour tout $k \in \{1, \dots, n\}$, X_k est une variable aléatoire discrète de fonction de masse donnée par*

$$\mathbb{P}(X_k = x) = \sum_{x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n} \mathbb{P}(X_1 = x_1, \dots, X_{k-1} = x_{k-1}, X_k = x, X_{k+1} = x_{k+1}, \dots, X_n = x_n).$$

Démonstration. (I.I) donne, avec $x \in \mathbb{R}$ et $A = \mathbb{R}^{k-1} \times \{x\} \times \mathbb{R}^{n-k}$:

$$\begin{aligned} \mathbb{P}(X_k = x) &= \sum_{(x_1, \dots, x_n) \in \mathbb{R}^{k-1} \times \{x\} \times \mathbb{R}^{n-k}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \\ &= \sum_{x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n} \mathbb{P}(X_1 = x_1, \dots, X_{k-1} = x_{k-1}, X_k = x, X_{k+1} = x_{k+1}, \dots, X_n = x_n). \end{aligned}$$

□

VECTEUR ALÉATOIRE À DENSITÉ

Définition 1.3. Un vecteur aléatoire $X = (X_1, \dots, X_n)$ est à densité s'il existe une fonction $f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}_+$ telle que, pour tout $A \subset \mathbb{R}^n$,

$$\mathbb{P}((X_1, \dots, X_n) \in A) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \mathbb{1}_A(y_1, \dots, y_n) f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n.$$

La fonction $f_{X_1, \dots, X_n}$ est alors appelée la densité conjointe des v.a. $X_1, \dots, X_n$.

Notons que l'ordre des intégrales ci-dessus n'importe pas grâce au théorème de Fubini–Tonelli. On peut vérifier que cela définit bien une loi satisfaisant aux axiomes 1.-4.

Proposition 1.3. Un vecteur aléatoire $X = (X_1, \dots, X_n)$ est à densité ssi il existe une fonction $f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}_+$ telle que

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_n} \cdots \int_{-\infty}^{x_1} f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n.$$

Démonstration. Il suffit de prendre $A = \prod_{1 \leq i \leq n}]-\infty, x_i]$ pour voir que la fonction de répartition prend cette forme. Réciproquement, si un vecteur aléatoire possède cette fonction de répartition, alors elle coïncide avec la fonction de répartition de $X_1, \dots, X_n$. Puisque la fonction de répartition détermine la loi, elle est alors bien donnée par cette formule. $\square$

Proposition 1.4. Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est la densité d'un vecteur aléatoire de $\mathbb{R}^n$ si et seulement si

- f est positive et
- $\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, \dots, x_n) dx_1 \dots dx_n = 1$.

La proposition suivante détaille le calcul des lois marginales.

Proposition 1.5. Supposons que le vecteur aléatoire $(X_1, \dots, X_n)$ admette la densité $f_{X_1, \dots, X_n}$. Alors pour tout $k \in \{1, \dots, n\}$, la v.a. X_k admet la densité

$$f_{X_k}(x) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_{k-1}, x, x_{k+1}, \dots, x_n) dx_1 \dots dx_{k-1} dx_{k+1} \dots dx_n.$$

Cas à densité. On rappelle que la fonction de répartition du vecteur $(X_1, \dots, X_n)$ est donnée par

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_n} \cdots \int_{-\infty}^{x_1} f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n.$$

En faisant tendre $x_j \rightarrow +\infty$ pour $j \neq k$ et en changeant l'ordre d'intégration, on obtient

$$F_{X_k}(x) = \int_{-\infty}^x \left(\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f_{X_1, \dots, X_n}(y_1, \dots, y_{k-1}, y, y_{k+1}, \dots, y_n) dy_1 \dots dy_{k-1} dy_{k+1} \dots dy_n \right) dy.$$

Ceci montre que X_k est à densité avec la densité écrite dans l'énoncé. $\square$

En revanche, contrairement à ce qui se passait dans le cas discret, (voir proposition 3.5), il ne suffit pas que chacune des variables $X_1, \dots, X_n$ soit à densité pour que le vecteur $(X_1, \dots, X_n)$ soit à densité. Par exemple, soit X une v.a. à densité; on pose $Y = -X$, alors (X, Y) ne définit pas un vecteur aléatoire à densité. Voici un contre-exemple : le couple (X, Y) prend ses valeurs dans la droite $D = \{(x, -x) : x \in \mathbb{R}\}$, or, pour toute fonction positive f , d'après le théorème de Fubini-Tonelli :

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x, y) f(x, y) dx dy = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} \mathbb{1}_{\{-y\}}(x) f(x, y) dx \right) dy = 0,$$

car la fonction $\mathbb{1}_{\{-y\}}(x) f(x, y)$ est nulle sauf en un point, donc son intégrale est nulle.

FONCTION D'UN VECTEUR ALÉATOIRE

Si $X_1, \dots, X_n$ sont des v.a. et $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m, m \in \mathbb{N}^*$ une fonction, alors $Y = \phi(X_1, \dots, X_n)$ est encore un vecteur aléatoire, c'est-à-dire que ses coordonnées $Y_1, \dots, Y_m$ satisfont

$$\mathbb{P}(\phi(X_1, \dots, X_n) \in A) = \mathbb{P}((X_1, \dots, X_n) \in \phi^{-1}(A)), \quad A \subset \mathbb{R}^m.$$

Espérance Si $X = (X_1, \dots, X_n)$ est un vecteur aléatoire discret et $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$ (il est important que ϕ soit à valeurs réelles désormais) est telle que ϕ est positive, ou

$$\sum_{(x_1, \dots, x_n) \in A} |\phi(x_1, \dots, x_n)| \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) < \infty,$$

alors on définit l'espérance de $\phi(X)$ dans le cas discret par :

$$\begin{aligned} \mathbb{E}[\phi(X)] &= \mathbb{E}[\phi(X_1, \dots, X_n)] \\ &= \sum_{(x_1, \dots, x_n) \in A} \phi(x_1, \dots, x_n) \mathbb{P}(X_1 = x_1, \dots, X_n = x_n). \end{aligned}$$

De même, si $X = (X_1, \dots, X_n)$ est un vecteur aléatoire à densité et $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$ est telle que ϕ est positive, ou

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} |\phi(y_1, \dots, y_n)| f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n < \infty,$$

alors :

$$\begin{aligned} \mathbb{E}[\phi(X)] &= \mathbb{E}[\phi(X_1, \dots, X_n)] \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \phi(y_1, \dots, y_n) f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n. \end{aligned}$$

Dans le cas d'un vecteur aléatoire X discret, $Y = \phi(X)$ est une variable aléatoire réelle discrète, et on disposait déjà d'une définition de l'espérance : on doit alors vérifier

que les deux définitions coïncident, et la preuve est rigoureusement la même que dans le cas où X est une variable aléatoire réelle. De même, dans le cas où $Y = \phi(X)$ est à densité, on disposait déjà d'une définition de l'espérance pour Y , et il faudrait vérifier que les deux définitions coïncident. Finalement, dans le cas d'un vecteur aléatoire X à densité, il est possible que $\phi(X)$ ne soit pas à densité, mais l'expression ci-dessus fait encore sens : il s'agit alors d'une définition.

L'espérance satisfait encore les propriétés vues précédemment :

Proposition 1.6 (Linéarité de l'espérance). *Si $X = (X_1, \dots, X_n)$ est un vecteur aléatoire et $\phi_1, \dots, \phi_m : \mathbb{R}^n \rightarrow \mathbb{R}$ sont des fonctions positives ou telles que $\phi_1(X), \dots, \phi_m(X)$ sont intégrables, alors*

$$\mathbb{E} \left[\sum_{i=1}^m \phi_i(X_1, \dots, X_n) \right] = \sum_{i=1}^m \mathbb{E}[\phi_i(X_1, \dots, X_n)].$$

On peut encore mettre le résultat précédent sous la forme plus simple suivante (en fait équivalente) :

Corollaire 1.1. *Si les X_i sont intégrables pour tout $i = 1, \dots, n$, alors :*

$$\mathbb{E}[X_1 + \dots + X_n] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_n].$$

Il est crucial de noter que cette relation ne suppose aucune forme d'indépendance des coordonnées du vecteur aléatoire (l'indépendance est définie dans la section à venir). Cette relation sera comparée avec profit avec la relation similaire sur la variance, à venir également, Proposition 3.22, qui elle nécessite l'indépendance. Enfin, on note que la formule de sommation permet de définir $\mathbb{E}[X_1 + \dots + X_n]$, pour un vecteur aléatoire $X = (X_1, \dots, X_n)$ qui n'est pas forcément discret ou à densité (mais dont les marginales appartiennent à l'une de ces deux classes).

1.2 VARIABLES ALÉATOIRES INDÉPENDANTES

Les liens entre variables aléatoires ne sont pas toujours aussi simples que pour le premier exemple ci-dessus des nombres des lancers pile ou face, où il y avait un lien déterministe entre les deux variables aléatoires ($X + Y = n$). Par exemple, si on note encore $X_1, \dots, X_n$ les résultats des n lancers pile ou face, alors ces variables ne semblent avoir aucun lien entre elles, car le résultat d'un lancer n'influence pas les résultats des autres lancers. C'est ce qu'on appelle l'*indépendance (stochastique)*, elle se traduit mathématiquement par la définition suivante :

Définition 1.4. On dit qu'un vecteur aléatoire $X = (X_1, \dots, X_n)$ est à coordonnées indépendantes, ou simplement que les variables aléatoires $X_1, \dots, X_n$ sont *indépendantes*, si pour tout $A_1, \dots, A_n \subset \mathbb{R}$,

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \mathbb{P}(X_1 \in A_1) \times \dots \times \mathbb{P}(X_n \in A_n). \quad (\text{I.2})$$

Remarque 1.1. Pour comprendre l'intuition de la définition, considérons le cas $n = 2$, X_1 et X_2 indépendantes, et calculons la probabilité conditionnelle suivante, pour A_2 tel que $\mathbb{P}(X_2 \in A_2) \neq 0$:

$$\mathbb{P}(X_1 \in A_1 \mid X_2 \in A_2) = \frac{\mathbb{P}(X_1 \in A_1, X_2 \in A_2)}{\mathbb{P}(X_2 \in A_2)} = \mathbb{P}(X_1 \in A_1).$$

Intuitivement, la donnée d'une information portant sur X_2 n'influence pas la loi de X_1 .

Définition 1.5. On dit qu'un vecteur aléatoire $X = (X_1, \dots, X_n)$ est à coordonnées deux à deux indépendantes, ou simplement que les variables aléatoires $X_1, \dots, X_n$ sont **deux à deux indépendantes**, si pour tout $1 \leq i \neq j \leq n$, X_i et X_j sont indépendantes.

Remarque 1.2. Des variables aléatoires $X_1, \dots, X_n$ indépendantes sont bien sûr deux à deux indépendantes, mais la réciproque est fausse :

Exercice 1.1. Soit X_1, X_2, X_3 trois variables aléatoires indépendantes de loi de Rademacher : $\mathbb{P}(X_i = \pm 1) = 1/2$. Montrer que les variables aléatoires

$$Y_1 = X_2 X_3, \quad Y_2 = X_1 X_3, \quad Y_3 = X_1 X_2$$

sont deux à deux indépendantes mais pas indépendantes.

Ainsi la relation "être indépendant" n'est pas transitive : X_1 peut être indépendant de X_2 et X_2 de X_3 , sans que X_1 ne soit indépendant de X_3 .

Proposition 1.7. *Si $X = (X_1, \dots, X_n)$ est à coordonnées indépendantes alors on a la formule suivante pour la fonction de répartition conjointe :*

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = F_{X_1}(x_1) \times \dots \times F_{X_n}(x_n), \quad x_1, \dots, x_n \in \mathbb{R}. \quad (1.3)$$

Inversement, si la fonction de répartition conjointe d'un vecteur aléatoire $X = (X_1, \dots, X_n)$ s'écrit sous la forme (1.3), alors ses coordonnées sont indépendantes.

Remarque 1.3. En appliquant (1.2) à des ensembles de la forme $A_i =]-\infty, x_i]$, $x_i \in \mathbb{R}$, on obtient la formule pour la fonction de répartition conjointe. La réciproque tient au fait que la fonction de répartition conjointe détermine la loi.

On peut se demander si des variables aléatoires indépendantes $X_1, \dots, X_n$ avec des lois marginales prescrites *existent*. C'est le cas car si on prend (1.3) comme *définition* d'une fonction de répartition conjointe. En revanche, s'il y a existence, il n'y a pas en revanche unicité en général : on dit d'un vecteur aléatoire dont les lois marginales sont prescrites qu'il est un couplage de ces lois.

Proposition 1.8. *Soit $(X_1, \dots, X_n)$ un vecteur aléatoire.*

— *Si $(X_1, \dots, X_n)$ est un vecteur aléatoire discret, alors ses coordonnées sont indépendantes si et seulement si la fonction de masse se factorise sous la forme :*

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \times \dots \times \mathbb{P}(X_n = x_n), \quad x_1, \dots, x_n \in \mathbb{R}.$$

— *Si $(X_1, \dots, X_n)$ est un v.a. à densité, alors ses coordonnées sont indépendantes si et seulement si le vecteur admet la densité :*

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \times \dots \times f_{X_n}(x_n), \quad x_1, \dots, x_n \in \mathbb{R}. \quad (1.4)$$

Démonstration. Nous montrons seulement le cas à densité, le cas discret, plus facile, est laissé en exercice. Posons

$$g(x_1, \dots, x_n) = f_{X_1}(x_1) \times \dots \times f_{X_n}(x_n), \quad x_1, \dots, x_n \in \mathbb{R}.$$

Alors g est positive et

$$\begin{aligned} & \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} g(x_1, \dots, x_n) dx_1 \dots dx_n \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1}(x_1) \times \dots \times f_{X_n}(x_n) dx_1 \dots dx_n \\ &= \left(\int_{-\infty}^{\infty} f_{X_1}(x_1) dx_1 \right) \times \dots \times \left(\int_{-\infty}^{\infty} f_{X_n}(x_n) dx_n \right) \\ &= 1, \end{aligned}$$

donc g est bien la densité conjointe de n variables aléatoires, notons-les $Y_1, \dots, Y_n$.
On a pour tous $A_1, \dots, A_n \subset \mathbb{R}$,

$$\begin{aligned} & \mathbb{P}(Y_1 \in A_1, \dots, Y_n \in A_n) = \\ & \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \mathbb{1}_{A_1 \times \dots \times A_n}(x_1, \dots, x_n) g(x_1, \dots, x_n) dx_1 \dots dx_n \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \mathbb{1}_{A_1}(x_1) f_{X_1}(x_1) \times \dots \times \mathbb{1}_{A_n}(x_n) f_{X_n}(x_n) dx_1 \dots dx_n \\ &= \left(\int_{-\infty}^{\infty} \mathbb{1}_{A_1}(x_1) f_{X_1}(x_1) dx_1 \right) \times \dots \times \left(\int_{-\infty}^{\infty} \mathbb{1}_{A_n}(x_n) f_{X_n}(x_n) dx_n \right) \\ &= \mathbb{P}(X_1 \in A_1) \times \dots \times \mathbb{P}(X_n \in A_n). \end{aligned}$$

□

Par conséquent, $X_1, \dots, X_n$ sont indépendantes si et seulement si leur loi jointe est égale à la loi jointe de $Y_1, \dots, Y_n$, donc si et seulement si $X_1, \dots, X_n$ admettent la densité conjointe g . Ceci permet de conclure.

Au regard des formules vues précédemment sur les espérances de fonctions de vecteurs aléatoires, (1.2) peut encore s'écrire :

$$\mathbb{E} \left[\prod_{i=1}^n \mathbb{1}_{A_i}(X_i) \right] = \prod_{i=1}^n \mathbb{E}[\mathbb{1}_{A_i}(X_i)]$$

La proposition suivante généralise cette identité :

Corollaire 1.2. Soient $X_1, \dots, X_n$ des v.a. indépendantes discrètes ou à densité et $g_1, \dots, g_n : \mathbb{R} \rightarrow \mathbb{R}$ des fonctions telles que $g_1(X_1), \dots, g_n(X_n)$ soient intégrables. On a alors :

$$\mathbb{E} \left[\prod_{i=1}^n g_i(X_i) \right] = \prod_{i=1}^n \mathbb{E}[g_i(X_i)]$$

Démonstration. En effet, dans le cas à densité, on a

$$\begin{aligned} \mathbb{E} \left[\prod_{i=1}^n g_i(X_i) \right] &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^n g_i(x_i) f_{X_1}(x_1) \cdots f_{X_n}(x_n) dx_1 \cdots dx_n \\ &= \prod_{i=1}^n \left(\int_{-\infty}^{\infty} g_i(x_i) f_{X_i}(x_i) dx_i \right) \quad \text{de Fubini} \\ &= \prod_{i=1}^n \mathbb{E}[g_i(X_i)]. \end{aligned}$$

Le cas discret se démontre de manière analogue. $\square$

En particulier, en prenant $g_i(x) = x$ pour tout i , on obtient la formule, pour $X_1, \dots, X_n$ des variables aléatoires intégrables,

$$\mathbb{E}[X_1 \cdots X_n] = \mathbb{E}[X_1] \cdots \mathbb{E}[X_n].$$

Remarque 1.4. On notera donc que pour des variables aléatoires indépendantes, il suffit que chaque variable soit intégrable pour que leur produit le soit : cela ne vaut pas pour des variables qui ne sont pas indépendantes (prendre $n = 2$ et $X_1 = X_2$ pour s'en convaincre : on a alors inégalité stricte entre les deux membres de l'inégalité sauf si la variable aléatoire X_1 est presque sûrement constante d'après la définition de la variance.)

Le critère suivant s'avère souvent très utile pour démontrer l'indépendance de v.a. :

Proposition 1.9. Soit $X = (X_1, \dots, X_n) \in \mathbb{R}^n$ un vecteur aléatoire discret ou à densité. Supposons qu'il existe des fonctions $f_1, \dots, f_n : \mathbb{R} \rightarrow \mathbb{R}_+$ telles que

$$- \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = f_1(x_1) \times \cdots \times f_n(x_n) \text{ (cas discret)}$$

— $f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_1(x_1) \times \dots \times f_n(x_n)$ (cas à densité).

Alors les coordonnées $X_1, \dots, X_n$ du vecteur aléatoire X sont indépendantes.

Les fonctions f_i de l'énoncé précédent sont en fait proportionnelles aux marginales du vecteur aléatoire; l'avantage d'appliquer cette proposition est qu'on n'a pas à calculer ces constantes; d'un point de vue théorique, on peut toujours expliciter ces constantes :

- $f_i(x_i) / \sum_x f_i(x)$ est la fonction de masse de X_i .
- $f_i(x_i) / \int_{\mathbb{R}} f_i(x_i) dx_i$ est la densité marginale de X_i .

Démonstration. On traite seulement le cas à densité, le cas discret est analogue. On pose

$$C_i = \int_{-\infty}^{\infty} f_i(x) dx, \quad i = 1, \dots, n.$$

Notons que $C_i > 0$ pour tout i , sinon on aurait pour tout $x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n \in \mathbb{R}$,

$$\int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_i = f_1(x_1) \dots f_{i-1}(x_{i-1}) C_i f_{i+1}(x_{i+1}) \dots f_n(x_n) = 0,$$

et donc $\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n = 0$. Aussi,

$$\begin{aligned} C_1 \times \dots \times C_n &= \left(\int_{-\infty}^{\infty} f_1(x_1) dx_1 \right) \times \dots \times \left(\int_{-\infty}^{\infty} f_n(x_n) dx_n \right) \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_1(x_1) \times \dots \times f_n(x_n) dx_1 \dots dx_n \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n = 1. \end{aligned}$$

En particulier, $C_i < \infty$ pour tout i .

On définit alors des fonctions $g_i = f_i / C_i$ qui sont toutes positives et d'intégrale 1, donc des densités de v.a. Notons $Y_1, \dots, Y_n$ des v.a. indépendantes de densités respectives $g_1, \dots, g_n$. Alors, puisque $C_1 \times \dots \times C_n = 1$,

$$\begin{aligned} f_{X_1, \dots, X_n}(x_1, \dots, x_n) &= f_1(x_1) \times \dots \times f_n(x_n) = g_1(x_1) \times \dots \times g_n(x_n) \\ &= f_{Y_1, \dots, Y_n}(x_1, \dots, x_n). \end{aligned}$$

Ceci montre que la loi jointe des v.a. $X_1, \dots, X_n$ est égale à la loi jointe de $Y_1, \dots, Y_n$. En particulier, les v.a. $X_1, \dots, X_n$ sont indépendantes. $\square$

Variance d'une somme de v.a. indépendantes On a vu que la variance était liée au carré de la distance entre la variable aléatoire et son espérance. La notion de couple de variables indépendantes permet de donner une nouvelle interprétation. Si X_1 et X_2 sont deux variables aléatoires indépendantes et identiquement distribuées, de carrés intégrables, par linéarité de l'espérance puis par indépendance,

$$\begin{aligned}\mathbb{E}[(X_1 - X_2)^2] &= \mathbb{E}[X_1^2] - 2\mathbb{E}[X_1 X_2] + \mathbb{E}[X_2^2] \\ &= 2(\mathbb{E}[X_1^2] - \mathbb{E}[X_1]^2) \\ &= 2\mathbb{V}(X_1),\end{aligned}$$

c'est-à-dire que la variance mesure aussi (à un facteur multiplicatif 2 près) l'espérance du carré de la distance entre deux réalisations indépendantes.

Proposition 1.10. *Soient $X_1, \dots, X_n$ des v.a. indépendantes tel que $\mathbb{E}[X_i^2] < \infty$ pour tout $i \in \{1, \dots, n\}$ (donc $\mathbb{E}[|X_i|] < \infty$ pour tout i). Alors*

$$\mathbb{V}(X_1 + \dots + X_n) = \mathbb{V}(X_1) + \dots + \mathbb{V}(X_n).$$

Démonstration. Posons $Y_i = X_i - \mathbb{E}[X_i]$ pour tout i . Alors $\mathbb{E}[Y_i] = 0$ pour tout i .

$$\begin{aligned}\mathbb{V}(X_1 + \dots + X_n) &= \mathbb{V}(Y_1 + \dots + Y_n) \\ &= \mathbb{E}[(Y_1 + \dots + Y_n)^2] \\ &= \mathbb{E}\left[\sum_{i=1}^n Y_i^2 + 2 \sum_{1 \leq i < j \leq n} Y_i Y_j\right] \\ &= \sum_{i=1}^n \mathbb{E}[Y_i^2] + 2 \sum_{1 \leq i < j \leq n} \mathbb{E}[Y_i Y_j],\end{aligned}$$

par linéarité de l'espérance. Par indépendance, $\mathbb{E}[Y_i Y_j] = \mathbb{E}[Y_i] \mathbb{E}[Y_j] = 0$ pour tous $i < j$. De plus, $\mathbb{E}[Y_i^2] = \mathbb{V}(Y_i)$ pour tout i . Ceci permet de conclure. $\square$

Notons une conséquence remarquable : de l'inégalité de Tchebychev, on a pour des variables $(X_i)_{1 \leq i \leq n}$ indépendantes centrées, et de même variance :

$$\mathbb{P}(X_1 + \dots + X_n \geq \alpha\sqrt{n}) \leq \frac{\mathbb{V}(X_1)}{\alpha^2}$$

Par exemple, pour des variables i.i.d. de Rademacher de paramètre $1/2$, pour lesquelles $\mathbb{P}(X_1 = \pm 1) = 1/2$, on obtient :

$$\mathbb{P}(X_1 + \dots + X_n \geq \alpha\sqrt{n}) \leq \frac{1}{\alpha^2}.$$

Alors que l'ensemble des valeurs possibles de la variable aléatoire $X_1 + \dots + X_n$ est

$$\{-n, \dots, n\},$$

elle se concentre en fait sur un sous-ensemble bien plus petit,

$$\{-\lfloor \alpha\sqrt{n} \rfloor, \dots, \lfloor \alpha\sqrt{n} \rfloor\},$$

avec probabilité $\geq 1 - \frac{1}{\alpha^2}$. Cet énoncé profond de la théorie des probabilités se trouvera précisé dans le chapitre consacré au théorème central limite. En dépit de sa simplicité, il n'est pas exagéré de dire que c'est l'énoncé le plus important de ce cours.

1.3 FONCTIONS DE VARIABLES ALÉATOIRES INDÉPENDANTES

Dans cette section, on s'intéresse à la loi de certaines fonctions particulières d'un vecteur aléatoire dont les n coordonnées sont des v.a. indépendantes $X_1, \dots, X_n$. On considère les cas du maximum ou minimum ainsi que de la somme.

MAXIMUM ET MINIMUM

On s'intéresse à la loi de $Y = \max(X_1, \dots, X_n)$ pour des variables aléatoires $X_1, \dots, X_n$ indépendantes. L'outil le plus adapté à la caractérisation de cette loi est la fonction de répartition. En effet,

$$\begin{aligned} F_Y(x) &= \mathbb{P}(\max(X_1, \dots, X_n) \leq x) \\ &= \mathbb{P}(X_1 \leq x, \dots, X_n \leq x) \\ &= F_{X_1, \dots, X_n}(x, \dots, x), \end{aligned}$$

et l'indépendance des $X_1, \dots, X_n$ donne alors

$$F_Y(x) = F_{X_1}(x) \dots F_{X_n}(x).$$

La loi du minimum $Z = \min(X_1, \dots, X_n)$ s'obtient de manière similaire :

$$F_Z(x) = 1 - \mathbb{P}(X_1 > x, \dots, X_n > x) = 1 - \prod_{i=1}^n (1 - F_{X_i}(x)).$$

Si de plus, $X_1, \dots, X_n$ sont conjointement à densité, alors la densité du vecteur se met sous la forme $f_{X_1}(x_1) \dots f_{X_n}(x_n)$, et

$$F_Y(x) = \int_{-\infty}^x \sum_{i=1}^n f_{X_i}(t) \cdot \prod_{j \neq i} F_{X_j}(t) dt,$$

donc Y est à densité, de densité :

$$f_Y(x) = \sum_{i=1}^n f_{X_i}(x) \cdot \prod_{j \neq i} F_{X_j}(x). \quad (1.5)$$

De même, et sous les mêmes hypothèses, Z est à densité, de densité :

$$f_Z(x) = \sum_{i=1}^n f_{X_i}(x) \cdot \prod_{j \neq i} (1 - F_{X_j}(x)). \quad (1.6)$$

L'interprétation des relations est comme suit : dans l'expression de la densité de Y , $f_{X_i}(x)$ quantifie la probabilité que X_i soit "égal" à x puis $\prod_{j \neq i} F_{X_j}(x)$ la probabilité que les autres variables soient inférieures à cette valeur, auquel cas le maximum est égal à x , réalisé par la variable X_i ; de même, dans l'expression de la densité de Z , $f_{X_i}(x)$ quantifie la probabilité que X_i soit "égal" à x puis $\prod_{j \neq i} (1 - F_{X_j}(x))$ la probabilité que les autres variables soient supérieures à cette valeur, auquel cas le minimum est égal à x , réalisé par la variable X_i .

Exemple 1.2. Soient $X_1, \dots, X_n$ i.i.d. (indépendantes et identiquement distribuées) de loi $\mathcal{U}(0, 1)$. Alors,

$$F_{\max(X_1, \dots, X_n)}(x) = \begin{cases} 0, & x \leq 0 \\ x^n, & x \in [0, 1] \\ 1, & x \geq 1. \end{cases}$$

Exercice 1.2. Retrouver les expressions (1.5) et (1.6) des densités du minimum et du maximum de variables aléatoires indépendantes conjointement à densité à l'aide de la méthode de la fonction muette.

SOMME

On s'intéresse à la loi de $S = X_1 + \dots + X_n$ à n fixé. On présente deux méthodes pour la déterminer.

Première méthode : par la fonction génératrice des moments Dans le cas précédent du maximum, il était commode de calculer la fonction de répartition puisque celle-ci s'écrivait comme le produit des fonctions de répartitions respectives des v.a. $X_1, \dots, X_n$. Qu'en est-il pour la somme $S = \sum_{i=1}^n X_i$? Existe-t-il encore une quantité fonction de S qui s'écrit comme un produit de mêmes quantités fonction des X_i ?

La réponse est oui, et l'outil en question est la fonction génératrice des moments. En effet, pour tout $t \in \mathbb{R}$,

$$\begin{aligned}\phi_S(t) &= \mathbb{E}[e^{tS}] \\ &= \mathbb{E}[e^{t(X_1 + \dots + X_n)}] \\ &= \mathbb{E}[e^{tX_1} \dots e^{tX_n}] \\ &= \mathbb{E}[e^{tX_1}] \dots \mathbb{E}[e^{tX_n}] \\ &= \prod_{i=1}^n \phi_{X_i}(t),\end{aligned}$$

par indépendance.

Exemple 1.3. On suppose que $X_i \sim \mathcal{P}(\lambda_i)$, $\lambda_i \geq 0$, pour tout i . On rappelle que $\phi_{X_i}(t) = e^{\lambda_i(e^t - 1)}$, $t \in \mathbb{R}$. Par conséquent,

$$\phi_{X_1 + \dots + X_n}(t) = e^{\lambda_1(e^t - 1)} \dots e^{\lambda_n(e^t - 1)} = e^{(\lambda_1 + \dots + \lambda_n)(e^t - 1)},$$

si bien que $X_1 + \dots + X_n \sim \mathcal{P}(\lambda_1 + \dots + \lambda_n)$.

Exemple 1.4. On suppose que $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, $\mu_i \in \mathbb{R}$, $\sigma_i^2 > 0$, pour $i = 1 \dots n$. On rappelle que $\phi_{X_i}(t) = e^{t\mu_i + \sigma_i^2 t^2 / 2}$, $t \in \mathbb{R}$. Par conséquent,

$$\phi_{X_1 + \dots + X_n}(t) = e^{t\mu_1 + \sigma_1^2 t^2 / 2} \dots e^{t\mu_n + \sigma_n^2 t^2 / 2} = e^{t(\mu_1 + \dots + \mu_n) + (\sigma_1^2 + \dots + \sigma_n^2) t^2 / 2},$$

si bien que $X_1 + \dots + X_n \sim \mathcal{N}(\mu_1 + \dots + \mu_n, \sigma_1^2 + \dots + \sigma_n^2)$. Noter que les valeurs des paramètres ne sont pas surprenantes : Admettons que l'on sache a priori que

$X_1 + \cdots + X_n$ suit une loi normale $\mathcal{N}(\mu, \sigma^2)$ pour un certain μ et un certain σ^2 à déterminer, alors, puisque l'on sait que μ_i est l'espérance de X_i et σ_i^2 la variance de X_i , d'après les règles d'addition des espérances et des variances (dans le cas indépendant), on a que $\mu = \mu_1 + \cdots + \mu_n$ et $\sigma^2 = \sigma_1^2 + \cdots + \sigma_n^2$.

Deuxième méthode : par la convolution des densités Supposons maintenant que les v.a. $X_1, \dots, X_n$ sont soit discrètes et à valeurs dans $\mathbb{Z}$, soit à densité. Au lieu de calculer la fonction génératrice des moments de leur somme, on peut aussi calculer directement la fonction de masse ou densité. Pour cela, nous introduisons la notation suivante.

Définition 1.6. Soient $f, g : \mathbb{R} \rightarrow \mathbb{R}_+$.

— On définit leur *convolée* $f \star g : \mathbb{R} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ par

$$(f \star g)(x) = \int_{-\infty}^{\infty} f(t)g(x-t)dt \stackrel{t \mapsto x-t}{=} \int_{-\infty}^{\infty} f(x-t)g(t)dt.$$

— Si $p, q : \mathbb{Z} \rightarrow \mathbb{R}_+$, on définit leur *convolée discrète* $p \star_{\mathbb{Z}} q : \mathbb{Z} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ par

$$(p \star_{\mathbb{Z}} q)(n) = \sum_{m \in \mathbb{Z}} p(m)q(n-m) \stackrel{m \mapsto n-m}{=} \sum_{m \in \mathbb{Z}} p(n-m)q(m).$$

Exercice 1.3. On peut vérifier que les opérations $\star$ et $\star_{\mathbb{Z}}$, appelées *convolution* / *convolution discrète* sont commutatives et associatives.

Proposition 1.11. Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes, ou bien discrètes et à valeurs dans $\mathbb{Z}$, ou bien à densité.

— Cas discret : Notons $p_{X_i}(n) = \mathbb{P}(X_i = n)$ la fonction de masse de X_i . Alors la fonction de masse de $S = X_1 + \dots + X_n$ est égale à

$$p_S = p_{X_1} \star_{\mathbb{Z}} \dots \star_{\mathbb{Z}} p_{X_n}.$$

— Cas à densité : la v.a. $S = X_1 + \dots + X_n$ admet la densité

$$f_S = f_{X_1} \star \dots \star f_{X_n}.$$

Démonstration. Il suffit de considérer le cas $n = 2$, le cas général se montre par récurrence. On note alors $X = X_1$ et $Y = X_2$. On commence par le cas discret. Il suffit alors de décomposer :

$$\begin{aligned} p_S(n) &= \mathbb{P}(X + Y = n) \\ &= \sum_{m \in \mathbb{Z}} \mathbb{P}(X = m, X + Y = n) \\ &= \sum_{m \in \mathbb{Z}} \mathbb{P}(X = m, Y = n - m) \\ &= \sum_{m \in \mathbb{Z}} \mathbb{P}(X = m) \mathbb{P}(Y = n - m) && \text{par indépendance} \\ &= (p_X \star_{\mathbb{Z}} p_Y)(n) \end{aligned}$$

Dans le cas à densité, c'est moins simple et on calcule la fonction de répartition de S :

$$\begin{aligned} \mathbb{P}(S \leq z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_{x+y \leq z} f_X(x) f_Y(y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_{x \leq z} f_X(x - y) f_Y(y) dx dy && (x \mapsto x - y) \\ &= \int_{-\infty}^z \left(\int_{-\infty}^{\infty} f_X(x - y) f_Y(y) dy \right) dx \\ &= \int_{-\infty}^z (f_X \star f_Y)(x) dx. \end{aligned}$$

Ceci montre que S admet la densité $f_S = f_X \star f_Y$ (par définition de la densité d'une variable aléatoire réelle). $\square$

Exemple 1.5. Soient $X, Y \sim \mathcal{U}(0, 1)$ indépendantes, donc de densité $f = \mathbb{K}_{[0,1]}$. Alors $X + Y$ admet la densité

$$\begin{aligned} f_{X+Y}(x) &= (f \star f)(x) \\ &= \int_{-\infty}^{\infty} \mathbb{K}_{[0,1]}(x-t) \mathbb{K}_{[0,1]}(t) dt \\ &= \int_0^1 \mathbb{K}_{x-1 \leq t \leq x} dt \\ &= x \mathbb{K}_{[0,1]}(x) + (2-x) \mathbb{K}_{[1,2]}(x). \end{aligned}$$

Exemple 1.6. Soient $\alpha_1, \alpha_2, \beta > 0$, et $X \sim \Gamma(\alpha_1, \beta)$ et $Y \sim \Gamma(\alpha_2, \beta)$ indépendantes. Soit $y > 0$.

Alors $X + Y$ admet la densité suivante en $y > 0$:

$$\begin{aligned} f_{X+Y}(y) &= (f_X \star f_Y)(y) \\ &= \int_{\mathbb{R}} f_X(x) f_Y(y-x) dx \\ &= \int_0^y \frac{\beta^{\alpha_1}}{\Gamma(\alpha_1)} x^{\alpha_1-1} e^{-\beta x} \frac{\beta^{\alpha_2}}{\Gamma(\alpha_2)} (y-x)^{\alpha_2-1} e^{-\beta(y-x)} dx \\ &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^y x^{\alpha_1-1} (y-x)^{\alpha_2-1} e^{-\beta y} dx \\ &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} y^{\alpha_1+\alpha_2-1} e^{-\beta y} \int_0^y \left(\frac{x}{y}\right)^{\alpha_1-1} \left(1 - \frac{x}{y}\right)^{\alpha_2-1} \frac{dx}{y} \\ &= \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} y^{\alpha_1+\alpha_2-1} e^{-\beta y} \int_0^1 z^{\alpha_1-1} (1-z)^{\alpha_2-1} dz \end{aligned}$$

Maintenant deux densités de probabilité proportionnelles sont nécessairement égales, on en tire que

$$f_{\alpha_1, \beta} \star f_{\alpha_2, \beta}(y) = \frac{\beta^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1 + \alpha_2)} y^{\alpha_1+\alpha_2-1} e^{-\beta y} \mathbb{K}_{y>0} = f_{\alpha_1+\alpha_2, \beta}(y)$$

avec en prime l'expression de l'intégrale suivante en terme de fonction Γ :

$$\int_0^1 z^{\alpha_1-1}(1-z)^{\alpha_2-1}dz = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}$$

De ce résultat on tire (par une récurrence finie) que la somme de n variables i.i.d de loi $\mathcal{E}(\beta)$ suit une loi $\Gamma(n, \beta)$.

Exercice 1.4. *Retrouver ce résultat à l'aide de la méthode portant sur la fonction génératrice des moments.*

Comparaison des deux méthodes Chacune des deux méthodes a ses avantages et ses inconvénients. La méthode par la fonction génératrice des moments est souvent plus simple et rapide, car une simple multiplication est plus facile à calculer qu'une convolution.

En revanche, même si on réussit à calculer la fonction génératrice des moments de S , rien ne dit qu'on sera capable d'inverser cette fonction génératrice, c'est-à-dire de trouver la loi dont cette fonction est la fonction génératrice. Cette méthode peut donc ne pas aboutir, auquel cas on pourra passer à la méthode de la convolution des densités.

Dans le cas particulier de la loi Binomiale, on peut aussi se dispenser de convolution et calculer directement la loi de la somme.

Exercice 1.5. Soit $n \geq 1$ entier, et $(B_i)_{1 \leq i \leq n}$ une suite de variables aléatoires i.i.d. selon la loi $\mathcal{B}(p)$, pour $p \in [0, 1]$. On s'intéresse à la loi de $S_n = \sum_{1 \leq i \leq n} B_i$.

1. Soit $x \in \{0, 1\}$. Observer que

$$\mathbb{P}(B_1 = x) = p^x(1-p)^{1-x}$$

2. En déduire que si $(x_i)_{1 \leq i \leq n} \in \{0, 1\}^n$,

$$\mathbb{P}\left(\bigcap_{1 \leq i \leq n} \{B_i = x_i\}\right) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

3. Quel est le cardinal de l'ensemble

$$\{(x_i)_{1 \leq i \leq n} \in \{0, 1\}^n : \sum_{1 \leq i \leq n} x_i = k\}?$$

4. En déduire que, pour $0 \leq k \leq n$,

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

5. Calculer la fonction génératrice des moments de S_n et de la loi $\mathcal{B}(n, p)$ et retrouver ce résultat.

Exercice 1.6. Soit $n \geq 1$ entier, et $(B_i)_{i \geq 1}$ une suite de variables aléatoires i.i.d. selon la loi $\mathcal{B}(p)$, pour $p \in]0, 1]$.

1. On pose $L = \min\{n \geq 1, B_n = 1\} \in \mathbb{N} \cup \{\infty\}$. Quelle est la loi de L ?

2. On pose $N_r = \min\{n \geq 1, \sum_{i=1}^n B_i = r\}$. Observer que

$$\{N_r = n\} = \left\{ \sum_{i=1}^{n-1} B_i = r - 1, B_n = 1 \right\}.$$

Quelle est la loi de N_r ?

3. Montrer que N_r est distribué comme $L_1 + \dots + L_r$ avec les L_i i.i.d. selon la loi de L .

CAS GÉNÉRAL

Soient $X_1, \dots, X_n$ des v.a. conjointement à densité et $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ une fonction.

On s'intéresse à la loi du vecteur aléatoire $\phi(X_1, \dots, X_n)$. Sous des conditions convenables sur la fonction ϕ , ce vecteur aléatoire admettra encore une densité jointe qu'on peut exprimer en fonction de la densité conjointe des v.a. $X_1, \dots, X_n$. Pour cela, nous rappelons d'abord le changement de variable multidimensionnel.

Changement de variable dans $\mathbb{R}^n$ Si $\phi(x) = (\phi_1(x), \dots, \phi_n(x))$ pour $x \in \mathbb{R}^n$, on définit la *matrice jacobienne* de la fonction ϕ par

$$\mathcal{J}_\phi : x \mapsto \begin{pmatrix} \frac{\partial \phi_1}{\partial x_1}(x) & \cdots & \frac{\partial \phi_1}{\partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \frac{\partial \phi_n}{\partial x_1}(x) & \cdots & \frac{\partial \phi_n}{\partial x_n}(x) \end{pmatrix},$$

partout où toutes les dérivées partielles sont bien définies. Notons que la matrice jacobienne est une *fonction* à valeurs dans les matrices.

Le déterminant de la matrice jacobienne joue un rôle important, il est appelé le *jacobien* :

$$\begin{cases} \mathbb{R}^n \rightarrow \mathbb{R} \\ x \mapsto J_\phi(x) = \det \mathcal{J}_\phi(x) \end{cases}$$

La matrice jacobienne et le jacobien étant des notions locales, ils sont également définis pour des fonctions sur un ouvert $O \subset \mathbb{R}^n$. On dira qu'une fonction ϕ est *continûment dérivable* sur O , et on notera $\phi \in C^1(O)$, si la matrice jacobienne $\mathcal{J}_\phi(x)$ est définie et continue sur O .

Nous avons besoin de savoir comment le volume d -dimensionnel d'un petit parallélépipède I_x de centre x se transforme par l'application ϕ . La réponse est donnée par le jacobien :

Théorème 1.2 (Changement de variables dans $\mathbb{R}^n$). *Soit ϕ une bijection continûment différentiable ainsi que son inverse ϕ^{-1} d'un ouvert $O \subset \mathbb{R}^n$ sur un ouvert O' de $\mathbb{R}^n$, $g : \mathbb{R}^n \rightarrow \mathbb{R}$ bornée et $f : \mathbb{R}^n \rightarrow \mathbb{R}$ intégrable. Alors :*

$$\int_O g(\phi(x)) f(x) dx = \int_{O'} g(y) f(\phi^{-1}(y)) |\mathcal{J}_{\phi^{-1}}(y)| dy, \quad (1.7)$$

avec de plus :

$$\mathcal{J}_{\phi^{-1}}(y) = \frac{1}{\mathcal{J}_{\phi}(\phi^{-1}(y))} \quad (1.8)$$

Remarque 1.5 (Au sujet de la valeur absolue du jacobien). En dimension $d = 1$, lorsque $O =]a, b[$ avec $a < b$ et ϕ est strictement décroissante alors $O' =]\phi(b), \phi(a)[$ et ϕ^{-1} est décroissante si bien que $|\mathcal{J}_{\phi^{-1}}(y)| = -(\phi^{-1})'(y)$. Ainsi le second membre de (1.7) s'écrit :

$$\int_{\phi(b)}^{\phi(a)} g(y) f(\phi^{-1}(y)) (-(\phi^{-1})'(y)) dy = \int_{\phi(a)}^{\phi(b)} g(y) f(\phi^{-1}(y)) (\phi^{-1})'(y) dy$$

et on retrouve bien le changement de variables usuel dans $\mathbb{R}$.

Remarque 1.6. La relation (1.8) entre $\mathcal{J}_{\phi^{-1}}$ et $\mathcal{J}_{\phi}$ est l'analogue multidimensionnel de la relation $(\phi^{-1})'(y) = 1/(\phi' \circ \phi^{-1})(y)$; elle permet quelquefois de se dispenser du calcul du jacobien de la fonction réciproque, voire de la fonction réciproque elle-même.

Application : fonction d'un vecteur à densité Soit $X = (X_1, \dots, X_n)$ un vecteur aléatoire à densité à valeurs dans un ouvert $O \subset \mathbb{R}^n$, de densité conjointe $f_{X_1, \dots, X_n}$. On suppose que $\phi : O \rightarrow O'$ est une bijection continûment différentiable ainsi que son inverse ϕ^{-1} . On s'intéresse au vecteur aléatoire

$$Y = \phi(X) = \phi(X_1, \dots, X_n).$$

Pour caractériser la loi de ce vecteur, on combine la méthode de la fonction muette avec le changement de variables multidimensionnel : dans la formule (1.7) ci-dessus, on prend pour g une fonction bornée qui est la fonction "test" ou fonction "muette", et pour f la densité du vecteur aléatoire X , qui est donc intégrable. Le changement de variable multidimensionnel donne :

$$\begin{aligned}
 \mathbb{E}[g(\phi(X))] &= \int_O g(\phi(x)) f(x) dx \\
 &= \int_{O'} g(y) f(\phi^{-1}(y)) |\mathcal{J}_{\phi^{-1}}(y)| dy \\
 &= \int_{\mathbb{R}^d} g(y) f(\phi^{-1}(y)) |\mathcal{J}_{\phi^{-1}}(y)| \mathbb{K}_{O'}(y) dy,
 \end{aligned}$$

c'est-à-dire que $\phi(X)$ est à densité, de densité $f(\phi^{-1}(y)) |\mathcal{J}_{\phi^{-1}}(y)| \mathbb{K}_{O'}(y)$. Dans le cas où ϕ n'est pas bijective sur O entier, il faut partitionner O en "bouts" sur lesquels ϕ est bijective. La meilleure façon de comprendre ce résultat est par la pratique. Nous développons dans la suite de nombreux exemples.

Exemple 1.7. Soit X, Y indépendantes de loi $\mathcal{U}(0, 1)$. Soit $\phi : O =]0, 1]^2 \rightarrow \mathbb{R}^2$ donnée par

$$(z, w) = \phi(x, y) = (x + y, x - y).$$

Déterminons $O' = \phi(O)$. $(x, y) = \phi^{-1}(z, w) = \left(\frac{z+w}{2}, \frac{z-w}{2}\right)$ donne

$$(z, w) \in O' \iff \left(\frac{z+w}{2}, \frac{z-w}{2}\right) \in O \iff (z+w \in]0, 2[\text{ et } z-w \in]0, 2[).$$

En d'autres termes, l'ensemble O' est le carré d'extrémités $(0, 0)$, $(1, 1)$, $(2, 0)$ et $(1, -1)$ (notons que son aire vaut 2). ϕ est une bijection continûment différentiable, ainsi que son inverse, de O sur O' , et $\mathcal{J}_{\phi^{-1}}(z, w) = 1/2$ pour tout $(z, w) \in O'$. On peut donc calculer, pour g bornée,

$$\begin{aligned}
 \mathbb{E}[g(Z, W)] &= \mathbb{E}[g(X + Y, X - Y)] \\
 &= \int_O g(x + y, x - y) dx dy \\
 &= \int_{O'} g(z, w) \frac{dz dw}{2} \\
 &= \int_{O'} g(z, w) \mathbb{K}_{O'}(z, w) \frac{dz dw}{2}
 \end{aligned}$$

Ainsi (Z, W) possède la densité uniforme sur O' ; ses marginales sont données par :

$$\begin{aligned} f_Z(z) &= \int \mathbb{1}_{\{-z < w < 2-z, z-2 < w < z\}} \frac{dw}{2} \\ &= \mathbb{1}_{\{0 < z < 1\}} \int \mathbb{1}_{\{-z < w < z\}} \frac{dw}{2} + \mathbb{1}_{\{1 \leq z < 2\}} \int \mathbb{1}_{\{z-2 < w < 2-z\}} \frac{dw}{2} \\ &= \mathbb{1}_{\{0 < z < 2\}} (z \wedge (2 - z)) \end{aligned}$$

et

$$\begin{aligned} f_W(w) &= \int \mathbb{1}_{\{-w < z < 2-w, w < z < 2+w\}} \frac{dz}{2} \\ &= \mathbb{1}_{\{-1 < w < 0\}} \int \mathbb{1}_{\{-w < z < 2+w\}} \frac{dz}{2} + \mathbb{1}_{\{0 \leq w < 1\}} \int \mathbb{1}_{\{w < z < 2-w\}} \frac{dz}{2} \\ &= \mathbb{1}_{\{-1 < w < 1\}} \frac{1 - |w|}{2} \end{aligned}$$

Enfin, Z et W ne sont pas indépendantes car (Z, W) n'admet pas la densité produit $f_Z(z)f_W(w)$.

Exemple 1.8. Soit X, Y indépendantes de loi $\mathcal{E}(\lambda)$. On reprend la même fonction ϕ mais cette fois-ci définie sur $O =]0, +\infty[^2 \rightarrow \mathbb{R}^2$. Alors

$$(z, w) \in O' = \phi(O) \iff (z + w > 0 \text{ et } z - w > 0) \iff z > |w|.$$

Ainsi $O' = \{(z, w) \in \mathbb{R}^2, |w| < z\}$. On a encore que ϕ est une bijection continûment différentiable ainsi que son inverse, et, pour g bornée :

$$\begin{aligned} \mathbb{E}[g(Z, W)] &= \mathbb{E}[g(X + Y, X - Y)] \\ &= \int_O g(x + y, x - y) \lambda^2 e^{-\lambda(x+y)} dx dy \\ &= \int_{O'} g(z, w) \lambda^2 e^{-\lambda z} \frac{dz dw}{2} \\ &= \int_{\mathbb{R}^2} g(z, w) \lambda^2 e^{-\lambda z} \mathbb{1}_{|w| < z} \frac{dz dw}{2} \end{aligned}$$

donc le couple (Z, W) admet la densité jointe $f_{Z,W}(z, w) = \frac{\lambda^2}{2} e^{-\lambda z} \mathbb{1}_{|w| < z}$ et on peut calculer les densités marginales :

$$\begin{aligned} f_Z(z) &= \frac{\lambda^2}{2} e^{-\lambda z} \left(\int_{-z}^z dw \right) \\ &= \lambda^2 z e^{-\lambda z} \mathbb{1}_{z > 0}, \end{aligned}$$

on reconnaît donc que Z suit une loi $\Gamma(2, \lambda)$, ainsi que :

$$\begin{aligned} f_W(w) &= \frac{\lambda}{2} \int_{-z}^z \mathbb{1}_{z > |w|} \lambda e^{-\lambda z} dz \\ &= \frac{\lambda}{2} e^{-\lambda |w|} \end{aligned}$$

encore appelée loi de Laplace de paramètre λ , et qui peut être réalisée comme la valeur absolue d'une variable aléatoire de loi $\mathcal{E}(\lambda)$.

Exemple 1.9. Enfin, soit X, Y indépendantes de loi normale centrée réduite, $\mathcal{N}(0, 1)$. On considère toujours la même fonction ϕ mais cette fois-ci définie sur $O = \mathbb{R}^2$ entier; ϕ définit une bijection sur $O' = \mathbb{R}^2$ cette fois. On obtient donc, pour g bornée, que

$$\begin{aligned} \mathbb{E}[g(Z, W)] &= \mathbb{E}[g(X + Y, X - Y)] \\ &= \int_O g(x + y, x - y) \frac{1}{2\pi} e^{-\frac{x^2 + y^2}{2}} dx dy \\ &= \int_{O'} g(z, w) \frac{1}{2\pi} e^{-\frac{((z+w)/2)^2 + ((z-w)/2)^2}{2}} \frac{dz dw}{2} \\ &= \int_{\mathbb{R}^2} g(z, w) \frac{1}{4\pi} e^{-\frac{z^2 + w^2}{4}} dz dw \end{aligned}$$

Ainsi (Z, W) admet la densité $f_{Z,W}(z, w) = \frac{1}{4\pi} e^{-\frac{z^2 + w^2}{4}}$ de lois marginales $f_Z(z) = f_W(z) = \frac{1}{\sqrt{4\pi}} e^{-\frac{z^2}{4}}$ et donc la relation $f_{Z,W}(z, w) = f_Z(z) f_W(w)$ implique que Z et W sont indépendantes de loi $\mathcal{N}(0, 2)$.

Exemple 1.10. Considérons la somme de variables aléatoires $X_1, \dots, X_n$ i.i.d. selon la loi exponentielle de paramètre β (on pourra faire le lien avec la somme de v.a. de loi

Gamma). Puisque $\beta e^{-\beta x} \mathbb{1}_{x>0}$ est la densité de la loi exponentielle, le vecteur aléatoire $(X_1, \dots, X_n)$ possède la densité

$$\beta^n e^{-\beta(x_1+\dots+x_n)} \mathbb{1}_{x_1>0, \dots, x_n>0}.$$

On pose $\phi(x_1, \dots, x_n) = (y_1, \dots, y_n)$ avec $y_i = \sum_{j=1}^i x_j$; ϕ est une bijection de $O =]0, +\infty[^n$ sur $O' = \{0 < y_1 < \dots < y_n\}$, elle est continûment différentiable ainsi que son inverse; pour cette transformation, $\mathcal{J}_\phi$ vaut identiquement 1 sur O et donc, de la formule (1.8), pour tout $y \in O'$, $\mathcal{J}_{\phi^{-1}}(y) = 1$ (sans même avoir besoin d'explicitier l'inverse ϕ^{-1}). Ainsi, pour $g : \mathbb{R} \rightarrow \mathbb{R}$ bornée, on obtient

$$\begin{aligned} \mathbb{E}[g(X_1 + \dots + X_n)] &= \int_O g(x_1 + \dots + x_n) \beta^n e^{-\beta(x_1+\dots+x_n)} \mathbb{1}_{x_1>0, \dots, x_n>0} dx_1 \dots dx_n \\ &= \int_{O'} g(y_n) \beta^n e^{-\beta y_n} \mathbb{1}_{0<y_1<y_2<\dots<y_n} dy_1 \dots dy_n \\ &= \int_{\mathbb{R}} g(y_n) \beta^n e^{-\beta y_n} \left(\int_{\mathbb{R}^{n-1}} \mathbb{1}_{0<y_1<y_2<\dots<y_n} dy_1 \dots dy_{n-1} \right) dy_n \\ &= \int_{\mathbb{R}} g(y_n) \frac{\beta^n}{(n-1)!} (y_n)^{n-1} e^{-\beta y_n} \mathbb{1}_{y_n>0} dy_n \end{aligned}$$

ayant utilisé que

$$\begin{aligned} \int_{\mathbb{R}^{n-1}} \mathbb{1}_{0<y_1<y_2<\dots<y_n} dy_1 \dots dy_{n-1} &= \int_{\mathbb{R}^{n-2}} y_2 \mathbb{1}_{0<y_2<\dots<y_n} dy_2 \dots dy_{n-1} \\ &= \int_{\mathbb{R}^{n-3}} \frac{y_3^2}{2} \mathbb{1}_{0<y_3<\dots<y_n} dy_3 \dots dy_{n-1} \\ &= \frac{(y_n)^{n-1}}{(n-1)!} \end{aligned}$$

Ainsi $X_1 + \dots + X_n$ suit une loi $\Gamma(n, \beta)$.

Exemple 1.11. Soient $X_1, \dots, X_n$ des v.a. i.i.d. de loi $\text{Unif}(0, 1)$ et soit $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ la fonction

$$\phi(x_1, \dots, x_n) = (x_{(1)}, \dots, x_{(n)}),$$

où $x_{(1)}, \dots, x_{(n)}$ sont les valeurs $x_1, \dots, x_n$ rangées par ordre croissant. On s'intéresse au vecteur aléatoire $Y = (X_{(1)}, \dots, X_{(n)}) = \phi(X_1, \dots, X_n)$. La fonction ϕ n'est évidemment pas injective, ni de classe C^1 , mais on peut se restreindre à l'ouvert

$$O = \{(x_1, \dots, x_n) \in \mathbb{R}^n : x_i \neq x_j, i \neq j\}.$$

Alors le vecteur aléatoire $(X_1, \dots, X_n)$ est p.s. à valeurs dans O , car $\mathbb{P}(X_i = X_j) = 0$ pour tout $i \neq j$, par continuité de la loi $\mathcal{U}(0, 1)$.

La matrice jacobienne : Soit $x = (x_1, \dots, x_n) \in O$ et pour $i \in \{1, \dots, n\}$, notons $\pi(i)$ l'indice tel que $x_i = x_{(\pi(i))}$, soit le rang de x_i dans l'arrangement croissant. Alors pour tout i et pour $\varepsilon > 0$ assez petit,

$$\phi(x_1, \dots, x_{i-1}, x_i + \varepsilon, x_{i+1}, \dots, x_n) = (x_{\pi(1)}, \dots, x_{\pi(i-1)}, x_{\pi(i)} + \varepsilon, x_{\pi(i+1)}, \dots, x_{\pi(n)}),$$

puisque l'ordre des $x_1, \dots, x_n$ ne change pas quand on perturbe un peu les valeurs. Par conséquent, la matrice jacobienne est donnée par

$$\mathcal{J}_\phi(x_1, \dots, x_n) = (\mathbb{K}_{j=\pi(i)})_{i,j=1,\dots,n}.$$

En particulier, le jacobien est donné par le signe $\sigma(\pi)$ de la permutation π .

$$\mathcal{J}_\phi(x_1, \dots, x_n) = \sigma(\pi) \in \{-1, 1\},$$

Il reste à déterminer la préimage de ϕ . Clairement, l'image de O par ϕ est incluse dans l'ensemble

$$E = \{(x_1, \dots, x_n) \in \mathbb{R}^n : x_1 < \dots < x_n\}.$$

Inversement, étant donné $x \in E$, sa préimage $\phi^{-1}(x)$ consiste en tous les points dans D obtenus en permutant les coordonnées de x . Il existe exactement $n!$ telles permutations et chacune donne un point différent, si bien que $\text{Card}(\phi^{-1}(x)) = n!$. Puisque $f_{X_1, \dots, X_n} = \mathbb{K}_{[0,1]^n}$, on obtient pour tout $x \in E$,

$$f_{X_{(1)}, \dots, X_{(n)}}(x) = n! \times \mathbb{K}_S(x), \text{ avec } S = \{(x_1, \dots, x_n) \in \mathbb{R}^n : 0 \leq x_1 < \dots < x_n \leq 1\}.$$

Autrement dit, le vecteur aléatoire $(X_{(1)}, \dots, X_{(n)})$ est de loi uniforme dans l'ensemble S .

Exemple 1.12. Soit $\phi(x) = Ax + b$ avec A une matrice carrée et $b \in \mathbb{R}^n$. Alors

$$\mathcal{J}_\phi \equiv A,$$

en particulier, $\mathcal{J}_\phi \equiv \det A$. Pour appliquer les théorèmes, il faut alors que $\det A \neq 0$, c'est-à-dire que A soit inversible. La fonction ϕ est alors bijective d'inverse

$$\phi^{-1}(x) = A^{-1}(x - b).$$

On obtient donc :

$$f_{AX+b}(x) = |\det A^{-1}| \times f_X(A^{-1}(x - b)).$$

Exemple 1.13. Soient $X_1, \dots, X_n$ des v.a. i.i.d. de loi $\mathcal{N}(0, 1)$. On appelle le vecteur $X = (X_1, \dots, X_n)$ un vecteur gaussien standard (n -dimensionnel). Sa densité conjointe est donnée par

$$f_X(x_1, \dots, x_n) = \prod_{i=1}^n \frac{e^{-x_i^2/2}}{\sqrt{2\pi}} = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n x_i^2},$$

ce qu'on peut encore écrire à l'aide de la norme euclidienne $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ de $x = (x_1, \dots, x_n)$:

$$f_X(x) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{\|x\|_2^2}{2}}.$$

Si maintenant A est une matrice de dimension $n \times n$ et $\mu \in \mathbb{R}^n$, alors on dit que $AX + \mu$ est un *vecteur gaussien de moyenne μ* et de *matrice de covariance* $\Sigma = AA^t$ et on note $AX + \mu \sim \mathcal{N}(\mu, \Sigma)$. Dans le cas où A est inversible, par l'exemple précédent, $AX + \mu$ admet la densité conjointe

$$\begin{aligned} f_{AX+\mu}(x) &= |\det A^{-1}| \times \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \|A^{-1}(x-\mu)\|_2^2} \\ &= \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} \times e^{-\frac{1}{2} \langle \Sigma^{-1}(x-\mu), (x-\mu) \rangle}, \end{aligned}$$

où la seconde identité vient du fait que $\det \Sigma = \det A \times \det A^t = (\det A)^2$ et pour tout $y \in \mathbb{R}^n$,

$$\|A^{-1}y\|_2^2 = \langle A^{-1}y, A^{-1}y \rangle = \langle (A^{-1})^t A^{-1}y, y \rangle = \langle (AA^t)^{-1}y, y \rangle = \langle \Sigma^{-1}y, y \rangle.$$

En particulier, la loi de $AX + \mu$ ne dépend que de μ et Σ : si B est une autre matrice telle que $BB^t = \Sigma$, alors $AX + \mu$ et $BX + \mu$ ont même loi et on peut montrer que cela reste vrai même si A n'est pas inversible (ce qui justifie la notation $AX + \mu \sim \mathcal{N}(\mu, \Sigma)$ qui ne fait pas mention de A).

Exemple 1.14. Pour un couple $(x, y) \in \mathbb{R}^2$, notons (r, θ) ses coordonnées polaires, i.e. $(x, y) = (r \cos \theta, r \sin \theta)$. Ceci induit un difféomorphisme, avec $D := \mathbb{R}^2 \setminus ([-\infty, 0] \times \{0\})$,

$$\phi : D \rightarrow \mathbb{R}_+^* \times]-\pi, \pi[, \quad (x, y) \mapsto (r, \theta).$$

Son inverse est donné par

$$\phi^{-1}(r, \theta) = (r \cos \theta, r \sin \theta),$$

dont le jacobien est donné par

$$\mathcal{J}_{\phi^{-1}}(r, \theta) = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r(\cos^2 \theta + \sin^2 \theta) = r.$$

On applique la fonction ϕ à un vecteur gaussien standard (X, Y) , i.e. $X, Y \sim \mathcal{N}(0, 1)$ et sont indépendantes. Celui-ci est à valeurs dans D , car $\mathbb{P}((X, Y) \notin D) \leq \mathbb{P}(Y = 0) = 0$.

Notons $(R, \Theta) = \phi(X, Y)$, i.e. $(X, Y) = (R \cos \Theta, R \sin \Theta)$. On obtient donc :

$$\begin{aligned} f_{R, \Theta}(r, \theta) &= |\mathcal{J}_{\phi^{-1}}(r, \theta)| \times f_{X, Y}(\phi^{-1}(r, \theta)) \\ &= r \frac{1}{2\pi} e^{-\frac{r^2(\cos^2 \theta + \sin^2 \theta)}{2}} \\ &= r e^{-r^2/2} \times \frac{1}{2\pi}. \end{aligned}$$

Ceci est le produit des deux fonctions $f_R(r) = re^{-r^2/2}$ et $f_\Theta(\theta) = \frac{1}{2\pi}$. Par conséquent, les v.a. R et Θ sont indépendantes et de densités proportionnelles à f_R et f_Θ , respectivement. Mais puisque f_Θ est d'intégrale 1, f_R doit l'être aussi et donc f_R et f_Θ sont en fait les densités. On résume : R et Θ sont des v.a. indépendantes, avec Θ de loi $\text{Unif}(-\pi, \pi)$ et R de loi de densité

$$f_R(r) = re^{-r^2/2} \mathbb{1}_{r>0}.$$

TDI : VARIABLES ALÉATOIRES INDÉPENDANTES

Exercice 1.7. Calculer les intégrales suivantes :

1. $\int_{\mathbb{R}^2} \lambda e^{-\lambda x} \cdot \mu e^{-\mu y} \mathbb{1}_{\{0 < x < y\}} dx dy$
2. $\int_{\mathbb{R}^2} \lambda e^{-\lambda x} \cdot \mu e^{-\mu y} \mathbb{1}_{\{x+y \leq t\}} \mathbb{1}_{\{0 < x, y\}} dx dy$
3. $\int_{\mathbb{R}^2} \lambda e^{-\lambda x} \cdot \mu e^{-\mu y} \mathbb{1}_{\{x < t < x+y\}} \mathbb{1}_{\{0 < x, y\}} dx dy$

Dans 2 et 3, on distinguera trois cas en fonction de λ et μ et on donnera un équivalent pour 3 lorsque $t \rightarrow \infty$.

Exercice 1.8. Calculer les intégrales suivantes (on pourra proposer/s'aider d'une interprétation géométrique) :

1. $\int_{\mathbb{R}^2} \mathbb{1}_{\{x+y \leq t\}} \mathbb{1}_{\{0 < x < 1, 0 < y < 1\}} dx dy$
2. $\int_{\mathbb{R}^2} \mathbb{1}_{\{x-y \leq t\}} \mathbb{1}_{\{0 < x < 1, 0 < y < 1\}} dx dy$
3. $\int_{\mathbb{R}^2} \mathbb{1}_{\{xy \leq t\}} \mathbb{1}_{\{0 < x < 1, 0 < y < 1\}} dx dy$
4. $\int_{\mathbb{R}^2} \mathbb{1}_{\{x/y \leq t\}} \mathbb{1}_{\{0 < x < 1, 0 < y < 1\}} dx dy$

Exercice 1.9. Soit X_1, X_2, X_3 trois variables aléatoires indépendantes distribuées selon la loi de Rademacher : $\mathbb{P}(X_1 = \pm 1) = 1/2$. On pose

$$Y_1 = X_2 X_3, \quad Y_2 = X_1 X_3, \quad Y_3 = X_1 X_2.$$

1. Soit $i \neq j$. Montrer que les variables Y_i et Y_j sont indépendantes. (On dit alors que les variables Y_1, Y_2, Y_3 sont deux à deux indépendantes).
2. Les variables Y_1, Y_2, Y_3 sont-elles indépendantes ? On pourra calculer $\mathbb{P}(Y_1 = 1, Y_2 = 1, Y_3 = 1)$.

Exercice 1.10. Soit (X, Y) un couple de variables aléatoires de densité :

$$f_{X,Y}(x, y) = 2e^{-x-2y} \mathbb{1}_{]0, +\infty[}(x) \mathbb{1}_{]0, +\infty[}(y)$$

1. Calculer les lois marginales de X et de Y . En déduire que les variables X et Y sont indépendantes.
2. Calculer $\mathbb{P}(X > 1, Y < 1)$.
3. Calculer $\mathbb{P}(X < Y)$.

Exercice 1.11. Soit (X, Y) un couple de variables aléatoires de densité :

$$f_{X,Y}(x, y) = \begin{cases} 24xy & \text{si } 0 \leq x \leq 1 \text{ et } 0 \leq y \leq 1 \text{ et } 0 \leq x + y \leq 1, \\ 0 & \text{sinon.} \end{cases}$$

Les variables X et Y sont-elles indépendantes ?

Exercice 1.12. Soit U et V deux variables uniformes indépendantes sur $[0, 1]$. On coupe un bâton, assimilé au segment $[0, 1]$, en 3 bouts selon les points de découpe U et V . On note A, B et C les longueurs des 3 bouts (pris de gauche à droite).

1. Exprimer A en fonction de U et de V . En déduire, pour $x \in [0, 1]$, $\mathbb{P}(A > x)$ puis la fonction de répartition de A et enfin, si cela a un sens, sa densité.
2. De même, trouver la loi de C .
3. Quelle est la loi de B ? On pourra commencer par chercher $\Delta_x \subset [0, 1]^2$ tel que $\{B \leq x\} = \{(U, V) \in \Delta_x\}$.
4. On peut former un triangle avec les 3 bouts si la longueur d'aucun des bouts n'excède la somme des deux autres. Quelle est la probabilité de pouvoir former un triangle ?

Exercice 1.13. Soit X, Y, Z trois variables i.i.d. de fonction de répartition commune F . On pose U, V, W le réarrangement croissant de X, Y, Z , c'est-à-dire les trois nombres tels que $U \leq V \leq W$ et $\{U, V, W\} = \{X, Y, Z\}$.

1. Quelle est la fonction de répartition de $W = \max\{X, Y, Z\}$?
2. Quelle est la fonction de répartition de $U = \min\{X, Y, Z\}$?
3. Quelle est la fonction de répartition de V ?

Exercice 1.14. Soit X, Y, Z des variables aléatoires indépendantes de loi $\text{Unif}(0, 1)$. Calculer $\mathbb{P}(X \geq YZ)$.

Exercice 1.15. Soit X, Y indépendantes de loi exponentielle de paramètre $\lambda > 0$.

1. Calculer la fonction de répartition de X/Y et en déduire une densité de cette variable aléatoire.
2. En déduire la fonction de répartition de $X/(X + Y)$ et faire le lien avec une loi connue.

Exercice 1.16. Soit X, Y et ε trois variables aléatoires indépendantes; on suppose que $X, Y \sim \text{Exp}(\lambda)$ pour $\lambda > 0$ un réel, et ε est un signe aléatoire, c'est-à-dire que $\mathbb{P}(\varepsilon = +1) = \mathbb{P}(\varepsilon = -1) = 1/2$.

1. Calculer la loi de εX à l'aide de :
 - (a) la fonction de répartition
 - (b) la méthode de la fonction muette
2. Calculer la loi de $X - Y$.

Exercice 1.17. Soit $X_1, \dots, X_n$ des variables aléatoires indépendantes, avec $X_i \sim \text{Exp}(\lambda_i)$ pour tout $i \in \{1, \dots, n\}$.

1. Déterminer la loi de $Y = \min\{X_i, i \in \{1, \dots, n\}\}$, reconnaître cette loi.
2. Déterminer la loi de $Z = \max\{X_i, i \in \{1, \dots, n\}\}$, et calculer sa densité (si elle existe).

Exercice 1.18. Soit $X_1, \dots, X_n$ des variables aléatoires indépendantes, avec $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ pour tout $i \in \{1, \dots, n\}$. Donner la loi de $S_n = X_1 + \dots + X_n$ en calculant sa fonction génératrice des moments.

Exercice 1.19. Soit $X_1, \dots, X_n$ des variables aléatoires indépendantes et telles que $X_i \sim \Gamma(\alpha_i, \beta)$ pour tout $i \in \{1, \dots, n\}$, avec $\alpha_i, \beta > 0$.

1. Donner la loi de $S_n = X_1 + \dots + X_n$ en considérant sa fonction génératrice des moments.
2. En déduire la loi de $Z_1^2 + \dots + Z_n^2$ où les Z_i sont des variables aléatoires indépendantes et de loi $\mathcal{N}(0, 1)$.

Exercice 1.20. Soient X et Y deux variables aléatoires réelles indépendantes et identiquement distribuées suivant la loi de Pareto de paramètre 2, i.e. qui possèdent la densité $p(x) = \frac{\mathbb{1}_{\{x \geq 1\}}}{x^2}$.

On pose

$$(Z, W) = \left(\ln(X), \frac{1 + \ln(Y)}{\ln(X)} \right)$$

1. Quelle est la loi de (Z, W) ? Les variables Z et W sont-elles indépendantes?
2. Quelle est la loi de W ?
3. Quelle est la loi de Z ?

Exercice 1.21. Soit (X, Y) un couple de variables aléatoires indépendantes de loi $\mathcal{N}(0, 1)$.

1. Déterminer la loi de $(Z, W) = (X/Y, X + Y)$.
2. En déduire la loi de Z .

Exercice 1.22. Soient X et Y des variables aléatoires réelles indépendantes de densités respectives f et g .

1. Montrer qu'une densité de $Z = X/Y$ est donnée par

$$h(z) = \int_0^{+\infty} y(f(zy)g(y) + f(-zy)g(-y))dy.$$

2. Application : déterminer la loi de Z dans le cas où X et Y sont indépendantes, de même loi la loi :
 - (a) normale centrée réduite $\mathcal{N}(0, 1)$.
 - (b) exponentielle de paramètre $\lambda > 0$.

SUITES DE VARIABLES ALÉATOIRES ET THÉORÈMES LIMITES

Dans ce chapitre, nous allons énoncer deux théorèmes concernant le comportement limite quand $n \rightarrow \infty$ de la somme $X_1 + \dots + X_n$, où $X_1, X_2, \dots$ sont des variables i.i.d. (indépendantes et identiquement distribuées). Pour cela, nous allons d'abord introduire des notions de convergence pour des suites de variables aléatoires.

2.1 CONVERGENCE DE SUITES DE VARIABLES ALÉATOIRES

Dans cette section, $X_1, X_2, \dots$ désigne une suite de variables aléatoires, c'est-à-dire une famille de v.a. indexée par $\mathbb{N}^*$. On introduit plusieurs notions de convergence.

CONVERGENCE EN LOI

Définition 2.1. On dit que la suite $X_1, X_2, \dots$ converge en loi s'il existe une variable aléatoire X telle que pour tout $x \in \mathbb{R}$ tel que F_X est continue en x (donc pour tout $x \in \mathbb{R}$ qui n'est pas un atome de X),

$$F_{X_n}(x) \rightarrow F_X(x), \quad n \rightarrow \infty.$$

On dit alors que X_n converge en loi vers X quand $n \rightarrow \infty$ et on note $X_n \xrightarrow{\text{loi}} X$.

Remarque 2.1. La convergence en loi de variables aléatoires porte seulement sur les lois marginales des v.a. $X, X_1, X_2, \dots$ et non pas sur leur loi jointe. Le lien entre les v.a. ne joue donc aucun rôle pour la convergence en loi, elles peuvent même décrire des expériences aléatoires différentes. Il serait même plus naturel de parler de la convergence des lois au lieu de la convergence des variables aléatoires, mais cette dernière terminologie est bien établie.

De la définition de la convergence en loi découlent des convergences de probabilités plus générales : si X_n converge en loi vers X quand $n \rightarrow \infty$ et si I est un intervalle tel que $\inf I$ et $\sup I$ ne sont pas des atomes de X , alors

$$\mathbb{P}(X_n \in I) \rightarrow \mathbb{P}(X \in I), \quad n \rightarrow \infty.$$

Exemple 2.1. Soit X_n la v.a. constante égale à $1/n$ (donc $X_n \sim \delta_{1/n}$). Vérifions que $X_n \rightarrow 0$ quand $n \rightarrow \infty$. La fonction de répartition de la loi δ_0 est $F_0 = \mathbb{1}_{[0, \infty[}$. Elle est discontinue en 0 (un atome de la loi δ_0) et continue ailleurs. Pour $x < 0$, on a

$$F_{X_n}(x) = \mathbb{K}_{[1/n, \infty[}(x) = 0 = F_0(x), \quad \text{pour tout } n,$$

et pour $x > 0$,

$$F_{X_n}(x) = \mathbb{K}_{[1/n, \infty[}(x) = 1 = F_0(x) \quad \text{pour tout } n \text{ tel que } 1/n < x.$$

Par conséquent, $F_{X_n}(x) \rightarrow F_0(x)$ pour tout $x \in \mathbb{R}^*$, et donc $X_n \xrightarrow{\text{loi}} 0$. Notons que $F_{X_n}(0) = 0$ pour tout n , alors que $F_0(0) = 1$, donc $F_{X_n}(0) \nrightarrow F_0(0)$.

Exemple 2.2. Soit $\lambda > 0$, $X_n \sim \mathcal{G}_{\mathbb{N}^*}(\lambda/n)$, et $X \sim \mathcal{E}(\lambda)$. Alors, pour $t \geq 0$ réel,

$$\mathbb{P}(X_n \leq t) = 1 - (1 - \lambda/n)^{\lfloor t \rfloor},$$

et partant,

$$\mathbb{P}(X_n/n \leq t) = 1 - (1 - \lambda/n)^{\lfloor tn \rfloor}.$$

Les bornes $tn - 1 \leq \lfloor tn \rfloor \leq tn$ permettent alors de conclure que :

$$\mathbb{P}\left(\frac{X_n}{n} \leq t\right) \rightarrow 1 - e^{-\lambda t}$$

et la convergence vaut encore pour $t \leq 0$ avec limite 0; au final, on a donc convergence en tout point t , et donc $X_n/n \xrightarrow{\text{loi}} X$.

Lemme 2.1. Si les v.a. $(X_n)_{n \geq 1}$ et X sont à valeurs dans $\mathbb{N}$, on a l'équivalence

$$X_n \xrightarrow{\text{loi}} X \iff \mathbb{P}(X_n = k) \rightarrow \mathbb{P}(X = k) \quad \forall k \in \mathbb{N},$$

Démonstration. Il suffit de noter que $F_{X_n}(x) = \sum_{k=0}^{\lfloor x \rfloor} \mathbb{P}(X_n = k)$ pour tout x . $\square$

L'exemple suivant est fondamental.

Exemple 2.3. Soit $p_n \in [0, 1]$ une suite telle que $np_n \rightarrow \lambda \geq 0$, $X_n \sim \mathcal{B}(n, p_n)$, et $X \sim \mathcal{P}(\lambda)$. Alors

$$\begin{aligned} \mathbb{P}(X_n = k) &= \binom{n}{k} (p_n)^k (1 - p_n)^{n-k} \\ &= \frac{n(n-1) \dots (n-k+1)}{k!} (p_n)^k (1 - p_n)^{n-k} \\ &= \frac{n(n-1) \dots (n-k+1)}{n^k} \cdot \frac{1}{k!} \cdot (np_n)^k \cdot e^{(n-k) \ln(1-p_n)} \\ &\rightarrow 1 \cdot \frac{1}{k!} \cdot \lambda^k \cdot e^{-k} = \mathbb{P}(X = k) \end{aligned}$$

Ainsi

$$\mathcal{B}(n, p_n) \rightarrow \mathcal{P}(\lambda), \quad \text{si } p_n \rightarrow 0 \text{ et } np_n \rightarrow \lambda.$$

D'un point de vue théorique il est bon de noter la caractérisation suivante de la convergence en loi :

Proposition 2.1. X_n converge en loi vers X si et seulement s'il existe un sous-ensemble dense $D \subset \mathbb{R}$ tel que pour tout $x \in D$

$$F_{X_n}(x) \rightarrow F_X(x), \quad n \rightarrow \infty.$$

Démonstration. Pour le sens direct, il suffit de noter que l'ensemble S_X des atomes de X étant au plus dénombrable, son complémentaire (sur lequel on a convergence de F_{X_n} vers F) est dense dans $\mathbb{R}$ (pour voir ceci noter qu'un ensemble de mesure de Lebesgue non nulle est non vide). Pour le sens réciproque il faut travailler un peu plus : on se donne $D \subset \mathbb{R}$ sous-ensemble dense sur lequel (??) a lieu et $x \in \mathbb{R} \setminus S_X$. Soit $\varepsilon > 0$, par densité de D , il existe $y, z \in D$ tels que $x - \varepsilon < y < x < z < x + \varepsilon$ et l'inégalité $F_{X_n}(y) \leq F_{X_n}(x) \leq F_{X_n}(z)$ donne alors, en prenant la limite en n :

$$F_X(y) \leq \liminf F_{X_n}(x) \leq \limsup F_{X_n}(x) \leq F_X(z)$$

En prenant maintenant la limite en $\varepsilon \rightarrow 0$ et en utilisant que $x \in \mathbb{R} \setminus S_X$, on a :

$$\begin{aligned}
 0 &\leq F_X(z) - F_X(y) \\
 &\leq F_X(x + \varepsilon) - F_X(x - \varepsilon) \\
 &= F_X(x) - F_X(x-) \rightarrow 0 \quad \text{quand } \varepsilon \rightarrow 0
 \end{aligned}$$

de sorte que $\liminf F_{X_n}(x) = \limsup F_{X_n}(x)$ pour $x \in \mathbb{R} \setminus S_X$ et on conclut bien que $\lim_n F_{X_n}(x) = F_X(x)$. $\square$

Une seconde caractérisation très utile est la suivante (elle se généralise mieux à des espaces d'état plus généraux, et fait pour cette raison souvent office de définition dans les cours plus avancés).

Proposition 2.2. X_n converge en loi vers X si et seulement si pour toute fonction continue bornée $\phi : \mathbb{R} \rightarrow \mathbb{R}$:

$$\mathbb{E}[\phi(X_n)] \rightarrow \mathbb{E}[\phi(X)]$$

Démonstration. Pour l'implication on se contente de prouver la propriété pour une fonction ϕ continue positive strictement croissante. La fonction ϕ induit une bijection de $\mathbb{R}$ sur un intervalle I de $\mathbb{R}_+$, et $\{\phi(X_n) > x\} = \{X_n > \phi^{-1}(x)\}$. Si S_X est au plus dénombrable c'est encore le cas de $\phi^{-1}(S_X)$, et donc pour tout x en dehors de cet ensemble, $\mathbb{P}(\phi(X_n) > x) = \mathbb{P}(X_n > \phi^{-1}(x)) \rightarrow \mathbb{P}(X > \phi^{-1}(x)) = \mathbb{P}(\phi(X) > x)$, on déduit du théorème de convergence dominée que : $\mathbb{E}[\phi(X_n)] = \int \mathbb{P}(\phi(X_n) > x) dx \rightarrow \int \mathbb{P}(\phi(X) > x) dx = \mathbb{E}[\phi(X)]$.

On considère maintenant la réciproque. Soit $y \in \mathbb{R}$. On introduit les deux fonctions $\phi_{\varepsilon,-}(x) = 1 \wedge (-\frac{1}{\varepsilon}(x - y)) \vee 0$ et $\phi_{\varepsilon,+}(x) = 1 \wedge (-\frac{1}{\varepsilon}(x - y - \varepsilon)) \vee 0$, et on note :

$$\mathbb{E}[\phi_{\varepsilon,-}(X_n)] \leq \mathbb{P}(X_n \leq y) \leq \mathbb{E}[\phi_{\varepsilon,+}(X_n)]$$

Puisque $\phi_{\varepsilon,-}$ et $\phi_{\varepsilon,+}$ sont continues et bornées, il suit de l'hypothèse que :

$$\mathbb{E}[\phi_{\varepsilon,-}(X)] \leq \liminf \mathbb{P}(X_n \leq y) \leq \limsup \mathbb{P}(X_n \leq y) \leq \mathbb{E}[\phi_{\varepsilon,+}(X)].$$

Des inégalités $\mathbb{1}_{x \leq y-\varepsilon} \leq \phi_{\varepsilon,-} \leq \phi_{\varepsilon,+} \leq \mathbb{1}_{x \leq y+\varepsilon}$, on déduit alors :

$$\mathbb{P}(X \leq y - \varepsilon) \leq \liminf \mathbb{P}(X_n \leq y) \leq \limsup \mathbb{P}(X_n \leq y) \leq \mathbb{P}(X \leq y + \varepsilon),$$

ce qui implique :

$$\mathbb{P}(X < y) \leq \liminf \mathbb{P}(X_n \leq y) \leq \limsup \mathbb{P}(X_n \leq y) \leq \mathbb{P}(X \leq y).$$

Si maintenant y n'est pas un atome de X , les deux membres extrêmes de l'inégalité coïncident et on conclut bien que : $\lim_{n \rightarrow \infty} \mathbb{P}(X_n \leq y) = \mathbb{P}(X \leq y)$. $\square$

CONVERGENCE EN PROBABILITÉ

Définition 2.2. On dit que la suite $X_1, X_2, \dots$ converge en probabilité s'il existe une variable aléatoire X telle que

$$\forall \varepsilon > 0 : \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0, \quad n \rightarrow \infty.$$

On dit alors que X_n converge en probabilité vers X quand $n \rightarrow \infty$ et on note $X_n \xrightarrow{\mathbb{P}} X$.

Exemple 2.4. Soit X une v.a. et $X_n = \min(X, n)$. Alors pour tout $\varepsilon > 0$,

$$\begin{aligned} \mathbb{P}(|X_n - X| > \varepsilon) &\leq \mathbb{P}(X_n \neq X) \\ &= \mathbb{P}(X > n) \rightarrow 0, \quad n \rightarrow \infty. \end{aligned}$$

Par conséquent, $X_n \xrightarrow{\mathbb{P}} X, \quad n \rightarrow \infty$.

Proposition 2.3. 1. La convergence en probabilité entraîne la convergence en loi.

2. On a équivalence entre

$$X_n \xrightarrow{\mathbb{P}} X \iff |X_n - X| \xrightarrow{\text{loi}} 0 \iff X_n - X \xrightarrow{\text{loi}} 0.$$

3. Si la limite est une constante, les deux notions de convergence sont équivalentes. Autrement dit, si $c \in \mathbb{R}$, alors

$$X_n \xrightarrow{loi} c \iff X_n \xrightarrow{\mathbb{P}} c.$$

Démonstration. 1. Soit $x \in \mathbb{R}$ tel que F_X est continue en x . Soit $\varepsilon > 0$. Alors,

$$\begin{aligned} F_{X_n}(x) &= \mathbb{P}(X_n \leq x) \\ &= \mathbb{P}(X_n \leq x, |X - X_n| \leq \varepsilon) + \mathbb{P}(X_n \leq x, |X_n - X| > \varepsilon) \\ &\leq \mathbb{P}(X \leq x + \varepsilon, |X - X_n| \leq \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) \\ &\leq F_X(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon). \end{aligned}$$

Puisque $X_n \xrightarrow{\mathbb{P}} X$, le second terme tend vers 0, si bien que

$$\limsup_{n \rightarrow \infty} F_{X_n}(x) \leq F_X(x + \varepsilon).$$

Par ailleurs,

$$\begin{aligned} \mathbb{P}(X \leq x - \varepsilon) &\leq \mathbb{P}(X \leq x - \varepsilon, |X - X_n| \leq \varepsilon) + \mathbb{P}(X \leq x - \varepsilon, |X - X_n| > \varepsilon) \\ &\leq \mathbb{P}(X_n \leq x) + \mathbb{P}(|X - X_n| > \varepsilon) \end{aligned}$$

Donc :

$$\begin{aligned} F_{X_n}(x) &= \mathbb{P}(X_n \leq x) \\ &\geq \mathbb{P}(X \leq x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \\ &= F_X(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon). \end{aligned}$$

Puis

$$\liminf_{n \rightarrow \infty} F_{X_n}(x) \geq F_X(x - \varepsilon).$$

Laissant $\varepsilon \rightarrow 0$, puisque F_X est continue en x , on obtient :

$$F_{X_n}(x) \rightarrow F_X(x), \quad n \rightarrow \infty.$$

2. Montrons la première équivalence : puisque $F_{|X_n - X|}(x) = 0$ pour tout $x < 0$, on a

$$\begin{aligned} |X_n - X| \xrightarrow{\text{loi}} 0 &\iff \forall x > 0 : F_{|X_n - X|}(x) \rightarrow 1 \\ &\iff \forall x > 0 : \mathbb{P}(|X_n - X| > x) \rightarrow 0 \\ &\iff X_n \xrightarrow{\mathbb{P}} X. \end{aligned}$$

Pour la deuxième équivalence, on a

$$\begin{aligned} X_n - X \xrightarrow{\text{loi}} 0 &\iff \forall x > 0 : F_{X_n - X}(x) \rightarrow 1 \text{ et } F_{X_n - X}(-x) \rightarrow 0 \\ &\iff \forall x > 0 : \mathbb{P}(X_n - X \leq x) \rightarrow 1 \text{ et } \mathbb{P}(X_n - X \leq -x) \rightarrow 0 \\ &\iff \forall x > 0 : \mathbb{P}(X_n - X > x) \rightarrow 0 \text{ et } \mathbb{P}(X_n - X < -x) \rightarrow 0 \\ &\iff \forall x > 0 : \mathbb{P}(X_n - X > x) + \mathbb{P}(X_n - X < -x) \rightarrow 0 \\ &\iff \forall x > 0 : \mathbb{P}(|X_n - X| > x) \rightarrow 0 \\ &\iff X_n \xrightarrow{\mathbb{P}} X. \end{aligned}$$

3. Il suffit de montrer que la convergence en loi entraîne la convergence en probabilité si la limite est une constante. Si $X_n \xrightarrow{\text{loi}} c$, alors pour tout $\varepsilon > 0$,

$$\begin{aligned} \mathbb{P}(|X_n - c| > \varepsilon) &= \mathbb{P}(X_n < c - \varepsilon) + \mathbb{P}(X_n > c + \varepsilon) \\ &\leq F_{X_n}(c - \varepsilon) + (1 - F_{X_n}(c + \varepsilon)) \rightarrow 0, \end{aligned}$$

car les deux termes tendent vers 0.

□

Si $(x_n)_{n \geq 1}$ est une suite de nombres qui converge vers $x \in \mathbb{R}$ et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction, alors $g(x_n) \rightarrow g(x)$ si g est continue en x . Pour les v.a., il existe un résultat analogue :

Théorème 2.1 (Lemme de l'application continue). *Supposons que X est à valeurs dans un ensemble $E \subset \mathbb{R}$. Soit $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction qu'on suppose continue en tout point $x \in E$. Alors*

$$1. \quad X_n \xrightarrow{\mathbb{P}} X \text{ implique } g(X_n) \xrightarrow{\mathbb{P}} g(X).$$

$$2. X_n \xrightarrow{\text{loi}} X \text{ implique } g(X_n) \xrightarrow{\text{loi}} g(X).$$

Démonstration. 1. On suppose $X_n \xrightarrow{\mathbb{P}} X$. Pour simplifier, on suppose que les v.a. $(X_n)_{n \geq 1}$ et X sont à valeurs dans un compact K et que g est continue sur K (il s'avère qu'on peut toujours se ramener à ce cas). Alors g est uniformément continue, c'est-à-dire, pour tout $\varepsilon > 0$, il existe $\delta > 0$ tel que pour tout $x, y \in K$, $|g(x) - g(y)| > \varepsilon$ implique $|x - y| \geq \delta$. Par conséquent,

$$\mathbb{P}(|g(X_n) - g(X)| > \varepsilon) \leq \mathbb{P}(|X_n - X| > \delta) \rightarrow 0, \quad n \rightarrow \infty,$$

$$\text{si bien que } g(X_n) \xrightarrow{\mathbb{P}} g(X), \quad n \rightarrow \infty.$$

2. Si ϕ est continue bornée, g étant continue, la composée $\phi \circ g$ est encore continue bornée et il suit que $\mathbb{E}[\phi \circ g(X_n)] \rightarrow \mathbb{E}[\phi \circ g(X)]$, ce qui prouve la convergence en loi.

□

Exemple 2.5. Comme ci-dessus, soit $p \in]0, 1[$ et pour tout $n \in \mathbb{N}^*$, soit $X_n \sim \mathcal{B}(n, p)$, et soit $X \sim \mathcal{N}(0, 1)$. Posons $\tilde{X}_n = (Y_n - np) / \sqrt{p(1-p)n}$ (note : j'ai supposé que c'est $Y_n \sim \text{Bin}(n, p)$ ou bien X_n redéfini)*. On définit

$$g(x) = \begin{cases} 1/x, & \text{si } x \neq 0 \\ 0, & \text{si } x = 0. \end{cases}$$

Alors g est continue sur $\mathbb{R}^*$ et X est à valeurs dans $\mathbb{R}^*$, car $\mathbb{P}(X = 0) = 0$. Par le lemme de l'application continue,

$$g(\tilde{X}_n) \xrightarrow{\text{loi}} g(X), \quad n \rightarrow \infty,$$

ce qu'on peut écrire avec un très léger abus de notation,

$$1/\tilde{X}_n \xrightarrow{\text{loi}} 1/X, \quad n \rightarrow \infty.$$

CONVERGENCE DANS L^p

Définition 2.3. Soit $p > 0$. On dit que la suite $X_1, X_2, \dots$ converge dans L^p s'il existe une variable aléatoire X avec $\mathbb{E}[|X|^p] < \infty$ et telle que

$$\mathbb{E}[|X_n - X|^p] \rightarrow 0, \quad n \rightarrow \infty.$$

et on note alors $X_n \xrightarrow{L^p} X$. Le cas où $p = 2$ est le plus courant et on dit alors que X_n converge en moyenne quadratique vers X .

Proposition 2.4. Soit $0 < q < p$. Si $X_n \xrightarrow{L^p} X$ alors $X_n \xrightarrow{L^q} X$.

Démonstration. Cela découle de l'inégalité de Jensen. Supposons la convergence L^p . Puisque $p/q > 1$, la fonction $x \geq 0 \mapsto x^{p/q}$ est convexe et il suit que

$$(\mathbb{E}[|X_n - X|^q])^{p/q} \leq \mathbb{E}[|X_n - X|^p] \rightarrow 0.$$

□

Proposition 2.5. Soit $p > 0$. La convergence dans L^p implique la convergence en probabilité.

Démonstration. Supposons que $X_n \xrightarrow{L^p} X$. On note que $\{|X_n - X| > \varepsilon\} = \{|X_n - X|^p > \varepsilon^p\}$ puis, d'où on déduit par l'inégalité de Markov que, pour tout $\varepsilon > 0$,

$$\begin{aligned} \mathbb{P}(|X_n - X| > \varepsilon) &= \mathbb{P}(|X_n - X|^p > \varepsilon^p) \\ &\leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p} \rightarrow 0. \end{aligned}$$

□

CONVERGENCE PRESQUE SÛRE

Définition 2.4. On dit que la suite $X_1, X_2, \dots$ converge presque sûrement s'il existe une variable aléatoire X telle que

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

On dit alors que X_n converge presque sûrement vers X quand $n \rightarrow \infty$ et on

note $X_n \xrightarrow{\text{p.s.}} X$.

Nous n'allons pas utiliser cette notion de convergence par la suite. On peut montrer que la convergence presque sûre implique la convergence en probabilité (mais pas nécessairement la convergence dans L^p).

2.2 CONVERGENCE DE COUPLES ALÉATOIRES

On introduit dans cette section les notions de convergence en loi et en probabilité de couples aléatoires. Elles se généralisent de manière évidente à des vecteurs aléatoires, mais nous nous restreignons aux couples pour rendre la notation plus simple.

Soit $(X_n, Y_n)_{n \geq 1}$ une suite de couples aléatoires et (X, Y) un autre couple aléatoire.

Définition 2.5 (Convergence en loi). On dit que (X_n, Y_n) converge en loi vers (X, Y) et on écrit $(X_n, Y_n) \xrightarrow{\text{loi}} (X, Y)$ si pour tout $x, y \in \mathbb{R}$ tels que $F_{X,Y}$ est continue en (x, y) ,

$$F_{X_n, Y_n}(x, y) \rightarrow F_{X, Y}(x, y), \quad n \rightarrow \infty.$$

On utilisera souvent le résultat suivant (qui est valable aussi dans le cas unidimensionnel) :

Lemme 2.2. $(X_n, Y_n) \xrightarrow{\text{loi}} (X, Y)$ si et seulement s'il existe un ensemble dense $E \subset \mathbb{R}^2$ tel que pour tout $(x, y) \in E$,

$$F_{X_n, Y_n}(x, y) \rightarrow F_{X, Y}(x, y), \quad n \rightarrow \infty.$$

Démonstration. Exercice, utilise la croissance des fonctions de répartition. □

La définition qui se généralise le mieux est en fait celle qui utilise les fonctions continues bornées :

Proposition 2.6. (X_n, Y_n) converge en loi vers (X, Y) si et seulement si pour toute fonction continue bornée $\phi : \mathbb{R}^2 \rightarrow \mathbb{R}$:

$$\mathbb{E}[\phi(X_n, Y_n)] \rightarrow \mathbb{E}[\phi(X, Y)]$$

Définition 2.6 (Convergence en probabilité). On dit que (X_n, Y_n) converge en probabilité vers (X, Y) et on écrit $(X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y)$ si pour tout $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| + |Y_n - Y| > \varepsilon) \rightarrow 0, \quad n \rightarrow \infty.$$

Remarque 2.2. On peut remplacer la norme $|X_n - X| + |Y_n - Y|$ par n'importe quelle autre norme, par exemple la norme euclidienne.

Proposition 2.7. 1. La convergence en probabilité entraîne la convergence en loi.

2. On a équivalence entre

$$\begin{aligned} (X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y) &\iff (X_n - X, Y_n - Y) \xrightarrow{\text{loi}} (0, 0) \\ &\iff |X_n - X| + |Y_n - Y| \xrightarrow{\text{loi}} 0. \end{aligned}$$

3. Si la limite est une constante, les deux notions de convergence sont équivalentes. Autrement dit, si $c, c' \in \mathbb{R}$, alors

$$(X_n, Y_n) \xrightarrow{\text{loi}} (c, c') \iff (X_n, Y_n) \xrightarrow{\mathbb{P}} (c, c').$$

Démonstration. Preuves similaires au cas univarié. □

Théorème 2.2 (Lemme de l'application continue; version couple). Supposons que le couple (X, Y) est à valeurs dans un ensemble $E \subset \mathbb{R}^2$. Soit $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ ou $g : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ une fonction qu'on suppose continue en tout point $x \in E$. Alors

1. $(X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y)$ implique $g(X_n, Y_n) \xrightarrow{\mathbb{P}} g(X, Y)$.
2. $(X_n, Y_n) \xrightarrow{\text{loi}} (X, Y)$ implique $g(X_n, Y_n) \xrightarrow{\text{loi}} g(X, Y)$.

Démonstration. La première partie se démontre comme dans le cas univarié. Pour la seconde, on admet qu'on peut encore se ramener à une convergence en probabilité. La preuve est alors similaire. $\square$

- Lemme 2.3.**
1. $(X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y)$ si et seulement si $X_n \xrightarrow{\mathbb{P}} X$ et $Y_n \xrightarrow{\mathbb{P}} Y$.
 2. Si $(X_n, Y_n) \xrightarrow{\text{loi}} (X, Y)$, alors $X_n \xrightarrow{\text{loi}} X$ et $Y_n \xrightarrow{\text{loi}} Y$ (la réciproque est fausse en général).
 3. Si $X_n \xrightarrow{\text{loi}} X$ et $Y_n \xrightarrow{\text{loi}} c$, où $c \in \mathbb{R}$ est une constante, alors $(X_n, Y_n) \xrightarrow{\text{loi}} (X, c)$.
 4. Si $X_n \xrightarrow{\text{loi}} X$ et $Y_n \xrightarrow{\text{loi}} Y$ et si X_n et Y_n sont indépendantes pour tout $n \in \mathbb{N}$, alors $(X_n, Y_n) \xrightarrow{\text{loi}} (X, Y)$, où X et Y sont indépendantes.

Démonstration. 1. Si $(X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y)$, alors le lemme de l'application continue appliqué aux fonctions $(x, y) \mapsto x$ et $(x, y) \mapsto y$ donne $X_n \xrightarrow{\mathbb{P}} X$ et $Y_n \xrightarrow{\mathbb{P}} Y$. Pour la réciproque, soit $\varepsilon > 0$. Puisque $|X_n - X| + |Y_n - Y| > \varepsilon$ implique $|X_n - X| > \varepsilon/2$ ou $|Y_n - Y| > \varepsilon/2$,

$$\mathbb{P}(|X_n - X| + |Y_n - Y| > \varepsilon) \leq \mathbb{P}(|X_n - X| > \varepsilon/2) + \mathbb{P}(|Y_n - Y| > \varepsilon/2).$$

Par conséquent, quand $n \rightarrow \infty$, $\mathbb{P}(|X_n - X| + |Y_n - Y| > \varepsilon) \rightarrow 0$ pour tout $\varepsilon > 0$ si et seulement si $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$ et $\mathbb{P}(|Y_n - Y| > \varepsilon) \rightarrow 0$ pour tout $\varepsilon > 0$.

2. Encore lemme de l'application continue comme ci-dessus.
3. La fonction de répartition de (X, c) s'écrit

$$F_{X,c}(x, y) = F_X(x) \mathbb{1}_{y \geq c}.$$

Soit $A \subset \mathbb{R}$ un ensemble dense de points $x \in \mathbb{R}$ tels que $F_{X_n}(x) \rightarrow F_X(x)$. Alors pour tout $y < c$,

$$F_{X_n, Y_n}(x, y) \leq F_{Y_n}(y) \rightarrow 0,$$

et pour tout $y > c$,

$$F_{X_n, Y_n}(x, y) \geq F_{X_n}(x) - \mathbb{P}(Y_n > y) \rightarrow F_X(x),$$

donc

$$F_{X_n, Y_n}(x, y) \rightarrow F_{X, c}(x, y) \quad \forall (x, y) \in A \times (\mathbb{R} \setminus \{c\}).$$

L'ensemble $A \times (\mathbb{R} \setminus \{c\})$ est dense dans $\mathbb{R}^2$, ce qui permet de conclure que $(X_n, Y_n) \xrightarrow{\text{loi}} (X, c)$.

4. Par indépendance, $F_{X, Y}(x, y) = F_X(x)F_Y(y)$ pour tout $(x, y) \in \mathbb{R}^2$. Par conséquent, pour tout $x, y \in \mathbb{R}$ points de continuité respectifs de F_X et F_Y ,

$$F_{X_n, Y_n}(x, y) = F_{X_n}(x)F_{Y_n}(y) \rightarrow F_X(x)F_Y(y) = F_{X, Y}(x, y).$$

Cet ensemble de points (x, y) étant dense dans $\mathbb{R}^2$, on conclut que $(X_n, Y_n) \xrightarrow{\text{loi}} (X, c)$.

□

Corollaire 2.1 (Lemme de Slutsky). *Supposons que $X_n \xrightarrow{\text{loi}} X$ et $Y_n \xrightarrow{\text{loi}} c$, où $c \in \mathbb{R}$ est une constante. Alors*

- $X_n + Y_n \xrightarrow{\text{loi}} X + c$
- $X_n Y_n \xrightarrow{\text{loi}} cX$
- Si $c \neq 0$, $X_n / Y_n \xrightarrow{\text{loi}} X / c$.

2.3 LOI DES GRANDS NOMBRES

Théorème 2.3 (Loi des grands nombres). *Soient $X_1, X_2, \dots$ i.i.d. avec $\mathbb{E}[|X_1|] < \infty$. Alors*

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{\mathbb{P}} \mathbb{E}[X_1].$$

Remarque 2.3. — Comme expliqué lors de l'introduction de l'espérance, la loi des grands nombres justifie l'interprétation de celle-ci comme "moyenne" de la v.a. : la moyenne empirique de n réalisations de cette v.a. approche son espérance quand n est grand.

- Dans l'énoncé de la loi des grands nombres, on peut en fait remplacer la convergence en probabilité par de la convergence presque sûre. C'est ce qu'on appelle aussi la loi forte des grands nombres.

Démonstration. Nous commençons par fournir une preuve très simple sous l'hypothèse $\mathbb{E}[X_1^2] < \infty$. On montre alors la convergence en moyenne quadratique qui on le rappelle implique la convergence en probabilité. Le cas général où on a seulement $\mathbb{E}[|X_1|] < \infty$ est plus évolué. Remarquons d'abord que $\mathbb{E}[(X_1 + \dots + X_n)/n] = n\mathbb{E}[X_1]/n = \mathbb{E}[X_1]$, par linéarité de l'espérance. Par conséquent,

$$\begin{aligned} \mathbb{E} \left[\left(\frac{X_1 + \dots + X_n}{n} - \mathbb{E}[X_1] \right)^2 \right] &= \mathbb{V} \left(\frac{X_1 + \dots + X_n}{n} \right) \\ &= \frac{1}{n^2} (\mathbb{V}(X_1) + \dots + \mathbb{V}(X_n)) \quad \text{par indépendance} \\ &= \frac{\mathbb{V}(X_1)}{n} \rightarrow 0, \quad n \rightarrow \infty. \end{aligned}$$

Nous présentons maintenant l'extension au cas intégrable, c'est-à-dire qu'on suppose seulement $\mathbb{E}[|X_1|] < \infty$ (1). Posons $S_n = X_1 + \dots + X_n$. Quitte à considérer $X_1 - \mathbb{E}[X_1]$ on peut supposer que les $(X_i)_{1 \leq i \leq n}$ sont des variables aléatoires centrées, ce qu'on fera désormais $\mathbb{E}[X_1] = 0$. Maintenant, pour N entier, on pose :

$$X_i^N = X_i \mathbb{1}_{|X_i| \leq N} \quad \text{et} \quad S_n^N = \sum_{1 \leq i \leq n} X_i^N,$$

c'est-à-dire qu'on considère les variables tronquées ainsi que leur somme. On se fixe $\varepsilon > 0$. Il nous suffit de montrer que pour tout n suffisamment grand, $\mathbb{P}(|S_n| > \varepsilon n) \leq \varepsilon$. Pour ce faire, on note que par convergence dominée : $\mathbb{E}[X_1^N] \rightarrow \mathbb{E}[X_1] = 0$ et $\mathbb{E}[|X_1 - X_1^N|] \rightarrow 0$, et donc on peut choisir N suffisamment grand tel que

$$|\mathbb{E}[X_1^N]| \leq \varepsilon/4 \quad \text{et} \quad \mathbb{E}[|X_1 - X_1^N|] = \mathbb{E}[|X_1| \mathbb{1}_{|X_1| > N}] \leq \varepsilon^2/4.$$

Puisque les variables bornées sont de carré intégrable, la première partie de la preuve implique : $\mathbb{P}(|S_n^N - n\mathbb{E}[X_1^N]| > \varepsilon n/4) \rightarrow 0$, et donc il existe un rang n_0 à partir duquel on a $\mathbb{P}(|S_n^N - n\mathbb{E}[X_1^N]| > \varepsilon n/4) \leq \varepsilon/2$. Notons également que $S_n - S_n^N = \sum_{1 \leq i \leq n} X_i \mathbb{1}_{|X_i| > N}$ donc

$$\begin{aligned}
 \mathbb{P}(|S_n - S_n^N| > \varepsilon n/2) &\leq \frac{2\mathbb{E}[|S_n - S_n^N|]}{\varepsilon n} \\
 &\leq \frac{2n\mathbb{E}[|X_1 - X_1^N|]}{\varepsilon n} \\
 &\leq \frac{\varepsilon}{2}
 \end{aligned}$$

grâce à la majoration précédente de $\mathbb{E}[|X_1| \mathbb{1}_{|X_1| > N}]$. Finalement pour $n \geq n_0$:

$$\begin{aligned}
 \mathbb{P}(|S_n| > \varepsilon n) &= \mathbb{P}(|S_n^N| > \varepsilon n/2) + \mathbb{P}(|S_n - S_n^N| > \varepsilon n/2) \\
 &\leq \mathbb{P}(|S_n^N - n\mathbb{E}[X_1^N]| > \varepsilon n/4) + \mathbb{P}(|S_n - S_n^N| > \varepsilon n/2) \\
 &\leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} \\
 &\leq \varepsilon.
 \end{aligned}$$

□

2.4 THÉORÈME CENTRAL LIMITE

La loi des grands nombres nous dit que si $X_1, \dots, X_n$ sont i.i.d. d'espérance finie, alors $X_1 + \dots + X_n \approx n \times \mathbb{E}[X_1]$. Il est naturel de se demander quelles sont les fluctuations autour de cette moyenne, c'est-à-dire, quelle est l'ordre de grandeur et la loi de $X_1 + \dots + X_n - n \times \mathbb{E}[X_1]$?

Les réponses diffèrent selon que $\sigma^2 = \mathbb{V}(X_1)$ est finie ou non, et on suppose dorénavant que $\sigma^2 < \infty$. Alors $\mathbb{V}(X_1 + \dots + X_n) = n\sigma^2$, ce qui laisse penser que $X_1 + \dots + X_n - n \times \mathbb{E}[X_1]$ est d'ordre $\sigma\sqrt{n}$. Le théorème central limite donne une réponse positive et très précise à cette question.

Théorème 2.4 (Théorème central limite). *Soient $X_1, X_2, \dots$ i.i.d. de variance $\sigma^2 = \mathbb{V}(X_1) < \infty$. Alors*

$$\frac{X_1 + \dots + X_n - n\mathbb{E}[X_1]}{\sigma\sqrt{n}} \xrightarrow{\text{loi}} \mathcal{N}(0, 1).$$

Les propriétés de stabilité de la loi normale/gaussienne montrent qu'on n'avait guère le choix pour la loi limite, comme le justifie l'exercice suivant :

Exercice 2.1. *On suppose dans cet exercice connaître l'énoncé du théorème central limite, à l'exception de la forme de la loi limite : précisément, on sait qu'on a convergence, mais on ne sait pas vers quelle loi limite.*

1. Si l'on choisit $X_1, X_2, \dots$ v.a.r. i.i.d. selon la loi normale, quelle loi suit $\frac{X_1 + \dots + X_n - n\mathbb{E}[X_1]}{\sigma\sqrt{n}}$?
2. En déduire la loi limite.

Nous allons démontrer ce théorème à l'aide des fonctions génératrices des moments. Nous aurons besoin du lemme suivant que nous admettons.

Lemme 2.4. Soit $(X_n)_{n \geq 1}$ une suite de v.a. et X une v.a. telle que ϕ_X est finie dans un voisinage de 0. Supposons que $\phi_{X_n}(t) \rightarrow \phi_X(t)$ pour tout $t \in \mathbb{R}$. Alors $X_n \xrightarrow{\text{loi}} X$.

Démonstration du théorème central limite. On peut supposer que $\mathbb{E}[X_1] = 0$ et $\sigma^2 = 1$, quitte à remplacer X_i par sa variable centrée réduite. On suppose de plus que la fonction génératrice des moments $\phi(t) = \mathbb{E}[e^{tX_1}]$ est finie dans un voisinage de 0 (dans le cas général il faudrait passer par la fonction caractéristique $t \mapsto \mathbb{E}[e^{itX}]$ que nous n'avons pas introduite). On rappelle que

$$\phi(0) = 1, \quad \phi'(0) = \mathbb{E}[X_1] = 0, \quad \phi''(0) = \mathbb{E}[X_1^2] = \text{Var}(X_1) = 1.$$

Par conséquent, le développement en 0 de ϕ est

$$\phi(t) = 1 + \frac{1}{2}t^2 + o(t^2) = e^{\frac{1}{2}t^2 + o(t^2)}.$$

Par indépendance, on a pour t fixé et $n \rightarrow \infty$,

$$\begin{aligned} \phi_{\frac{X_1 + \dots + X_n}{\sqrt{n}}}(t) &= \phi\left(\frac{t}{\sqrt{n}}\right)^n \\ &= e^{n\left(\frac{1}{2}\frac{t^2}{n} + o(1/n)\right)} \rightarrow e^{\frac{t^2}{2}}. \end{aligned}$$

On reconnaît la fonction génératrice des moments de la loi $\mathcal{N}(0, 1)$. Le lemme précédent montre alors que

$$\frac{X_1 + \dots + X_n}{\sqrt{n}} \xrightarrow{\text{loi}} \mathcal{N}(0, 1).$$

□

Un corollaire immédiat est le théorème d'approximation suivant :

Corollaire 2.2 (Approximation normale de la loi Binomiale; de Moivre, Laplace).
 Soit $p \in]0, 1[$. Pour tout $n \in \mathbb{N}$, soit X_n une variable aléatoire de loi binomiale de paramètres n et p . Alors, pour tout $-\infty \leq a < b \leq +\infty$,

$$\mathbb{P}\left(np + a \times \sqrt{p(1-p)n} \leq X_n \leq np + b \times \sqrt{p(1-p)n}\right) \rightarrow \Phi(b) - \Phi(a),$$

Quand $n \rightarrow \infty$.

Démonstration. On note que

$$\left\{np + a \times \sqrt{p(1-p)n} \leq X_n \leq np + b \times \sqrt{p(1-p)n}\right\} = \left\{a \leq \frac{X_n - np}{\sqrt{np(1-p)}} \leq b\right\}$$

puis que X_n est distribué comme $\sum_{i=1}^n B_i$, avec $B_1, B_2, \dots, B_n$ i.i.d. selon la loi de $\mathcal{B}(p)$, d'espérance p et de variance $p(1-p)$. La quantité

$$N_n := \frac{\sum_{i=1}^n B_i - n\mathbb{E}[B_1]}{\sqrt{n\mathbb{V}(B_1)}}$$

a donc la même loi que $\frac{X_n - np}{\sqrt{np(1-p)}}$ d'où l'on tire :

$$\begin{aligned} \mathbb{P}\left(np + a \times \sqrt{p(1-p)n} \leq X_n \leq np + b \times \sqrt{p(1-p)n}\right) \\ = \mathbb{P}(a \leq N_n \leq b) \\ = F_{N_n}(b) - F_{N_n}(a-) \end{aligned}$$

Le corollaire découle du théorème central limite en appliquant la définition de la convergence en loi via la fonction de répartition aux points a et b (on rappelle que la fonction de répartition de la gaussienne est continue en tout point). $\square$

Heuristiquement, ce théorème dit que si $X \sim \mathcal{B}(n, p)$, alors quand n est grand et p fixé,

$$X \approx np + \sqrt{p(1-p)n} \times N, \quad \text{avec } N \sim \mathcal{N}(0, 1).$$

Il s'agit d'une relation formelle (mais qui peut aider l'intuition) : elle n'a pas d'autre sens que celle que lui confère le théorème central limite.

Domaine de validité On admettra que la qualité de cette approximation est très bonne dès lors que

$$np(1-p) \geq 10.$$

Noter que ceci implique au passage que $n \geq 40$ (obtenu dans le cas le plus "favorable" $p = 0.5$); bien sûr, des valeurs de p plus petites requièrent des valeurs de n plus grandes encore, par exemple $p = 0.1$ demande $n \geq 112$.

Correction de continuité En pratique on utilise cette approximation à n fixé, et souvent pour de petits intervalles. L'exemple typique est celui où on veut approcher la probabilité que la variable binomiale prenne une valeur donnée k . Mais alors on ne peut pas directement écrire :

$$\mathbb{P}(X = k) \approx \mathbb{P}\left(np + \sqrt{p(1-p)n} \times N = k\right)$$

car le membre de droite vaut 0, puisque N est à densité. Il faut donc choisir à droite un intervalle et non le singleton $\{k\}$: le plus naturel est bien sûr de choisir un intervalle de taille 1 qui contient k ; plusieurs choix sont possibles, mais à nouveau, ce qui semble le plus légitime est de considérer l'intervalle de taille 1 centré en k , c'est-à-dire $[k - 1/2, k + 1/2]$. Cette méthode s'appelle la *correction de continuité* : on l'utilise à chaque fois qu'on approche la loi d'une variable aléatoire discrète (ici, X à valeurs dans $\mathbb{N}$) par la loi d'une variable aléatoire à densité (ici, N ou plutôt sa transformée linéaire $np + \sqrt{p(1-p)n} \times N$); la correction de continuité consiste à écrire, pour $k \in \mathbb{N}$:

$$\mathbb{P}(X = k) \approx \mathbb{P}\left(k - \frac{1}{2} \leq np + \sqrt{p(1-p)n} \times N \leq k + \frac{1}{2}\right)$$

Maintenant, si $J = \{a, \dots, b\}$ avec $a < b$ deux entiers, alors

$$\begin{aligned}
 \mathbb{P}(X \in J) &= \sum_{k \in J} \mathbb{P}(X = k) \\
 &\approx \sum_{k \in J} \mathbb{P}\left(k - \frac{1}{2} \leq np + \sqrt{p(1-p)n} \times N \leq k + \frac{1}{2}\right) \\
 &= \mathbb{P}\left(a - \frac{1}{2} \leq np + \sqrt{p(1-p)n} \times N \leq b + \frac{1}{2}\right) \\
 &= \mathbb{P}\left(np + \sqrt{p(1-p)n} \times N \in \left[a - \frac{1}{2}, b + \frac{1}{2}\right]\right)
 \end{aligned}$$

en particulier, pour $b \in \mathbb{N}$ on obtient :

$$\mathbb{P}(X < b + 1) = \mathbb{P}(X \leq b) \approx \mathbb{P}\left(np + \sqrt{p(1-p)n} \times N \leq b + \frac{1}{2}\right)$$

Pour retenir qu'on doit choisir $b + 1/2$ dans cette approximation, noter qu'il s'agit de la moyenne entre b et $b + 1$ (ce n'est qu'un moyen mnémotechnique). Cette "correction" peut représenter des différences numériques significatives. On notera pour retenir cette dernière formule que $k + 1/2$ est la moyenne entre k et $k + 1$.

VARIABLES ALÉATOIRES DÉPENDANTES

3.1 LOIS MARGINALES

On rappelle que la loi jointe de n variables aléatoires $X_1, \dots, X_n$ détermine la loi de chacune des variables par la formule : $k \in \{1, \dots, n\}$

$$\mathbb{P}(X_k \in A) = \mathbb{P}((X_1, \dots, X_n) \in \mathbb{R}^{k-1} \times A \times \mathbb{R}^{n-k}).$$

Définition 3.1. On appelle les lois des v.a. $X_1, \dots, X_n$ dans ce contexte les *lois marginales* du vecteur aléatoire $(X_1, \dots, X_n)$. On peut obtenir la fonction de répartition de X_k en fonction de la fonction de répartition conjointe par la formule :

$$\begin{aligned} F_{X_k}(x) &= \lim_{x_j \rightarrow +\infty, \forall j \neq k} F_{X_1, \dots, X_n}(x_1, \dots, x_{k-1}, x, x_{k+1}, \dots, x_n) \\ &=: F_{X_1, \dots, X_n}(+\infty, \dots, +\infty, x, +\infty, \dots, +\infty), \quad k \in \{1, \dots, n\}. \end{aligned}$$

Dans le cas où les v.a. sont discrètes ou conjointement à densité, on a les formules suivantes pour les fonctions de masse ou les densités des lois marginales :

Proposition 3.1. — *Supposons que les v.a. $X_1, \dots, X_n$ sont discrètes. Alors pour tout $k \in \{1, \dots, n\}$ la fonction de masse de X_k est donnée par :*

$$\begin{aligned} &\mathbb{P}(X_k = x) \\ &= \sum_{x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n} \mathbb{P}(X_1 = x_1, \dots, X_{k-1} = x_{k-1}, X_k = x, X_{k+1} = x_{k+1}, \dots, X_n = x_n). \end{aligned}$$

— *Supposons que les v.a. $X_1, \dots, X_n$ admettent la densité conjointe $f_{X_1, \dots, X_n}$. Alors pour tout $k \in \{1, \dots, n\}$, la v.a. X_k admet la densité :*

$$\begin{aligned} &f_{X_k}(x) \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_{k-1}, x, x_{k+1}, \dots, x_n) dx_1 \dots dx_{k-1} dx_{k+1} \dots dx_n. \end{aligned}$$

Démonstration. Cas discret : On rappelle que pour tout $A \subset \mathbb{R}^n$,

$$\mathbb{P}((X_1, \dots, X_n) \in A) = \sum_{(x_1, \dots, x_n) \in A} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n).$$

Avec $x \in \mathbb{R}$ et $A = \mathbb{R}^{k-1} \times \{x\} \times \mathbb{R}^{n-k}$, cela donne :

$$\begin{aligned} & \mathbb{P}(X_k = x) \\ &= \sum_{(x_1, \dots, x_n) \in \mathbb{R}^{k-1} \times \{x\} \times \mathbb{R}^{n-k}} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \\ &= \sum_{x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n} \mathbb{P}(X_1 = x_1, \dots, X_{k-1} = x_{k-1}, X_k = x, X_{k+1} = x_{k+1}, \dots, X_n = x_n). \end{aligned}$$

Cas à densité : On rappelle que la fonction de répartition conjointe de $X_1, \dots, X_n$ est donnée par :

$$\begin{aligned} & F_{X_1, \dots, X_n}(x_1, \dots, x_n) \\ &= \int_{-\infty}^{x_n} \cdots \int_{-\infty}^{x_1} f_{X_1, \dots, X_n}(y_1, \dots, y_n) dy_1 \dots dy_n. \end{aligned}$$

En faisant tendre $x_j \rightarrow +\infty$ pour $j \neq k$ et en changeant l'ordre d'intégration, on obtient :

$$= \int_{-\infty}^x \left(\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f_{X_1, \dots, X_n}(y_1, \dots, y_{k-1}, y, y_{k+1}, \dots, y_n) dy_1 \dots dy_{k-1} dy_{k+1} \dots dy_n \right) dy. \quad F_{X_k}(x)$$

Ceci montre que X_k est à densité avec la densité écrite dans l'énoncé. $\square$

Exemple 3.1. On teste des individus d'une population pour l'infection à un virus. Pour un individu pris au hasard, on note $X = 1$ si l'individu est infecté, $X = 0$ sinon ; ainsi que $Y = 1$ si le test est positif, $Y = 0$ sinon. Après un grand nombre de tests, on a pu établir empiriquement la loi jointe de X et Y , dont la fonction de masse est représentée dans le tableau croisé suivant :

	$X = 0$	$X = 1$
$Y = 0$	0.7	0
$Y = 1$	0.2	0.1

On calcule les lois marginales :

$$\mathbb{P}(X = 0) = \mathbb{P}(X = 0, Y = 0) + \mathbb{P}(X = 0, Y = 1) = 0.7 + 0.2 = 0.9$$

$$\mathbb{P}(X = 1) = 1 - \mathbb{P}(X = 0) = 0.1$$

$$\mathbb{P}(Y = 0) = \mathbb{P}(X = 0, Y = 0) + \mathbb{P}(X = 1, Y = 0) = 0.7 + 0 = 0.7$$

$$\mathbb{P}(Y = 1) = 1 - \mathbb{P}(Y = 0) = 0.3.$$

En mots, 10% de la population sont infectés et le test est positif chez 30% de la population.

Exemple 3.2. Soit (X, Y) un couple aléatoire de loi uniforme sur le triangle $T = \{(x, y) \in [0, 1]^2 : x + y \geq 1\}$, i.e. de loi jointe $f_{X,Y} = \frac{\mathbb{1}_T}{\text{aire}(T)} = 2\mathbb{1}_T$. Alors X est de densité :

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy \\ &= \int_{-\infty}^{+\infty} 2\mathbb{1}_{[0,1]}(x)\mathbb{1}_{\{y \in [0,1], x+y \geq 1\}} dy \\ &= 2\mathbb{1}_{[0,1]}(x) \int_{1-x}^1 dy \\ &= 2x\mathbb{1}_{[0,1]}(x). \end{aligned}$$

Par symétrie $((X, Y) \stackrel{\text{loi}}{=} (Y, X))$, on a également $f_Y(x) = f_X(x) = 2x\mathbb{1}_{[0,1]}(x)$.

3.2 LOIS CONDITIONNELLES

Définition 3.2. Soient X et Y deux v.a. discrètes. Alors pour tout y tel que $\mathbb{P}(Y = y) > 0$, la loi de X conditionnellement à $Y = y$ est la loi discrète de fonction de masse :

$$p_{X|Y}(x | y) = \mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}.$$

Dans le cas où les v.a. X et Y ont une densité conjointe $f_{X,Y}$, et $y \in \mathbb{R}$ est tel que $f_Y(y) > 0$, on définit de manière analogue la loi de X conditionnellement à $Y = y$ comme étant la loi de densité :

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

On peut traiter la loi conditionnelle comme n'importe quelle loi.

Définition 3.3. En particulier, on peut définir l'espérance conditionnelle :

$$\mathbb{E}[f(X) | Y = y] = \begin{cases} \sum_x f(x) \times p_{X|Y}(x | y) & (\text{cas discret}) \\ \int_{-\infty}^{+\infty} f(x) f_{X|Y}(x | y) dx & (\text{cas à densité}) \end{cases}$$

Proposition 3.2. On vérifie aisément les formules suivantes (dites formules de la probabilité totale) :

— Si X, Y discrètes de fonctions de masse p_X et p_Y , alors :

$$\begin{aligned} p_X(x) &= \sum_y p_{X|Y}(x | y) p_Y(y) \\ \mathbb{E}[f(X)] &= \sum_y \mathbb{E}[f(X) | Y = y] p_Y(y) \quad \text{pour tout } f. \end{aligned}$$

— Si X, Y conjointement à densité :

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{+\infty} f_{X|Y}(x | y) f_Y(y) dy \\ \mathbb{E}[f(X)] &= \int_{-\infty}^{+\infty} \mathbb{E}[f(X) | Y = y] f_Y(y) dy \quad \text{pour tout } f. \end{aligned}$$

Exemple 3.3. On reprend l'exemple du test d'infection de la section précédente. On calcule les lois conditionnelles :

$$\begin{aligned}
 \mathbb{P}(Y = 1 \mid X = 0) &= 0.2/0.9 \approx 22\% & \mathbb{P}(Y = 0 \mid X = 0) &\approx 78\% \\
 \mathbb{P}(Y = 1 \mid X = 1) &= 0.1/0.1 = 1 & \mathbb{P}(Y = 0 \mid X = 1) &= 0 \\
 \mathbb{P}(X = 1 \mid Y = 0) &= 0/0.7 = 0 & \mathbb{P}(X = 0 \mid Y = 0) &= 1 \\
 \mathbb{P}(X = 1 \mid Y = 1) &= 0.1/0.3 \approx 33\% & \mathbb{P}(X = 0 \mid Y = 1) &\approx 67\%.
 \end{aligned}$$

En mots, on retient :

- Chez une personne infectée, le test est positif dans 100% des cas, mais aussi dans 22% des cas chez une personne non infectée.
- Une personne dont le test est négatif peut être 100% sûre de ne pas être infectée.
- Une personne dont le test est positif est réellement infectée dans un tiers des cas seulement.

Exemple 3.4. On reprend l'exemple de la loi uniforme sur le triangle. On calcule pour tout $y \in [0, 1]$ la densité de X conditionnellement à $Y = y$:

$$\begin{aligned}
 f_{X|Y}(x \mid y) &= \frac{f_{X,Y}(x, y)}{f_Y(y)} \\
 &= \frac{2\mathbb{1}_{\mathcal{T}}(x, y)}{2y\mathbb{1}_{[0,1]}(y)} \\
 &= \frac{1}{y}\mathbb{1}_{\{x \in [0,1], x+y \geq 1\}} \\
 &= \frac{1}{y}\mathbb{1}_{[1-y,1]}(x).
 \end{aligned}$$

Autrement dit, conditionnellement à $Y = y$, X suit la loi uniforme sur l'intervalle $[1 - y, 1]$. En particulier, l'espérance de X conditionnellement à $Y = y$ vaut :

$$\mathbb{E}[X \mid Y = y] = \frac{1 - y + 1}{2} = 1 - \frac{y}{2}.$$

3.3 COVARIANCE ET CORRÉLATION

Définition 3.4. Soient X et Y des v.a. de carrés intégrables, c'est-à-dire $\mathbb{E}[X^2] < \infty$ et $\mathbb{E}[Y^2] < \infty$. On définit la covariance de X et Y par :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

A priori, il n'est pas clair que cette covariance est bien définie et finie, mais nous allons voir ci-dessous que c'est toujours le cas.

En développant le produit et en utilisant la linéarité de l'espérance, on obtient :

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}[XY - X\mathbb{E}[Y] - \mathbb{E}[X]Y + \mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - 2\mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y],\end{aligned}$$

si bien que :

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y],$$

une formule qui rappelle la formule $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$. D'ailleurs, par définition,

$$\mathbb{V}(X) = \text{Cov}(X, X),$$

donc la variance d'une v.a. est égale à sa covariance avec elle-même.

Proposition 3.3. Soient X, Y, Z des v.a. de carrés intégrables et $a, b \in \mathbb{R}$,

1. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
2. $\text{Cov}(aX + bY, Z) = a \text{Cov}(X, Z) + b \text{Cov}(Y, Z)$.
3. $\text{Cov}(a, X) = 0$.
4. $\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2 \text{Cov}(X, Y)$.

Les deux premières propriétés de la proposition ci-dessus disent que la covariance est une forme bilinéaire symétrique.

Démonstration. 1. Évident par la définition.

2. Par linéarité de l'espérance,

$$\begin{aligned}\text{Cov}(aX + bY, Z) &= \mathbb{E}[(aX + bY - \mathbb{E}[aX + bY])(Z - \mathbb{E}[Z])] \\ &= a\mathbb{E}[(X - \mathbb{E}[X])(Z - \mathbb{E}[Z])] + b\mathbb{E}[(Y - \mathbb{E}[Y])(Z - \mathbb{E}[Z])] \\ &= a \text{Cov}(X, Z) + b \text{Cov}(Y, Z).\end{aligned}$$

3. Puisque $\mathbb{E}[a] = a$,

$$\text{Cov}(a, X) = \mathbb{E}[(a - a)X] = \mathbb{E}[0X] = 0.$$

4. . On suppose que $\mathbb{E}[X] = \mathbb{E}[Y] = 0$ quitte à remplacer les v.a. par leurs variables centrées. Alors :

$$\begin{aligned} \mathbb{V}(X + Y) &= \mathbb{E}[(X + Y)^2] \\ &= \mathbb{E}[X^2 + Y^2 + 2XY] \\ &= \mathbb{E}[X^2] + \mathbb{E}[Y^2] + 2\mathbb{E}[XY] \\ &= \mathbb{V}(X) + \mathbb{V}(Y) + 2\text{Cov}(X, Y). \end{aligned}$$

□

La covariance est une mesure de dépendance entre les variables X et Y . Pour illustrer cela, on considère un exemple :

Exemple 3.5. Soient A et B des événements (par exemple de la forme $\{X \in S\}$ pour une v.a. X et $S \subset \mathbb{R}$) et soient $\mathbb{1}_A$ et $\mathbb{1}_B$ leurs indicatrices. On calcule :

$$\begin{aligned} \mathbb{E}[\mathbb{1}_A] &= \mathbb{P}(A), \quad \mathbb{E}[\mathbb{1}_B] = \mathbb{P}(B) \\ \mathbb{E}[\mathbb{1}_A \mathbb{1}_B] &= \mathbb{P}(A \cap B) \\ \text{Cov}(\mathbb{1}_A, \mathbb{1}_B) &= \mathbb{E}[\mathbb{1}_A \mathbb{1}_B] - \mathbb{E}[\mathbb{1}_A]\mathbb{E}[\mathbb{1}_B] = \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B). \end{aligned}$$

Par conséquent,

$$\begin{aligned} \text{Cov}(\mathbb{1}_A, \mathbb{1}_B) = 0 &\iff \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \\ &\iff A \text{ et } B \text{ sont indépendants.} \end{aligned}$$

Ceci conforte l'idée de la covariance comme une mesure de dépendance entre les v.a.

On peut même interpréter le signe de la covariance. Supposons que $\mathbb{P}(A) \neq 0$ et $\mathbb{P}(B) \neq 0$, alors on peut également écrire :

$$\begin{aligned}\text{Cov}(\mathbb{1}_A, \mathbb{1}_B) &= \mathbb{P}(B)(\mathbb{P}(A | B) - \mathbb{P}(A)) \\ &= \mathbb{P}(A)(\mathbb{P}(B | A) - \mathbb{P}(B))\end{aligned}$$

avec $\mathbb{P}(A | B) = \mathbb{P}(A \cap B) / \mathbb{P}(B)$ la probabilité de A conditionnellement à B . Cette écriture montre que :

$$\begin{aligned}\text{Cov}(\mathbb{1}_A, \mathbb{1}_B) > 0 &\iff \mathbb{P}(A | B) > \mathbb{P}(A) \\ &\iff \mathbb{P}(B | A) > \mathbb{P}(B).\end{aligned}$$

Les deux dernières inégalités signifient que la réalisation d'un des deux événements augmente la chance que l'autre événement se réalise. On dit dans ce cas que les deux événements sont *positivement corrélés*. Dans le cas d'une inégalité dans l'autre sens, on dit qu'ils sont *négativement corrélés*.

On résume : Soient A et B deux événements. Alors, A et B sont :

- *positivement corrélés* si $\mathbb{P}(A \cap B) > \mathbb{P}(A)\mathbb{P}(B)$ ($\iff \text{Cov}(\mathbb{1}_A, \mathbb{1}_B) > 0$)
- *négativement corrélés* si $\mathbb{P}(A \cap B) < \mathbb{P}(A)\mathbb{P}(B)$ ($\iff \text{Cov}(\mathbb{1}_A, \mathbb{1}_B) < 0$)
- *indépendants* si $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ ($\iff \text{Cov}(\mathbb{1}_A, \mathbb{1}_B) = 0$).

Au vu du dernier exemple, on dit que deux v.a. X et Y sont :

- *positivement corrélées* si $\text{Cov}(X, Y) > 0$
- *négativement corrélées* si $\text{Cov}(X, Y) < 0$
- *non corrélées* si $\text{Cov}(X, Y) = 0$

On remarque que l'absence de corrélation est équivalente à $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. On a alors l'implication :

$$X \text{ et } Y \text{ indépendantes} \implies X \text{ et } Y \text{ non corrélées.}$$

La réciproque est fausse en général, mais elle est vraie dans certains cas particuliers (par exemple quand X et Y sont des v.a. de Bernoulli, cf. exemple ci-dessus).

Exemple 3.6. Soit X une v.a. de loi symétrique avec $\mathbb{E}[X^4] < \infty$, par exemple $X \sim \mathcal{N}(0, 1)$. On pose $Y = X^2$ qui est de carré intégrable. Évidemment, X et Y ne sont en général pas indépendantes. En effet, on vérifie facilement que X et Y sont indépendantes si et seulement si $X \sim \delta_0$ (calculer $\mathbb{P}(Y > \varepsilon^2 \mid |X| > \varepsilon)$ pour tout $\varepsilon > 0$). Par contre :

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \\ &= \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2] = 0,\end{aligned}$$

car $\mathbb{E}[X^3] = \mathbb{E}[X] = 0$ par la symétrie de X . Ceci donne un exemple où les v.a. X et Y sont non corrélées mais dépendantes.

Pour quantifier la corrélation entre deux variables aléatoires, on introduit le coefficient de corrélation $\rho(X, Y)$ comme suit :

$$\begin{aligned}\rho(X, Y) &= \text{Cov}\left(\frac{X}{\sqrt{\text{Var}(X)}}, \frac{Y}{\sqrt{\text{Var}(Y)}}\right) \\ &= \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.\end{aligned}$$

Proposition 3.4. *Le coefficient de corrélation satisfait aux inégalités suivantes :*

$$-1 \leq \rho(X, Y) \leq 1.$$

Cette proposition sera une conséquence du résultat suivant :

Lemme 3.1 (Inégalité de Cauchy–Schwarz). *Soient X, Y des v.a. de carrés intégrables. Alors :*

$$\mathbb{E}[|XY|] \leq \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}.$$

Démonstration. On peut supposer que $X \geq 0$ et $Y \geq 0$ et que $\mathbb{E}[X^2] = \mathbb{E}[Y^2] = 1$, sinon on remplace X et Y par $X' = |X|/\sqrt{\mathbb{E}[X^2]}$ et $Y' = |Y|/\sqrt{\mathbb{E}[Y^2]}$ (notons que les deux côtés de l'inégalité sont homogènes en X et Y). On a alors :

$$\begin{aligned}0 &\leq \mathbb{E}[(X - Y)^2] \\ &= \mathbb{E}[X^2 + Y^2 - 2XY] \\ &= \mathbb{E}[X^2] + \mathbb{E}[Y^2] - 2\mathbb{E}[XY] \\ &= 2(1 - \mathbb{E}[XY]).\end{aligned}$$

Par conséquent, $\mathbb{E}[|XY|] = \mathbb{E}[XY] \leq 1$. □

Démonstration de la proposition. Par l'inégalité de Jensen,

$$\begin{aligned} |\text{Cov}(X, Y)| &= |\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]| \\ &\leq \mathbb{E}[|(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])|]. \end{aligned}$$

Par l'inégalité de Cauchy–Schwarz,

$$\begin{aligned} \mathbb{E}[|(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])|] &\leq \sqrt{\mathbb{E}[(X - \mathbb{E}[X])^2] \mathbb{E}[(Y - \mathbb{E}[Y])^2]} \\ &= \sqrt{\mathbb{V}(X) \mathbb{V}(Y)}. \end{aligned}$$

Ces deux inégalités donnent $|\rho(X, Y)| \leq 1$. □

Remarque 3.1. La preuve ci-dessus montre aussi ce que nous avons admis plus haut : que la covariance est toujours bien définie et finie pour des v.a. de carrés intégrables.

Exemple 3.7. Soient U, V, W des v.a. de carrés intégrables, indépendantes, et de variance égale à 1. On pose :

$$X = U + aV, \quad Y = U + bW,$$

pour $a, b \in \mathbb{R}$. On peut voir X et Y comme des observations "*bruitées*" d'une même quantité U , les v.a. aV and bW modélisant le "*bruit*". Par indépendance :

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}(U, U) + \text{Cov}(U, bW) + \text{Cov}(aV, U) + \text{Cov}(aV, bW) \\ &= \mathbb{V}(U) \\ &= 1. \end{aligned}$$

et $\mathbb{V}(X) = \mathbb{V}(U) + \text{Var}(aV) = 1 + a^2$ et $\mathbb{V}(Y) = 1 + b^2$. Par conséquent :

$$\rho(X, Y) = \frac{1}{\sqrt{(1 + a^2)(1 + b^2)}}.$$

On observe :

— Les v.a. X et Y sont positivement corrélées.

- La corrélation est parfaite (c'est-à-dire $\rho = 1$) si $a = b = 0$.
- La corrélation tend vers 0 quand $|a| \rightarrow \infty$ ou $|b| \rightarrow \infty$, ce qui correspond à un bruit qui devient de plus en plus fort.

Il transparaît des deux derniers exemples que le coefficient de corrélation mesure bien des relations linéaires entre les v.a., mais pas nécessairement des relations non-linéaires.

Exemple 3.8. On reprend l'exemple du test d'infection. On calcule :

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mathbb{P}(X = 1) - \mathbb{P}(X = 1)^2 = 0.1 - 0.1^2 = 0.09 \\ \text{Var}(Y) &= \mathbb{P}(Y = 1) - \mathbb{P}(Y = 1)^2 = 0.3 - 0.3^2 = 0.21 \\ \text{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{P}(X = 1, Y = 1) - \mathbb{P}(X = 1)\mathbb{P}(Y = 1) = 0.1 - 0.03 = 0.07 \\ \rho(X, Y) &= \frac{0.07}{\sqrt{0.09 \times 0.21}} \approx 0.51.\end{aligned}$$

Ce calcul montre que les v.a. X et Y sont sensiblement corrélées, mais loin d'être parfaitement corrélées.

Exemple 3.9. On reprend l'exemple de la loi uniforme sur le triangle. On calcule :

$$\begin{aligned}\mathbb{E}[X] &= \int_0^1 x \times 2x \, dx = \frac{2}{3} \\ \mathbb{E}[X^2] &= \int_0^1 x^2 \times 2x \, dx = \frac{2}{4} = \frac{1}{2} \\ \mathbb{V}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{1}{2} - \frac{4}{9} = \frac{1}{18}.\end{aligned}$$

Et pareil pour Y , car $Y \stackrel{\text{loi}}{=} X$. De plus :

$$\begin{aligned}
\mathbb{E}[XY] &= \int_0^1 \int_0^1 2xy \mathbb{1}_{x+y \geq 1} dx dy \\
&= \int_0^1 x [y^2]_{1-x}^1 dx \\
&= \int_0^1 x(1 - (1-x)^2) dx \\
&= \int_0^1 (2x^2 - x^3) dx \\
&= \frac{2}{3} - \frac{1}{4} = \frac{5}{12}.
\end{aligned}$$

Par conséquent :

$$\begin{aligned}
\text{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \frac{5}{12} - \left(\frac{2}{3}\right)^2 = \frac{15}{36} - \frac{16}{36} = -\frac{1}{36} \\
\rho(X, Y) &= \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{-1/36}{1/18} = -\frac{1}{2}.
\end{aligned}$$

Les v.a. X et Y sont alors sensiblement mais pas parfaitement négativement corrélées.

Ceci s'explique par le fait que si l'une des v.a. est petite, l'autre doit être grande pour que la somme soit supérieure à 1, il s'agit donc d'un biais "*dans l'autre sens*".

TD2 : CONVERGENCE DE VARIABLES ALÉATOIRES ET THÉORÈMES LIMITES.

Exercice 3.1. Préciser pour chacune des suites $(X_n)_{n \geq 1}$ suivantes si $(X_n)_{n \geq 1}$ converge en loi, en probabilité et au sens L^2 , et le cas échéant, identifier la limite :

1. Pour tout $n \geq 1$, la variable X_n suit la loi de Bernoulli de paramètre $p_n \in]0, 1[$ avec $p_n \rightarrow 0$.
2. Pour tout $n \geq 1$, la variable X_n suit la loi $\text{Unif}(-1/n, 1/n)$.
3. Pour tout $n \geq 1$, la variable X_n suit la loi $\text{Unif}(-n, n)$.

Exercice 3.2. Soit $p_1, p_2, \dots \in [0, 1]$ une suite numérique telle que $np_n \rightarrow \lambda$ pour un certain $\lambda > 0$, et $(X_n)_{n \geq 1}$ une suite de variables aléatoires avec $X_n \sim \text{Geom}(p_n)$.

1. Montrer que pour $t \in \mathbb{R}_+$, $\mathbb{P}(X_n > t) = (1 - p_n)^{\lfloor t \rfloor}$ avec $\lfloor t \rfloor$ la partie entière de t .
2. En déduire que pour tout $t \in \mathbb{R}_+$, $\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{X_n}{n} > t\right) = e^{-\lambda t}$.
3. Conclure que $\frac{X_n}{n} \xrightarrow{\text{loi}} \text{Exp}(\lambda)$.

Exercice 3.3. Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes et identiquement distribuées. On suppose que X_1 est à densité, de densité f qui satisfait :

$$f(x) = 0 \text{ si } x < 0, \quad f(0) > 0 \quad \text{et} \quad f \text{ continue à droite en } 0.$$

On pose pour tout $n \geq 1$, $Y_n = \min_{1 \leq i \leq n} X_i$.

1. Montrer que la suite de variables aléatoires $(Y_n)_{n \geq 1}$ converge en probabilité, et identifier sa limite.
2. Montrer que la fonction de répartition F de X_1 satisfait :

$$\lim_{t \rightarrow 0, t > 0} \frac{F(t)}{t} = f(0),$$

c'est-à-dire $F(t) = t f(0) + o(t)$ lorsque t approche 0 par la droite.

3. Montrer que $nY_n \xrightarrow{\text{loi}} \text{Exp}(\lambda)$ pour un certain paramètre $\lambda > 0$ qu'on identifiera en fonction de $f(0)$.
4. Dans le cas où X_1 suit la loi exponentielle de paramètre λ , calculer la loi de nY_n .

Exercice 3.4. Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires indépendantes d'espérance 1 qui prennent deux valeurs a et b ($0 < a < 1 < b$) avec probabilité p et $1 - p$ respectivement ($0 < p < 1$). On pose $Y_n = \prod_{i=1}^n X_i$.

1. Vérifier que pour $x \in]0, 1[\cup]1, +\infty[$, $\log(x) < x - 1$.
2. Exprimer $\mathbb{E}[\log(X_1)]$ à l'aide de la formule de transfert, et en déduire $\mathbb{E}[\log(X_1)] < 0$.
3. Montrer à l'aide de la loi des grands nombres que la suite $\left(\frac{\log(Y_n)}{n}\right)_{n \geq 1}$ converge en probabilité.
4. Montrer que pour $n \geq 2 \log(\varepsilon) / \mathbb{E}[\log(X_1)]$,

$$\mathbb{P}(|Y_n| \geq \varepsilon) \leq \mathbb{P}\left(\frac{\log Y_n}{n} \geq \frac{\log(\varepsilon)}{n}\right) \leq \mathbb{P}\left(\frac{\log Y_n}{n} \geq \frac{\mathbb{E}[\log(X_1)]}{2}\right)$$

5. En déduire que la suite $(Y_n)_n$ converge en probabilité vers 0.
6. Calculer $\mathbb{E}[Y_n]$. La suite $(Y_n)_n$ converge-t-elle dans L^1 ?

Exercice 3.5. Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires i.i.d. de carrés intégrables. On note $m = \mathbb{E}[X_1]$ et $\sigma^2 = \text{Var}(X_1)$.

1. Étudier la convergence en probabilité de $\frac{X_1^2 + \dots + X_n^2}{n}$, exprimer sa limite en fonction de m et de σ^2 .

On suppose désormais que n est pair.

2. Étudier la convergence en probabilité de $\frac{X_1 X_2 + X_3 X_4 + \dots + X_{n-1} X_n}{n/2}$

(Note : le dénominateur usuel ici serait $n/2$ ou la somme allant jusqu'à $n/2$ termes, l'énoncé d'origine a été adapté pour la clarté mathématique).

3. En déduire que $\frac{X_1 X_2 + X_3 X_4 + \dots + X_{n-1} X_n}{n}$ converge en probabilité vers m^2 .

Exercice 3.6. Soit n un entier naturel non nul.

1. Rappeler la densité de la loi $\Gamma(n, 1)$ et en déduire la valeur de $\int_0^\infty x^{n-1} e^{-x} dx$.

2. *Rappeler quelle est la loi de la somme de n variables aléatoires $\text{Exp}(1)$ indépendantes.*
3. *Soit $0 < \varepsilon < 1$. Appliquer la loi des grands nombres à une somme de n variables aléatoires i.i.d. de loi $\text{Exp}(1)$. En déduire un équivalent quand $n \rightarrow \infty$ de*

$$\int_{n(1-\varepsilon)}^{n(1+\varepsilon)} x^{n-1} e^{-x} dx.$$

4. *Soit $\alpha < \beta$ deux réels. Appliquer le théorème central limite à la même collection de variables aléatoires. En déduire un équivalent quand $n \rightarrow \infty$ de*

$$\int_{n+\alpha\sqrt{n}}^{n+\beta\sqrt{n}} x^{n-1} e^{-x} dx.$$

Exercice 3.7. *On cherche à montrer le résultat suivant :*

$$\lim_{n \rightarrow \infty} \int_0^1 \cdots \int_0^1 \sqrt{\frac{n}{n + x_1 + \cdots + x_n}} dx_1 \cdots dx_n = \sqrt{\frac{2}{3}}$$

Soit $f : [0, 1] \rightarrow \mathbb{R}$ une fonction continue sur $[0, 1]$.

1. *Soit $n \geq 1$. Montrer qu'il existe des variables aléatoires $X_1, \dots, X_n$, dont on donnera la loi, telles que :*

$$\int_0^1 \cdots \int_0^1 f\left(\frac{x_1 + \cdots + x_n}{n}\right) dx_1 \cdots dx_n = \mathbb{E} \left[f\left(\frac{X_1 + \cdots + X_n}{n}\right) \right].$$

2. *Quelle est la limite en probabilité de la suite $\left(\frac{X_1 + \cdots + X_n}{n}\right)_{n \in \mathbb{N}^*}$?*
3. *Montrer que*

$$\lim_{n \rightarrow \infty} \left| \mathbb{E} \left[f\left(\frac{X_1 + \cdots + X_n}{n}\right) \right] - f(\mathbb{E}[X_1]) \right| = 0.$$

On pourra distinguer par exemple les contributions sur les évènements $\left\{ \left| \frac{X_1 + \dots + X_n}{n} - \mathbb{E}[X_1] \right| > \delta \right\}$ et $\left\{ \left| \frac{X_1 + \dots + X_n}{n} - \mathbb{E}[X_1] \right| \leq \delta \right\}$ pour δ bien choisi.

4. Dédurre le résultat annoncé au début de l'exercice.

Exercice 3.8. Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes de loi de Bernoulli de paramètre $p \in]0, 1[$. Posons pour tout $n \geq 1$,

$$M_n = \frac{X_1 + \dots + X_n}{n}.$$

1. Montrer que $M_n(1 - M_n)$ converge en probabilité vers $p(1 - p)$.
2. Montrer que $\sqrt{n} \frac{M_n - p}{\sqrt{p(1-p)}}$ converge en loi vers une limite à préciser.
3. En déduire que $\sqrt{n} \frac{M_n - p}{\sqrt{M_n(1-M_n)}}$ converge en loi vers une limite à préciser.
*(Rappelons le lemme de Slutsky : si le couple (X_n, Y_n) est tel que X_n converge en loi vers X et Y_n converge en loi vers une constante y , alors (X_n, Y_n) converge en loi vers (X, y))**

Probabilité

Ce cours présente les fondements de la théorie des probabilités au-delà d'une seule variable aléatoire. On y étudie d'abord les vecteurs aléatoires (loi jointe, lois marginales, cas discret et à densité) et la notion centrale d'indépendance, avec ses critères de factorisation et ses conséquences sur l'espérance et la variance d'une somme. On apprend ensuite à déterminer la loi de fonctions de variables indépendantes : maximum, minimum, somme (par fonction génératrice des moments ou convolution) et transformations générales via le changement de variable et le jacobien. Le cœur du cours porte sur les théorèmes limites : les différents modes de convergence (en loi, en probabilité, dans L^p , presque sûre), la loi des grands nombres et le théorème central limite, illustré par l'approximation normale de la binomiale. Enfin, on aborde les variables dépendantes : lois conditionnelles, espérance conditionnelle, covariance et coefficient de corrélation. Le fil conducteur est la distinction permanente entre ce qui exige l'indépendance et ce qui n'en a pas besoin.

